

Detección y determinación de severidad de fallas en paneles solares a partir de imágenes aéreas termográficas

Estefanía Alfaro Mejía, Ing.



Facultad de Ingeniería
Escuela de Ingeniería Eléctrica y Electrónica
Maestría en Ingeniería énfasis en Electrónica
Santiago de Cali

Julio 2019

Detección y determinación de severidad de fallas en paneles solares a partir de imágenes aéreas termográficas

Estefanía Alfaro Mejía, Ing.

*Trabajo de investigación
Maestría en Ingeniería, énfasis en Electrónica*

Directores:

Humberto Loaiza Correa, Ph.D.

Édinson Franco Mejía, Dr.-Ing.

Trabajo de investigación presentado como requisito
parcial para optar por el título de:
Magister en Ingeniería-Énfasis en Electrónica.
Universidad del Valle

Facultad de Ingeniería
Escuela de Ingeniería Eléctrica y Electrónica
Maestría en Ingeniería énfasis en Electrónica
Santiago de Cali

Julio 2019

DETECTION AND DETERMINATION OF SEVERITY OF FAULTS IN
SOLAR PANELS FROM THERMOGRAPHIC AERIAL IMAGES.

Estefanía Alfaro Mejía, programa de posgrados de la Escuela de Ingeniería
Eléctrica y Electrónica, Universidad del Valle, Cali, Colombia 2019.

En este trabajo se presenta la propuesta de un método para la detección y determinación de la severidad de fallas en módulos fotovoltaicos, a partir de la técnica de la termografía infrarroja TIR. El método esta conformado por las fases de adquisición de las imágenes: pre-procesamiento y segmentación; transformaciones; extracción de características; clasificación de las fallas celda fracturada y *hot spot* y finalmente una escala de severidad. Para la fase de adquisición de las imágenes termográficas IIR aéreas, se desarrolló un protocolo de captura definiendo los parámetros de altura del UAV y ángulo de la cámara, las condiciones ambientales y los rangos de las variables meteorológicas. Posteriormente al proceso de adquisición se plantea un algoritmo de procesamiento para las IIR, que incluyen la adecuación de las imágenes (pre-procesamiento), segmentación con los métodos MCA LS y FA y las transformaciones para presentar el objeto de interés con una morfología deseada. El diagnóstico se hace sobre la localidad de las celdas del panel solar y se clasifican las fallas tipo *hot spot* y celdas fracturadas empleando métodos supervisados como SVM y RNA y no supervisados como k-medias y mezcla de gaussianas, relacionando los daños presentados en el módulo fotovoltaico con una escala de severidad de tres niveles alerta, severo y crítico que sugiere temporalidades para la intervención de los módulos fotovoltaicos. El sistema propuesto alcanzó desempeños en la clasificación para los métodos supervisados de 82.92 % para las celdas buenas y *hot spot*, buenas y fracturadas de 77.02 %, *hot spot* y fracturadas de 97.43 %. Para los no supervisados alcanzó desempeños en la clasificación de 72.21 % para las celdas buenas y *hot spot*, buenas y fracturadas de 66.63 %, *hot spot* y fracturadas de 84.56 %.

Palabras claves— Panel solar, termografía infrarroja, *hot spot*, celdas fracturadas, reconocimiento de patrones y escala de severidad.

DETECTION AND DETERMINATION OF SEVERITY OF FAULTS IN SOLAR PANELS FROM THERMOGRAPHIC AERIAL IMAGES.

Estefanía Alfaro Mejía, programa de posgrados de la Escuela de Ingeniería Eléctrica y Electrónica, Universidad del Valle, Cali, Colombia 2019.

This work presents a method proposal for the detection and determination of the severity of faults in photovoltaic modules, based on the TIR infrared thermography technique. The method by the following phases: image acquisition, pre-processing and segmentation; transformation; feature extraction; classification and lastly a severity scale. The acquisition phase of the aerial IIR thermographic images is based on stages for the protocol capture defining UAV parameters such as height and camera angle, environmental conditions and the ranges of meteorological variables. After the acquisition process, a processing algorithm for the IIR is proposed, which includes the adaptation of the images (pre-processing), segmentation with the MCA LS and FA methods and the transformations to present the object of interest with a desired morphology. The diagnosis is made on the location of the cells of the PPV and faults are classified *hot spot* and fractured cells using supervised methods such as SVM and ANN and unsupervised as k-means and Gaussian mixtures, relating the damages presented in the photovoltaic module with a severity scale of three alert levels, severe and critical that suggests temporalities for the intervention of the photovoltaic modules. The proposed system reached performances in the classification for the supervised methods of 82.92 % for good cells and *hot spot*, good and fractured of 77.02 %, *hot spot* and fractured of 97.43 %. For the unsupervised, it achieved performances in the classification of 72.21 % for good cells and *hot spot*, good and fractured of 66.63 %, *hot spot* and fractured of 84.56 %.

Palabras claves— Solar panel, Infrared thermography, *hot spot*, fractured cell, pattern recognition.

Agradecimientos

Es difícil encontrar las palabras para describir el profundo sentimiento de gratitud que hoy tengo. Quiero agradecer a mi padre Jose Jaír por su constante apoyo y a mi madre Myriam que ya no está, pero permanece como un recuerdo imperdurable en el tiempo. A mis profesores Édinson Franco Mejía y Humberto Loaiza Correa por las revisiones exhaustivas y por el constante apoyo en todos los aspectos, no sólo en el académico sino también en el personal y profesional. A mis profesores de posgrado, que con sus cursos y sugerencias me permitieron explorar muchas de las técnicas implementadas, el método desarrollado y a los jurados por sus valiosas revisiones para mejorar este trabajo. A mis compañeros y amigos de PSI y GICI por sus sugerencias e incondicional amistad.

A Daniel López Ortíz por su constante colaboración en la lectura del documento y por las largas discusiones desde la física y la ingeniería, gracias por tanto!.

A la Universidad del Valle que financió el proyecto de convocatoria interna CI 2919 “Detección de fallas en paneles solares a partir de imágenes termográficas tomadas por un drone con navegación autónoma” y sus rubros permitieron la compra de los equipos. A la empresa Celsia ® ubicada en Yumbo por permitirnos realizar las inspecciones de los paneles solares policristalinos *Eagle 72 315-335 Watt* y la constante disponibilidad para las visitas de inspección. El esfuerzo y los retos en el desarrollo de este trabajo se vieron representados en el conocimiento adquirido y las personas conocidas, espero que los resultados obtenidos sirvan para los siguientes desarrollos en la temática.

Mil gracias a todos quienes hicieron posible este trabajo.

Nomenclaturas

PPV Panel Fotovoltaico

TIR Termografía Infrarroja

IIR Imágenes termográficas

UAV Unmanned aerial vehicle

EL Electroluminiscencia

PL Fotoluminiscencia

MDF Método de detección de fallas

CDIT Conjunto de imágenes termográficas

SVM Máquina de soporte vectorial

PH Precisión con la sintonización de Hiperparámetros para SVM

PD Precisión con parámetros por defecto SVM

RBF Función de base radial

RNA Redes Neuronales artificiales

GMM Mezcla de gausianas

MCA Método de contornos activos

FA Filtrado de área

B celda en buen estado

F celda fracturada

Hs celda *hot spot*

Hs celda *hot spot*

VTC Vector de todas las características

HOG Histograma de orientación de gradientes

DICE Coeficiente de similaridad

IOU Jaccard

R Rectangularidad entre 0 y 1

r Relación de la longitud y ancho del rectángulo mínimo

S_0 Área del objeto

sMer Mínimo rectangulo externo

Lum_{AVG} Promedio de luminancia

CSD Criterio de desviación estándar

Índice general

Agradecimientos	I
Nomenclatura	II
1. Introducción	1
2. Antecedentes y Marco Teórico	5
2.1. Antecedentes nacionales	5
2.2. Antecedentes internacionales	9
2.3. Estructura física de los paneles solares	13
2.4. Fallas comunes en paneles solares	14
2.4.1. Hot spot	15
2.4.2. Degradación Inducida por Potencial (PDI)	15
2.4.3. Celda Fracturada	16
2.4.4. Snails trails	16
2.5. Inspección termográfica para diagnóstico de fallas	17
2.5.1. Generalidades de la termografía	17
2.5.2. Termografía IR técnica de inspección	18
2.5.3. Procesamiento de imágenes termográficas	19
2.5.4. <i>Lock in Thermography</i>	20
2.5.5. Escalas de severidad para termografía según la Norma NFPA 70B	20
2.5.6. Temporalidades sugeridas para la inspección en sistemas fotovoltaicos	20
2.5.7. Curva I-V	21
2.6. Vehículos aéreos no tripulados UAV	23
2.7. Procesamiento de imágenes	24
2.7.1. Filtrado mediana	24

2.7.2.	Detector de bordes Canny	25
2.7.3.	Segmentación	25
2.7.4.	Método de contornos activos <i>Level sets</i> (MCA)	26
2.7.5.	Transformada de Hough	27
2.7.6.	Transformación proyectiva	28
2.8.	Métricas para la evaluación del desempeño en la segmentación de imágenes	29
2.8.1.	Métrica Sorensen DICE	29
2.8.2.	Métrica IOU	30
2.9.	Extracción de características en las imágenes	30
2.9.1.	Características estadísticas	31
2.9.2.	Histogramas de orientación de gradientes (HOG)	31
2.9.3.	Texturas de Haralick	32
2.10.	Selección de características con métodos <i>Wrapper</i> y de Filtrado	33
2.11.	Métodos de clasificación no supervisada	34
2.11.1.	K-medias	34
2.11.2.	Mezcla de Gausianas	34
2.12.	Métodos de clasificación supervisada	35
2.12.1.	Máquina de soporte vectorial (SVM)	35
2.12.2.	Redes Neuronales Artificiales (RNA)	37
2.13.	Conclusiones	39
3.	Plataforma para la adquisición y análisis de imágenes aéreas termográficas	41
3.0.1.	UAV <i>Matrice 100</i>	42
3.0.2.	Cámara Zenmuse XT	44
3.0.3.	Paneles solares	45
3.0.4.	Carga electrónica	48
3.0.5.	Estación meteorológica	48
3.0.6.	Piranómetro <i>Apogee SP110</i>	49
3.0.7.	Arquitectura computacional	50
3.1.	Conclusiones	51
4.	Método para detección y diagnóstico de fallas <i>hot spot</i> y celdas fracturadas en paneles solares usando imágenes termográficas aéreas	52
4.0.1.	Fase 1: Adquisición de imágenes	54
4.0.1.1.	Etapa 1: verificación de cumplimiento de las condiciones medioambientales	54
4.0.1.2.	Etapa 2: verificación de condición de operación del generador fotovoltaico	54

4.0.1.3. Etapa 3: medición de las variables medioambientales	55
4.0.1.4. Etapa 4: protocolo de vuelo	55
4.0.2. Fase 2: Pre-procesamiento y segmentación	57
4.0.3. Fase 3: Procesamiento de las imágenes	57
4.0.4. Fase 4: Extracción de características	58
4.0.5. Fase 5: Asignación de severidad	59
4.1. Conclusiones	59
5. Pruebas y resultados	61
5.1. Descripción del conjunto de imágenes termográficas aéreas	61
5.2. Prueba 1: Métricas DICE, IOU para medir la segmentación	63
5.2.1. Finalidad	63
5.2.2. Descripción	63
5.2.3. Resultados	63
5.3. Prueba 2: Clasificación de celdas buenas <i>hot spot</i> y celda fracturada a partir de métodos supervisados	65
5.3.1. Finalidad	65
5.3.2. Descripción	65
5.3.3. Resultados	66
5.3.3.1. Método 1 SVM:	67
5.3.3.2. Método 2 RNA:	84
5.4. Prueba 3: Clasificación de celdas buenas <i>hot spot</i> y celdas fracturada a partir de métodos no supervisados	119
5.4.1. Finalidad	119
5.4.2. Descripción	119
5.4.3. Resultados	119
5.5. Conclusiones	137
6. Detalles de la implementación del método en los escenarios de prueba EIEE y planta solar Celsia ®	140
6.1. Escenario de prueba 1: Generador PPV en planta piloto Universidad del Valle.	140
6.1.1. Fase 1: Adquisición de imágenes	142
6.1.1.1. Etapa 1: condiciones iniciales	142
6.1.1.2. Etapa 2: Condiciones de operación del PPV .	142
6.1.1.3. Etapa 3: medición de variables ambientales .	142
6.1.1.4. Etapa 4: protocolo de vuelo	143
6.1.2. Fase 2: Pre-procesamiento	143
6.1.2.1. Imagen de entrada	144
6.1.2.2. Filtrado y adecuación de las IIR	144

6.1.2.3. Segmentación extracción de objetos por filtrado de área	145
6.1.2.4. Método de contornos activos level sets (MCA)	146
6.1.3. fase 3: Procesamiento de las imágenes	146
6.1.3.1. Transformada de Hough	146
6.1.3.2. Transformación de proyección	147
6.1.4. Fase 4: Extracción de características	149
6.1.4.1. Extracción de características	149
6.1.4.2. Clasificación usando métodos supervisados	149
6.1.4.3. Clasificación usando métodos no supervisados	150
6.1.5. Fase 5: escala de severidad	151
6.2. Escenario de prueba 2: Generador PPV en generador fotovoltaico Celsia-Yumbo.	151
6.2.1. Fase 1: Adquisición de imágenes	152
6.2.2. Fase 2: Pre-procesamiento y segmentación	154
6.2.3. Fase 3: Procesamiento de las imágenes	154
6.2.4. Fase 4: Extracción de las características	154
6.2.4.1. Clasificación usando métodos no supervisados	154
6.2.5. Fase 5: Asignación de la escala de severidad	155
6.3. Conclusiones	155
7. Conclusiones	156
7.1. Conclusiones generales	156
8. Perspectivas futuras de trabajo	158
9. Contribuciones	160

Índice de figuras

2.1. Ecuación búsquedas antecedentes regionales [Fuente de datos: Scopus].	7
2.2. Ecuación búsquedas antecedentes nacionales [Fuente de datos: Scopus].	8
2.3. Ecuación búsquedas antecedentes internacionales [Fuente de datos: Scopus].	9
2.4. Ecuación búsquedas antecedentes internacionales [Fuente de datos: Scopus].	11
2.5. Esquema de la composición de la celda solar [Fuente propia]. .	13
2.6. Esquema de funcionamiento sistema fotovoltaico [Fuente propia].	14
2.7. Visualización del <i>hot spot</i> con las técnicas TIR,EL y PL. . . .	15
2.8. <i>Snail trails</i> [Fuente propia].	17
2.10. Diagrama de bloques de la termografía activa [1].	19
2.11. Curva voltaje corriente de un panel solar [Fuente propia]. . . .	22
2.12. Modelo de un diodo panel solar [2].	22
2.14. Métrica IOU [3].	30
2.15. Visualización del descriptor HOG [Fuente propia].	32
2.16. Matriz de co-ocurrencia [Fuente propia].	33
2.17. Vector de características etiquetado [Fuente propia].	35
2.18. Hiperplano de separación de las características [4].	36
2.19. Esquema de una neurona [5].	38
3.1. Descripción del diseño experimental [Fuente propia].	42
3.2. UAV <i>Matrice 100</i> [Fuente propia].	42
3.3. Aplicaciones UAV [Fuente propia].	43
3.4. Cámara <i>Zenmuse XT</i> [Fuente propia].	45
3.5. <i>String</i> de módulos solares de Si [Fuente propia].	46
3.6. <i>String</i> paneles solares monocristalinos [Fuente propia]. . . .	46
3.7. <i>String</i> paneles solares policristalinos [Fuente propia]. . . .	46

3.8.	Etiquetado de las fallas presentes [Fuente propia].	48
3.9.	Especificaciones carga electrónica [6].	49
3.10.	Estación meteorológica <i>Ambient Weather WS</i> [Fuente propia].	49
4.1.	Método propuesto para la detección de fallas en PPV.	53
4.2.	Protocolo de adquisición de las imágenes.	54
4.3.	Estimación del ángulo y altura para adquisición de imágenes [Fuente propia].	56
4.4.	Extracción de celdas para características [Fuente propia].	58
5.1.	Comparación estadística de los métodos de segmentación a partir de DICE.	64
5.2.	Comparación estadística de los métodos de segmentación a partir de IOU.	65
5.3.	Superficies de precisión para la clasificación de las clases Hs-B-F.	67
5.4.	Superficies de precisión para la clasificación de las clases Hs-F-B.	68
5.5.	Tipos de <i>kernel</i> para la clasificación de la celda Buena- <i>hot-spot</i>	70
5.6.	Análisis estadístico para la clasificación de las celdas buenas- <i>hot spot</i> empleando diferentes <i>kernel</i>	71
5.7.	Características para la clasificación celda Buena- <i>Hot spot</i>	72
5.8.	Test kruskalwallis de las características para la clasificación celda Buena- <i>Hot spot</i>	73
5.9.	Tipos de <i>kernel</i> para la clasificación la celda Buena-Fracturada.	73
5.10.	Análisis estadístico para la clasificación de las celdas buenas-fracturada empleando diferentes <i>kernel</i>	74
5.11.	Características para la clasificación de la celda fracturada-buena.	75
5.12.	Test kruskallwallis de las características para la clasificación de las celdas Fracturada-Buena	75
5.13.	Tipos de <i>kernel</i> para la clasificación celda Fracturada- <i>hot-spot</i>	75
5.14.	Análisis estadístico para la clasificación celda <i>hot spot</i> -Fracturada empleando diferentes <i>kernel</i>	77
5.15.	Características para la clasificación de la celda fracturada- <i>hot spot</i>	78
5.16.	Test Kruskallwallis de las características para la clasificación de las celdas Fracturada-hot spot.	78
5.17.	Matrices de confusión para la clasificación de la celda Buena- <i>Hot spot</i> usando una SVM con <i>kernel</i> RBF.	79
5.18.	Matrices de confusión para la clasificación de la celda Buena-Fracturada usando una SVM con <i>kernel</i> RBF.	80
5.19.	Matrices de confusión para la clasificación de la celda Fracturada- <i>Hot spot</i> usando una SVM con <i>kernel</i> RBF.	81

5.20. Tipos de <i>kernel</i> para la clasificación celda Fracturada- <i>hot spot-Buena</i>	81
5.21. Análisis estadístico para la clasificación de celdas B-Hs-F	82
5.22. Matrices de confusión para la clasificación de las tres clases Buena-Fracturada- <i>Hot spot</i>	83
5.23. Matrices de confusión para la clasificación de las tres clases B-F-H <i>kernel</i> RBF por defecto.	84
5.24. Clasificación del las celdas Hs-B a partir de las variaciones de la arquitectura de las RNA.	85
5.25. Análisis estadístico de las arquitecturas de la RNA para la clasificación de celdas B-Hs.	85
5.26. Análisis estadístico de las características para la clasificación de las celdas B-Hs.	86
5.27. Matrices de confusión de entrenamiento y prueba para las combinaciones de características que mejor clasifican las fallas B-Hs #:6,RBP-MSE.	88
5.28. Matrices de confusión de entrenamiento y prueba para las combinaciones de características que mejor clasifican las fallas B-Hs #:6,RBP-MSE.	89
5.29. Matrices de confusión de entrenamiento y prueba para las combinaciones de características que mejor clasifican las fallas B-Hs #:8,RBP-MSE.	90
5.30. Matrices de confusión de entrenamiento y prueba para las combinaciones de características que mejor clasifican las fallas B-Hs #:8,RBP-MSE.	91
5.31. Matrices de confusión de entrenamiento y prueba para las combinaciones de características que mejor clasifican las fallas B-Hs #:10,RBP-MSE.	92
5.32. Matrices de confusión de entrenamiento y prueba para las combinaciones de características que mejor clasifican las fallas B-Hs #:10,RBP-MSE.	93
5.33. Clasificación de las celdas F-B a partir de las variaciones de la arquitectura de las RNA.	94
5.34. Análisis estadístico de las topologías de la RNA para la clasificación de las celdas F-celda en buen estado (B).	94
5.35. Características para la clasificación B-F.	95
5.36. Matrices de confusión de entrenamiento y prueba para las combinaciones de características que mejor clasifican las fallas B-F #:6, SCG-CRO.	97

5.37. Matrices de confusión de entrenamiento y prueba para las combinaciones de características que mejor clasifican las fallas B-F #:6, SCG-CRO.	98
5.38. Matrices de confusión de entrenamiento y prueba para las combinaciones de características que mejor clasifican las fallas B-F #:8, RBP-MSE.	99
5.39. Matrices de confusión de entrenamiento y prueba para las combinaciones de características que mejor clasifican las fallas B-F #:8, RBP-MSE.	100
5.40. Matrices de confusión de entrenamiento y prueba para las combinaciones de características que mejor clasifican las fallas B-F #:10, RBP-MSE.	101
5.41. Matrices de confusión de entrenamiento y prueba para las combinaciones de características que mejor clasifican las fallas B-F #:10, RBP-MSE.	102
5.42. Clasificación de las celdas F-Hs a partir de las variaciones de la arquitectura RNA.	103
5.43. Tipos de topologías de las RNA para la clasificación de las clases F-Hs.	103
5.44. Características para la clasificación de las celdas F-Hs.	103
5.45. Matrices de confusión de entrenamiento y prueba para las combinaciones de características que mejor clasifican las fallas Hs-F #:6 RBP-MSE.	105
5.46. Matrices de confusión de entrenamiento y prueba para las combinaciones de características que mejor clasifican las fallas Hs-F #:6 RBP-MSE.	106
5.47. Matrices de confusión de entrenamiento y prueba para las combinaciones de características que mejor clasifican las fallas Hs-F #:8 RBP-CRO.	107
5.48. Matrices de confusión de entrenamiento y prueba para las combinaciones de características que mejor clasifican las fallas Hs-F #:8 RBP-CRO.	108
5.49. Matrices de confusión de entrenamiento y prueba para las combinaciones de características que mejor clasifican las fallas Hs-F #:10 RBP-CRO.	109
5.50. Matrices de confusión de entrenamiento y prueba para las combinaciones de características que mejor clasifican las fallas Hs-F #:10 RBP-CRO.	110
5.51. Clasificación de las celdas Hs-F-B a partir de las variaciones de las topologías RNA.	111

5.52. Tipos de topologías de la RNA para la clasificación de las clases Hs-F-B.	111
5.53. Características para la clasificación de las celdas Hs-F-B.	112
5.54. Matrices de confusión de entrenamiento y prueba para las combinaciones de características que mejor clasifican las fallas Hs-F-B #:6 RBP-MSE.	113
5.55. Matrices de confusión de entrenamiento y prueba para las combinaciones de características que mejor clasifican las fallas Hs-F-B #:6 RBP-MSE.	114
5.56. Matrices de confusión de entrenamiento y prueba para las combinaciones de características que mejor clasifican las fallas Hs-F-B #:8 RBP-MSE.	115
5.57. Matrices de confusión de entrenamiento y prueba para las combinaciones de características que mejor clasifican las fallas Hs-F-B #:8 RBP-MSE.	116
5.58. Matrices de confusión de entrenamiento y prueba para las combinaciones de características que mejor clasifican las fallas Hs-F-B #:10 RBP-MSE.	117
5.59. Matrices de confusión de entrenamiento y prueba para las combinaciones de características que mejor clasifican las fallas Hs-F-B #:10 RBP-MSE.	118
5.60. Clasificación de las celdas Hs-B con el método k-medias K:2:5 distancia E.	120
5.61. Análisis estadístico de la variación de k:2:5 para la clasificación de las celdas Hs-B distancia E.	121
5.62. Métricas Silhouete para la clasificación de las celdas Hs-B. . .	121
5.63. Matrices de confusión para el método no supervisado k-medias clasificación de Hs, B, F	122
5.64. Clasificación de las celdas F-B con el método k-medias K:2:5 distancia E.	123
5.65. Análisis estadístico de la variación de k=2:5 para la clasificación de las celdas F-B distancia E.	123
5.66. Métricas Silhouete para la clasificación de las celdas F-B. . .	124
5.67. Clasificación de las celdas F-Hs con el método k-medias H:2:5 distancia E.	124
5.68. Análisis estadístico de la variación de k:2:5 para la clasificación de las celdas F-Hs distancia E.	125
5.69. Métricas Silhouete para la clasificación de las celdas F-Hs. . .	125
5.70. Clasificación de las celdas Hs-F-B con el método k-medias K:2:5 distancia E.	126
5.71. Métricas Silhouete para la clasificación de las celdas Hs-F-B. .	126

5.72. Análisis estadístico de la variación de k:2:5 para la clasificación de las celdas Hs-F-B distancia E.	127
5.73. Clasificación de las celdas Hs-B con el método k-medias K=2:5 distancia coseno.	128
5.74. Análisis estadístico de la variación de k=2:5 para la clasificación de las celdas Hs-B.	129
5.75. Métricas Silhouette para la clasificación de las celdas Hs-B.	130
5.76. Clasificación de las celdas F-B con el método k-medias K=2:5 distancia coseno.	130
5.77. Análisis estadístico de la variación k:2:5 con métrica coseno para la clasificación de las celdas F-B.	131
5.78. Métricas Silhouette para la clasificación de las celdas F-B.	131
5.79. Clasificación de las celdas F-Hs con el método k-medias K=2:5 distancia coseno.	132
5.80. Análisis estadístico de la variación k:2:5 con métrica coseno para la clasificación de las celdas F-Hs.	132
5.81. Métricas Silhouette para la clasificación de las celdas F-Hs.	133
5.82. Clasificación de las celdas Hs-B-F con el método k-medias K=2:5 distancia coseno.	133
5.83. Análisis estadístico de la variación de k:2:5 con métrica coseno para la clasificación de las celdas Hs-B-F.	134
5.84. Métricas Silhouette para la clasificación de las celdas Hs-B-F.	134
5.85. Métricas de clasificación Silhouette para la clasificación de las celdas Hs-B.	135
5.86. Matrices de confusión método no supervisado GMM para la clasificación de Hs-B-F.	137
 6.1. Ajuste del MDF para inspección nanored Universidad del Valle EIEE.	141
6.2. Estación meteorológica y piránmetro SP-110.	143
6.3. Imágenes IR de los paneles solares.	144
6.4. Diagrama de filtrado y adecuación de las IIR.	144
6.5. Filtrado de área.	145
6.6. Enfoque de filtrado por área.	146
6.7. Transformada de Hough.	147
6.8. Asignación de coordenadas.	148
6.9. Transformación proyectiva.	148
6.10. Diagrama de los clasificadores.	150
6.11. Método propuesto para la detección de anomalías en PPV escenario de inspección planta solar Celsia ® MDF1.	152
6.12. Imágenes adquiridas en la planta solar Celsia ®.	153

1.	Superficies de precisión características C1 con todas.	174
2.	Mejores superficies de precisión.	175
3.	Superficies de precisión características C2 con todas.	176
5.	177
4.	Superficies de precisión características C3 con todas.	177

Índice de cuadros

2.1.	Antecedentes internacionales.	12
2.2.	Escalas de severidad.	20
2.3.	Temporalidades en la intervención de paneles solares.	21
2.4.	Características estadísticas.	31
2.5.	Texturas de Haralick.	33
2.6.	Tipos de kernel de las SVM.	37
2.7.	Tipos de funciones de activación.	38
3.1.	UAV's empleados en la investigación.	43
3.2.	Especificaciones UAV <i>Matrice 100</i>	44
3.3.	Cámaras IR empleadas en la inspección de fallas en PPV.	44
3.4.	Especificaciones cámara termográfica <i>Zenmuse XT</i>	45
3.5.	Tecnología de paneles solares inspeccionada en los dos escenarios de prueba.	47
3.6.	Especificaciones carga electrónica.	49
3.7.	Especificaciones estación meteorológica.	50
3.8.	Especificaciones carga electrónica.	50
3.9.	Especificaciones computador y clúster.	50
4.1.	Alturas de vuelo reportadas en la literatura.	55
4.2.	Características extraídas por celda.	59
4.3.	Escala de severidad para intervención de módulos fotovoltaicos.	59
5.1.	CDIT.	62
5.2.	Valores promedio de los coeficiente DICE e IOU por carpeta de imágenes.	64
5.3.	Mejores características para clasificar las celdas B, F y Hs usando la máquina de soporte vectorial <i>kernel RBF</i>	69

5.4.	Mejores características para clasificar las celdas Hs-F-B empleando el método de k-medias con $k=1:5$ distancia euclídea.	120
5.5.	Mejores características para clasificar las celdas Hs-F-B empleando el método de k-medias con $k=2:5$ distancia coseno.	128
5.6.	Mejores características para clasificar las celdas Hs-B-F con MG.	136
6.1.	Características extraídas por cada una de las celdas del panel.	149
1.	Resultados segmentación carpeta 4 Mayo 2018 LS.	171
2.	Resultados segmentación carpeta 4 Mayo 2018 área.	171
3.	Resultados segmentación carpeta 18 de abril 2018 ls.	172
4.	Resultados segmentación carpeta 18 de abril 2018 área.	172
5.	Resultados segmentación carpeta 28 de abril 2018 ls.	172
6.	Resultados segmentación carpeta 28 de abril 2018 área.	173
7.	Resultados segmentación carpeta 20 de diciembre 2018 área.	173
8.	Clasificación usando las características C1 a C6 con parámetros por defecto y con búsqueda de hiperparámetros.	178
9.	Clasificación usando las características C2 a C6 con parámetros por defecto y con búsqueda de hiperparámetros.	178
10.	Clasificación usando las características C3 a C6 con parámetros por defecto y con búsqueda de hiperparámetros.	178
11.	Clasificación usando las características C4 a C6 con parámetros por defecto y con búsqueda de hiperparámetros.	179
12.	Clasificación usando las características C5 y C6 con parámetros por defecto y con búsqueda de hiperparámetros.	179
13.	Clasificación usando las características H8 con parámetros por defecto y con búsqueda de hiperparámetros.	179
14.	Clasificación usando k-medias celda sana y fracturada <i>wrapper</i> C1 vs CT.	179
15.	Clasificación usando k-medias celda sana y fracturada <i>wrapper</i> C2 vs CT.	180
16.	Clasificación usando k-medias celda sana y fracturada <i>wrapper</i> C3 vs CT.	180
17.	Clasificación usando k-medias celda sana y fracturada <i>wrapper</i> C4 vs CT.	180
18.	Clasificación usando k-medias celda sana y fracturada <i>wrapper</i> C5 vs CT.	180
19.	Clasificación usando k-medias celda sana y <i>hot spot wrapper</i> C1 vs CT.	180
20.	Clasificación usando k-medias celda sana y <i>hot spot wrapper</i> C2 vs CT.	181

21.	Clasificación usando k-medias celda sana y <i>hot spot wrapper</i> C3 vs CT.	181
22.	Clasificación usando k-medias celda sana y <i>hot spot wrapper</i> C4 vs CT.	181
23.	Clasificación usando k-medias celda sana y <i>hot spot wrapper</i> C5 vs CT.	181
24.	Clasificación usando k-medias celda fracturada y <i>hot spot wrapper</i> C1 vs CT.	181
25.	Clasificación usando k-medias celda fracturada y <i>hot spot wrapper</i> C2 vs CT.	182
26.	Clasificación usando k-medias celda fracturada y <i>hot spot wrapper</i> C3 vs CT.	182
27.	Clasificación usando k-medias celda fracturada y <i>hot spot wrapper</i> C4 vs CT.	182
28.	Clasificación usando k-medias celda fracturada y <i>hot spot wrapper</i> C5 vs CT.	182
29.	Clasificación usando k-medias celda fracturada y <i>hot spot wrapper</i> C3 vs CT.	182
30.	Clasificación usando k-medias celda fracturada y <i>hot spot wrapper</i> C3 vs CT.	183
31.	Clasificación usando k-medias celda fracturada y <i>hot spot wrapper</i> C3 vs CT.	183
32.	Clasificación usando k-medias celda fracturada y <i>hot spot wrapper</i> C4 vs CT.	183
33.	Clasificación usando k-medias celda fracturada y <i>hot spot wrapper</i> C5 vs CT.	183
34.	Clasificación usando mezcla de gausianas celda fracturada y sana <i>wrapper</i> C1 vs CT.	183
35.	Clasificación usando mezcla de gausianas celda fracturada y sana <i>wrapper</i> C2 vs CT.	184
36.	Clasificación usando mezcla de gausianas celda fracturada y sana <i>wrapper</i> C4 vs CT S1.	184
37.	Clasificación usando mezcla de gausianas celda fracturada y sana <i>wrapper</i> C5 vs CT S1.	184
38.	Clasificación usando mezcla de gausianas celda <i>hot spot</i> y sana <i>wrapper</i> C1 vs CT.	184
39.	Clasificación usando mezcla de gausianas celda <i>hot spot</i> y sana <i>wrapper</i> C2 vs CT.	184
40.	Clasificación usando mezcla de gausianas celda <i>hot spot</i> y sana <i>wrapper</i> C3 vs CT.	185

41.	Clasificación usando mezcla de gausianas celda <i>hot spot</i> y sana <i>wrapper</i> C4 vs CT.	185
42.	Clasificación usando mezcla de gausianas celda <i>hot spot</i> y sana <i>wrapper</i> C5 vs CT.	185

Capítulo 1

Introducción

La generación de energía a partir de combustibles fósiles es la principal contribuyente de contaminación por gases de efecto invernadero, aproximadamente el 70 % de las emisiones de CO_2 son consecuencias del actual sistema de energía. La dependencia a estos recursos no renovables representa un gran problema, debido a que los depósitos de combustible son limitados tanto física como económicamente, para su producción se necesita de un millón de años de acumulación de biomasa, por esta razón la tasa de producción es mucho más lenta que la tasa de extracción [7].

Los efectos nocivos generados por el uso de combustibles fósiles han sido objeto de investigación actual, relacionándolos con la problemática del calentamiento global; en [8], estudian cuatro escenarios propuestos por (SRES) “The special report on emission scenarios”, en donde se exploran las consecuencias del efecto invernadero en las variaciones del desarrollo global y regional. Una posible solución que mitigue estas consecuencias son las energías renovables [9], gran parte de la conciencia ambiental en latinoamérica se ha generado desde países como Brasil y México que han implementado el uso de energías limpias provenientes del sol, el agua, el viento y la biomasa.

La energía solar es una fuente limpia y aprovechable mediante Paneles Solares PPV, compuestos de celdas fotovoltaicas que permiten captar la energía de la radiación solar. Los PPV son fabricados con materiales semiconductores como el silicio y arseniuro de galio. Entre mayor sea el área expuesta al sol por los paneles, mayor será la energía captada.

La instalación de grandes sistemas de generación (parques solares) ha presentado un importante crecimiento en el mundo, motivado por el impacto ambiental, la definición de normas, leyes y la reducción en los costos de instalación y mantenimiento [10].

Los altos niveles de irradiancia, necesarios para que se produzca el efecto fo-

tovoltaico, generan incrementos de temperatura en las celdas que reducen la eficiencia de los paneles solares. Las anomalías o defectos pueden presentarse durante la manufactura, la instalación y la operación de los paneles solares [11]. Existen diferentes técnicas para inspeccionar los PPV, entre las que se encuentran: técnicas eléctricas como la curva I-V y de análisis de imágenes generadas por Electroluminiscencia EL, fotoluminiscencia PL y termografía infrarroja TIR [12].

La mayor parte de las fallas en los paneles solares son imperceptibles al ojo humano, la inspección manual no es eficaz ya que no es una tarea sencilla debido a que generalmente los paneles se encuentran en zonas altas, de difícil acceso y con poco espacio entre ellos; sumado al hecho de exposición a riesgo eléctrico ante circuitos con corriente continua de varios amperios.

El uso de vehículos aéreos no tripulados UAV constituye una alternativa de solución para la inspección de los módulos fotovoltaicos [9], [13], [14], [15], etc. estos UAV deben ser pilotados de forma remota y manualmente para capturar las imágenes, teniendo en cuenta múltiples consideraciones como lo son: la altura del UAV, los ángulos de la cámara y las condiciones meteorológicas que alteran el procedimiento de adquisición. Una vez se adquieren las imágenes termográficas TIR se hace necesario emplear métodos de procesamiento para las TIR y técnicas de reconocimiento de patrones que permitan la clasificación del estado de los paneles solares.

Con base en el panorama expuesto anteriormente, la pregunta problema de investigación que surgió fue: ¿Cuál es el procedimiento que permite la detección y determinación de la severidad de las fallas en paneles solares de Si monocristalino a partir de imágenes aéreas termográficas?. Para responder a la pregunta de investigación se propuso como objetivo general “Desarrollar un procedimiento para la detección y determinación de severidad de las fallas tipo *hot spot* y celdas fracturadas en paneles solares de silicio monocristalino a partir de imágenes aéreas termográficas”; y como objetivos específicos:

- Establecer las características y condiciones de captura de las imágenes termográficas aéreas para la inspección de paneles solares.
- Analizar termográficamente las fallas tipo *hot spot* y celdas fracturadas en paneles bajo prueba, para parametrizar sus características.
- Desarrollar un algoritmo de procesamiento de imágenes termográficas para detección de fallas tipo *hot spot* y celdas fracturadas.
- Definir e implementar escenarios de prueba que permita validar el procedimiento establecido.

- Proponer una escala de severidad de las fallas seleccionadas para establecer tiempos de mantenimiento.

En esta investigación se planteó un método para la inspección de fallas en paneles solares mediante la técnica de termografía infrarroja TIR, que fue sometido a prueba en un arreglo de cuatro paneles solares de silicio monocrystalino conectados en serie ubicados en la terraza de la Escuela de Ingeniería Eléctrica y Electrónica (EIEE) de la Universidad del Valle y con seis arreglos de módulos fotovoltaicos de la planta solar de Celsia ® Yumbo ¹.

El trabajo de investigación se desarrolló en cuatro etapas, la primera de ellas correspondió a la revisión bibliográfica de experimentos similares para definir los equipos y la existencia de procedimientos empleados para el diagnóstico de fallas con UAV y termografía infrarroja. Esta búsqueda arrojó como resultados las variables importantes para seleccionar el UAV como: la autonomía de vuelo superior a 15 min y una resistencia al viento mayor 5 m/s y para la cámara IR: una resolución $\leq 336 \times 256$, una sensibilidad $< 50 mK$ y un peso apropiado para el UAV escogido. De acuerdo con los parámetros mencionados anteriormente, se adquiere el UAV *Matrice 100* y la *Zenmuse XT*. Por otra parte, en la actualidad no existe ningún consenso en los protocolos de adquisición de las imágenes termográficas (IIR) debido a que los parámetros definidos para el procedimiento de captura de las IIR presentan variaciones en la altura de adquisición y los ángulos de la cámara [13], [14], [16], [17], [18] y [19], por tal motivo se plantea el diseño de un protocolo propio para la captura de IIR. En este protocolo se definió una ecuación para estimar las alturas para el posicionamiento del UAV, los ángulos de la cámara térmica entre 40 y 60°debido que la reflexión y la emisividad permanecen constantes [20] y las condiciones ambientales idóneas para las imágenes como la velocidad del viento $< 5 m/s$ e irradiancia superior a $500 W/m^2$. Con el protocolo definido se construyó un conjunto de datos de imágenes termográficas (CDIT) de 411 imágenes para los dos escenarios de prueba que incluía mediciones de irradiancia, temperatura y velocidad del viento.

Una vez establecidas las condiciones para la captura de las IIR, se planteó un método para el diagnóstico de las fallas enfocado en la localidad, es decir, en la inspección de cada una de las celdas del panel clasificando dos tipos de fallas y proponiendo una escala para estimar la severidad de las mismas a diferencia de los propuestos en [21],[13], [16] etc. donde emplean estrategias para la detección de fallas en todo el panel sin analizar regiones ni discernir entre los tipos de anomalías que pueden presentar los módulos.

El método para la detección de fallas (MDF) desarrollado planteó un algoritmo de procesamiento para las IIR que incluyó un filtro mediana y la binarización de la imagen. La segmentación de los paneles solares a partir de

contornos activos *level set* MCA y el enfoque de filtrado de área FA. La clasificación del estado de las celdas en Buena (B), Fracturada (F) y *Hot-spot* (Hs); para esto cada celda se sub-dividió en cuatro regiones y por región se obtuvieron las siguientes características: 4 primeros momentos estadísticos, 14 de textura de Haralick y 36 de histograma de gradientes. Estas características fueron clasificadas con métodos supervisados como: las máquinas de soporte vectorial (SVM) sintonizando los hiperparámetros, redes neuronales artificiales (RNA) y no supervisados como: k-medias y mezcla de gausianas. El sistema propuesto alcanzó una efectividad para las SVM sintonizadas de 82.92 % para las B-Hs, para B y F de 77.02 %, para las F-Hs de 97.43 % y para el experimento F-B-Hs de 64.80 %. En las redes neuronales alcanzó una efectividad de 73.40 % para B-Hs, B-F 83.70 % , F-Hs 93.8 % y F-B-Hs de 73.6 %. Con los métodos no supervisados k-medias alcanzó una efectividad en las celdas Hs-B 72.1 %, B-F 66.63 %, F-Hs 84.5 % y F-Hs-B 63.27 %. Finalmente, con la mezcla de gausianas presentó una efectividad para B-Hs de 69.80 %, B-F 55.04 % *hot spot*, F-Hs 80.98 % y F-Hs-B 46.70 %.

Por último, se propuso una escala de severidad de tres niveles de acuerdo con el porcentaje de celdas con fallas en un panel solar: 5 % < alerta \leq 20 %, 20 % < severo \leq 50 % y crítico > 50 %. Cada nivel de severidad tiene asociado una ventana de tiempo recomendada para realizar el mantenimiento preventivo o correctivo del panel. El desarrollo de este método para la inspección de fallas en PPV marca un precedente a nivel nacional, debido a que en la actualidad no se dispone de ninguno.

El presente documento se encuentra estructurado en siete capítulos:

La introducción, motivación y descripción del problema abordado, en el capítulo uno. El estado del arte a nivel nacional e internacional y los fundamentos teóricos, para la inspección de fallas en sistemas fotovoltaicos en el capítulo dos.

La plataforma *hardware* para la adquisición de las imágenes termográficas aéreas en el capítulo tres. La descripción del método propuesto, una explicación de sus etapas y fases en el capítulo cuatro.

La aplicación del método propuesto para la detección de fallas en dos escenarios de prueba en el capítulo cinco. La descripción del CDIT adquirida para la detección de fallas y las pruebas para evaluar el desempeño de los algoritmos, generando una descripción de las anomalías detectadas y su escala de severidad en el capítulo seis. Finalmente, en el capítulo siete se reportan las conclusiones, trabajos futuros y un resumen de resultados.

¹<https://www.celsia.com/es/Granjas-Solares>

Capítulo 2

Antecedentes y Marco Teórico

En este capítulo se explora el panorama investigativo a nivel nacional e internacional en la temática de inspección de fallas en paneles solares (PPV) específicamente: los fundamentos teóricos de la construcción de los PPV, sus fallas comunes, las técnicas eléctricas como la curva IV y de procesamiento de imágenes como electroluminiscencia EL, fotoluminiscencia PL y termografía IR TIR, las condiciones de captura con vehículos aéreos no tripulados, el procesamiento de imágenes y el reconocimiento de patrones. Esta información se sintetizó a partir de ecuaciones de búsqueda que permitieron definir el impacto del diagnóstico de anomalías en las plantas solares, los laboratorios con mayor producción y la cantidad de publicaciones por año. Finalmente, se presenta el resumen de los resultados por publicación de la técnica TIR de especial interés en este trabajo para el análisis de fallas en PPV, condensando los indicadores y las metodologías empleadas en la tabla. 2.1.

2.1. Antecedentes nacionales

A nivel nacional el panorama investigativo se encuentra dividido en, el uso de UAV para agricultura de precisión usando cámaras de espectro IR y las aplicaciones de la termografía activa para el diagnóstico de defectos sobre materiales. En el proceso de búsqueda que se llevo a cabo utilizando 3 ecuaciones, no se encuentra reportado el impacto generado por la inspección de fallas en sistemas fotovoltaicos usando termografía aérea.

Las ecuaciones de búsqueda empleadas son:

- (1) *TITLE-ABS-KEY (Thermography AND Colombia AND Image Processing) AND (LIMIT-TO (PUBYEAR , 2018) OR LIMIT-TO (*

PUBYEAR , 2017) OR LIMIT-TO (PUBYEAR , 2016) OR LIMIT-TO (PUBYEAR , 2015) OR LIMIT-TO (PUBYEAR , 2013))

- (2) *Uav AND Precision AND Agriculture AND colombia AND (LIMIT-TO (PUBYEAR , 2019) OR LIMIT-TO (PUBYEAR , 2018) OR LIMIT-TO (PUBYEAR , 2017) OR LIMIT-TO (PUBYEAR , 2016) OR LIMIT-TO (PUBYEAR , 2015) OR LIMIT-TO (PUBYEAR , 2014))*
- (3) *Drone or UAV and Thermography and Colombia AND (LIMIT-TO (SRCTYPE,"p") OR LIMIT-TO (SRCTYPE,"k"))*

La ec. (1) permite analizar el impacto de la termografía a nivel nacional, en este ámbito se destacan artículos para el estudio de defectos en materiales, usos médicos y con fines deportivos la fig. 2.1, muestra un crecimiento en las publicaciones en los años 2013 y 2018.

Algunas aplicaciones en inspección de defectos en materiales son usadas en [22], donde utilizan la termografía para hacer inspección en las terminales de transformadores y comparan los valores de temperatura promedio obtenidos en el cobre y el aluminio. En [23], desarrollan una técnica de procesamiento para desacoplar la información del fondo y el calentamiento no uniforme, generado por la excitación de la fuente externa sobre una muestra de polímero reforzado con fibra de carbono (CFRP) que tiene insertados defectos a diferentes profundidades.

Por otra parte, las aplicaciones con fines médicos se evidencian en [24] donde proponen como experimento la captura de imágenes IR en el vasto lateral y aductor de la pierna dominante antes y después de iniciar una prueba deportiva para diagnóstico de fatiga muscular.

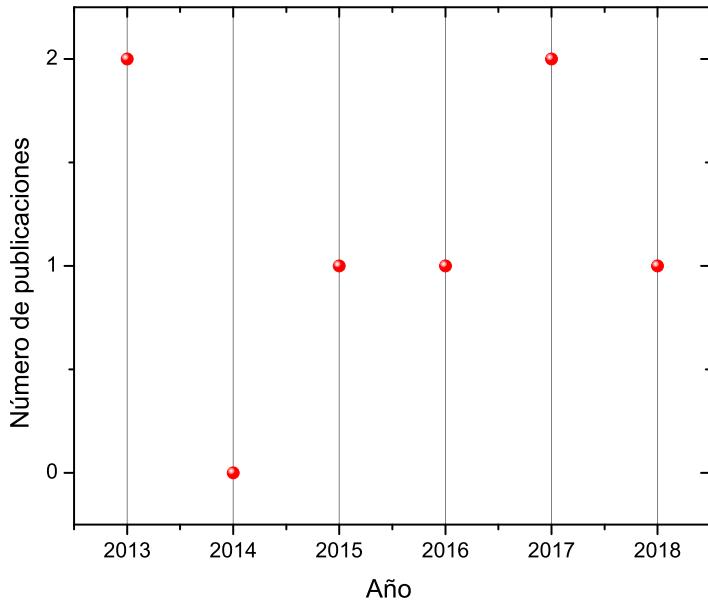


Figura 2.1: Ecuación búsqueda antecedentes regionales [Fuente de datos: Scopus].

La ec. (2), permite evidenciar preferencias en el sector investigativo por el uso de vehículos aéreos no tripulados UAV equipados con cámaras de espectro visible (RGB) y de espectro infrarrojo (IR), para las aplicaciones de agricultura de precisión. Durante el 2018 fig. 2.2, esta línea de trabajo reporto 18 artículos.

En [25], emplean una cámara de espectro visible (RGB) y multiespectral (Ms), para la detección de hierba *Gramineae* sobre campos de arroz, las imágenes son adquiridas en un rango de 60 a 70 m de altura, la fusión de la textura aportadas por RGB y la información de reflectancia de la Ms enriqueció el vector de características, por otra parte, en [26] proponen una metodología para el diseño, de una ruta de riego de cultivos usando un UAV, a partir de la estimación del índice de estrés hídrico del cultivo (CWSI) y de la segmentación de áreas definidas por las líneas de vuelo planteadas para la inspección.

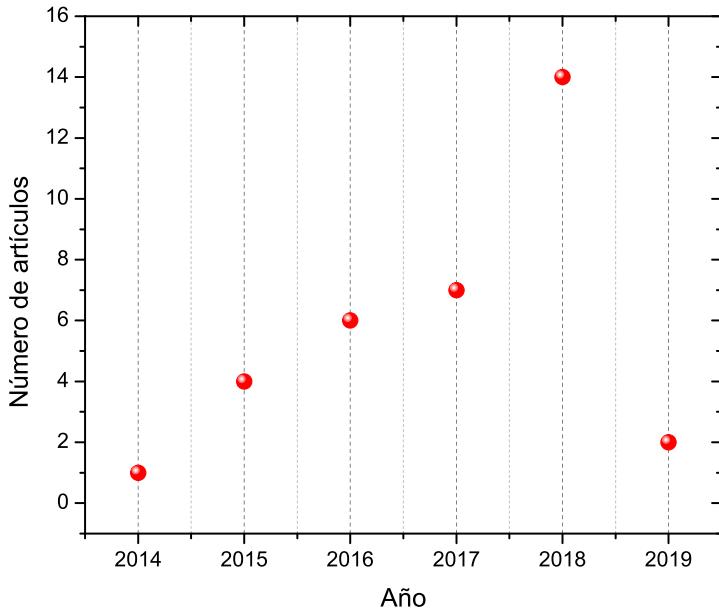


Figura 2.2: Ecuación búsqueda antecedentes nacionales [Fuente de datos: Scopus].

La ec. (3) muestra un leve crecimiento durante el año 2017 fig. 2.3 en la línea de trabajo del diagnóstico de fallas empleando termografía aérea, entre los que se destaca [27], en donde hacen una revisión de los equipos utilizados en la actualidad en el sector investigativo y comercial para caracterización de fallas en sistemas fotovoltaicos, analizando las prestaciones de la resolución de las cámaras IR y la autonomía de vuelo de los equipos. Por otra parte, en [28] desarrollan un protocolo de adquisición para la detección de minas antipersona y proponen como metodología de procesamiento de las imágenes, el uso de operaciones morfológicas como la dilatación y la erosión.

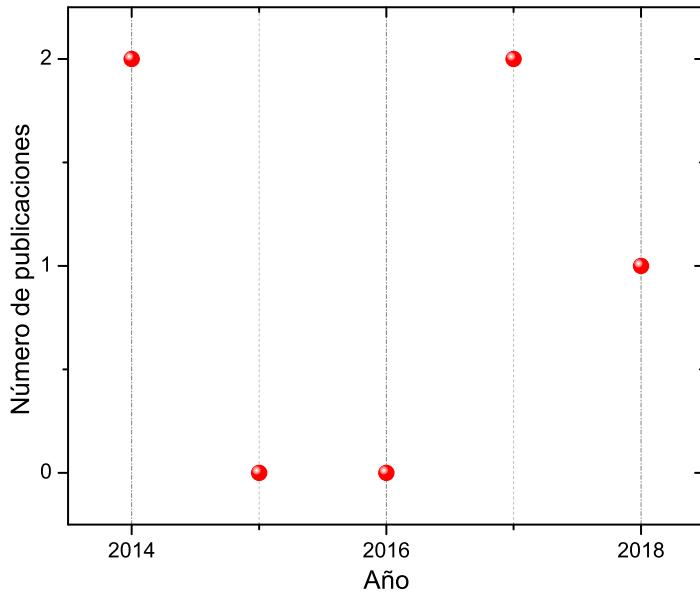


Figura 2.3: Ecuación búsqueda antecedentes internacionales [Fuente de datos: Scopus].

2.2. Antecedentes internacionales

El panorama a nivel internacional muestra un gran interés en las técnicas para inspección de fallas en sistemas fotovoltaicos, algunas de las metodologías desarrolladas implementan TIR, EL, PL, extracción de las curvas I-V. En este trabajo profundizaremos en la TIR, presentando las principales contribuciones para el diagnóstico de fallas y anomalías en PPV, para esto se empleó como ecuación de búsqueda en la base de datos de Scopus “*PV AND UAV AND THERMOGRAPHY*”, en la fig .2.3 se muestra un crecimiento en la producción académica para el año 2017 y asociadas a estas publicaciones se encuentran los centros de investigación *Das Bayerische Zentrum, Friedrich-Alexander Universität* ambas universidades ubicadas en Alemania y la Universidad de Valladolid en España.

A continuación se resumen en la tab .2.1 los protocolos para la captura y procesamiento de las imágenes termográficas, la definición de umbrales y métricas para el diagnóstico de fallas.

En [15] emplean un UAV *Matrice 100* y una cámara de espectro visible *Zen-*

muse X3, para estudiar los efectos generados por el polvo y los *snail trails* sobre los paneles solares a partir de la definición de rectángulos R que se obtienen como la relación del área de la celda S_0 y el mínimo rectángulo externo sMer, en estos rectángulos se hace el procesamiento de imágenes para excluir efectos de *busbards* y estructuras metálicas, las constantes β y γ representan los umbrales seleccionados de manera heurística para identificar las regiones con polvo y con *snail trails*. En [17], adquieren las imágenes IR para detectar regiones calientes celda *hot spot* (Hs) y diferenciarlas de regiones sanas, definiendo umbrales obtenidos de forma heurística a partir del promedio de luminancia Lum_{AVG} , para las regiones calientes (Hs) se compara con la relación $Lum(x, y) > Lum_{AVG} + 5\sigma$ en donde el término σ representa la desviación estándar; para el caso de regiones frías se estableció $Lum(x, y) > Lum_{AVG} - 1\sigma$. Por otra parte en [19], implementan un algoritmo para la segmentación de los paneles solares definiendo como relación de separación del fondo de los paneles la ec. 2.1 y detectan anomalías de temperatura que son evaluadas a partir del uso de test estadísticos como *Grubb's* y *Dixon* obteniendo un porcentaje de precisión en la detección de 82.76 %. En [14] proponen un procedimiento para la adquisición de las imágenes y la detección de anomalías en PPV con una precisión en la clasificación de las fallas Hs de 81.00 %. En [29] emplean detectores de líneas para la segmentación de las imágenes adquiridas con UAV y cámaras termográficas clasificando las fallas presentadas sin diferenciarlas con un porcentaje de acierto de 90.3 %. Finalmente, en [30] presentan una metodología para la extracción de la región de interés (panel) y posteriormente detectan los paneles defectuosos a partir de Criterio de desviación estándar (CSD), el término S_x representa el promedio de las desviaciones estándar, n el número de píxeles y S_x la desviación estándar de cada panel.

$$\vartheta := \mu - 4\sigma \quad (2.1)$$

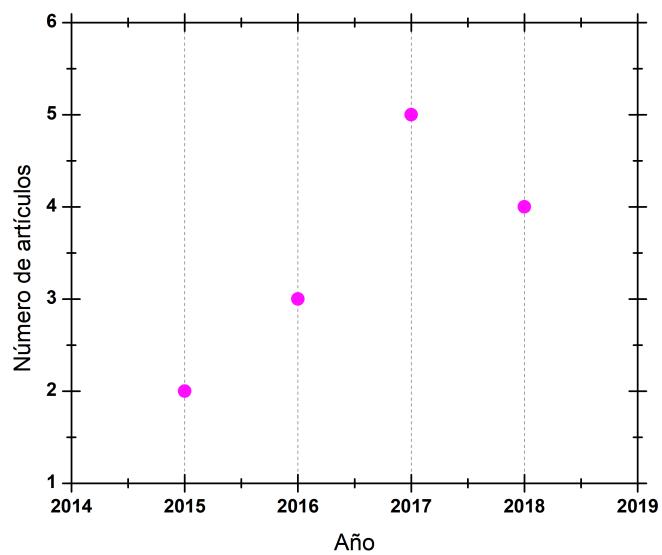


Figura 2.4: Ecuación búsqueda antecedentes internacionales [Fuente de datos: Scopus].

Artículo	Equipos	Técnicas de procesamiento	Umbrales	Observaciones	Altura (m)
[15]	Zennuse X3 (RGB) (4096 × 2160)	<ul style="list-style-type: none"> Filtrado (FODG) Detección de bordes 	$R = \frac{S_0}{S_{MER}} < \gamma$ Snail trails $R = \frac{S_0}{S_{mer}} > \beta$ Defecto	$r < \alpha$ reflejo de busbars $r > \alpha$ Defecto	2
		Polivo	$R = \frac{S_0}{S_{mer}} < \gamma$		
[17]	Flir A35 IR (336 × 256)	<ul style="list-style-type: none"> Grayscale Promedio de Iluminación Filtrado Gausiano 	Hot area: $Lum(x, y) > Lum_{AVG} + 5\sigma$ Cold area: $Lum(x, y) > Lum_{AVG} - 1\sigma$	Estimación de umbrales $5\sigma, -1\sigma$ de forma heurística	-
[19]	Scarabot X8 Cámara IR (Optiirs PI450) RGB (GoPro Hero3+) (382 × 288)	<ul style="list-style-type: none"> Normalización Umbralización Estimación de la orientación de PPV Corrección y refinamiento 	Segmentación: $\vartheta := \mu - 4\sigma$	<ul style="list-style-type: none"> Grubbs' test Dixon's test Hipótesis nula: No anomalidades de temperatura en cada PPV 	20
[16]	UAS (PLP-610) FLIR A35 cámara IR (336 × 256)	<ul style="list-style-type: none"> Imagen escala de grises Filtrado paso-bajo Gaussiano Laplaciano de la Imagen Determinación de la degradación 	$\%degradacion = \frac{White(hot)Area}{Totalareaofmodule} \times 100$		-
[30]	UAV	<ul style="list-style-type: none"> Extracción del área del panel 	$S_w = \sqrt{\frac{(n_1-1)S_1^2 + (n_k-1)S_k^2}{n_1+n_k-k}}$	Etiquetado y segmentación manual de paneles (CMI) Criterio para intensidades medias (CSD) Criterio para desviación estándar	-
	Flir T620 (cámara IR) (640 × 480)	<ul style="list-style-type: none"> Indexado de polígonos Grupos de PPV Cálculo del promedio de intensidad Desviación de cada panel Cálculo del rango CMI y CSD Detección de paneles defectuosos 			

Tabla 2.1: Antecedentes internacionales.

2.3. Estructura física de los paneles solares

Los paneles solares son dispositivos electrónicos compuestos de celdas conformadas por materiales semiconductores como el silicio y el arseniuro de galio, que al captar la radiación proveniente del sol (fuente de excitación externa) generan procesos de recombinación par electrón-hueco creando un flujo de corriente entre los terminales eléctricos de las celdas. Cada celda se compone de películas de mejora, vidrio, recubrimiento polimérico, material semiconductor, contactos eléctricos, etc. como se ilustra en la fig. 2.5.

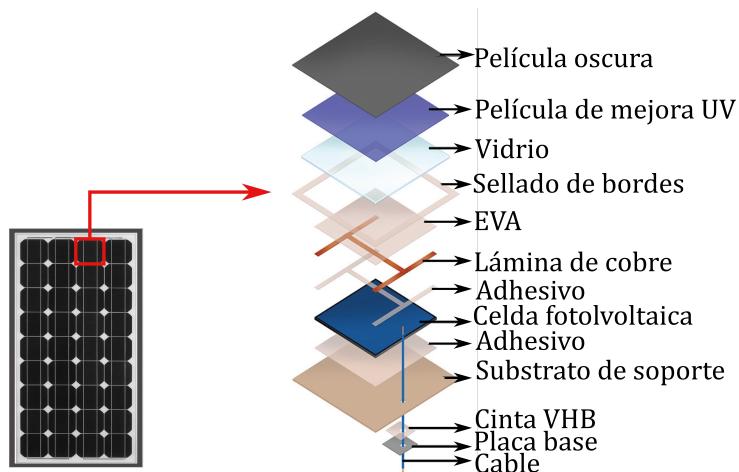


Figura 2.5: Esquema de la composición de la célula solar [Fuente propia].

Las películas de mejora proporcionan un mayor aprovechamiento de la absorción de la radiación. El vidrio protege al semiconductor de la exposición a la intemperie y el recubrimiento polimérico impermeabiliza la superficie evitando posibles filtraciones hacia las conexiones y el semiconductor.

Los contactos eléctricos permiten la interconexión de celdas de acuerdo a requerimientos específicos, siendo la configuración en serie el montaje habitual dispuesto para alcanzar valores de voltaje y corriente determinados.

Existen diferentes tipos de tecnologías de celdas solares, como son las constituidas por semiconductores y por materiales orgánicos. Dentro de esta primera categoría se subclasifican por la fase cristalina en la que se encuentra el semiconductor: monocristal o policristal. Así mismo, es importante recalcar que solo unos pocos semiconductores cumplen con las características requeridas para ser empleados en las celdas solares. Los paneles de silicio monocristalino y policristalino son la tecnología de sistemas fotovoltaicos con mayor uso en la actualidad, reportando eficiencias del 25 % en condiciones de

laboratorio [31]. Por otra parte, las celdas de compuestos orgánicos construidas sobre materiales basados en arquitecturas de carbono, han presentando gran resistencia y la posibilidad de adaptación para adecuarse a diferentes morfologías.

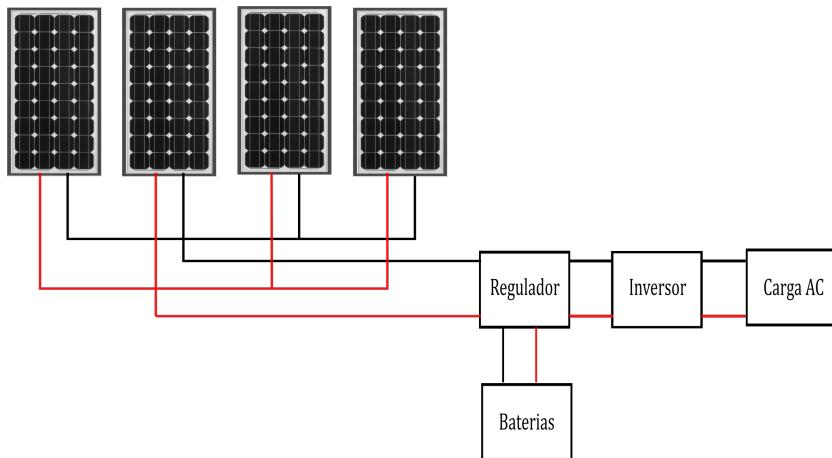


Figura 2.6: Esquema de funcionamiento sistema fotovoltaico [Fuente propia].

Las celdas solares conectadas en serie conforman los PPV, a su vez los sistemas fotovoltaicos son arreglos de paneles conectados en serie y/o paralelo, con el propósito de suplir los requerimientos de la demanda eléctrica de un sistema. El esquema habitual de un arreglo de paneles solares se muestra en la fig. 2.6, conformado por un regulador y un inversor, que básicamente son dispositivos electrónicos que permiten la adecuación de la energía generada por el arreglo para la carga que se desea alimentar y baterías dispuestas para almacenar la energía transformada.

2.4. Fallas comunes en paneles solares

Los módulos fotovoltaicos pueden presentar fallas, en la fabricación, en la instalación y en la operación.

En la etapa de fabricación, las anomalías se deben a la inyección de oxígeno en las películas de Si. En la instalación, pueden deberse a accidentes o sistemas eléctricos de respaldo mal calculados y se manifiestan como fracturas en las celdas, *snail trails*, etc. Finalmente, en la operación se deben a la exposición natural a la intemperie, las condiciones ambientales como la humedad, el viento, la lluvia y los cambios de temperatura que generan degradación sobre los PPV [32] y se evidencian por la delaminación en el recubrimiento polimérico EVA y la corrosión de los metales (*busbars*). Estas anomalías

generan incrementos de temperatura que deterioran el panel ocasionando pérdidas de potencia sobre el sistema. A continuación se presentan algunas de las fallas más comunes de los PPV.

2.4.1. Hot spot

El *hot spot* o punto caliente es una de las anomalías presentadas con mayor frecuencia sobre los PPV y se caracteriza por elevados gradientes de temperatura sobre las celdas. Este fenómeno puede producirse por el sombreado accidental del panel, fracturas o decoloración del recubrimiento polimérico [33]. Además, genera sobrecargas en el diodo de *bypass* que debe compensar el inadecuado funcionamiento de la celda por la que circula una corriente menor que la establecida por el arreglo de PPV.

La falla Hs puede presentarse también en estadios tempranos durante la fabricación de los lingotes de Si, debidas a la inserción no controlada de impurezas. En [34], establecen rangos de temperaturas a partir del análisis de las imágenes obtenidas por (TEM) *Microscopio Electrónico de transmisión* y (SEM) *Microscopio de barrido electrónico* exhibiendo temperaturas entre 60 y 80 °C. Por otra parte, en [35] reportan valores de temperatura promedio del *hot spot* de 60 °C, medidos con la cámara termográfica *Flir E95*.

En la actualidad no existe un consenso sobre los valores de temperatura que

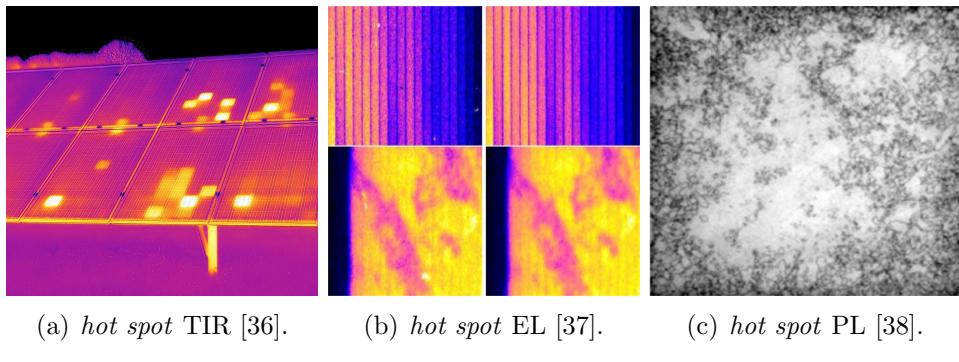


Figura 2.7: Visualización del *hot spot* con las técnicas TIR,EL y PL.

alcanzan los puntos calientes, pero en promedio presentan una temperatura 10 °C [39] por encima de las regiones sanas.

2.4.2. Degrado Inducida por Potencial (PDI)

La exposición a sombreados y elevados niveles de irradiancia sobre el sistema fotovoltaico generan la anomalía conocida como potencial de degra-

dación inducida. Esta falla ocasiona pérdidas de potencia mayores al 30 %. Físicamente se puede considerar como un efecto de la polarización reversible experimentada por una o un grupo de celdas deterioradas. Las metodologías de diagnóstico de fallas no reportan un consenso sobre la firma térmica del PDI, aunque ofrecen una aproximación de la variación de pendientes en la curva I-V presentada para este defecto [40]. Por otra parte, no presenta síntomas detectables mediante inspección visual por lo cual utilizar enfoques de visión artificial a partir de imágenes de espectro visible no representa una opción viable.

2.4.3. Celda Fracturada

Las fracturas en las celdas solares ocurren con gran frecuencia, estos daños pueden ocasionarse en la instalación, generando perdidas de potencia para el sistema fotovoltaico, por tal motivo en la actualidad se implementan técnicas de electroluminiscencia EL, fotoluminiscencia PL y análisis con espectro visible, para diagnosticarla.

Una de las ventajas presentadas en este defecto es que puede detectarse por inspección visual permitiendo el uso de cámaras (RGB) que cuentan con gran resolución y zoom. Para el caso de [15], adquieren imágenes RGB e implementan un detector de bordes para obtener las texturas que generan el patrón de daño de la celda fracturada. Por otra parte, en [41] utilizan como fuente de excitación una luz infrarroja sobre la película semiconductora de silicio y adquieren la secuencia de imágenes con una cámara CCD para su posterior procesamiento, esta metodología se plantea para líneas de producción y ensamblaje de PPV. En la actualidad no se encuentra reportado en la literatura la firma térmica del defecto conocido como celda fracturada.

2.4.4. Snails trails

La decoloración en el recubrimiento polimérico EVA ocasionada por la exposición a fuertes condiciones climáticas como se observa en la fig. 2.8, toma patrones comparables morfológicamente con el camino de un caracol, de ahí la particularidad en su nombre. Estas fallas degradan el panel solar, disminuyendo la potencia del PPV.

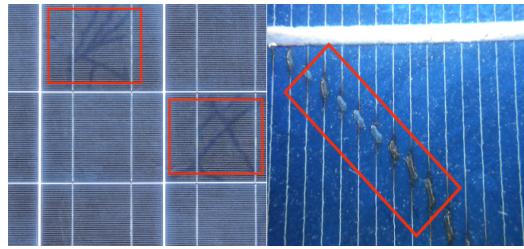


Figura 2.8: *Snail trails* [Fuente propia].

En [42], emiten un diagnóstico de las perdidas de generación a nivel de *string* provocadas por el deterioro óptico del polímero usando las técnicas EL y TIR. La termografía se emplea de forma cualitativa para describir el defecto sin asociar rangos de temperaturas; en el artículo se concluye que la generación de corriente disminuye en un 9.1 %, comparada con el rendimiento de un *string* sano.

2.5. Inspección termográfica para diagnóstico de fallas

La TIR es una técnica de inspección para equipos eléctricos que se fundamenta en el análisis de las variaciones de temperatura procesadas en las imágenes. A continuación se presentan las generalidades y algunas de las aplicaciones recientes para la detección de fallas en PPV.

2.5.1. Generalidades de la termografía

La distribución energética de las ondas electromagnéticas se define como espectro, la radiación infrarroja (IR) toma longitudes de onda entre 0.7 y 700 μm una porción grande comparada con el reducido rango del espectro visible fig. 2.9.

El interés del trabajo con el espectro IR se debe a que los paneles solares aprovechan la energía en el visible pero emiten en el infrarrojo, haciendo posible la caracterización de defectos, a partir de las lecturas de temperatura con cámaras termográficas, estas cámaras equipadas con sensores capaces de detectar la radiación IR, correspondiente a la bandapectral de 7-13 μm .

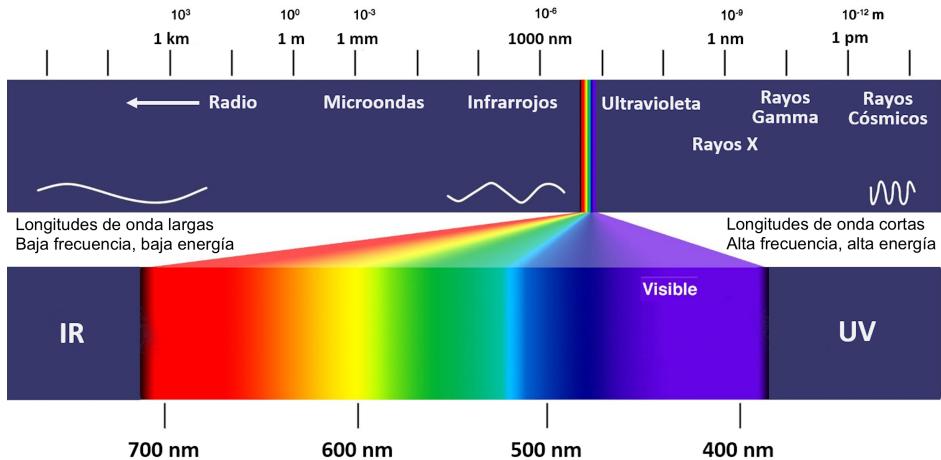


Figura 2.9: Espectro electromagnético [43].

Las cámaras IR idealmente pueden ser calibradas con un radiador de cuerpo negro. Físicamente es una cavidad que cuenta con un pequeño orificio, y cuando la cavidad es calentada a cierta temperatura, desde este hueco escapa un tipo de radiación que varía en función de la temperatura. Por lo que actúan como firmas térmicas ideales.

2.5.2. Termografía IR técnica de inspección

La termografía infrarroja es una técnica no destructiva que permite la inspección de fallas detectables a partir de variaciones de temperatura, sobre materiales, equipos e instalaciones eléctricas. Existen dos enfoques, el activo y el pasivo, la principal diferencia radica en el control que se ejerce sobre la fuente de excitación que incide sobre los materiales.

La termografía activa requiere de una fuente de calor externa como lámparas de luz incandescente o un láser de gran potencia que excite la muestra, el hardware presentado en la fig. 2.10 [44] se usa para la caracterización de defectos sobre un espécimen, se envía un pulso de calor con una fuente durante un tiempo determinado por la finalidad del experimento (características del material, defectos, etc.) buscando destacar los defectos de la región sana y se adquiere la secuencia de imágenes para su posterior procesamiento. Algunas de las aplicaciones comunes de este enfoque son la inspección de materiales en la etapa de fabricación.

Por otra parte, la termografía pasiva se usa en diagnóstico de equipos eléctricos, para tareas de inspección *in situ* en las etapas de producción y mantenimiento.

miento con la finalidad de detectar perfiles anormales de temperatura. Este enfoque de termografía se emplea para detección de fallas en sistemas fotovoltaicos en la etapa operativa, debido a que permite emitir un diagnóstico sin interrumpir el funcionamiento de la planta solar.

En este trabajo se emplea el enfoque pasivo y se describe el desarrollo experimental, en el capítulo 3.

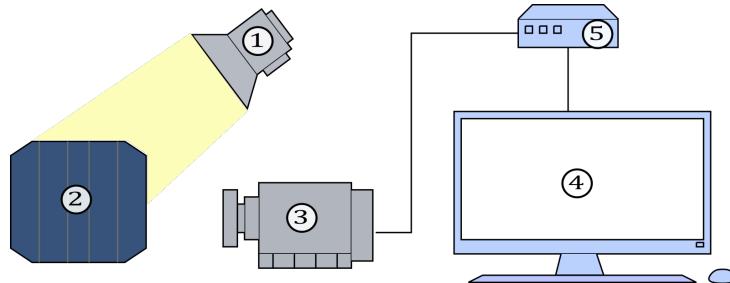


Figura 2.10: Diagrama de bloques de la termografía activa [1].

2.5.3. Procesamiento de imágenes termográficas

Las imágenes termográficas representan la distribución de temperatura de un objeto. Para garantizar que la temperatura obtenida corresponde a una lectura fidedigna de la real, deben ajustarse parámetros de calibración en la cámara IR, de acuerdo con el tipo de aplicación deben medirse variables adicionales a la medición principal (termogramas) como la temperatura ambiente, la humedad, velocidad del viento y la distancia del sensor (cámara IR) con respecto al objeto de interés, para garantizar una adecuada composición de la imagen.

Existen software a nivel comercial como *FLIR Tools*® que permiten cambiar parámetros de emisividad, para obtener lecturas de temperatura por medio de la selección de regiones de interés en las imágenes adquiridas, también pueden generarse archivos pdf acompañados de anotaciones y breves diagnósticos. Algunas cámaras IR cuentan con tecnología RGB, para fusionar los datos térmicos con imágenes visibles y enriquecer la información obtenida [45].

El procesamiento de las imágenes térmicas varía de acuerdo con la aplicación y la forma de adquisición. En la inspección de fallas para sistemas fotovoltaicos es común emplear una ajuste de emisividad en la cámara de 0.9 [46] por el reflejo generado en el recubrimiento polimérico EVA. Una vez se adquieren los datos empieza el procesamiento *offline*, iniciando con filtrado, segmentación de los paneles solares y extracción de las características que permitan detectar las variaciones de temperatura atribuidas a defectos sobre las celdas,

esta revisión queda resumida en la tab. 2.1 correspondiente a la sección de antecedentes internacionales.

2.5.4. *Lock in Thermography*

El enfoque de termografía pulsada es uno de los métodos de termografía activa que requiere como fuente un laser, en [47] usan una lámpara de potencia de 6 kJ para hacer detección de defectos sobre celdas solares variando el tiempo de exposición de la muestras, una vez se aplica el pulso de calor se adquiere la secuencia de imágenes y se comparan las fallas con la degradación presentada en la curva I-V.

2.5.5. Escalas de severidad para termografía según la Norma NFPA 70B

El diagnóstico de fallas en equipos eléctricos, a partir de la técnica de termografía infrarroja, se encuentra documentado en la norma *Recommended Practice for Electrical Equipment Maintenance (NFPA 70B)*, [48]. En esta norma se establecen niveles de severidad para conductores sin otros elementos de carga, sin carga y en equipos eléctricos sometidos a condiciones a la intemperie y con acceso a líquidos o aceites, etc., en la tab. 2.2 se presenta una escala de fallas con tres criterios de clasificación, alerta, severo y crítico, para cada nivel se establecen rangos de temperatura y una breve descripción relacionada con la temporalidad de atención del equipo inspeccionado.

Nivel de problema	Diferencial de temperatura ($^{\circ}\text{C}$)	Descripción
Alerta	4.1 a 8	Monitorear y durante el próximo mantenimiento programado
Severo	8.1 a 15	Debe ser reparado antes del mantenimiento programado
Crítico	> 15	Debe repararse inmediatamente

Tabla 2.2: Escalas de severidad.

2.5.6. Temporalidades sugeridas para la inspección en sistemas fotovoltaicos

La inspección en los sistemas fotovoltaicos (SF) se emplea para identificar los tipos de fallas presentes en los componentes del SF. Una vez son

detectadas las anomalías, es necesario iniciar operaciones de mantenimiento asociadas a tareas que permitan mejorar la vida útil del SF. En [49] sugieren tiempos de intervención de hasta tres meses para revisión de los paneles solares, inversores, tableros de conexión y mediciones eléctricas por *string*. Por otra parte, en [50] las revisiones periódicas se hacen en intervalos de tiempo de seis meses para la infraestructura metálica y en general para corroborar el estado del PPV. El resumen de las actividades con las temporalidades en la revisión se resumen en la tab. 2.3.

Inspección del generador fotovoltaico	Actividad de mantenimiento	Intervención (meses)
PPV general	<ul style="list-style-type: none"> • Limpieza de módulos • Revisión del soporte de los arreglos de PPV • Revisión del V y I de cada <i>string</i> en paralelo • Revisión de sombreados por arboles y/o estructuras <ul style="list-style-type: none"> • Limpieza de los PPV • Inspección visual • Inspección de la batería • Revisión de daños y oxidación 	3 3 3 3 1 0.25 0.25 6
Inversores	<ul style="list-style-type: none"> • Revisión daños externos <ul style="list-style-type: none"> • Verificación en las conexiones • Comprobación de continuidad y puesta a tierra 	6 6 6
<i>Switchboards</i>	<ul style="list-style-type: none"> • Daños externos (Corrosión) • Daños internos (eléctricos) • Medición individual de cada <i>string</i> V_{mpp}, I_{mpp} durante la operación 	6 6 6

Tabla 2.3: Temporalidades en la intervención de paneles solares.

2.5.7. Curva I-V

Las curvas corriente-voltaje se utilizan como técnica de diagnóstico de fallas en paneles solares. Para determinar la degradación del sistema fotovoltaico, se usan indicadores generados por las variaciones de las pendientes. Estas curvas se asocian a problemas en los componentes de modelos equivalentes. Uno de los modelos que presenta gran aceptación, es el de un solo diodo fig. 2.12, la resistencia R_h representa pérdidas de corriente y R_s las

pérdidas por los contactos eléctricos [39].

Los parámetros obtenidos en la curva I-V fig. 2.11, son:

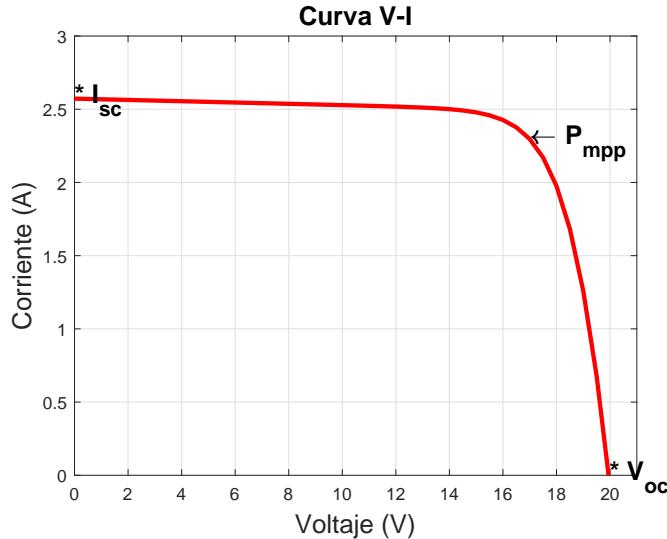


Figura 2.11: Curva voltaje corriente de un panel solar [Fuente propia].

- V_{oc} = voltaje de circuito abierto cuando la corriente en el panel solar es cero.
- I_{sc} = corriente que circula a través del módulo cuando el voltaje en la celda es cero.
- P_{max} = máxima potencia que ocurre cuando el producto del I_{mpp} y V_{mpp} son máximos.

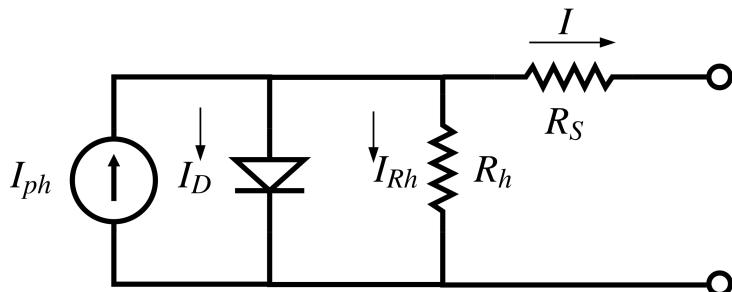


Figura 2.12: Modelo de un diodo panel solar [2].

Esta técnica ha presentado gran aceptación, en [2] realizan un sombreado parcial sobre los paneles solares, las mediciones se tomaron con un nivel de

irradiancia de 400 W/m^2 , estos resultados son comparados con la extracción de parámetros obtenida de la emulación de los modelos de un solo diodo y de doble diodo.

La curva I-V es utilizada para cuantificar el porcentaje de degradación que presenta el sistema fotovoltaico, esta técnica se implementa *in situ* para evaluar la integridad de los paneles de forma individual o a nivel de *string*. La interpretación de la curva permite diagnosticar la presencia de defectos sobre los PPV, pero no la identificación del tipo falla (Hs, celda fracturada, *snails trails*, PDI, etc).

Al finalizar la sección de fallas comunes en paneles solares y las técnicas de inspección para PPV, se presenta a continuación otro de los insumos utilizados en este trabajo, el uso de UAV equipados con cámaras IR. En la siguiente sección se definen algunos conceptos básicos del trabajo con vehículos aéreos no tripulados.

2.6. Vehículos aéreos no tripulados UAV

La definición de vehículo aéreo no tripulado (UAV por su sigla en inglés Unmanned Aerial Vehicle) se adoptó a comienzos de los años 90, el Ministerio de Defensa de los Estados Unidos define a los UAV como una aeronave teleoperada o de vuelo autónomo, que no cuenta con personas a bordo y puede transportar cargas letales o no tenerlas, los objetos que presentan exclusión son por tanto los relacionados con balística y artillería, también todo tipo de globos y dirigibles. Estos tipos de vehículos aéreos han recibido múltiples nombres a lo largo de su desarrollo, de acuerdo con la cronología que estos tienen asociada se emplea el término drone en el año 1940. El consenso internacional que permite definir de manera general a estos vehículos como aeronaves no tripuladas, piloteadas remotamente requiere establecer un enlace entre el mando y control y otros elementos como lo son los sensores usados para reportar el estado del vehículo [51].

Los UAV poseen 4 modos de operación relacionados con la forma teleoperada, estos son el manual, asistido, automático, autónomo. En el primer modo, el piloto maneja directamente al vehículo aéreo con el enlace de control establecido por el mando y el radiocontrol. El segundo modo es similar al primero pero con la diferencia de que el piloto no está realizando ningún tipo de interacción con el mando del vehículo, este indica las estrategias con las cuales debe maniobrar ya sea girar a la derecha, subir, etc. Para el tercer modo el piloto establece puntos de interés o waypoints y el vehículo realiza de forma automática el recorrido predefinido. Para el modo autónomo después de establecer el plan de vuelo, el vehículo realiza la ruta sin ningún tipo de in-

tervención del piloto.

La mayor parte de los UAV utilizados para propósitos de investigación y del sector civil son multirrotores, debido a la posibilidad que presentan de volar empleando bajas velocidades facilitando la adquisición de la información según la aplicación. Algunas de las principales aplicaciones son captura de imágenes en espectro visible (RGB), espectro infrarrojo (termográficas) y multiespectrales, videos y ortomosaicos para identificar el estado de cultivos, etc.

La selección del vehículo aéreo no tripulado para este trabajo, se hizo a partir de la búsqueda de los equipos empleados para inspección de plantas solares a nivel comercial e investigativo, tomando como factores relevantes la autonomía de vuelo y la compatibilidad con las cámaras termográficas seleccionadas. El UAV seleccionado es el *Matrice 100* y se describe en el capítulo 3.

Al finalizar el procedimiento destinado a la adquisición de las imágenes térmicas, inicia el algoritmo de procesamiento, incluyendo las etapas de filtrado, segmentación y clasificación, etc. Algunos de los conceptos básicos se muestran en la siguiente sección.

2.7. Procesamiento de imágenes

Las imágenes termográficas adquiridas empleadas en la inspección de fallas en paneles solares, requieren de un procesamiento que permitirá establecer los daños presentados en el módulo fotovoltaico, a partir de la clasificación de las celdas en buena, fracturada y con Hs, para emitir el diagnóstico es necesario aplicar técnicas de pre-procesamiento y segmentación sobre el objeto de interés (panel solar). A continuación se presentan los fundamentos teóricos de los métodos empleados en este trabajo.

2.7.1. Filtrado mediana

Las técnicas de filtrado en visión artificial se emplean para destacar o suprimir información de interés en las imágenes. Existen diferentes enfoques de filtrado, entre ellos el filtrado paso-bajo, paso-alto, direccionales y para detección de bordes. El filtrado mediana, se encuentra incluido en los filtros paso-bajo, usados para disminuir ruido, en esta configuración el pixel de entrada se reemplaza por la mediana de los píxeles, contenidos en una vecindad $W \times 2.2$ definida por el tamaño de una ventana [52] m, n representan el ancho y largo de la imagen en píxeles.

$$v(m, n) = \text{median} \{y(m - k, n - 1), (k, 1) \forall W\} \quad (2.2)$$

La ventaja que permite este filtrado es la remoción de líneas o píxeles aislados sin modificar la resolución espacial, en este trabajo se implementa para reducir el ruido de las imágenes IR. El pre-procesamiento de las imágenes, incluyen la etapa de filtrado, una vez termina la adecuación de la imagen, inicia el proceso de segmentación para extraer la región de interés, a continuación se definen algunos conceptos básicos de esta etapa.

2.7.2. Detector de bordes Canny

La detección de bordes permite destacar información de interés, como contornos que reflejan la geometría del escenario capturado [53]. El algoritmo para la detección de bordes de Canny puede describirse en cuatro etapas, la primera plantea el uso de un filtro gausiano para remover ruido en la imagen ec. 2.3

$$G(x, y, \sigma) = \frac{1}{2\pi\sigma} \exp\left(-\frac{x^2 + y^2}{2\sigma^2}\right) \quad (2.3)$$

la segunda, busca determinar la amplitud del gradiente, evaluada en un punto correspondiente a un pixel de la imagen que representa la intensidad del borde y su dirección ec. 2.7,

$$E_x = \frac{\partial G(x, y, \sigma)}{\partial x} \cdot f(x, y) \quad (2.4)$$

$$E_y = \frac{\partial G(x, y, \sigma)}{\partial y} \cdot f(x, y) \quad (2.5)$$

$$|\nabla g(x, y)| = \sqrt{E_x^2 + E_y^2} \quad (2.6)$$

$$\theta(x, y) = \arctan\left(\frac{E_y}{E_x}\right) \quad (2.7)$$

Finalmente se emplean umbrales para descartar los bordes de menor relevancia sobre la imagen, a partir de la estimación de las direcciones de los gradientes.

2.7.3. Segmentación

La visión artificial permite dotar a un sistema con las herramientas necesarias de decisión para desempeñar una tarea en específico, estas tareas

aunque intuitivas y de fácil ejecución para el desarrollo humano, suponen un reto complicado para las máquinas. La metodología de desarrollo requiere de *hardware* (cámaras CCD, RGB, IR, etc.) especializado que dependerá de la naturaleza del problema abordado y de algoritmos para la extracción de la información en las imágenes capturadas.

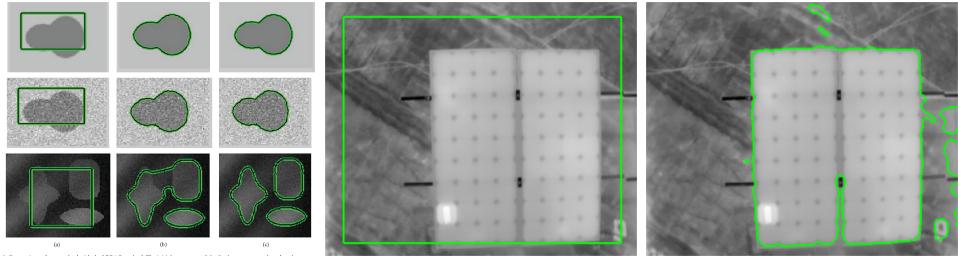
El proceso de preprocesamiento, implica etapas de filtrado y ajuste sobre las imágenes capturadas, esta etapa se hace necesaria debido a que son factibles las variaciones sobre el escenario de captura, este procedimiento busca homogeneizar la secuencia de datos analizada. Por otra parte, la definición de la región de interés es fundamental a la hora de clasificar características relevantes sobre la imagen, este procedimiento se conoce como segmentación y es en síntesis una de las tareas mas complejas en el tratamiento de imágenes. Los algoritmos de segmentación se basan en dos propiedades presentadas en los niveles de gris, estas son la discontinuidad y la similaridad. El objetivo que persigue la discontinuidad es la detección de líneas y bordes que contienen la región de interés, en el segundo enfoque la similaridad establece conexiones entre conjuntos de niveles abordando el concepto de crecimiento de regiones [54].

Para el desarrollo de este trabajo de investigación se emplean métodos basados en regiones, implementando el método de contornos activos (MCA) conocido en la literatura de procesamiento de imágenes como *Level sets* y la extracción por área, con la finalidad de delimitar la región de interés (panel) del fondo.

2.7.4. Método de contornos activos *Level sets* (MCA)

La segmentación empleando los métodos de contornos activos (MCA) ha presentado aceptación para la segmentación de imágenes médicas [55], debido a la robustez en la extracción de la región de interés para imágenes ruidosas. Existen dos enfoques en las técnicas de contornos, explícito e implícito. El algoritmo de procesamiento para los contornos implícitos, consiste en definir una región inicial en donde se encuentra contenido el objeto de interés, esta región convergerá por medio de las iteraciones hasta encontrar la segmentación adecuada. Algunas de las limitaciones presentadas radican en que el contorno no evoluciona su morfología, es decir no puede dividirse o partitionarse de tal forma que mejore la región segmentada. Por otra parte, el método usando el enfoque explícito busca la evolución de una superficie donde el contorno se encuentra definido en diferentes instantes de tiempo.

El ajuste de los modelos de contornos se encuentran inspirados en la evolución de la energía. La ec. 2.8 representa las variaciones del contorno, el término E_{int} depende de las propiedades intrínsecas de la curva, del factor



(a) segmentación LS [56]. (b) Contorno Inicial PPV-
Fuente propia. (c) Segmentación PPV-
Fuente propia.

Figura 2.13: Segmentación a partir de contornos activos ³.

de elasticidad y del factor de doblado; la energía externa E_{ext} esta relacionada con el contorno derivado de la imagen y finalmente E_{rest} corresponde a la restricción que tendrá la región inicial con respecto a la imagen [57].

$$E_{snake} = E_{int} + E_{ext} + E_{rest} \quad (2.8)$$

Por otra parte, para garantizar la adecuada convergencia del contorno se introduce el modelo del vector de flujo de gradiente en donde se busca minimizar la función de costo planteada en la ec. 2.9.

$$E = \int \int \mu (u_x^2 + u_y^2 + v_x^2 + v_y^2) + |\nabla f|^2 |V - \nabla f|^2 dx dy \quad (2.9)$$

En este trabajo se emplean métodos de contornos activos para la segmentación de paneles solares, en la fig. 2.13 (b), se define el contorno inicial de la imagen en donde se encuentra contenido el módulo fotovoltaico y en (c) se obtiene la segmentación de la región de interés, el ajuste de los parámetros se describe en el capítulo 4.

2.7.5. Transformada de Hough

La transformada de Hough se emplea para la detección de rectas, encontrando puntos alineados (x_i, y_i) que satisfacen la ec. 2.10

$$\begin{aligned} y_i &= ax_i + b \\ b &= -x_i + y_i \end{aligned} \quad (2.10)$$

para valores determinados de a y b , despejando la ec. 2.10 en coordenadas cartesianas se tiene la representación del espacio de parámetros. Para líneas

verticales hay indeterminaciones en la pendiente a , por lo cual se opta por la representación en coordenadas polares $\rho = x \cdot \cos(\theta) + y \cdot \sin(\theta)$ [58]. El procedimiento consiste en evaluar la ecuación de la recta para cada par de puntos coordinados y si existe una cantidad de votos mayor, el punto pertenece a la recta. La transformada requiere de un espacio discretizado definido en el intervalo (ρ_{min}, ρ_{max}) y $(\theta_{min}, \theta_{max})$, una vez se calculan los valores de ρ y θ para cada par de puntos y se incrementa la posición (ρ, θ) en el acumulador, se buscan las posiciones de más votos y finalmente se obtienen las rectas cuyos valores fueron mayores.

2.7.6. Transformación proyectiva

La segmentación persigue como objetivo, la extracción de regiones de interés en las imágenes, para su posterior análisis y clasificación. En este trabajo se obtienen los vértices correspondientes a las esquinas de los paneles, a partir de las intersecciones de las rectas encontradas en la imagen, con la transformada de Hough ver 2.7.5.

Una vez se obtienen los vértices, es necesario asociar un orden y una dirección, este procedimiento también se hace con las coordenadas deseadas de tal forma que cada punto encontrado se corresponda con cada punto deseado.

La transformación de proyección lleva al panel a las coordenadas deseadas, empleando las siguientes matrices.

El sistema de ecuaciones planteado para llevar las coordenadas reales $(xr_n, yr_n, 1, \dots)$ a las transformadas $(xt_n, yt_n, 1, \dots)$ es el planteado en la ec. 2.11.

$$\begin{bmatrix} xt_1 \\ yt_1 \\ 1 \end{bmatrix} = H \begin{bmatrix} xr_1 \\ yr_1 \\ 1 \end{bmatrix} \quad (2.11)$$

Expandiendo algebraicamente la ec. 2.11 se tiene:

$$\begin{aligned} xt &= H_{(1,1)} \cdot xr_1 + H_{(1,2)} \cdot yr_1 + H_{(1,3)} \cdot 1 \\ yt &= H_{(2,1)} \cdot xr_1 + H_{(2,2)} \cdot yr_1 + H_{(2,3)} \cdot 1 \\ 1 &= H_{(3,1)} \cdot xr_1 + H_{(3,2)} \cdot yr_1 + H_{(3,3)} \cdot 1 \end{aligned} \quad (2.12)$$

$$\begin{bmatrix} xt_1 \\ yt_1 \\ 1 \\ xt_2 \\ yt_2 \\ 1 \\ xt_3 \\ yt_3 \\ 1 \\ xt_4 \\ yt_4 \\ 1 \end{bmatrix} = \begin{bmatrix} H_{(1,1)} \\ H_{(1,2)} \\ H_{(1,3)} \\ H_{(2,1)} \\ H_{(2,2)} \\ H_{(2,3)} \\ H_{(3,1)} \\ H_{(3,2)} \\ H_{(3,3)} \end{bmatrix} \cdot \begin{bmatrix} xr_1 & yr_1 & 1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & xr_1 & yr_1 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & xr_1 & yr_1 & 1 \\ xr_2 & yr_2 & 1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & xr_2 & yr_2 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & xr_2 & yr_2 & 1 \\ xr_3 & yr_3 & 1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & xr_3 & yr_3 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & xr_3 & yr_3 & 1 \\ xr_4 & yr_4 & 1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & xr_4 & yr_4 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & xr_4 & yr_4 & 1 \end{bmatrix} \quad (2.13)$$

Los términos conocidos son las coordenadas reales $(xr_n, yr_n, 1, \dots)$ obtenidas a partir de los vértices encontrados del panel y las coordenadas transformadas $(xt_n, yt_n, 1, \dots)$ corresponden a las posiciones deseadas, guardando la proporción con la ocupación de la celda en el panel, la matriz de transformación H es la incógnita planteada, calculada de la ec. 2.13.

2.8. Métricas para la evaluación del desempeño en la segmentación de imágenes

Los desempeños en la segmentación se evalúan a partir de métodos subjetivos y objetivos. Los métodos subjetivos se determinan por medio de inspección visual, en este enfoque la precisión es baja y los criterios empleados pueden sesgar los resultados obtenidos. Por otra parte, los métodos objetivos permiten una comparación confiable en los algoritmos de extracción de la región de interés a partir de la definición de un *golden standard*, que representa la región que debió segmentarse por el algoritmo automático [59].

Algunos de las métricas empleadas para medición de segmentación son la Sorensen DICE e IOU.

2.8.1. Métrica Sorensen DICE

El coeficiente de similaridad DICE se usa en procesamiento de imágenes para medir el desempeño en la segmentación y se calcula a partir de la ec. 2.14, el término M corresponde a los píxeles diferentes de cero en el *ground truth* y N son los píxeles diferentes de cero en la imagen segmentada. El cálculo del coeficiente DICE proporciona un valor entre 0 y 1, siendo 1 el valor que representa que la región fue segmentada adecuadamente y cero

significa que la región segmentada no corresponde al *ground truth* [59].

$$DC = \frac{2|M \cap N|}{|M| + |N|} \quad (2.14)$$

2.8.2. Métrica IOU

El coeficiente IOU o Jaccard es una medición de similaridad entre dos conjuntos de imágenes y mide la variación entre dos imágenes se calcula a partir de la ec. 2.15, en donde M representa los píxeles diferentes de cero en el *ground truth* y N los píxeles diferentes de cero en la imagen segmentada [60]. El calculo del coeficiente IOU arroja un valor entre 0 y 1, el valor 1 o cercanos a 1 representan una adecuada segmentación como se ilustra en la fig. 2.14.

$$JC = \frac{|M \cap N|}{M \cup N} \quad (2.15)$$

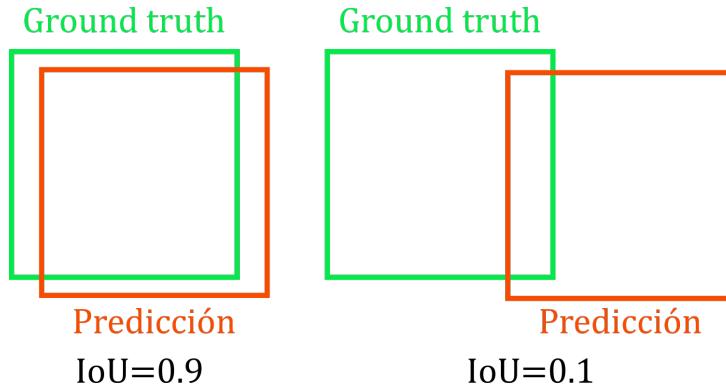


Figura 2.14: Métrica IOU [3].

2.9. Extracción de características en las imágenes

El reconocimiento de patrones dota a un sistema con la posibilidad de discernir las diferencias presentes en los objetos de interés, a partir de la extracción de características y descriptores que son el insumo para los métodos de aprendizaje supervisado y no supervisado. A continuación, se presentan las características extraídas por cada región de la celda del panel solar.

2.9.1. Características estadísticas

Los momentos estadísticos son usados en el procesamiento de imágenes como insumo para la clasificación y reconocimiento de patrones, aportando información sobre la distribución de los niveles de intensidad de gris [61], permitiendo destacar objetos de interés sobre las imágenes inspeccionadas. En la tab. 2.4, se presentan los cuatro momentos estadísticos.

Características	
Promedio	$\frac{1}{N} \sum_{i=1}^N A_i$
Varianza	$\frac{1}{N-1} \sum_{i=1}^N A_i - \mu $
Sesgo	$\frac{E(x-\mu)^3}{\sigma^3}$
Curtosis	$\frac{E(x-\mu)^4}{\sigma^4}$

Tabla 2.4: Características estadísticas.

2.9.2. Histogramas de orientación de gradientes (HOG)

Los HOG son descriptores que permiten tener una representación de la apariencia y forma de objeto de interés en la imagen, a partir de la distribución y orientación del gradiente. El concepto básico de este método se fundamenta en la división de pequeños bloques denominados celdas. En cada celda se acumula el histograma local normalizado de la región, el método HOG mejora su desempeño en cuanto a la invarianza por la iluminación y sombreado, acumulando medidas de energía en bloques espacialmente más grandes que las celdas [62].

El vector de características obtenido de la orientación de gradientes para cada subdivisión del PPV, es uno de los insumos para la clasificación de las celdas sanas y defectuosas tipo Hs y fracturadas. En la fig .2.15 se ilustra el patrón de descripción de HOG para las celdas sanas y las defectuosas.

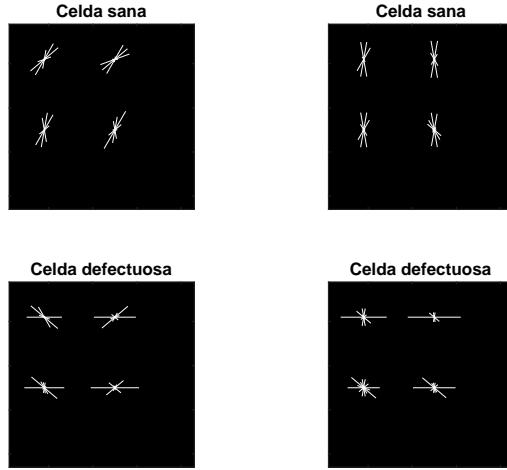


Figura 2.15: Visualización del descriptor HOG [Fuente propia].

2.9.3. Texturas de Haralick

Las texturas de Haralick son características usadas para identificar en la imagen objetos de interés a partir de: homogeneidad, contraste y niveles de intensidad de gris. La estimación de las características destacables en la imagen, se hacen a partir del cálculo de una matriz de co-ocurrencia; esta matriz es cuadrada $N_g \times N_g$ y representa la distribución espacial de intensidades de gris en la imagen. Los elementos $p(1, 1), \dots, p(1, N_g)$ se obtienen a partir de la acumulación de la cantidad de veces en que el pixel i presenta adyacencia con el pixel j [63], las formas de adyacencia se hacen en cuatro direcciones como se ilustra en la fig. 2.16. En total son 14 características de textura mencionadas en la tab. 2.5. Para el caso de estudio se obtienen por cada una de las cuatro sub-divisiones de las celdas del panel solar.

$$G = \begin{bmatrix} p(1, 1) & p(1, 2) & \dots & p(1, N_g) \\ p(2, 1) & p(2, 2) & \dots & p(2, N_g) \\ \vdots & \vdots & \ddots & \vdots \\ p(N_g, 1) & p(N_g, 2) & \dots & p(N_g, N_g) \end{bmatrix} \quad (2.16)$$

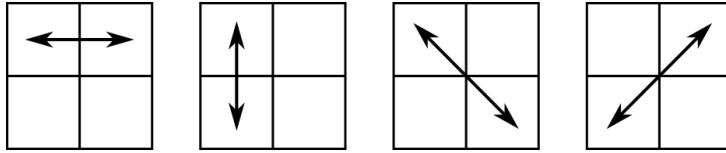


Figura 2.16: Matriz de co-ocurrencia [Fuente propia].

Características	
Segundo momento angular	$\sum_i \sum_j p(i, j)$
Contraste	$\sum_{n=0}^{N_g-1} n^2 \left\{ \sum_{i=1}^{N_g} \sum_{j=1}^{N_g} p(i, j) \right\}, i - j $
Correlación	$\frac{\sum_i \sum_j (ij)p(i, j) - \mu_x \mu_y}{\sigma_x \sigma_y}$
Varianza	$\sum_i \sum_j (i - \mu)^2 p(i, j)$
Momento de diferencia inversa	$\sum_i \sum_j \frac{1}{1+(i-j)^2} p(i, j)$
Suma promedio	$\sum_{i=2}^{2N_g} i_{px} + y(i)$
Suma de varianza	$\sum_{i=2}^{2N_g} N_g (i - f_8)^2 px + y(i)$
Suma de entropía	$- \sum_{i=2}^{2N_g} px + y(i) \log \{px + y(i)\}$
Entropía	$\sum_i \sum_j p(i, j) \log(p(i, j))$
Diferencia de varianza	$\sum_{i=0}^{N_g-1} i^2 p_{x-y}(i)$
Diferencia de entropía	$- \sum_{i=0}^{N_g-1} p_{x-y}(i) \log \{p_{x-y}(i)\}$
Medida de correlación 1	$\frac{HXY - HXY_1}{\max\{HX, HY\}}$
Medida de correlación 2	$(1 - \exp[-2(HXY_2 - HXY)])^{\frac{1}{2}}$
Máximo coeficiente de correlación	$Q(i, j) = \sum_k \frac{p(i, k)p(j, k)}{p_x(i)p_y(k)}$

Tabla 2.5: Texturas de Haralick.

2.10. Selección de características con métodos *Wrapper* y de Filtrado

La ingeniería de características permite encontrar entre un grupo de mediciones, cual o cuales corresponden a las mejores métricas para diferenciar las clases. Existen diferentes enfoques, estos son el *wrapper* y filtrado.

El *wrapper* emplea las mismas técnicas para la selección del subconjunto de características y para la clasificación, evaluando las relaciones que puedan presentarse para cada medición [64]. Por otra parte, el filtrado a diferencia del *wrapper*, usa técnicas distintas para el proceso de selección y para el clasificador sin estimar las relaciones posibles presentadas entre variables.

2.11. Métodos de clasificación no supervisada

Las técnicas de clasificación no supervisada, se basan en la formación de grupos representativos o clúster para discernir entre las posibles clases. A continuación se presentan dos técnicas usadas en este trabajo: k-medias y mezcla de gaussianas.

2.11.1. K-medias

La clusterización es uno de los métodos de clasificación no supervisada, que consiste en obtener grupos a partir la estimación de distancias euclidianas, la pertenencia de un sujeto de prueba a uno de los clúster dependerá de que tan cerca se encuentre del centroide del grupo. La descripción del algoritmo de K-medias se presenta a continuación:

1. Se inicia con una selección aleatoria de los centros de los clúster.
2. Se estiman las distancias entre cada punto y los centros de los clúster.
3. Se asignan como coordenadas del centro del clúster a los puntos cuya distancia sea mínima.
4. Se calcula de forma iterativa el nuevo centro del clúster $v_i = \frac{1}{C_i} \sum_{j=1}^{C_i} x_i$.
5. Si no se reasigna el punto, en otro caso se repite del paso 3 en adelante.

La implementación de técnicas no supervisadas también se ha utilizado para segmentación de imágenes, en [65] utilizan el método de k-medias para la detección de regiones calientes asociadas con las anomalías en paneles solares.

2.11.2. Mezcla de Gausianas

Los modelos de mezcla de gausianas (GMM) se componen de distribuciones de probabilidad multivariadas. Este enfoque, se ha usado en aplicaciones de clusterización, extracción de características, etc.

Matemáticamente una GMM se plantea como sigue a continuación:

$$p(x) = \sum_{i=1}^M w_i f(x; \mu_i, \sigma_i) \quad (2.17)$$

$$f(x; \mu_i, \sigma_i) = \frac{1}{\sqrt{2\pi}\sigma_i} e^{-\frac{(x - \mu_i)^2}{\sigma_i^2}} \quad (2.18)$$

El término M de la ec. 2.18, representa la cantidad de modelos, w_i el peso, μ_i la media, σ_i la varianza. Para el caso multivariable los términos x, μ son vectores y la varianza se representa ahora por la matriz de covarianza \sum_i [66].

La técnica GMM no solo se utiliza en clasificación, también se implementa en segmentación, en [67] proponen un método de extracción de la región de interés (ROI) en secuencias de imágenes térmicas utilizando la técnica de GMM.

2.12. Métodos de clasificación supervisada

La metodología de clasificación supervisada requiere del etiquetado (*labeling*) de las muestras del vector de características, en el caso de estudio para el diagnóstico de fallas en módulos fotovoltaicos se presenta un *labeling* para discernir entre las regiones sanas y las correspondientes a un Hs y celdas fracturadas de las imágenes adquiridas de un *string* de PPV fig. 2.17.

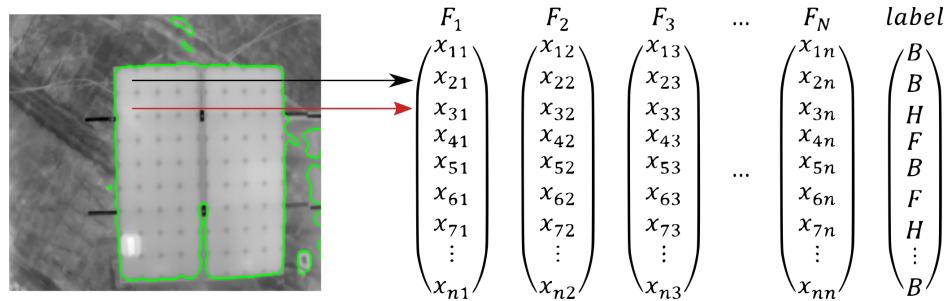


Figura 2.17: Vector de características etiquetado [Fuente propia].

En este trabajo se usan dos técnicas supervisadas para clasificar las regiones sanas y las defectuosas (fracturada y Hs) estas son: las máquinas de soporte vectorial (SVM) variando el tipo de *kernel*, sintonizando hiperparámetros y las redes neuronales artificiales (RNA) variando su topología.

2.12.1. Máquina de soporte vectorial (SVM)

Las SVM son maquinas de aprendizaje binarias, que permiten la separación entre clases de las características, a partir de la estimación de vectores de soporte que generan hiperplanos de separación entre las clases.

La superficie de decisión está dada por la ec. 2.19, $(\mathbf{x}_i, \mathbf{d}_i)$ x_i representa los patrones de entrada y d es el *target* o la respuesta de salida que puede ser 1

ó -1 , \mathbf{w} es el vector de pesos [4].

$$\mathbf{w}^T \mathbf{x} + b = 0 \quad (2.19)$$

La ec. 2.19 se puede rescribir para valores de *target* $d = 1$, como: $\mathbf{w}^T \mathbf{x}_i + b \geq 0$; y para valores de *target* $d = -1$, como: $\mathbf{w}^T \mathbf{x}_i + b < 0$.

El problema que aborda la clasificación empleando SVM se resume, en encontrar el mejor hiperplano que separa las características; para hallarlo se tienen en cuenta las siguientes consideraciones, se parte de la distancia entre el hiperplano y el dato más cercano ρ conocida como margen de separación, ver fig. 2.18 (las líneas punteadas son el hiperplano), se concibe el espacio de pesos como un problema con restricciones, luego se plantea el lagrangiano de la función ec. 2.20, se definen las condiciones de óptimalidad ec. 2.22 y finalmente se resuelve el problema de optimización para encontrar los multiplicadores de *Lagrange*.

En el ejercicio de la clasificación las SVM cuentan con diferentes funciones

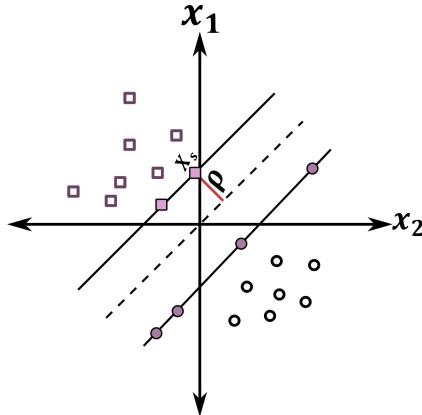


Figura 2.18: Hiperplano de separación de las características [4].

no lineales denominadas *kernel* que permiten llevar los datos a un espacio de mayor orden para ser separadas por un plano, los *kernel* se seleccionan de acuerdo al problema, si no existe información *apriori* pueden escogerse entre polinomiales, gausianas y de otras bases, en la tab. 2.6, se muestran los tipos de *kernel* con algunas observaciones.

$$J(\mathbf{w}, b, \alpha) = \frac{1}{2} \mathbf{w}^T \mathbf{w} - \sum_{i=1}^N \alpha_i [d_i (\mathbf{w}^T \mathbf{x}_i + b) - 1] \quad (2.20)$$

$$\frac{\partial J(\mathbf{w}, b, \alpha)}{\partial \mathbf{x}} = 0 \quad (2.21)$$

$$\frac{\partial J(\mathbf{w}, b, \alpha)}{\partial b} = 0 \quad (2.22)$$

Tipo de SVM	Kernel	Descripción
Polinomial	$(\mathbf{x}^T \mathbf{x}_i)^P$	P es el grado del polinomio
Función de base radial	$\exp\left(-\frac{1}{2\sigma^2} \ \mathbf{x} - \mathbf{x}_i\ ^2\right)$	Los parámetros de búsqueda corresponden a γ y c
Perceptrón de dos capas	$\tanh(\beta_0 \mathbf{x}^T \mathbf{x}_i + \beta_1)$	β_0 y β_1 son los parámetros encontrados

Tabla 2.6: Tipos de kernel de las SVM.

2.12.2. Redes Neuronales Artificiales (RNA)

Las Redes Neuronales Artificiales (RNA) son modelos bioinspirados empleados para la clasificación, el reconocimiento de patrones [5], la segmentación de imágenes [68], etc.

El elemento básico de procesamiento de una RNA es la neurona y se representa por el esquema ilustrado en la fig. 2.19, las entradas x_1, x_2, \dots, x_n tienen conexión a la neurona k y estas señales a su vez se multiplican por los pesos sinápticos ω_{kj} . El producto de las entradas con los pesos se suma con un bias b_k y finalmente son operadas con una función de activación φ que permite limitar la amplitud de salida de la neurona.

Matemáticamente el modelo de la RNA se expresa a partir de la ec. 2.24, la sumatoria del producto de los pesos ω_{kj} por las entradas x_j son u_k , en la ec. 2.24 el término b_k es el bias que permite disminuir o incrementar la función de activación dependiendo si es positiva o negativa y y_k corresponde a la señal de salida de la neurona.

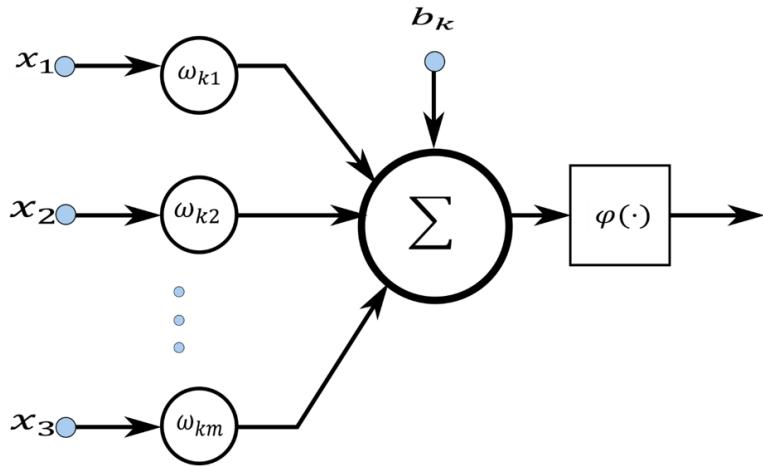


Figura 2.19: Esquema de una neurona [5].

$$u_k = \sum_{j=1}^m \omega_{kj} x_j \quad (2.23)$$

$$y_k = \phi(u_k + b_k) \quad (2.24)$$

La función de activación φ permite definir el tipo de salida de la neurona, en la tab. 2.7 se registran las funciones 2.7.

La forma en la cual se estructuran las neuronas en la red neuronal dependerá de las arquitecturas y del algoritmo usado para entrenar la red. Existen diferentes arquitecturas: redes de una sola capa, redes de múltiples de capas y redes recurrentes, de igual forma pueden presentarse variaciones en las topologías, la selección de estos parámetros dependerá de la complejidad del problema.

Función de activación	Función
Umbral	$\begin{cases} 1 & \text{if } v \leq 0 \\ 0 & \text{if } v > 0 \end{cases}$
Sigmoidal	$\begin{cases} 1 & \text{if } v \leq 0 \\ 0 & \text{if } v = 0 \\ -1 & \text{if } v > 0 \end{cases}$

Tabla 2.7: Tipos de funciones de activación.

2.13. Conclusiones

La termografía como técnica de inspección ha presentado múltiples aplicaciones para diagnóstico de defectos en materiales de fibra de carbono, películas de silicio, etc. En la actualidad se utilizan vehículos aéreos no tripulados equipados con cámaras de esta tecnología IR para expandir las áreas de estudio, esta modalidad ha presentado gran aceptación en la caracterización de anomalías para grandes campos de sistemas fotovoltaicos.

La revisión de los antecedentes nacionales e internacionales para el diagnóstico y detección de fallas en PPV muestran una línea de investigación con una clara tendencia hacia las técnicas de procesamiento de imágenes como IR, EL y PL y las técnicas eléctricas como la curva I-V. La metodología de las curvas I-V permite detectar la presencia de anomalías en los módulos fotovoltaicos a nivel de panel o de *string* a partir de la reducción del factor de relleno de la curva. La detección de la degradación se puede hacer con los módulos fotovoltaicos en operación a partir de la estimación de R_s con la técnica MPPT [69]. Las variaciones en las resistencias R_s y R_h son indicadores para la detección de fallas en los casos de estudio Hs y degradación inducida por potencial. Por otra parte, el uso de EL y PL requieren de montajes experimentales complejos, destacándose la inspección en el enfoque de ensamblaje y producción de los lingotes de silicio para las celdas solares.

Las técnicas para el diagnóstico de fallas permiten detectar la degradación en los sistemas fotovoltaicos. Sin embargo, las metodologías desarrolladas a partir de estas técnicas presentan pros y contras, por lo cual establecer combinaciones o proponer métodos híbridos permitirá obtener un diagnóstico más acertado. Si una de las técnicas no es fuerte en la detección de una anomalía es posible que la otra permita obtener un indicador. Combinar estas técnicas permitirá mejoras en los actuales sistemas propuestos para el diagnóstico de fallas al generar indicadores redundantes; es decir si dos o más técnicas arrojan un positivo hacia la detección de una falla específica se aumenta la confiabilidad en la clasificación.

El uso de la termografía presenta una solución plausible debido a que no es necesario retirar los PPV de su normal operación, permitiendo identificar fallas a partir de cambios de temperatura, algunas de las desventajas presentadas por esta técnica se encuentran en el protocolo de captura y la definición de los rangos de las variables ambientales como la irradiancia, la temperatura y la velocidad del viento, pues las mediciones se hacen sobre escenarios no controlados, en la actualidad no se encuentra unificado el protocolo de captura.

Actualmente a nivel internacional se reportan resultados de diagnóstico de fallas a partir de métodos no supervisados, presentados en la tab. 2.1 de la

sección 2.2, y únicamente el uso de métodos supervisados se proponen en [70] para la inspección de celdas usando imágenes de electroluminiscencia y no de TIR.

La revisión en el estado del arte, permitió establecer los equipos empleados en la inspección de paneles con TIR, a partir de los criterios de autonomía de vuelo del UAV de 18 a 30 min, la resolución de la cámara IR de 320×256 a 640×480 y la banda espectral de 7 a $13 \mu m$. Por otra parte, generó los insumos para definir las condiciones iniciales, del protocolo de adquisición de las imágenes aéreas termográficas desarrollado en este trabajo, determinando los rangos de los ángulos de la cámara IR entre 0 a 60° para evitar efectos de reflexión y cambios en la emisividad. La altura del UAV entre 0 a 20 m para analizar de forma global la integridad del panel. Las condiciones ambientales como la temperatura externa de 22 a $32^\circ C$, la irradiancia de 500 a 1000 W/m^2 y la velocidad del viento de 2 a 5 m/s . Finalmente, se recopilaron los procedimientos empleados para el pre-procesamiento, encontrando en común el uso de filtros paso-bajo y la definición de umbrales a partir de criterios heurísticos para diferenciar las regiones sanas de las defectuosas. Por otra parte, en las técnicas de reconocimiento de patrones la máxima precisión obtenida de clasificación reportada en la literatura corresponde al 90.3 % para la detección de fallas, sin discernir el tipo de anomalía de la cual proviene ya sean celdas fracturadas y/o Hs.

Capítulo 3

Plataforma para la adquisición y análisis de imágenes aéreas termográficas

La detección de fallas *hot spot* y celdas fracturadas en paneles solares, empleando la técnica de la termografía infrarroja (TIR), requiere de un *hardware* especializado para la inspección de anomalías. Por lo cual, la selección de los equipos se hace a partir de lo reportado en la literatura a nivel investigativo y comercial para diagnóstico en plantas solares con técnicas de visión artificial y vehículos aéreos no tripulados (UAV).

En este capítulo se detallan las características de los equipos seleccionados y el diseño experimental ilustrado en la fig. 3.1. El diagrama cuenta con 5 bloques: monitorización de las variables ambientales como temperatura, velocidad del viento (estación meteorológica *Ambient Weather*) e irradiancia (piránmetro *Apogee SP110*); ajuste de los parámetros de tensión para emular una carga resistiva (carga electrónica *B & K Precision 8514*); inicio del protocolo de vuelo que incluye el posicionamiento del UAV (Matrice 100) y los ángulos en la cámara (Zenmuse XT) para iniciar el procedimiento de captura; finalmente, se hace el procesamiento *offline* de las imágenes adquiridas en una estación en tierra.

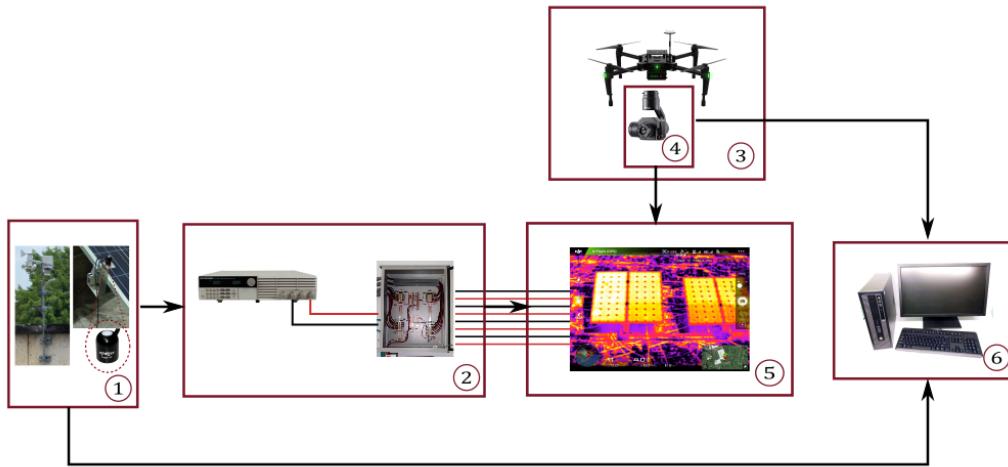


Figura 3.1: Descripción del diseño experimental [Fuente propia].

3.0.1. UAV *Matrice 100*

Los equipos utilizados en el campo investigativo y comercial, para inspección termográfica aérea en plantas solares, se resumen en la tab. 3.1; se observa una creciente preferencia por los UAV DJI debido a la robustez presentada en el control, a la precisión del GPS vertical de 0.5 m, horizontal de 2.5 m y a la compatibilidad con cámaras IR y RGB.



Figura 3.2: UAV *Matrice 100* [Fuente propia].

Artículo	UAV	Cámara IR	Cámara RGB
[14]	DJI Matrice 100	Flir Tau 2	-
[15]	DJI Matrice 100	-	Zenmuse x3
[13]	DJI-S1000	Flir Tau 2	-
[71]	PLP 610 Nimbus Plataform	Flir A35	-
[72]	Workswell WIRIS	Camera Workswell WIRIS	-

Tabla 3.1: UAV's empleados en la investigación.

El *Matrice 100* usado en este trabajo de investigación es un cuadricóptero, de dimensiones 6520 mm y peso aproximado 2.355 g, con autonomía de vuelo *full pay load* de 18 min, rango de temperatura operativo de -10 a 40 °C, controlador de vuelo N1, ver tab. 3.2.

Este UAV puede equiparse con cámaras térmicas y de espectro visible de forma separada, se opera con el programa DJI compatible en los sistemas operativos de Android ó IOS fig. 3.3, y permite conocer las variables de vuelo (altura, distancia, etc), la cantidad de satélites disponibles para obtener la posición del drone, el estado de carga de las baterías y las configuraciones necesarias para la adquisición como: el tiempo de captura de la secuencia de imágenes, la selección de cámara o video y la configuración de las paletas para la visualización.

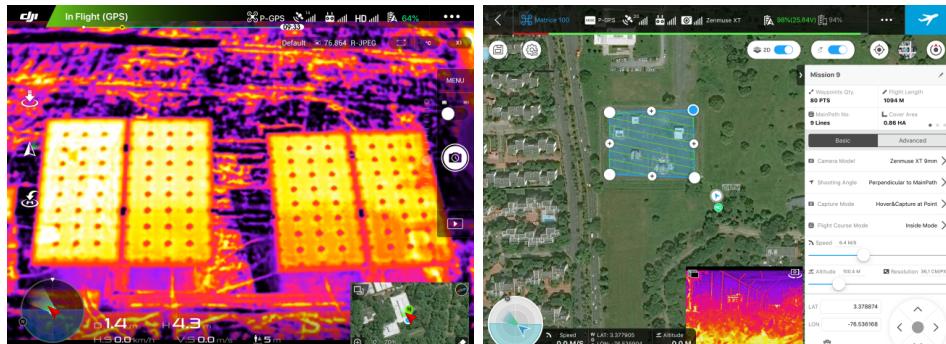


Figura 3.3: Aplicaciones UAV [Fuente propia].

Tipo	Tiempo de vuelo (min)	Max. velocidad de ascenso ($\frac{m}{s}$)	Max. velocidad de descenso ($\frac{m}{s}$)	Resistencia al viento ($\frac{m}{s}$)	Rango de Temperatura (°C)
Cuadrotor	18	5	4	10	-10 a 40

Tabla 3.2: Especificaciones UAV *Matrice 100*.

3.0.2. Cámara Zenmuse XT

La revisión de las publicaciones en la temática de diagnóstico de fallas en paneles solares ver tab. 3.3, permitió establecer las variables relevantes para la selección de las cámaras IR estas son: la resolución, la banda espectral y el peso. La resolución es importante debido a que restringe las alturas de inspección del UAV para la detección de fallas, en [73] sugieren que para alturas superiores a 30 m no es posible detectar el 24 % de las fallas. La banda espectral empleada para el diagnóstico es de onda larga es decir entre los 7 a 13 μm debido a que la absorción atmosférica es mínima, por lo cual no es adecuado seleccionar una cámara de onda corta o de onda media cercanas al espectro visible. Finalmente el peso de la cámara es importante debido a la limitante de carga con la cual se puede equipar el UAV menor a 900 g [74].

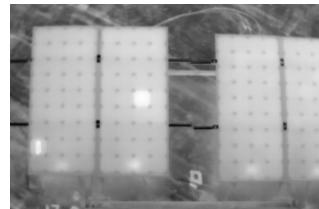
Artículo	Cámara IR	Banda Espectral (μm)	Resolución (píxeles)	Rango de temperatura operativo (°C)
[71]	<i>Flir A35</i>	7.5 a 13	320×256	-40 a 160
[75]	<i>PI 450 Optris</i>	7.5 a 13	382×288	-25 a 100
[30]	<i>Flir T620</i>	7.5 a 14	640×480	-40 a 150

Tabla 3.3: Cámaras IR empleadas en la inspección de fallas en PPV.

De acuerdo con lo obtenido en la revisión, se adquiere la cámara termográfica *Zenmuse XT* con una resolución 336×256 , banda espectral de 7 a 13 μm y un peso de 270 g, las especificaciones del equipo se resumen en la tab. 3.4. La cámara IR es compatible con los protocolos de comunicación del UAV *Matrice 100*. Los ajustes y la visualización para la captura de los videos e imágenes se hacen con la aplicación DJI GO, esta app permite modificar en tiempo real los ángulos *pitch* y *roll* de la cámara, seleccionar la paleta de colores aplicada en las imágenes, la cantidad de frames por s y el *zoom*.



(a) Cámara *Zenmuse Xt* [76]. (b) Panel solar paleta *Iron color*.



(c) Panel solar escala de gris.

Figura 3.4: Cámara *Zenmuse XT* [Fuente propia].

Resolución	Banda Espectral (μm)	Sensibilidad (mK)	Full Frame Rate (Hz)	Rango de temperatura operativo ($\frac{m}{s}$)	Ángulo controlable ($^{\circ}$)	Peso (g)	IFOV (mr)
336×256	7.5 a 13	< 50	30	10	inclinación +35 a 90; roll ± 15	270	1.889

Tabla 3.4: Especificaciones cámara termográfica *Zenmuse XT*.

3.0.3. Paneles solares

El sistema de generación solar de la escuela de Ingeniería Eléctrica y Electrónica (EIEE) de la Universidad del Valle sede Meléndez cuenta con un *string* de PPV de Si monocristalino de referencia *ERDM-85* ver tab. 3.5, cada *string* esta conformado por cuatro módulos solares en serie y se representa con el esquema contenido en 1 de la fig. 3.5.

El escenario de prueba número dos correspondiente a la empresa Celsia ®

ubicada Yumbo cuenta con 8.000 módulos fotovoltaicos de la tecnología de Si policristalino con referencia *Eagle 72 Eagle 72 JKM320PP-72* las especificaciones se detallan en la tab. 3.5.

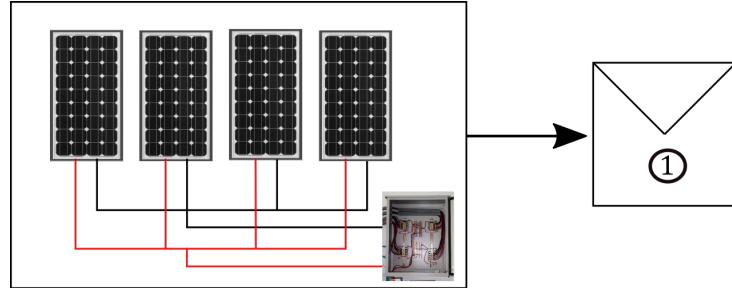


Figura 3.5: *String* de módulos solares de Si [Fuente propia].

El *string* de PPV de Si monocristalino de la EIEE no presenta conexión a una carga real ver fig. 3.6, por tal motivo se emula una carga resistiva empleando la carga electrónica *B&K precision 8514 electronic load at 12000W*, el ajuste de los parámetros de tensión se detallan en la etapa 2 del protocolo de vuelo 6.1.1.2.

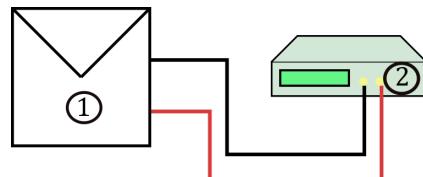


Figura 3.6: *String* paneles solares monocristalinos [Fuente propia].

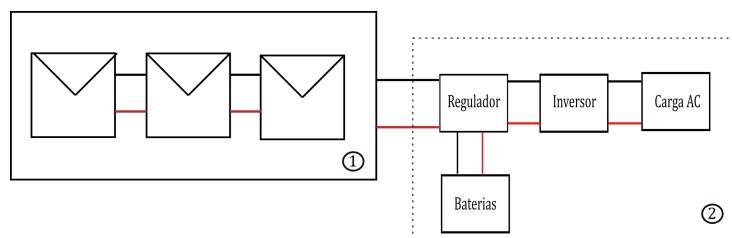


Figura 3.7: *String* paneles solares policristalinos [Fuente propia].

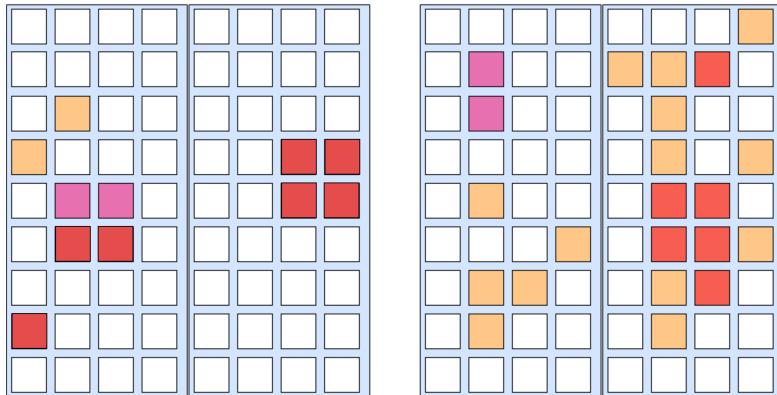
Características	ERDM-85 Monocristalino	Eagle 72 JKM320PP-72 Policristalino
Voltaje en circuito abierto (V)	21.78	43.2
Voltaje de operación óptimo (V)	17.95	17.95
Corriente de cortocircuito (A)	5.13	7.29
Potencia máxima (W)	85	235
Eficiencia %	13	16.23

Tabla 3.5: Tecnología de paneles solares inspeccionada en los dos escenarios de prueba.

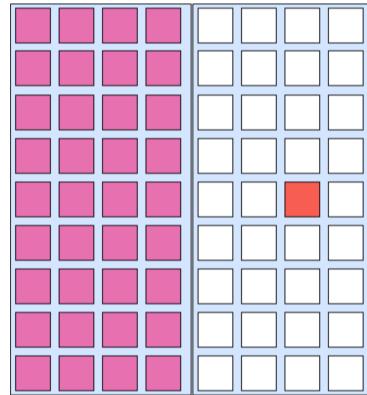
El CDIT de imágenes aéreas de los módulos solares, se adquirió con el sistema descrito; los PPV presentaban una notable degradación, identificándose como fallas principales las siguientes:

- Decoloración del recubrimiento polimérico EVA.
- Regiones de fractura (en magenta ver fig. 3.8).
- Fracturas incipientes denominadas en inglés como *snails trails* (en naranja ver fig. 3.8).
- Puntos calientes o *hot spot* (en rojo ver fig. 3.8).

Las fallas *hot spot* y celdas fracturadas se presentan en los módulos de Si monocristalino inspeccionados en la EIEE. El etiquetado de las celdas con defectos se ilustran en la fig. 3.8, los *hot spot* en rojo, las celdas fracturadas en magenta y las celdas sanas en blanco. En este trabajo solo se caracterizan dos de las fallas mencionadas anteriormente ver fig. 3.8.



(a) fallas *snail trails* en naranja, *hot spot* en rojo, fracturada en naranja y celdas sanas en blanco.



(b) fallas *snail trails* en naranja, *hot spot* en rojo, fracturada en naranja y celdas sanas en blanco.

Figura 3.8: Etiquetado de las fallas presentes [Fuente propia].

3.0.4. Carga electrónica

Las especificaciones de la carga electrónica *B&K Precision 8514 electronic load* fig. 3.9, se muestran en la tab. 3.6, este dispositivo puede operarse a partir de la definición de un voltaje, corriente ó potencia, permitiendo la función de extractor de curvas I-V.

3.0.5. Estación meteorológica

La estación meteorológica *Ambient Weather WS-2095* utilizada se instaló en la terraza del edificio 353 de la EIEE, a dos metros de la ubicación de los

Resolución ($\frac{mV}{mA}$)	Voltaje mínimo operativo (V)	Rango de voltaje(V)
$\frac{1}{0.1}$	0.1	0-120

Tabla 3.6: Especificaciones carga electrónica.



Figura 3.9: Especificaciones carga electrónica [6].

paneles solares a inspeccionar, cuenta con un termo-higrometro, pluviómetro, vela y sensor de velocidad de viento, el protocolo de comunicación se hace a partir de radio frecuencia (RF) con un módulo portable. La estación cuenta con una aplicación propia para visualización de los históricos de las mediciones ambientales ver fig. 3.10. Las especificaciones se presentan en la tab. 3.7.

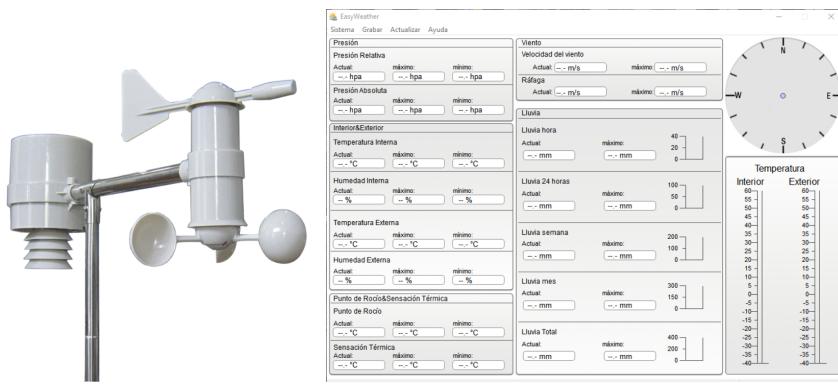


Figura 3.10: Estación meteorológica *Ambient Weather WS* [Fuente propia].

3.0.6. Piranómetro *Apogee SP110*

El piranómetro utilizado *Apogee SP110*, se ubicó en los soportes de los paneles solares de Si policristalino de tal forma que la radiación incidente se

Medición	Rango	Precisión	Resolución
Temperatura externa ($^{\circ}C$)	-23.3 a 65	± 1.1	± 0.06
Temperatura interna ($^{\circ}C$)	0 a 60	± 1.1	± 0.06
Dirección del viento ($^{\circ}$)	0 a 360	22.5	22.5
Velocidad del viento (mph)	0 a 112	2.2	0.1

Tabla 3.7: Especificaciones estación meteorológica.

encontrara en el rango de visión del sensor, las especificaciones se detallan en la tab. 3.8.

Rango espectral (nm)	Sensibilidad ($\frac{mVW}{m^2}$)	Campo de visión($^{\circ}$)	Operación ambiental ($^{\circ}C$)
— 330 a 1120	0.2	180	-40 a 70

Tabla 3.8: Especificaciones carga electrónica.

3.0.7. Arquitectura computacional

Las imágenes termográficas son procesadas después de la adquisición, es decir fuera de linea, en una estación en tierra. Los algoritmos propuestos se ejecutan en dos computadores, uno de escritorio y un clúster de procesamiento, las especificaciones se describen en la tab. 3.9. El computador de escritorio se empleó para los algoritmos de segmentación y extracción de características, el clúster para la búsqueda de hiperparámetros de las máquinas de soporte vectorial y los procedimientos de ingeniería de características.

Computador	Memoria RAM (GB)	Disco duro (TB)	Tarjetas gráficas	Cantidad de núcleos
Clúster	48	1	2	6Nvidia Geforce 1080 ti
Elitedesk	0.008	1	-	-

Tabla 3.9: Especificaciones computador y clúster.

3.1. Conclusiones

La inspección de fallas en paneles solares a partir de la técnica de la termografía infrarroja requiere de equipos especializados. De acuerdo con lo reportado se destacan los siguientes factores para la selección del UAV: la autonomía de vuelo 18 a 30 min, la temperatura de operación y la máxima carga con la cual se puede equipar < 900 g. El drone que cumplía con esos requerimientos es el *Matrice 100*. En el caso de la cámara son importantes: la resolución 320×256 a 640×480 y el rango espectral 7 a 13 μm , de acuerdo con estas características se adquiere la *Zenmuse XT*.

La plataforma experimental para la inspección de fallas quedó conformada por: el UAV *Matrice 100*, la cámara *Zenmuse Xt* y un computador Elite desk para la estación en tierra. El objeto de estudio principal fue un *string* de cuatro PPV en serie de Si monocristalino *ERDM-85* con evidentes síntomas de deterioro y las fallas estudiadas. Los paneles de silicio monocristalino no suministraban requerimientos eléctricos a una carga, por lo cual se seleccionó una carga electrónica *B & K Precision 8514 electronic load* emulando un elemento resistivo. La monitorización de la temperatura externa y la velocidad del viento se hizo con la estación meteorológica *Ambient Weather* a 2 m de los paneles, y se usó el piránmetro *Apogee SP110* para adquirir la irradiancia durante el tiempo de las capturas de las imágenes IR.

El escenario de Celsia ®, contaba con paneles de la tecnología de silicio policristalino *Eagle 72 JKM320PP-72*. La planta solar instalada en Yumbo hace parte del sistema interconectado nacional (SIN), cuenta con conexión a la carga y suple las necesidades eléctricas de la planta Postobon ®. Finalmente, las mediciones de las variables ambientales se obtienen del sistema SCADA de Celsia ®.

Capítulo **4**

Método para detección y diagnóstico de fallas *hot spot* y celdas fracturadas en paneles solares usando imágenes termográficas aéreas

En este capítulo se presenta el método para detección y diagnóstico de fallas *hot spot* y celdas fracturadas en paneles solares, a partir de imágenes termográficas aéreas (MDF) estructurado en cinco fases como se ilustra en la fig. 4.1. Estas fases son: la adquisición de las imágenes, el pre-procesamiento y segmentación, las trasformaciones, la extracción de características para la clasificación del estado de las celdas y finalmente una escala de severidad.

La fase de adquisición de las imágenes cuenta con cuatro etapas, estas son: la definición de las condiciones iniciales para la captura de las IIR que presentan como restricción no hacer la inspección en días lluviosos. La condición de operación del PPV con el objetivo de verificar que los PPV inspeccionados presenten conexión a la carga. La medición de variables ambientales como velocidad del viento > 3 (m/s) e irradiancia > 500 w/m^2 a partir de los rangos definidos en la literatura para la inspección con TIR [11] [78]. Finalmente, se estima la altura del UAV con la ecuación propuesta en la sección 4.0.1.4 y se ajusta el angulo de la cámara en $\sim 45^\circ$ debido a que entre 0 a 60° la emisividad y reflexión permanecen constantes [79]. La fase de pre-procesamiento emplea bloques de filtrado para la reducción del ruido de los termogramas y obtener la región de interés. La fase de transformaciones que permite llevar el panel a una morfología rectangular deseada a partir de transformaciones de proyección con los vértices encontrados por los algoritmos de segmentación. La fase de extracción de características en donde se obtienen los cuatro mo-

mentos estadísticos, las texturas de Haralick y los histogramas de gradiente HOG para iniciar el proceso de clasificación empleando métodos supervisados como SVM y RNA y no supervisados como k-medias y mezcla de gausianas. Finalmente se define una escala de severidad con tres niveles alerta, severo y crítico, además se sugieren temporalidades y recomendaciones para la intervención del PPV.

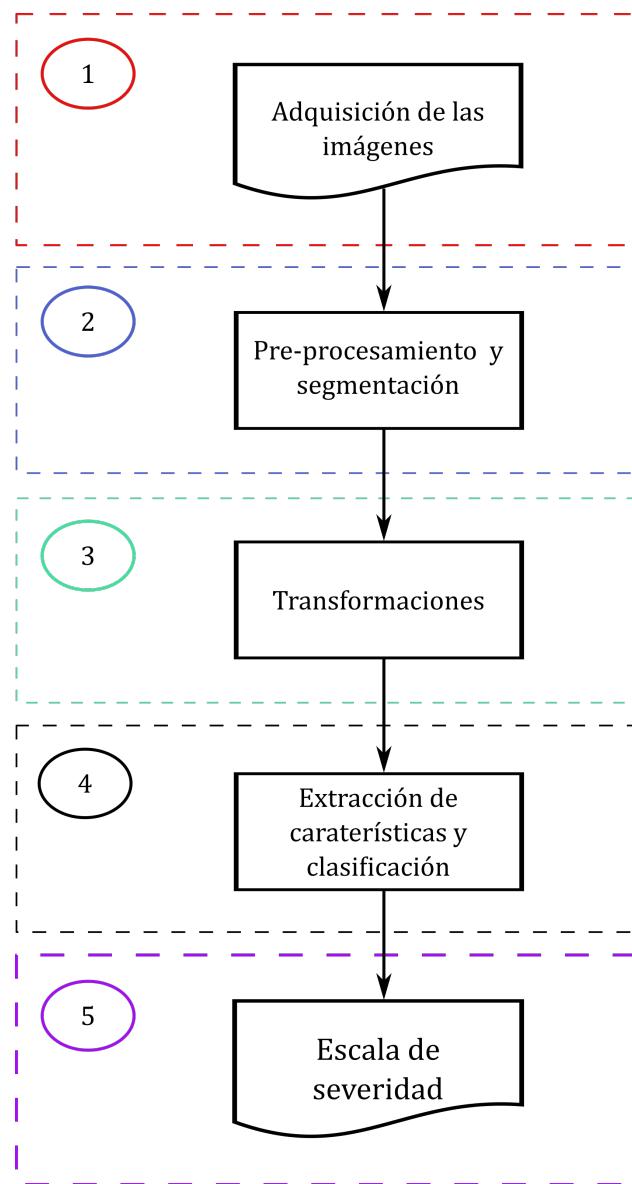


Figura 4.1: Método propuesto para la detección de fallas en PPV.

4.0.1. Fase 1: Adquisición de imágenes

El protocolo de adquisición de las imágenes desarrollado para el estudio de las fallas Hs y celdas fracturadas se compone de cuatro etapas, estas son: la verificación de cumplimiento de las condiciones ambientales, las condiciones de operación del generador fotovoltaico, la medición de las variables medioambientales y el protocolo de vuelo como se ilustra en la fig. 4.2.

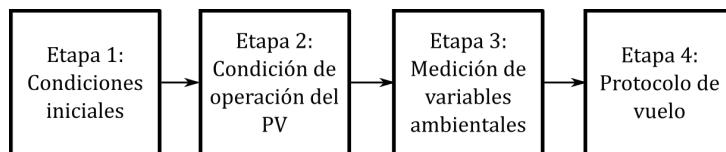


Figura 4.2: Protocolo de adquisición de las imágenes.

A continuación se presentan las etapas que conforman el protocolo de adquisición de las imágenes:

4.0.1.1. Etapa 1: verificación de cumplimiento de las condiciones medioambientales

Las condiciones ambientales permiten definir la viabilidad en el proceso de medición, restringiendo la captura de los termogramas. Es necesario realizar la adquisición de las imágenes en días soleados (sin lluvia ni nubosidad aparente), debido a que la lluvia es una de las restricciones de vuelo del UAV, y a que la nubosidad disminuye los niveles de irradiación en los paneles solares llegando a valores por debajo de 500 W/m^2 (mínimo valor establecido en experimentos similares) [80]. Otro aspecto clave del protocolo de adquisición es el intervalo de tiempo, para el caso de Cali-Colombia se recomienda capturas entre las 10:00-11:30 am y de 1:00-2:00 pm, debido a que en dicho intervalo se presenta un pico de máximo nivel de irradiancia $\sim 800\text{ W/m}^2$. El horario de 12:00 m a 1:00 pm se excluye, debido a que en esta franja horaria la ubicación del UAV proyecta sombras sobre los paneles solares que afectan las imágenes térmicas.

4.0.1.2. Etapa 2: verificación de condición de operación del generador fotovoltaico

Se verifica que el generador fotovoltaico esté entregando al menos el 50 % de su capacidad en Watts a la carga, idealmente del 80 % en adelante [81].

4.0.1.3. Etapa 3: medición de las variables medioambientales

Se verifica que la velocidad de viento se encuentre en rangos que garanticen la seguridad del UAV $< 5 \text{ m/s}$ y que favorezca una precisión aceptable en la temperatura de operación requerida por los sensores de la cámara térmica en este tipo de experimentos. Igualmente es necesario verificar que la medición de irradiancia, se encuentre en el rango establecido $> 500 \text{ W/m}^2$.

4.0.1.4. Etapa 4: protocolo de vuelo

Se posiciona el UAV en un rango de distancia respecto a los paneles estimada, a partir de las ecuaciones desarrolladas ec. 4.2, 4.11, 4.12 y se fija un ángulo en la cámara de $\sim 45^\circ$ para evitar problemas de reflexión y emisividad que pueden generar en las imágenes, falsos niveles de intensidad ocasionando un diagnóstico inadecuado. En la tab. 4.1 se recopilan algunos de los artículos de detección de fallas usando la TIR y las alturas respectivas a las que se hace la captura de las imágenes. En [82],[71], permiten hacer una inspección global en las huertas solares, pero difícilmente un análisis en la localidad de las celdas esto debido a la perdida de resolución por la altura de las capturas.

Artículo	Tipo de falla	Altura(m)	Cámara IR	Resolución (pixels)
[82]	-	20-40	<i>Tau2-typee</i>	640×512
[71]	<i>Snail trails</i> <i>Snail trails</i>	0-5 10-20	<i>Nikon 1-V1 (RGB)</i>	3206×2606
[83]	<i>Hot spot</i>	Adquisición en tierra	<i>Flir C2</i>	80×60

Tabla 4.1: Alturas de vuelo reportadas en la literatura.

La altura del UAV y el ángulo de la cámara definidas en el protocolo se estiman a partir de las siguientes ecuaciones desarrolladas.

La fig. 4.3, ilustra el escenario de experimentación para la adquisición de las imágenes IR, el objeto azul con inclinación α corresponde al panel solar y el vehículo aéreo no tripulado se encuentra posicionado a una altura H , con un ángulo de 45° definido en la cámara.

Tomando la consideración del ángulo permitido en la fig. 4.3 se plantea la ec. 4.2 para calcular la altura y despejando H de ec. 4.2 se obtiene:

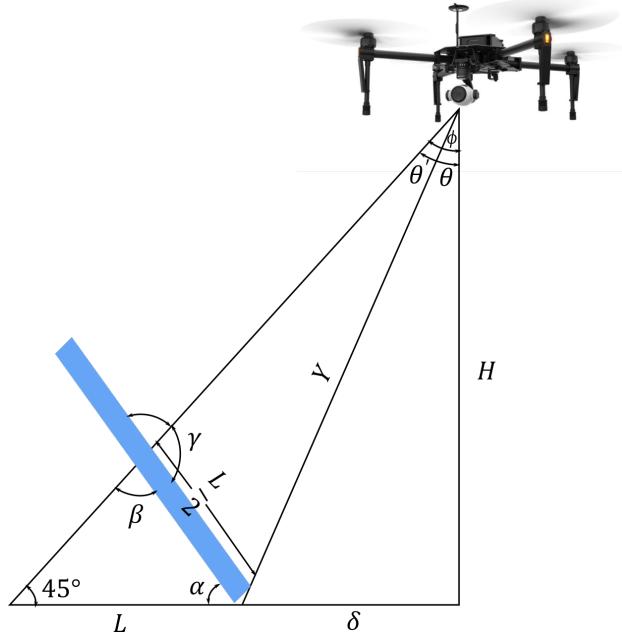


Figura 4.3: Estimación del ángulo y altura para adquisición de imágenes [Fuente propia].

$$\begin{aligned}\tan(\theta) &= \frac{\delta}{H} \\ H &= \frac{\delta}{\tan(\theta)}\end{aligned}\tag{4.1}$$

Se plantean un par de ecuaciones por consideraciones geométricas de ángulos alternos internos, a partir del triángulo generado por los soportes de los paneles y el suelo para encontrar el valor del ángulo auxiliar β que permitirá conocer el valor de θ , como se muestra a continuación.

$$2\gamma = 360^\circ - 2\beta\tag{4.2}$$

$$\gamma = 180^\circ - \beta\tag{4.3}$$

$$\beta = 180^\circ - 45^\circ - \alpha\tag{4.4}$$

Empleando la ley del seno de los dos triángulos se tiene la siguiente ec. 4.5.

$$\frac{\frac{L}{2}}{\sin(\theta')} = \frac{Y}{\sin(\gamma)}\tag{4.5}$$

Despejando la ec. 4.5 en términos de θ' se tiene:

$$\sin(\theta') = \sin(\gamma) \left(\frac{L}{2Y} \right) \quad (4.6)$$

$$\theta' = \sin^{-1} \left(\sin(\gamma) \left(\frac{L}{2Y} \right) \right) \quad (4.7)$$

$$\theta = 45^\circ - \theta' \quad (4.8)$$

Reemplazando la ec. 4.8 en la ec. 4.2 se tiene

$$H = \frac{\delta}{\tan(45^\circ - \theta')} \quad (4.9)$$

$$H = \frac{\delta}{\tan(45^\circ - \sin^{-1} [\sin(\gamma) \cdot \frac{L}{2Y}])} \quad (4.10)$$

$$Y = \sqrt{H^2 + \delta^2} \quad (4.11)$$

Finalmente se obtiene la ec. 4.12 de la altura del UAV en términos del ángulo de 45° .

$$H - \frac{\delta}{\tan(45^\circ - \sin^{-1} [\sin(\gamma \cdot (\frac{L}{2\sqrt{H^2 + \delta^2}}))])} = 0 \quad (4.12)$$

Donde δ es la distancia entre el soporte del panel y un punto predefinido; H es la altura de vuelo en m ; L es la longitud del panel en m y α, β, γ son ángulos auxiliares en $^\circ$.

La ec. 4.12 es implícita en la variable H y por lo tanto debe resolverse utilizando métodos numéricos.

4.0.2. Fase 2: Pre-procesamiento y segmentación

El pre-procesamiento de las IIR adquiridas, inicia con un bloque de filtrado que busca reducir el ruido presente en el termograma, seguido de este procedimiento inicia la extracción de la región de interés para remover el fondo de la imagen y analizar el módulo fotovoltaico. En este trabajo se proponen dos formas para la segmentación de los PPV, a partir de estos enfoques se obtienen los bordes de los paneles solares ver sección 2.7.

4.0.3. Fase 3: Procesamiento de las imágenes

Se emplean transformaciones para encontrar las rectas principales en la imagen y hallar los vértices a partir de las intersecciones. Los vértices encontrados son usados para llevar al panel a una morfología deseada, para esto se

asignan direcciones en un plano x-y, el origen del plano propuesto corresponde al punto medio de los puntos encontrados y se diferencia del plano usado habitualmente en el procesamiento de imágenes cuyo origen esta definido en la esquina superior izquierda.

4.0.4. Fase 4: Extracción de características

Cada una de las celdas del módulo fotovoltaico se analiza para el diagnóstico de su estado entre: buena, fracturada o con *hot spot*, para esto se obtienen características estadísticas, de textura de Haralick y descriptores de gradiente.

Debido a que el conjunto de imágenes termográficas se encuentra desbalanceado por la presencia de una mayor cantidad de celdas sanas que con fallas, se propone subdividir cada celda en cuatro regiones como se ilustra en la fig. 4.4.

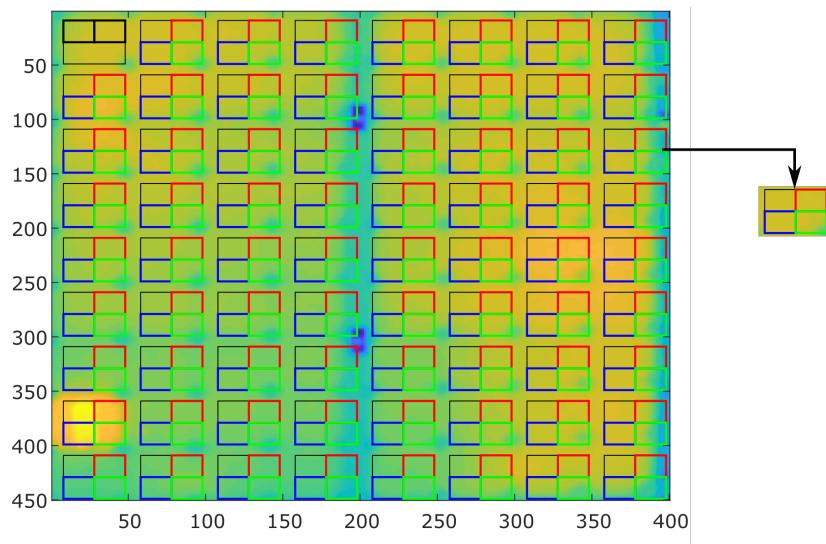


Figura 4.4: Extracción de celdas para características [Fuente propia].

Las características extraídas por cada imagen son: los momentos estadísticos, las texturas de Haralick y los vectores de descriptores de gradiente HOG consignadas en la tab .4.2.

Características	Sub-características	Etiquetado
Estadísticas	Promedio	C1
	Desviación estándar	C2
	Skewness	C3
	Curtosis	C4
	Entropía	C5
Textura	Energía	C6
	14 Características de Haralick	T7
<i>HOG features</i>	36 Orientación de gradientes	HOG8

Tabla 4.2: Características extraídas por celda.

4.0.5. Fase 5: Asignación de severidad

Finalmente con los resultados de clasificación se proponen tres niveles: alerta, severo y crítico, sugiriendo temporalidades para la intervención y algunas observaciones para monitorear las condiciones del PPV. Este diagnóstico se hace únicamente con los indicadores de las fallas extraídos de la termografía infrarroja (TIR).

Nivel de problema	Cantidad de celdas con fallas	Tiempo de intervención en meses	observaciones
Alerta	$5\% < \text{Alerta} \leq 20\%$	3	Monitorear y verificar condiciones del panel hasta la próxima revisión programada
Severo	$21\% < \text{Severo} \leq 50\%$	1	Se sugiere la revisión antes del mantenimiento programado
Crítico	$> 51\%$	0.25	Debe repararse inmediatamente, se aconseja remover el panel del <i>string</i>

Tabla 4.3: Escala de severidad para intervención de módulos fotovoltaicos.

4.1. Conclusiones

Las metodologías de procesamiento de imágenes, reportadas en la literatura para diagnóstico de fallas empleando termografía área, presentan un enfoque de análisis global del módulo fotovoltaico, es decir se analiza la totalidad del panel [21],[13] y [16]. En este trabajo se plantea un método para

la detección de anomalías a nivel de celdas del PPV.

El método para inspección de fallas Hs y celdas fracturadas, se estableció a partir de las siguientes fases: procedimiento de adquisición con sus etapas definiendo los rangos de las variables ambientales como sigue irradiancia $> 500 \text{ w/m}^2$, velocidad del viento $< 5 \text{ m/s}$, la altura de vuelo fue estimada a partir de una ecuación propuesta en la sección 4.0.1.4 y el ángulo de la cámara entre 40 y 60 ° de tal forma que la composición de la imagen en cuanto a la emisividad y reflexión se mantuviera constante; pre-procesamiento, segmentación; transformaciones, filtrado; finalmente, la escala de severidad con tres niveles alerta, severo y crítico con observaciones y sugerencias de temporalidades para la revisión de los PPV.

Una vez fueron adquiridas las imágenes se implementó un algoritmo de procesamiento, con etapas de segmentación proponiendo como métodos el MCA contornos activos y el enfoque por filtrado de área y transformaciones de proyección para obtener una morfología rectangular que facilitara el análisis por celdas. Posteriormente se inició el proceso de extracción de características y cada celda se subdividió en cuatro regiones, y por región se obtienen los 4 primeros momentos estadísticos, las 14 texturas de Haralick y 36 descriptores de gradientes, los vectores de características obtenidos fueron el insumo para la clasificación del estado de las celdas en sana, fracturada y Hs con métodos supervisados y no supervisados.

Capítulo 5

Pruebas y resultados

En este capítulo se presenta una descripción del conjunto de imágenes termográficas aéreas (CDIT) para la inspección de paneles, la definición de pruebas, objetivos que delimitan los alcances y los resultados obtenidos de la comparación de las métricas para cada procedimiento propuesto.

5.1. Descripción del conjunto de imágenes termográficas aéreas

El CDIT cuenta con un total de 411 imágenes termográficas, la adquisición de los termogramas se espació en días e incluso en meses, cada medida cuenta con un reporte de irradiancia, temperatura ambiente y la velocidad del viento. En la tab. 5.1 se reportan la cantidad de imágenes adquiridas y las mediciones adicionales. Las pruebas del 27 y 28 de abril, 4 de mayo, 9 de julio, 20 y 21 de diciembre del 2018, 16 y 19 de enero de 2019, se capturaron en la terraza de la EIEE.

Las pruebas del 30 de noviembre del 2018 y el 25 de enero del 2019 se capturaron en la planta solar de Celsia ®Yumbo. El diagnóstico de las fallas se hace sobre una población representativa de la granja solar, inspeccionado en total 5 de mesas, cada mesa se compone de 60 paneles conectados en serie. El CDIT se encuentran organizado en carpetas, cuyo nombre corresponde a la fecha de captura, dentro la carpeta principal hay tres sub-carpetas, la primera de ellas corresponde a las imágenes de los paneles de la derecha e izquierda (carpetas *Panels_left*, *Panels_right*), la segunda a las mediciones de irradiancia *Irradiance_Hour* guardadas en archivo .mat y finalmente la velocidad del viento y la temperatura externa *Temperature_WindSpeed* en un archivo .xls.

Fecha adquisición	Número de imágenes	Variables ambientales	Altura (m)	Ángulo(°)	Referencia de imágenes
27-Abril-2018	13	Irradiancia Temperatura Velocidad del viento	2.3 a 2.7	40 a 60	27-Abril-2018
28-Abril-2018	13	Irradiancia Temperatura Velocidad del viento	2.3 a 2.7	40 a 60	28-Abril-2018
04-Mayo-2018	29	Irradiancia Temperatura Velocidad del viento	2.3 a 2.7	40 a 60	04-Mayo-2018
30-Noviembre-2018 prueba Celsia	100	Temperatura Velocidad del viento Irradiancia	4.6 a 5	40 a 50	30-Noviembre-2018
20-Diciembre-2018	26	Temperatura Velocidad del viento	2.3 a 2.7	40 a 60	20-Diciembre-2018
21-Diciembre-2018	30	Irradiancia Temperatura Velocidad del viento	2.3 a 2.7	40 a 60	21-Diciembre-2018
16-Enero-2019	40	Irradiancia Temperatura Velocidad del viento	2.3 a 2.7	40 a 60	16-Enero-2019
19-Enero-2019	60	Irradiancia Temperatura Velocidad del viento	2.3 a 2.7	40 a 60	16-Enero-2019
25-Enero-2019 Prueba Celsia	100	Temperatura Irradiancia Velocidad del viento	4.6 a 5	40 a 50	25-Enero-2019

Tabla 5.1: CDIT.

5.2. Prueba 1: Métricas DICE, IOU para medir la segmentación

5.2.1. Finalidad

Evaluar los algoritmos propuestos para la extracción de la región de interés con las métricas DICE e IOU.

5.2.2. Descripción

Se selecciona una muestra representativa de imágenes por carpeta y se construye el *ground truth* para comparar las técnicas de segmentación propuestas con las métricas *DICE* e *IOU*.

5.2.3. Resultados

La extracción de la región de interés (paneles solares) en las imágenes termográficas aéreas, se abordó a partir de dos métodos, ambas propuestas fueron evaluadas con las métricas Sorensen DICE e IOU. Para esto se tomaron muestras representativas por carpeta y se reportaron en la tab. 5.2 los valores promedio.

En la fig. 5.1(a), se observa que el método FA tiene una menor dispersión en los datos centrándose al rededor de 0.98 y con *outliers* en 0.94, estos valores son cercanos a 1 representando una adecuada segmentación de los paneles. Por otra parte, el método MCA LS tiene puntos en cero que implican que en algunas de las imágenes los PV no fueron segmentados. Para analizar las diferencias estadísticas entre los dos métodos de segmentación propuestos, se emplea la prueba Kruskalwallis que parte de la hipótesis nula de que los datos provienen de una misma población, esta hipótesis es rechazada y se obtienen diferencias significativas entre los métodos de segmentación destacando el desempeño del FA sobre el MCA LS ver fig. 5.1(b).

Los resultados de la métrica IOU para las imágenes analizadas ver fig. 5.2(a), corroboran que el método FA tiene menor dispersión de los datos alcanzando una mejor aproximación al *ground truth* que el MCA LS. La hipótesis nula del test Kruskalwallis es nuevamente rechazada como se ilustra en la fig. 5.2(b) destacando el desempeño del FA.

Carpeta	Método de segmentación	DICE	IOU
18-abr-18	MCA (LS)	0,8378	0,7773
	FA	0,9795	0,9599
28-abr-18	MCA (LS)	0,9717	0,9449
	FA	0,9811	0,9630
4-may-18	MCA (LS)	0,9759	0,9531
	FA	0,9774	0,9558
20-dic-18	MCA (LS)	0,7549	0,7156
	FA	0,9624	0,9281

Tabla 5.2: Valores promedio de los coeficiente DICE e IOU por carpeta de imágenes.

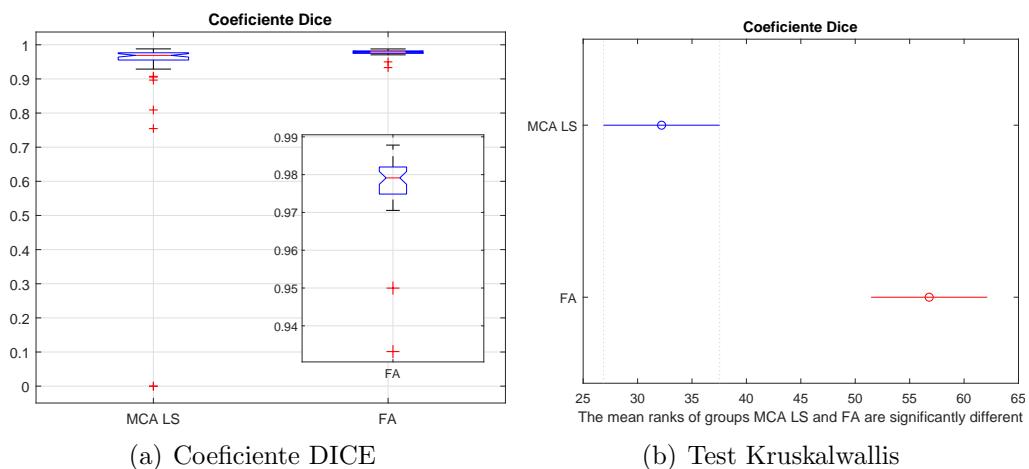


Figura 5.1: Comparación estadística de los métodos de segmentación a partir de DICE.

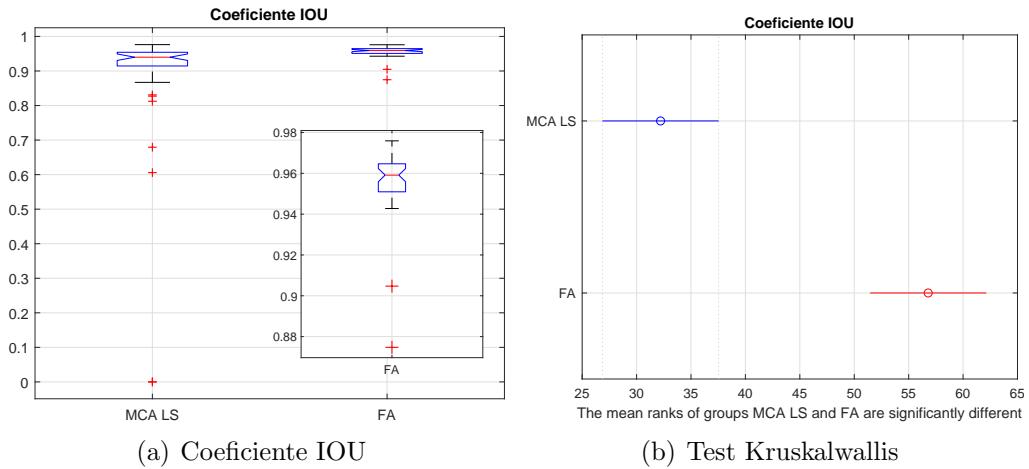


Figura 5.2: Comparación estadística de los métodos de segmentación a partir de IOU.

5.3. Prueba 2: Clasificación de celdas buenas *hot spot* y celda fracturada a partir de métodos supervisados

5.3.1. Finalidad

Clasificación del estado de las celdas en B,F y Hs a partir de métodos supervisados con SVM y RNA.

5.3.2. Descripción

La clasificación del estado de las celdas en B, F y Hs se abordó a partir de SVM y RNA. Para la SVM se emplearon los siguientes tipos de *kernel*: RBF por defecto, RBF sintonizado y polinómicos de grado 3,4 y 6. En cada una de las arquitecturas se hicieron experimentos biclase (B-Hs,B-F,Hs-F) y para las tres clases (Hs-B-F) se planteó el método *one vs all* con los *kernel* RBF por defecto y sintonizado. El *kernel* RBF fue sintonizado a partir de la búsqueda de hiperparámetros asignando vectores a *c* y γ .

Las características que se ingresaron a cada uno de los bloques clasificadores fueron: las combinatorias entre los cuatro momentos estadísticos y los dos de texturas, las 14 de Haralick y los 36 HOG de forma independiente entrenando con el 60 % de los datos y validando con el 40 %, por lo cual cada bloque clasificador biclase (B-F,B-Hs y Hs-F) presentaba en total tres experimentos

por cada tipo de *kernel*.

Una vez finaliza la prueba con la SVM se emplea una RNA variando sus topologías, neuronas en la capa oculta entre 6, 8 y 10, la función de entrenamiento entre gradiente conjugado escalado y *Resilient BackPropagation* y la función de desempeño en error cuadrático medio y *crossentropy*.

5.3.3. Resultados

En la tab. 5.3 se resumen las características con los mejores resultados de precisión en la clasificación. La columna PH representa los valores de precisión, obtenidos a partir de la sintonización de hiperparámetros y la columna PD corresponde a los valores de precisión por defecto en el *kernel* RBF. En la tab .5.3 se consignan los resultados de precisión para los experimentos biclase y tres clases al tiempo empleando una SVM con *kernel* RBF por defecto (RBF-D) y la RBF sintonizada. Para las clases B-H se obtiene una precisión de 82.02 % con los HOG como características, para un valor de $c = 10$ y $\gamma = 10$ mejorando los resultados obtenidos con los parámetros por defecto en un 32 %. Las combinaciones de características estadísticas y las dos de textura con mejor desempeño para las celdas B-Hs son C2-C5 alcanzando una precisión de 76.21 % en los datos de *test* mejorando el desempeño en 24 % del RBF por defecto. Las clases B-F son clasificadas con una precisión del 77.02 % con los HOG, mejorando el desempeño en un 11 % de los resultados obtenidos con RBF-D. Por otra parte, la combinación de las características estadísticas que mejor permiten diferenciar las B-F corresponde a C2-C3 con un desempeño del 70.07 % presentando una mejora del 9 % con la precisión obtenida en la RBF-D. Las clases F-Hs son clasificadas con una precisión del 97.43 % con las características C2-C3, mejorando en un 15 % los resultados de RBF-D. Finalmente en el experimento *one vs all* se obtiene una precisión del 64.08 % con las características C3-C4 mejorando en 32 % al RBF-D. En la fig. 5.3 se presentan las mejores superficies de precisión para cada experimento biclase, los puntos en rojo representan los valores c y γ asociados a la mejor clasificación.

5.3.3.1. Método 1 SVM:

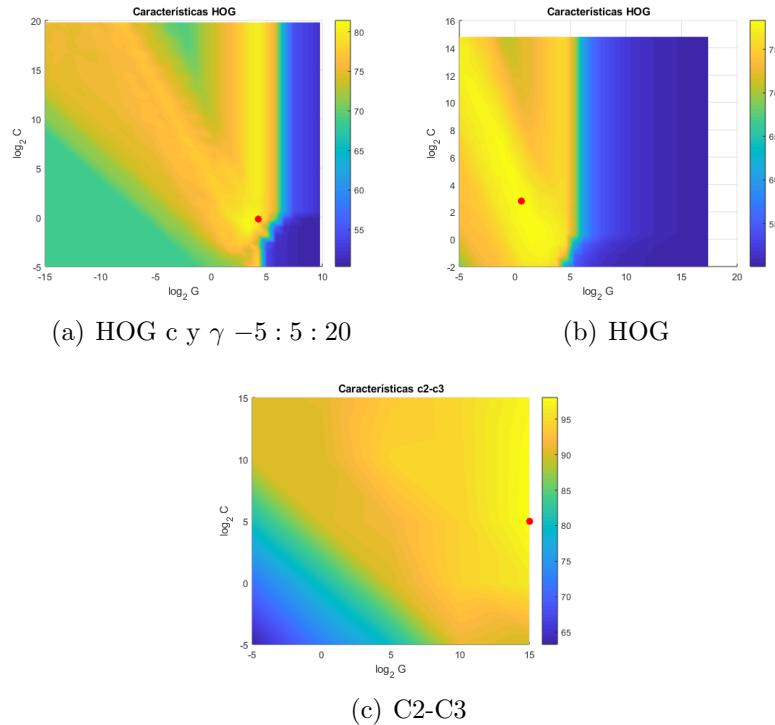


Figura 5.3: Superficies de precisión para la clasificación de las clases Hs-B-F.

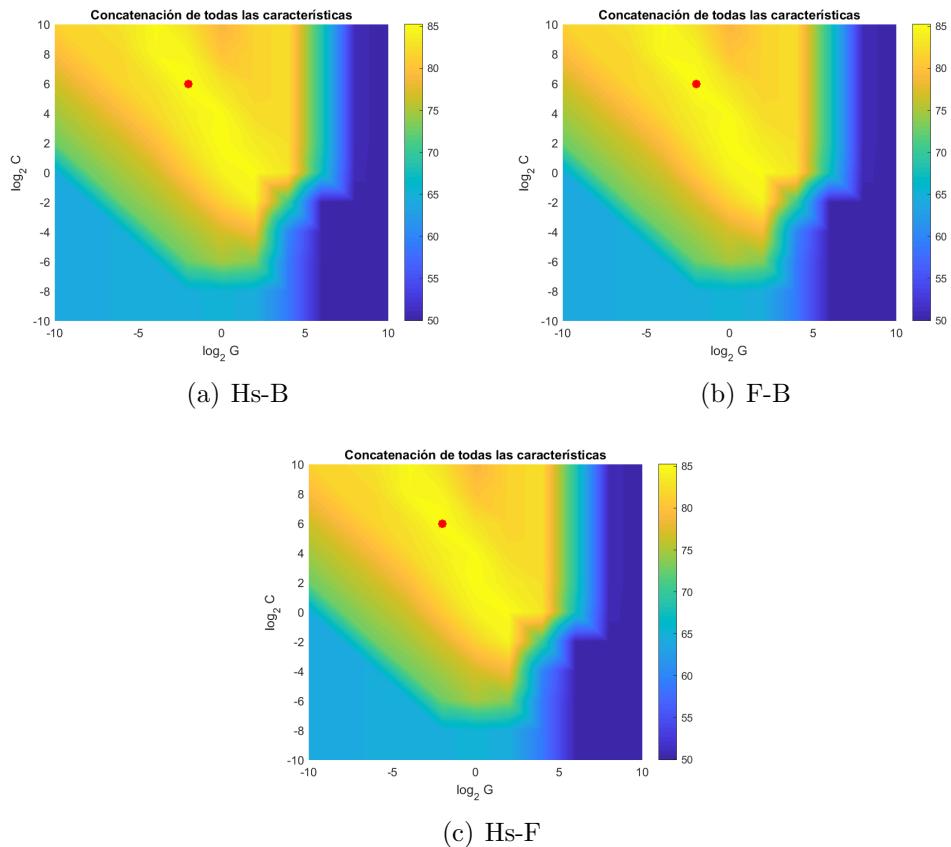


Figura 5.4: Superficies de precisión para la clasificación de las clases Hs-F-B.

Tipo	Características	PH	PD
B-Hs	C1-C2 C2-C5 C3-C4 C4-C5 C5-C6 HOG VTC	73,9024 $c = 10 \gamma = 10$ 76,2164 $c = 10 \gamma = 10$ 72,4299 $c = 10 \gamma = 20$ 71,2064 $c = 20 \gamma = 10$ 68,3845 $c = 10 \gamma = 10$ 82,92 $c = 2.8 \gamma = 0,2$ 85,29 $c = 6 \gamma = -2$	50,48 52,32 51,22 50,86 61,66 75,25 -
	C1-C2 C2-C3 C3-C4 C4-C6 C5-C6 HOG VTC	66,24 $c = 10 \gamma = 10$ 67,41 $c = 15 \gamma = 10$ 70,07 $c = 10 \gamma = 15$ 65,78 $c = 10 \gamma = 10$ 59,50 $c = 10 \gamma = 10$ 77,02 $c = 2 \gamma = 0$ 80,90 $c = 0 \gamma = 2$	51,22 58,00 58,42 52,20 68,70 66,80 -
F-Hs	C1-C3 C2-C3 C3-C5 C4-C5 C5-C6 HOG VTC	94,11 $c = 10 \gamma = 10$ 97,43 $c = 5 \gamma = 10$ 95,11 $c = 5 \gamma = 10$ 85,91 $c = 15 \gamma = 15$ 88,00 $c = 0 \gamma = 10$ 90,20 $c = 0 \gamma = 4$ 96,87 $c = 2 \gamma = 2$	89,60 82,71 91,80 86,14 88,73 74,30 -
	C1-C3 C2-C3 C3-C4 C4-C5 C5-C6 HOG VTC	56,6 $c = 10 \gamma = 10$ 64,8 $c = 10 \gamma = 10$ 64,8 $c = 10 \gamma = 20$ 46,7 $c = 20 \gamma = 10$ 59,8 $c = 10 \gamma = 10$ 46,7 $c = 2,8 \gamma = 0,6$ 36,9 $c = 2,8 \gamma = 0,6$ 66,67 $c = 17 \gamma = 10$	54,90 51,60 32,00 50,80 54,10 36,10 29,5
F-B-Hs	Haralick VTC	69	-

Tabla 5.3: Mejores características para clasificar las celdas B, F y Hs usando la máquina de soporte vectorial *kernel RBF*.

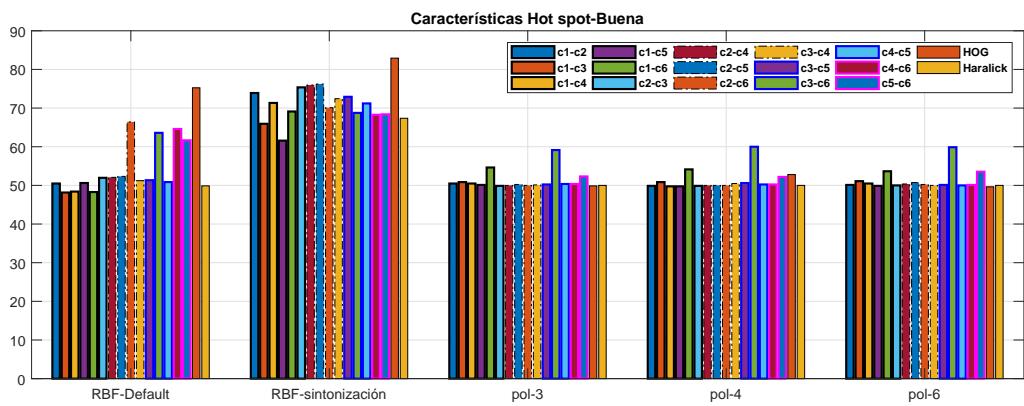
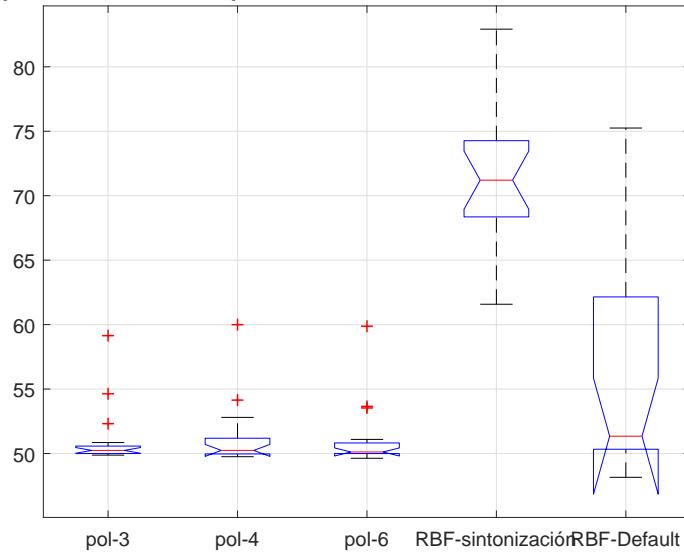


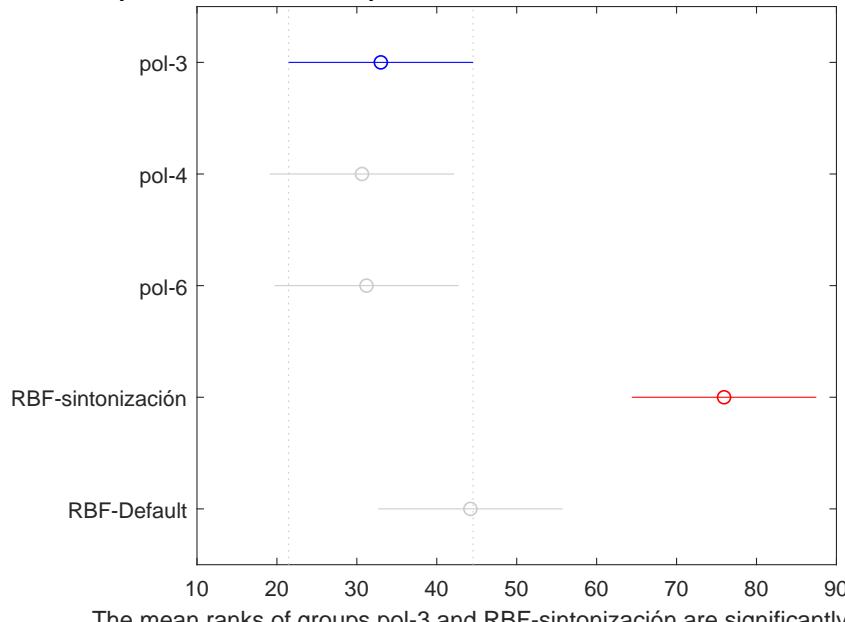
Figura 5.5: Tipos de *kernel* para la clasificación de la celda Buena-*hot-spot*.

Tipos de kernel de svm para la clasificación de las celdas Buena-Hot-spot



(a) Kernel clases B-Hs.

Tipos de kernel de svm para la clasificación de las celdas Buena-Hot-spot



The mean ranks of groups pol-3 and RBF-sintonización are significantly different

(b) Test kruskallwallis para B-Hs

Figura 5.6: Análisis estadístico para la clasificación de las celdas buenas-*hot spot* empleando diferentes *kernel*.

La clasificación del estado de las celdas se abordó inicialmente desde el enfoque de dos clases en las combinaciones: B-Hs, F-B y finalmente Hs-F.

Para la clasificación se uso una maquina de soporte vectorial variando los tipos de *kernel* RBF con los parámetros por defecto, RBF con el método de sintonización, y los polínomicos de grado 3, 4 y 6 sintonizados. En la fig. 5.5 se relaciona con un diagrama de barras los tipos de *kernel* y la precisión obtenida en las pruebas con los datos de *test* para clasificar una celda B vs Hs. De acuerdo con lo reportado el *kernel* RBF sintonizado es el mejor para discriminar las clases B-Hs de acuerdo con la precisión en la clasificación mejorando hasta en un 10% los resultados obtenidos para los histogramas de gradiente, seguido del RBF-D, el desempeño de los *kernel* polinómicos de grados 3,4 y 6 es similar. En la fig. 5.6(a) se observa que el mejor *kernel* para clasificar corresponde a la SVM con los parámetros C y γ sintonizados. La fig. 5.6(b) correspondiente al análisis estadístico arroja una $P > 4,8791e-08$ para la clasificación de las celdas por lo cual la hipótesis nula de que los datos se encuentran en un mismo rango es rechazada y por lo tanto el desempeño de los *kernel* de la SVM para clasificar son diferentes, de acuerdo con lo expuesto anteriormente el mejor método para la clasificación de las celdas corresponde al RBF con sintonización de hiperparámetros. Por otra parte, analizando las mejores características para el *kernel* RBF sintonizado se obtiene el mejor desempeño en la precisión a partir de los Histogramas de gradiente (HOG) como se reporta en la fig. 5.7. Para el caso de las características el valor de $P < 0,7818$, por lo cual la hipótesis nula es rechazada nuevamente y se obtiene un mejor comportamiento para todos los *kernel* en general usando las combinaciones de características C3-C6 correspondientes al sesgo y la energía.

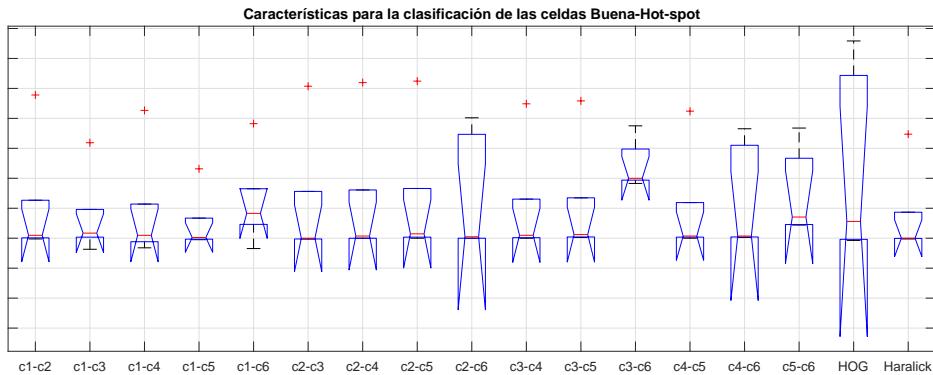


Figura 5.7: Características para la clasificación celda Buena-*Hot spot*.

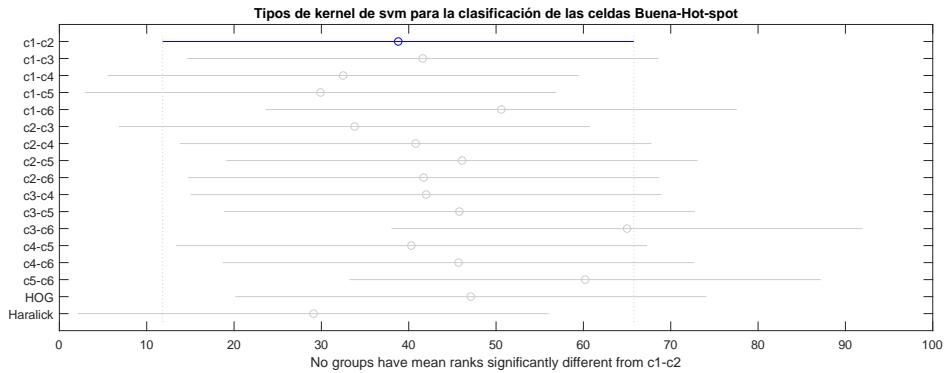


Figura 5.8: Test kruskalwallis de las características para la clasificación celda Buena-*Hot spot*.

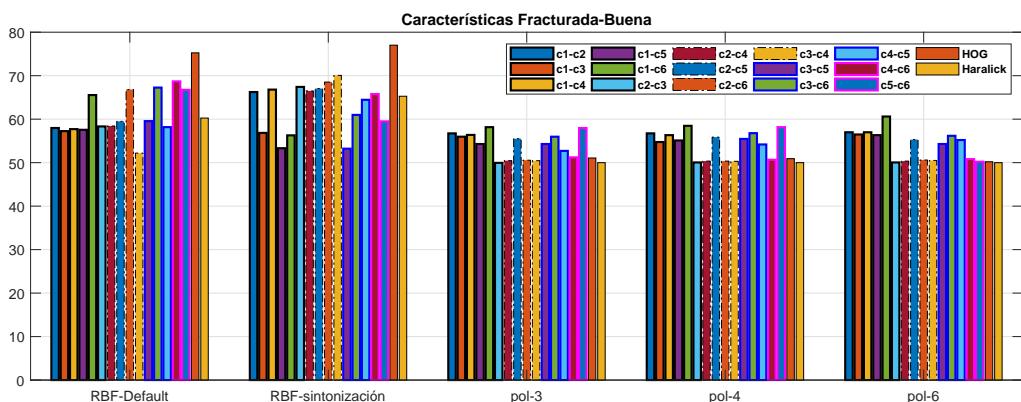
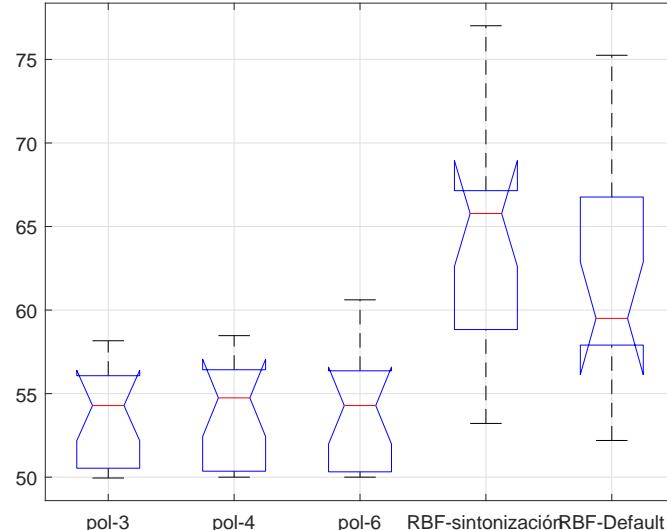


Figura 5.9: Tipos de *kernel* para la clasificación la celda Buena-Fracturada.

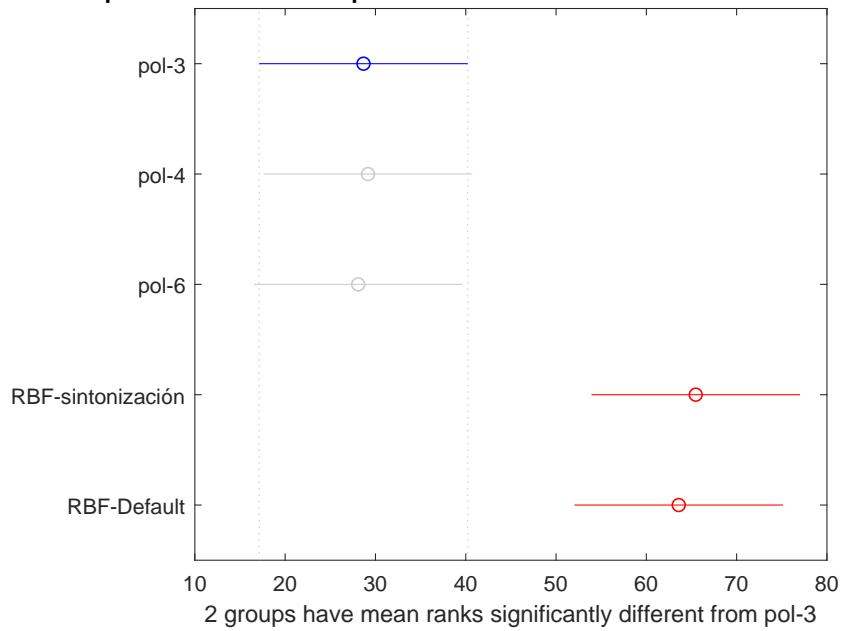
Para el caso de la clasificación de la celda B-F reportado en el gráfico de barras de la fig. 5.9, se observa un mejor desempeño con el *kernel* RBF sintonizado de acuerdo con la precisión en la clasificación mejorando en un 11% el desempeño para las características HOG que permiten discriminar las dos clases, seguido de los parámetros RBF-D fig. 5.10(a). El test estadístico kruskalwallis presenta diferencias significativas entre los *kernel* polinómicos y los RBF siendo estos últimos los mejores para clasificar las celdas B-F ver fig. 5.10(b). Por otra parte, en las características no se presentan diferencias 5.12 pero se obtiene un buen desempeño con las HOG y las C1-C6 (promedio y la energía).

Tipos de kernel de svm para la clasificación de las celdas Buena-Fracturada



(a) Kernel clases F-B.

Tipos de kernel de svm para la clasificación de las celdas Buena-Fracturada



(b) Test kruskalwallis para F-B.

Figura 5.10: Análisis estadístico para la clasificación de las celdas buenas-fracturada empleando diferentes *kernel*.

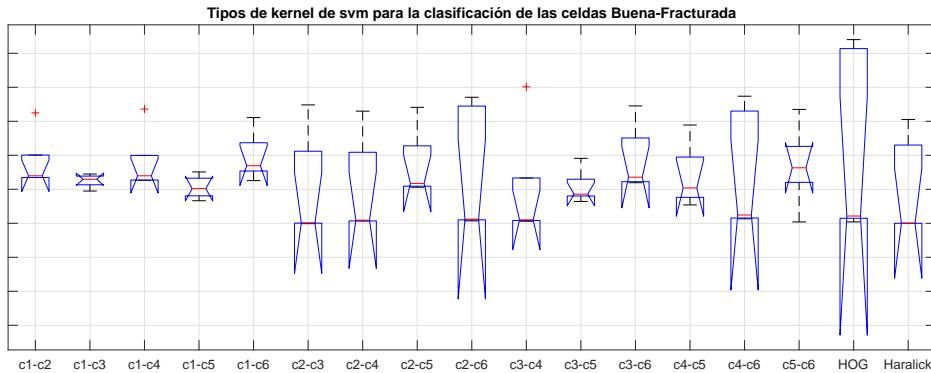


Figura 5.11: Características para la clasificación de la celda fracturada-buena.

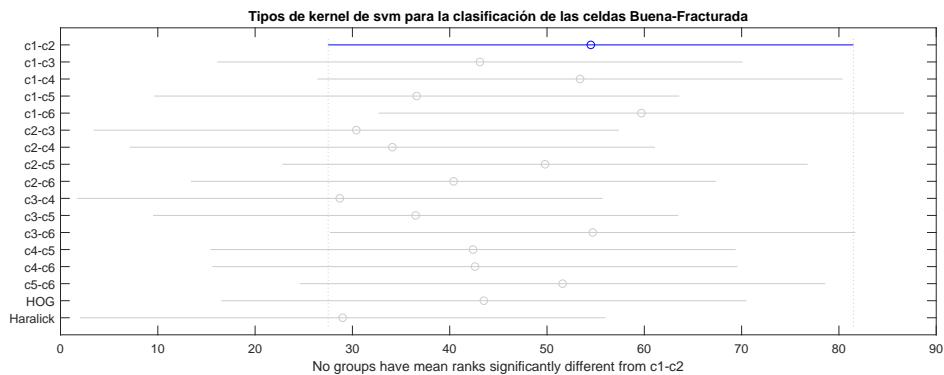


Figura 5.12: Test kruskallwallis de las características para la clasificación de las celdas Fracturada-Buena

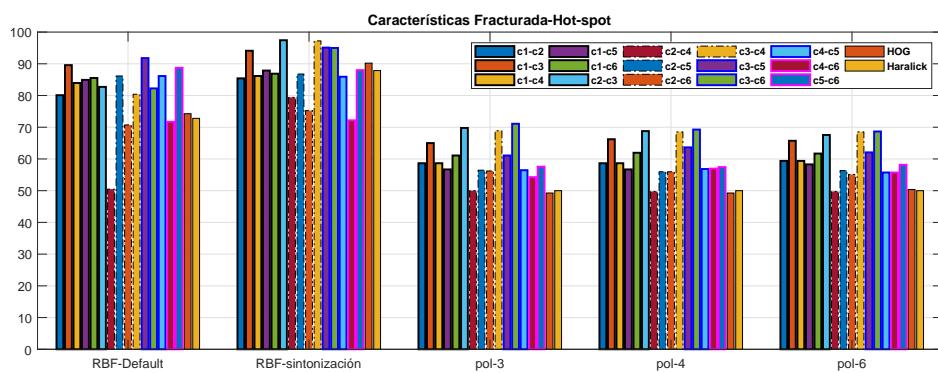
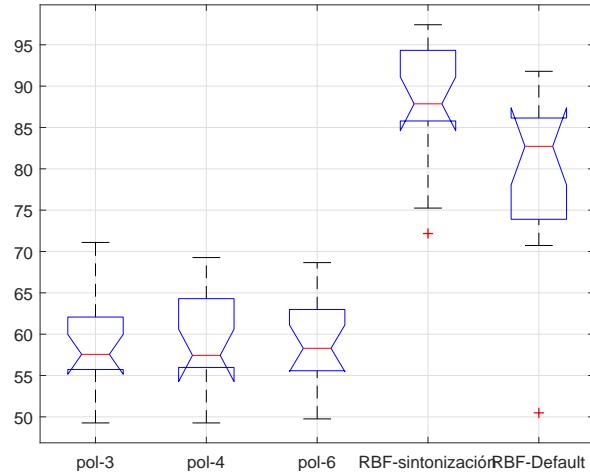


Figura 5.13: Tipos de *kernel* para la clasificación celda Fracturada-hot-spot.

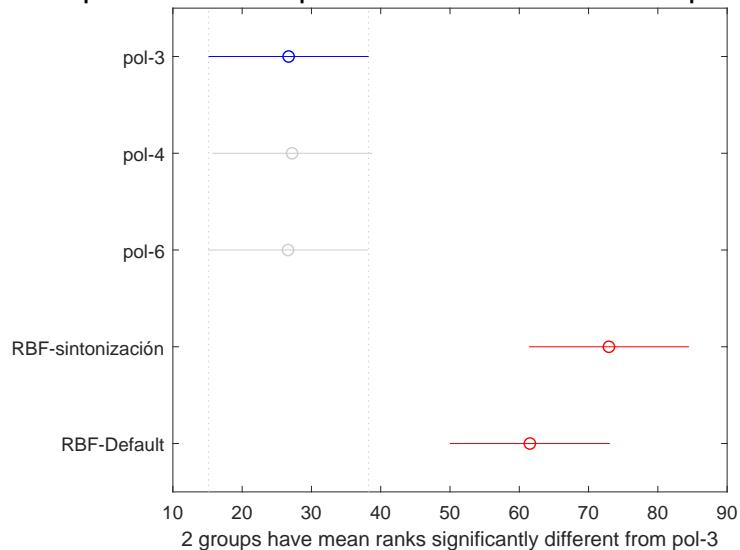
El caso de estudio para la clasificación de las fallas celda F-Hs reportado en el gráfico de barras de la fig. 5.13 permite inferir una mejora con los *kernel* RBF sobre los polinómicos, presentando una diferencia estadística significativa con los desempeños de precisión del polinomio grado 6. El *kernel* RBF sintonizado alcanza una mejor precisión en la clasificación. Por otra parte, las características fig. 5.16, no presentan una diferencia significativa pero se obtiene un buen desempeño con la combinación de C2-C3 (varianza y el sesgo).

Tipos de kernel de svm para la clasificación de las celdas Hot-spot-Fracturada



(a) *kernel* clases F-Hs

Tipos de kernel de svm para la clasificación de las celdas Hot-spot-Fracturada



(b) Test kruskalwallis para F-Hs

Figura 5.14: Análisis estadístico para la clasificación celda *hot spot*-Fracturada empleando diferentes *kernel*.

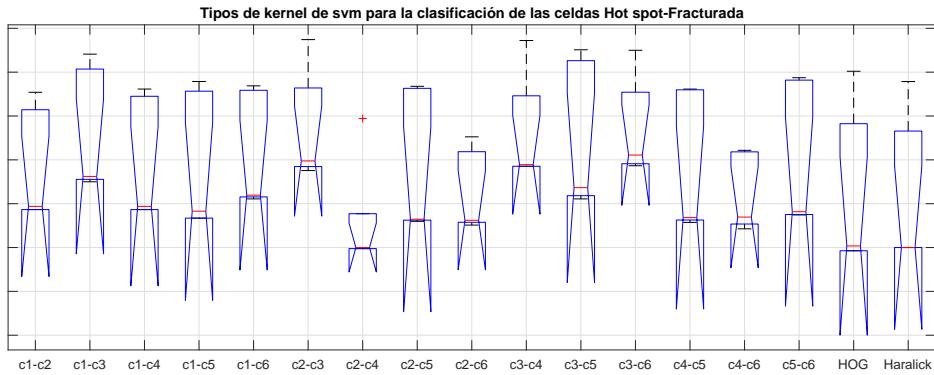


Figura 5.15: Características para la clasificación de la celda fracturada-*hot spot*.

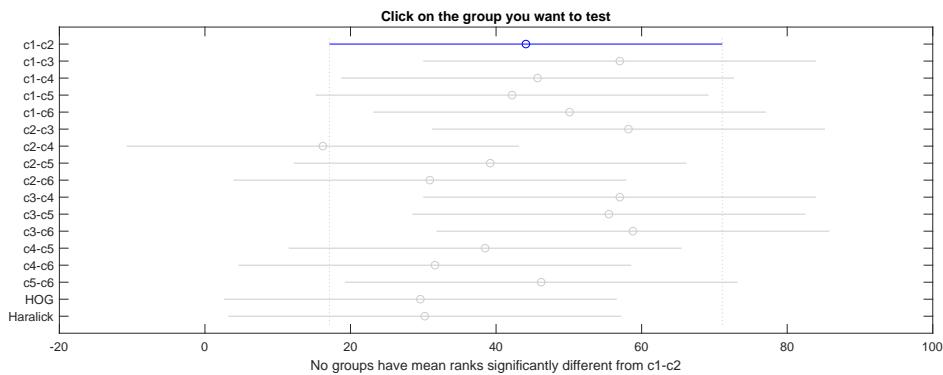


Figura 5.16: Test Kruskallwallis de las características para la clasificación de las celdas Fracturada-hot spot.

Las matrices de confusión obtenidas en las pruebas de los datos de *test* para las clases Buena-*hot spot* se presentan en la fig. 5.17, en la fig. 5.17(a) se obtiene una precisión en la clasificación del 89.00 % con un error del 11.00 % empleando los vectores de características HOG, en la fig. 5.17(b) se obtiene una precisión de 76.5 % con las características C2-C5 correspondiente a la varianza y la entropía. Los vectores HOG permiten detectar mejor las fallas tipo *hot spot*, en comparación de las características C2-C5 en donde los falsos negativos aumentan generando un porcentaje de equivocación en la detección de la falla que puede comprometer el diagnóstico en un 24.3 %, por lo cual usar el vector HOG mejora el porcentaje de precisión global del clasificador.

Matriz de confusión (a) HOG

		Target Class	
		B	HS
Output Class	B	38 46.3%	6 7.3%
	HS	3 3.7%	35 42.7%
		92.7% 7.3%	85.4% 14.6%
		89.0% 11.0%	75.0% 25.0%

Matriz de confusión (b) C2-C5

		Target Class	
		B	HS
Output Class	B	32 39.5%	10 12.3%
	HS	9 11.1%	30 37.0%
		78.0% 22.0%	75.0% 25.0%
		76.5% 23.5%	76.2% 23.8%

Figura 5.17: Matrices de confusión para la clasificación de la celda Buena-*Hot spot* usando una SVM con *kernel RBF*.

Las matrices de confusión para las clases Buena-Fracturada se presentan en la fig. 5.18. En la fig. 5.18(a) se obtiene una precisión en la clasificación de 81.5% usando el vector de características HOG, por otra parte, en la fig. 5.18(b) se obtiene una precisión de 72.4% empleando la combinación de características C3-C4 correspondientes al sesgo y curtosis. El porcentaje de falsos positivos para la clase fracturada es similar para las características HOG y C3-C4 respectivamente 12.8% y 19.4%.

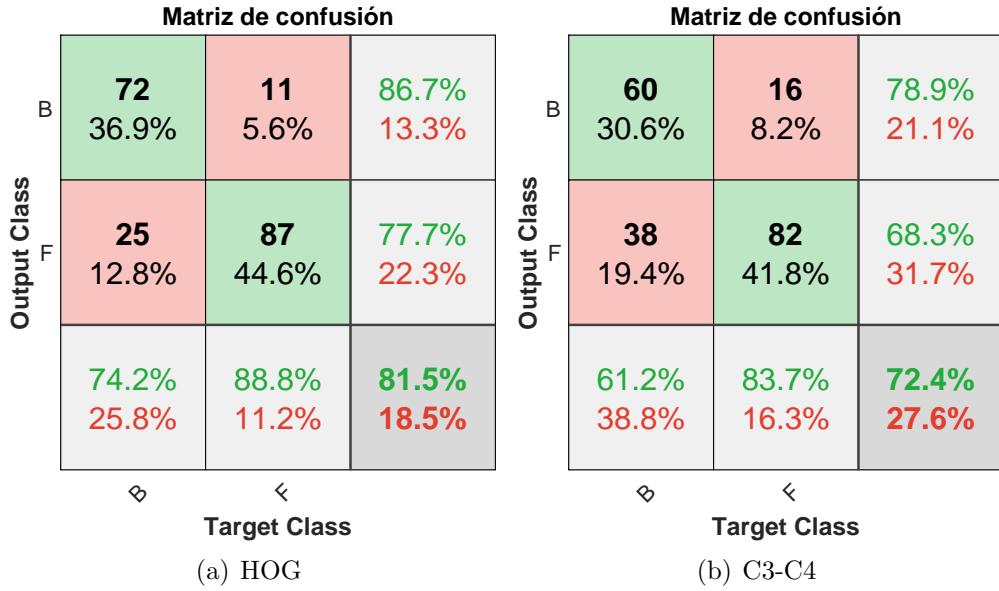
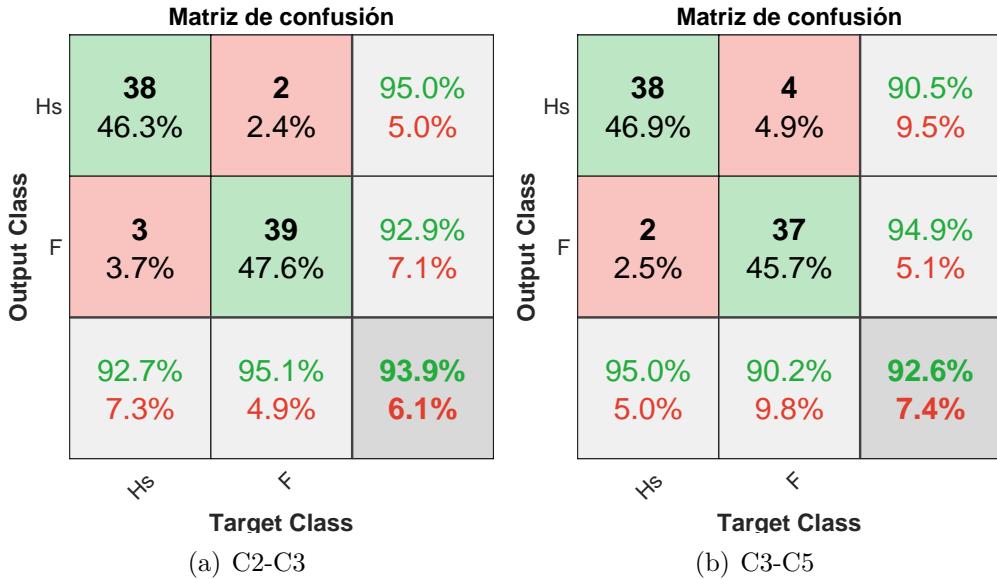


Figura 5.18: Matrices de confusión para la clasificación de la celda Buena-Fracturada usando una SVM con *kernel RBF*.

Las matrices de confusión para las clases fracturada- *hot spot* se presentan en la fig. 5.19. En la fig. 5.18(a) se obtiene una precisión en la clasificación de 93.9 % empleando las características C2-C3 correspondientes a la varianza y el sesgo, por otra parte, en la fig. 5.19(b) se obtiene una precisión del 92.6 % usando la combinación de características C3-C5. Las características C2-C3 tienen una mejor precisión en la clasificación de la falla *hot spot*, esta anomalía solo puede detectarse en el espectro infrarrojo a diferencia de las fracturas en las celdas que pueden observarse por inspección visual, por lo cual emplear los vectores C2-C3 es recomendable para discernir entre este tipo de fallas.



(a) C2-C3

(b) C3-C5

Figura 5.19: Matrices de confusión para la clasificación de la celda Fracturada-*Hot spot* usando una SVM con *kernel* RBF.

Una vez finaliza el experimento de la combinación entre pares de clases se emplea el método de uno vs todos para la clasificación de los defectos en las celdas solares. En este experimento se varían los tipos de *kernel* en RBF sintonizado y el RBF-D. En la fig. 5.20, se ilustra la precisión en los *kernel* para las características estadísticas, de textura y HOG.

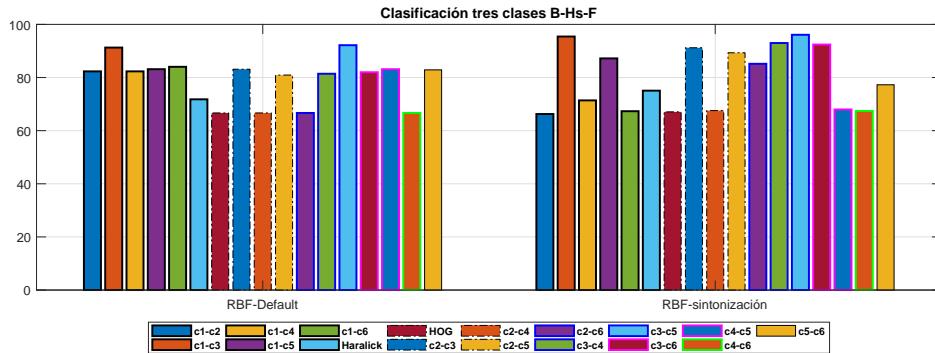


Figura 5.20: Tipos de *kernel* para la clasificación celda Fracturada-*hot spot*-Buena.

La comparación estadística entre los *kernel* RBF y RBF-D, no presentan una diferencia estadística significativa ver fig. 5.21(b), pero sigue obteniendo una mejora el método RBF sintonizado con respecto al RBF-D.

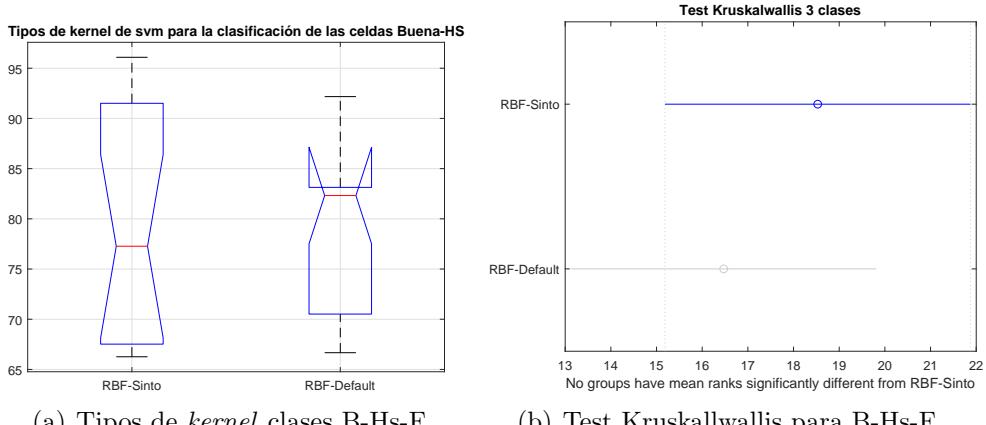


Figura 5.21: Análisis estadístico para la clasificación de celdas B-Hs-F.

A continuación se presentan las matrices de confusión para RBF sintonizado fig. 5.22 y el RBF-D fig. 5.23.

De acuerdo con los porcentajes de clasificación obtenidos de los datos de prueba, los pares de combinaciones de características que mejor precisión alcanzan son C2-C3 fig. 5.22(b) y C3-C4 fig. 5.22(c) obteniendo un porcentaje global de 64.8 %. La clase que mejor fue clasificada es la celda fracturada con 85.4 % y 83.3 % respectivamente para los pares de características. La falla *hot spot* fue detectada con el mejor porcentaje de precisión de 60.6 % en las combinaciones C5-C6 fig. 5.22(e) y la celda sana fue detectada con un porcentaje de 53.5 % para las combinaciones C2-C3 fig. 5.22(b).

Por otra parte, las matrices de precisión obtenidas para el *kernel* RBF por defecto con los datos de test, presentan como mejor porcentaje de clasificación general 54.9 % obtenido por la combinaciones C1-C3 fig. 5.23(a), la falla celda fracturada fue clasificada con 85 % de precisión, la celda buena con 37.1 % y el *hot spot* con un 42.6 %. Finalmente de forma global, la celda buena se clasificó mejor con 42 % de acierto con las combinaciones C3-C5 fig. 5.23(c) y el *hot spot* con C5-C6 fig. 5.23(e) y un acierto de 52.6 %.

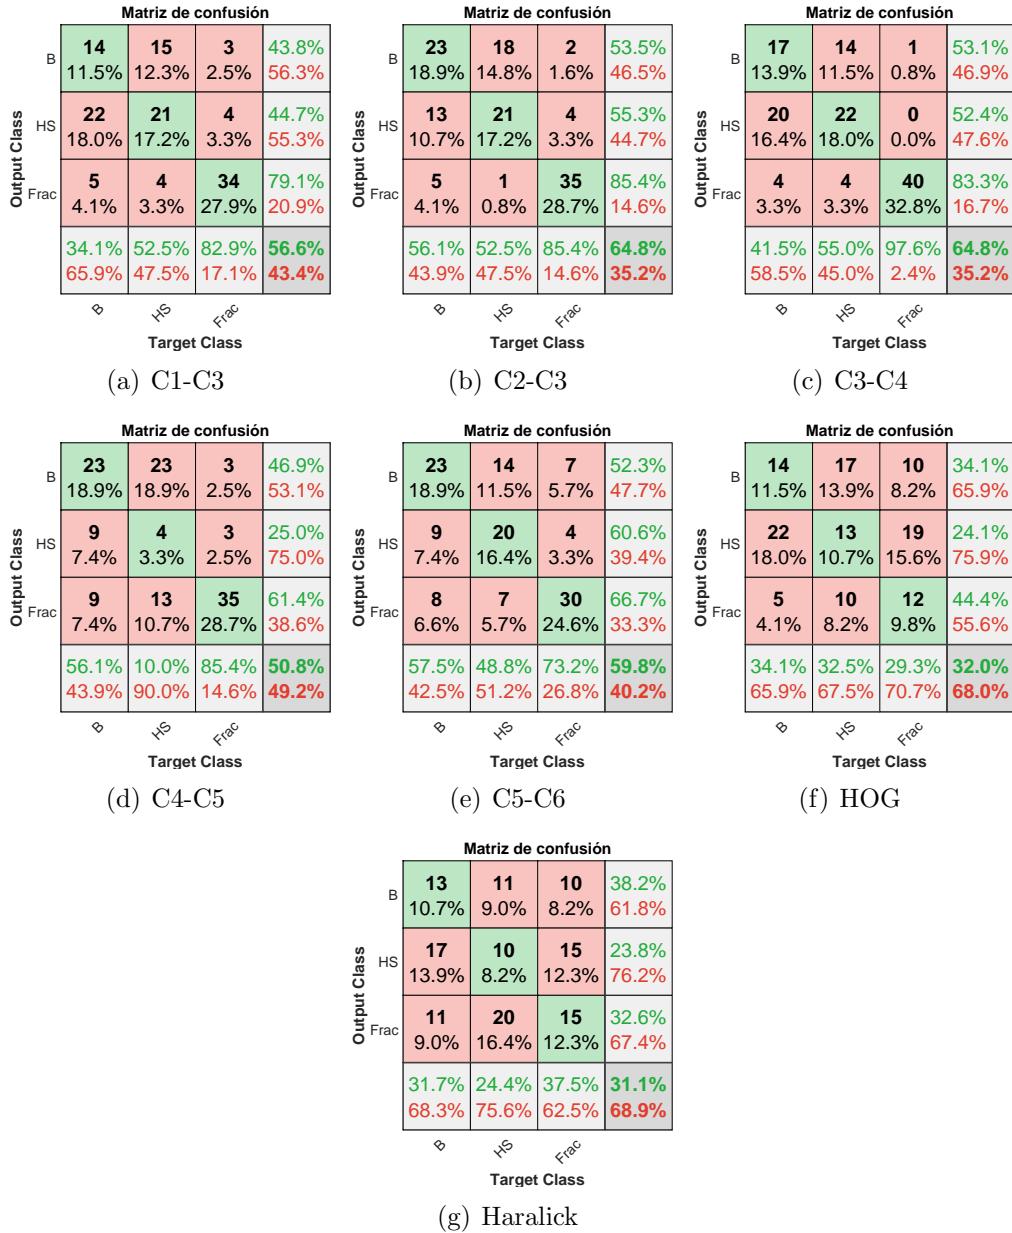


Figura 5.22: Matrices de confusión para la clasificación de las tres clases Buena-Fracturada-Hot spot.

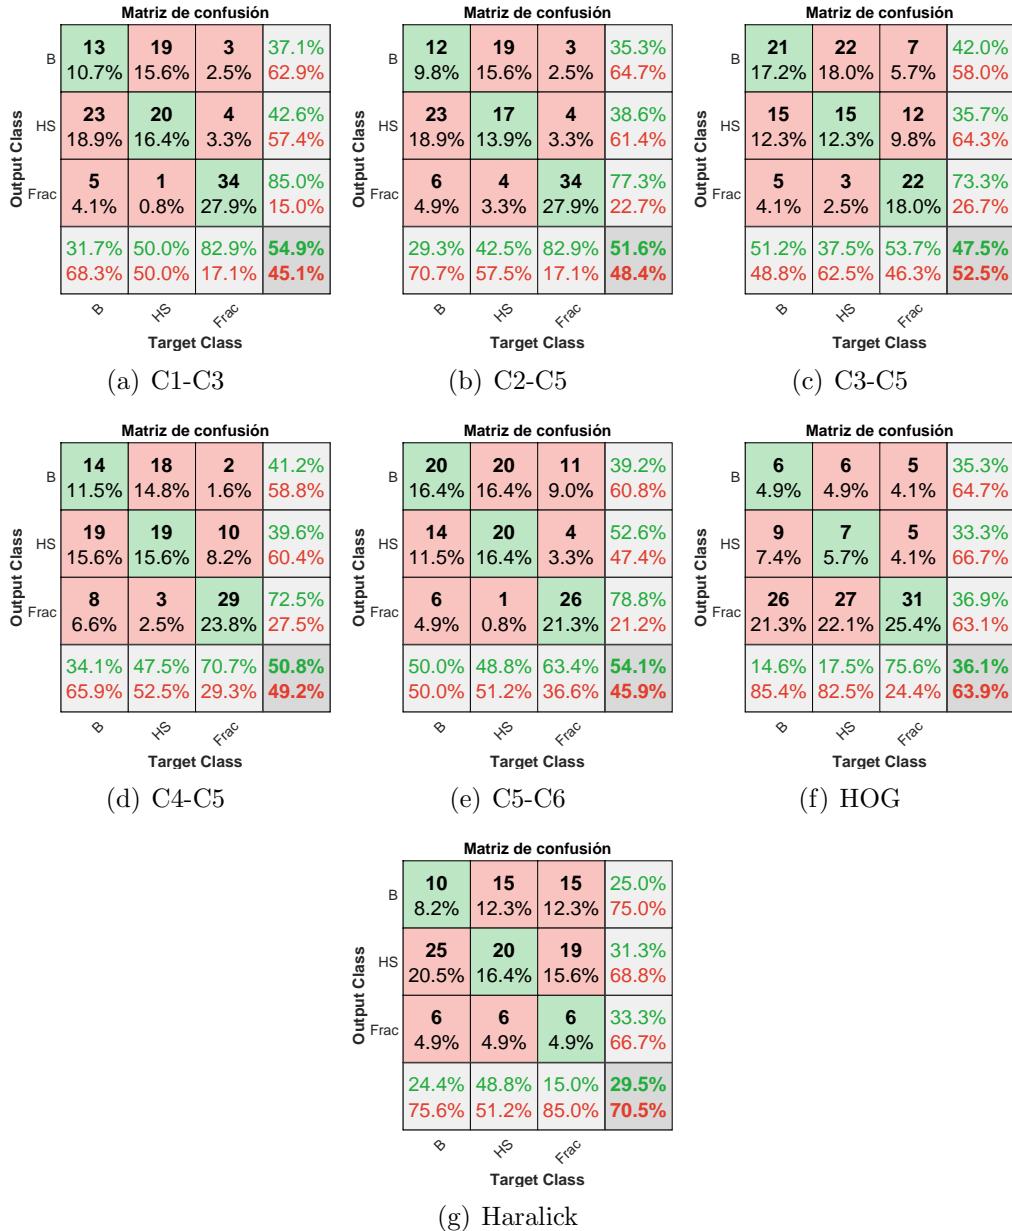


Figura 5.23: Matrices de confusión para la clasificación de las tres clases B-F-H *kernel RBF* por defecto.

5.3.3.2. Método 2 RNA:

La clasificación con RNA para identificar los tipos de clases B-Hs, B-F, F-Hs y tres clases F-Hs-B, se hace a partir de las variaciones en la topología; cantidad de neuronas de las capas ocultas, las funciones de entrenamiento y

desempeño. En la fig. 5.24 se presenta la precisión en la clasificación para: 6, 8 y 10 neuronas en la capa oculta, las funciones de entrenamiento *Resilient Back Propagation* (RBP), *Scaled Congujate Gradient Backpropagation* (SCG) y las funciones de desempeño *Mean Square Error* (MSE) y *Crossentropy* (CRO).

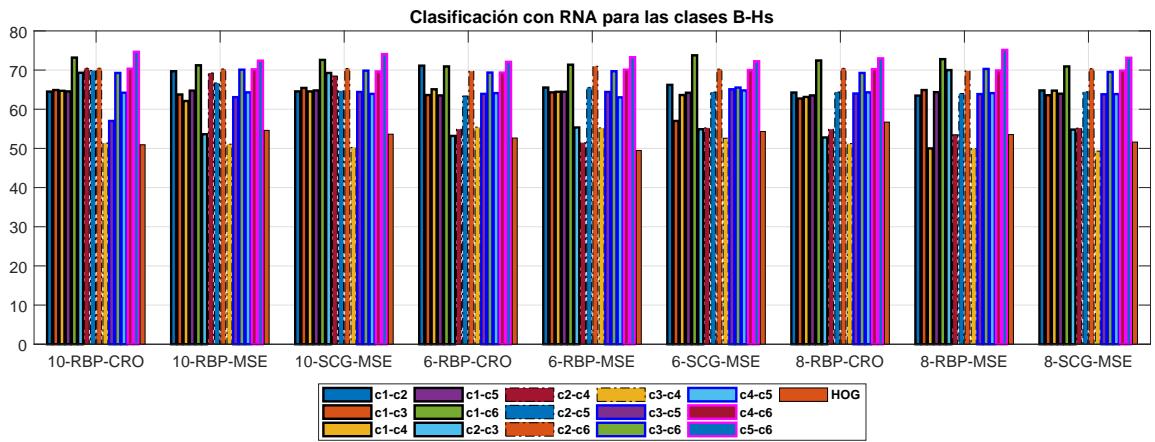


Figura 5.24: Clasificación del las celdas Hs-B a partir de las variaciones de la arquitectura de las RNA.

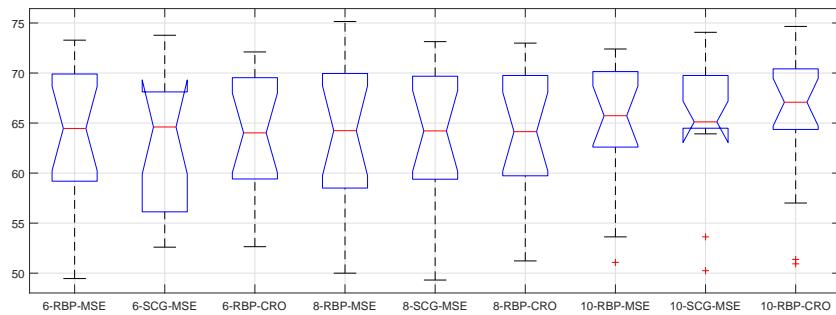


Figura 5.25: Análisis estadístico de las arquitecturas de la RNA para la clasificación de celdas B-Hs.

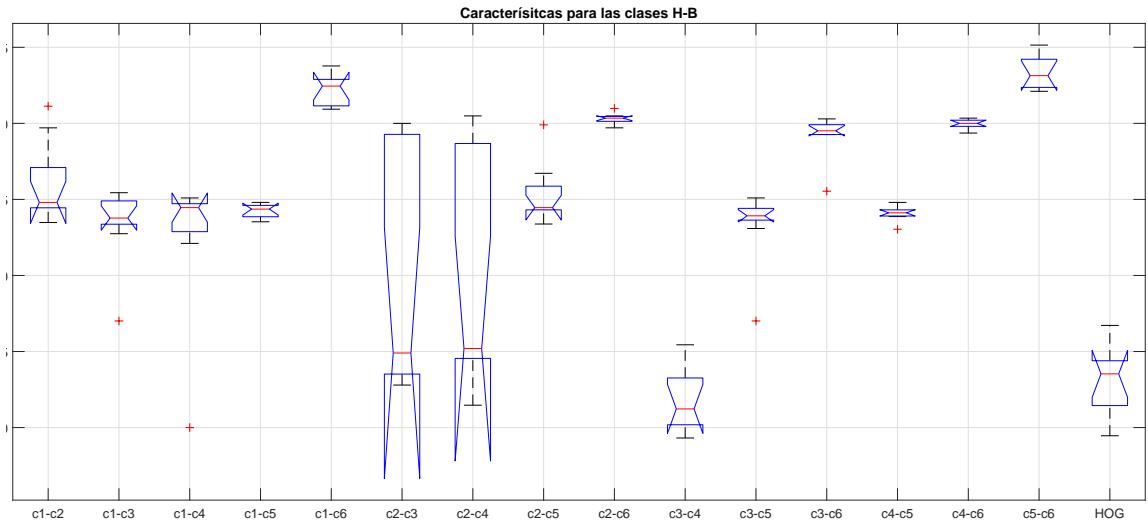


Figura 5.26: Análisis estadístico de las características para la clasificación de las celdas B-Hs.

La precisión en la clasificación de los datos de prueba se ilustra en la fig. 5.25 la distribución de los datos permanece en un rango entre el 65 y 70. Las topologías estudiadas no presentan una diferencia estadística significativa para la clasificación de las celdas B-H aunque el desempeño para discernir las clases B-Hs mejora con 10 neuronas en la capa oculta, función de entrenamiento RBP y función de desempeño de CRO.

Por otra parte, el análisis de las características muestra un mejor porcentaje de clasificación usando los HOG a diferencia de las posibles combinaciones de características estadísticas y de textura fig. 5.26.

A continuación, se presentan las matrices de confusión de entrenamiento y validación para la clasificación de las celdas B-Hs, empleando la RNA variando el número de neuronas en la capa oculta, la función de entrenamiento y de activación.

Tomando 6 neuronas en la capa oculta y función de entrenamiento RBP y de activación MSE se presentan las siguientes matrices de confusión fig. 5.27 a fig. 5.28: la mejor combinación que permite clasificar las fallas B-Hs corresponde a C5-C6 fig. 5.28(c) con un acierto en la clasificación de la celda Hs de 73.7% y un error de 26.3%.

Tomando 8 neuronas en la capa oculta y con función de entrenamiento RBP, función de activación MSE fig. 5.29 a 5.30: la mejor combinación de características para la clasificación de las celdas B-Hs corresponde a C1-C6 con un acierto del 74.5 %, un éxito para discernir las falla *hot spot* del 73.6 % y

un error del 26.4 %. Tomando 10 neuronas en la capa oculta y con función de entrenamiento RBP, función de activación MSE fig. 5.31 a fig. 5.33: la mejor combinación de características para la clasificación de las celdas B-Hs corresponde a C1-C6 fig. 5.27(c) con un acierto del 74.5 % y un error del 25.5 %. La falla *Hot spot* fue clasificada con el 70.30 % de la precisión.

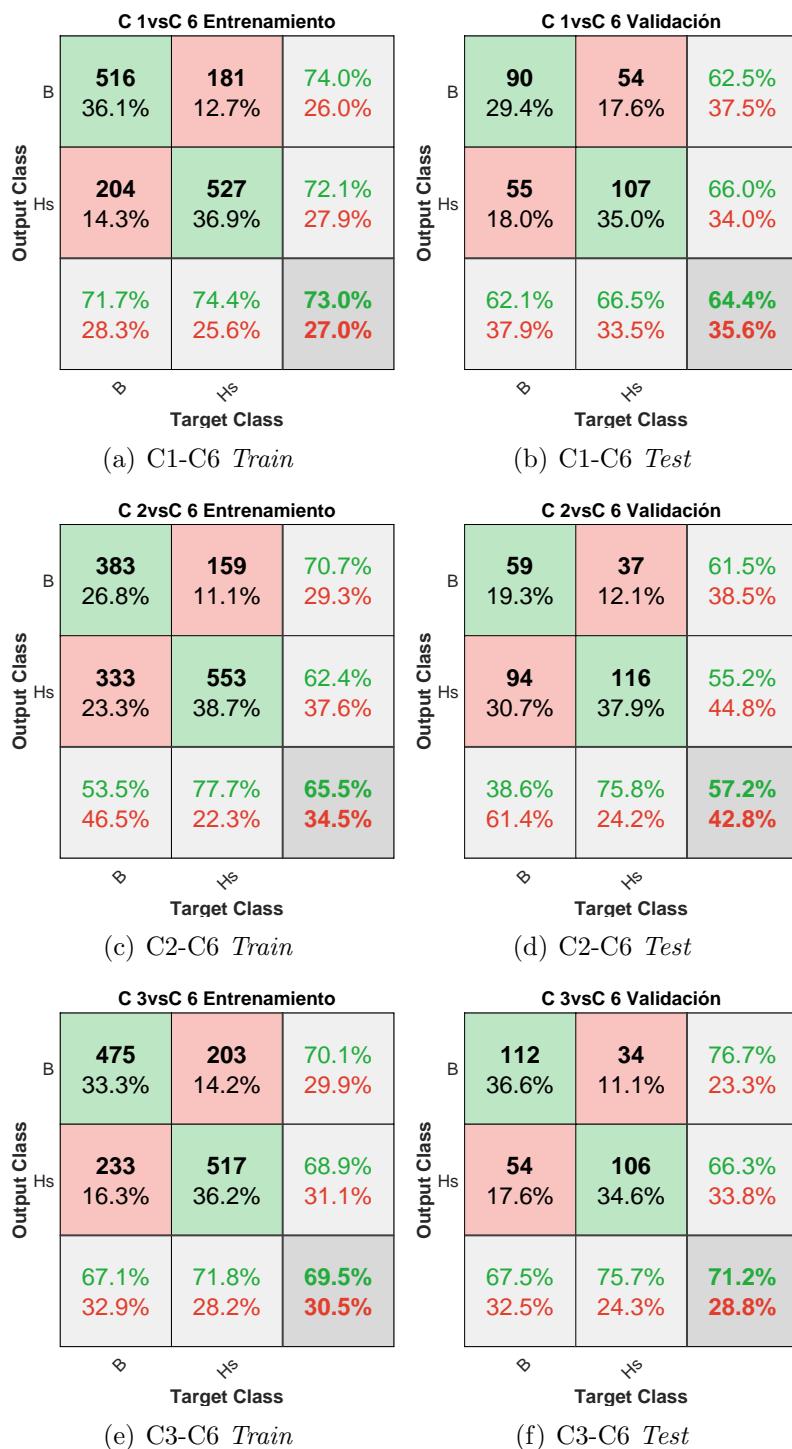


Figura 5.27: Matrices de confusión de entrenamiento y prueba para las combinaciones de características que mejor clasifican las fallas B-Hs #:6,RBP-MSE.

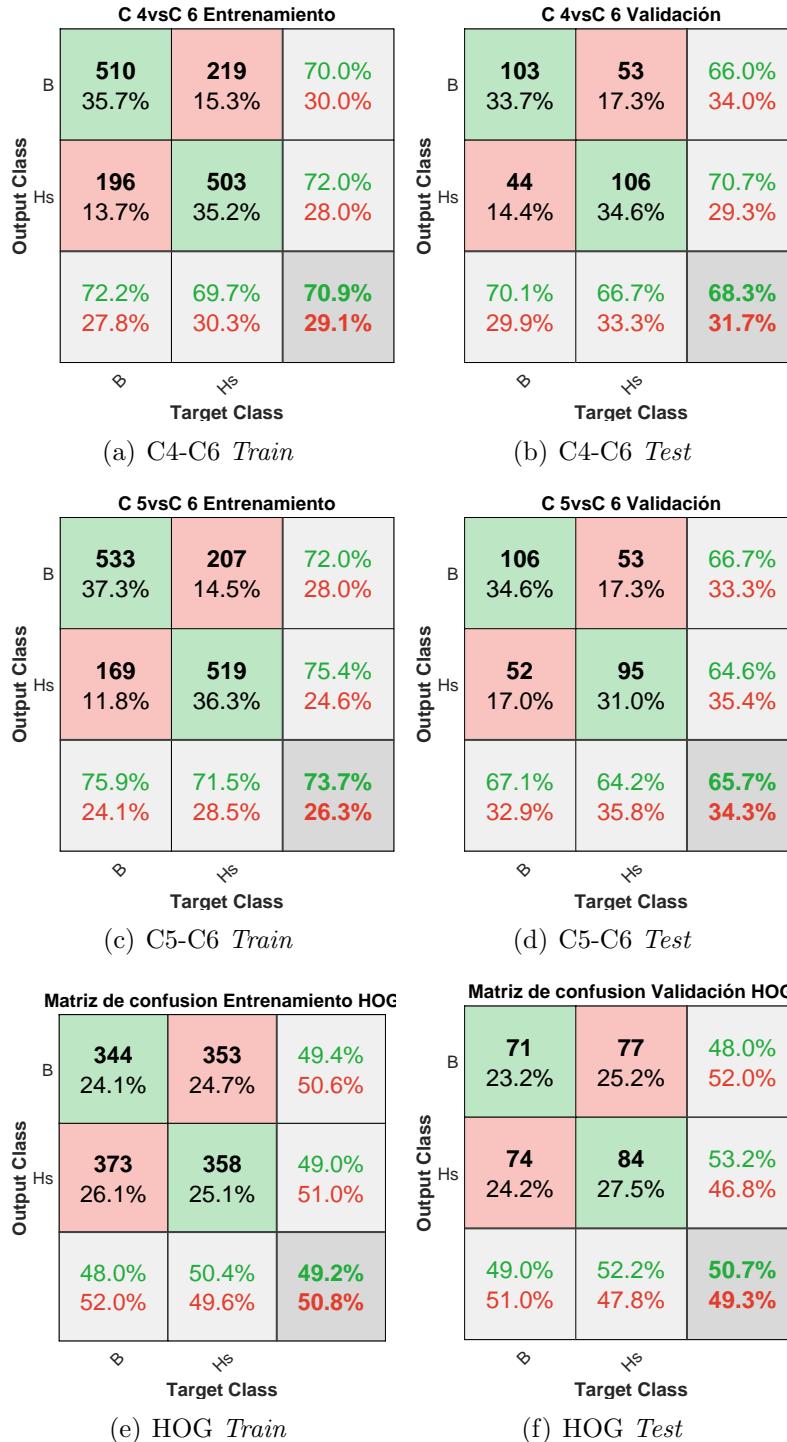


Figura 5.28: Matrices de confusión de entrenamiento y prueba para las combinaciones de características que mejor clasifican las fallas B-Hs #:6,RBP-MSE.

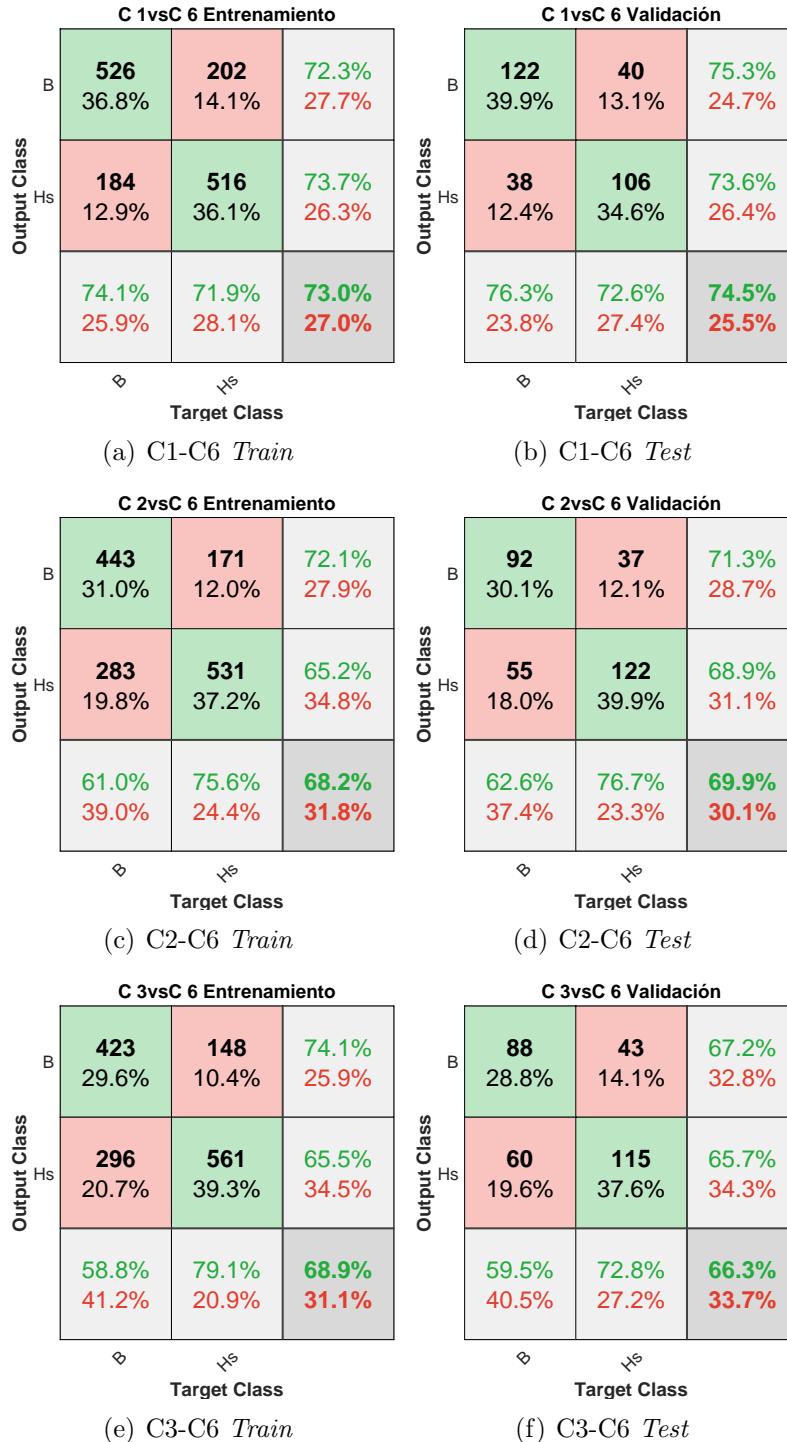


Figura 5.29: Matrices de confusión de entrenamiento y prueba para las combinaciones de características que mejor clasifican las fallas B-Hs #:8,RBP-MSE.

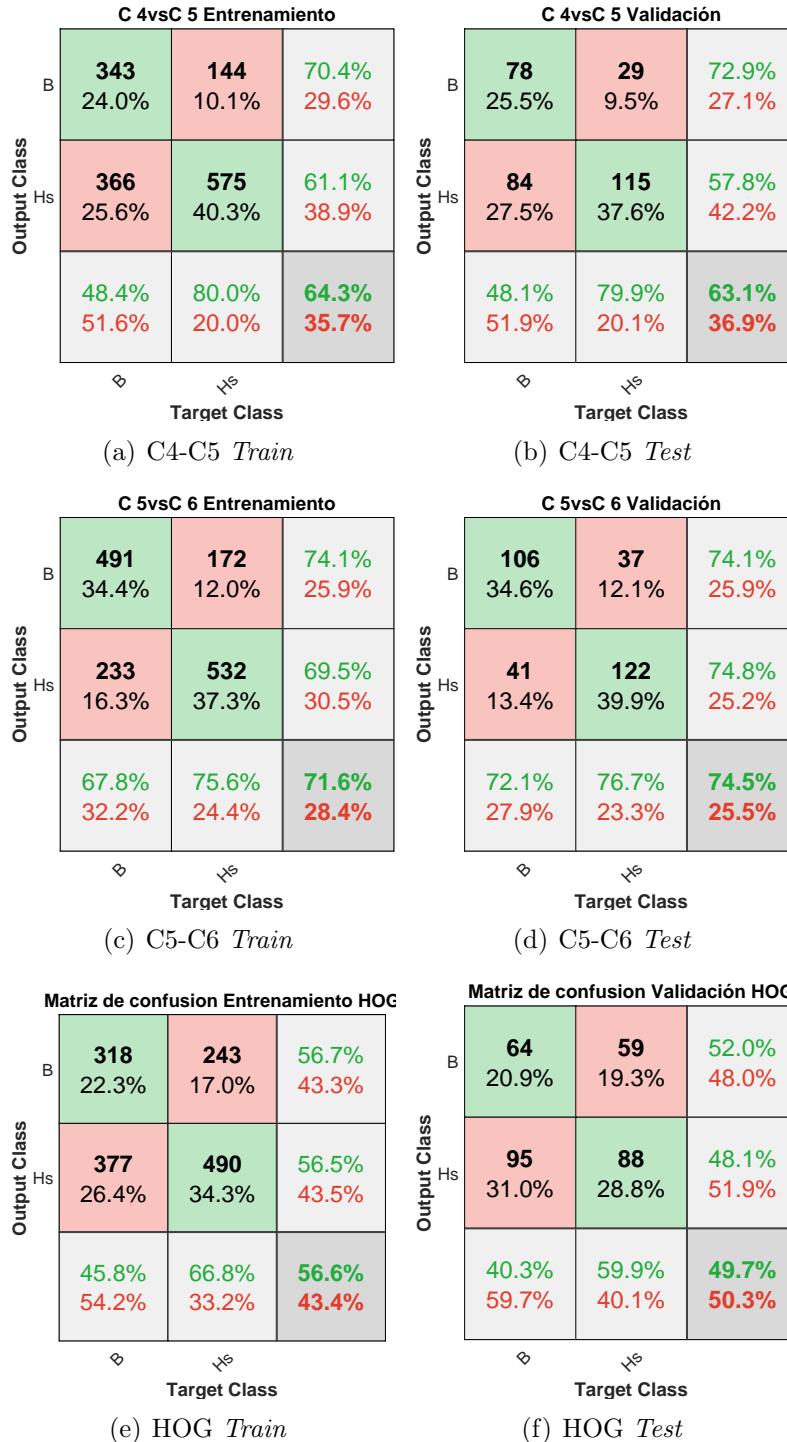


Figura 5.30: Matrices de confusión de entrenamiento y prueba para las combinaciones de características que mejor clasifican las fallas B-Hs #:8,RBP-MSE.

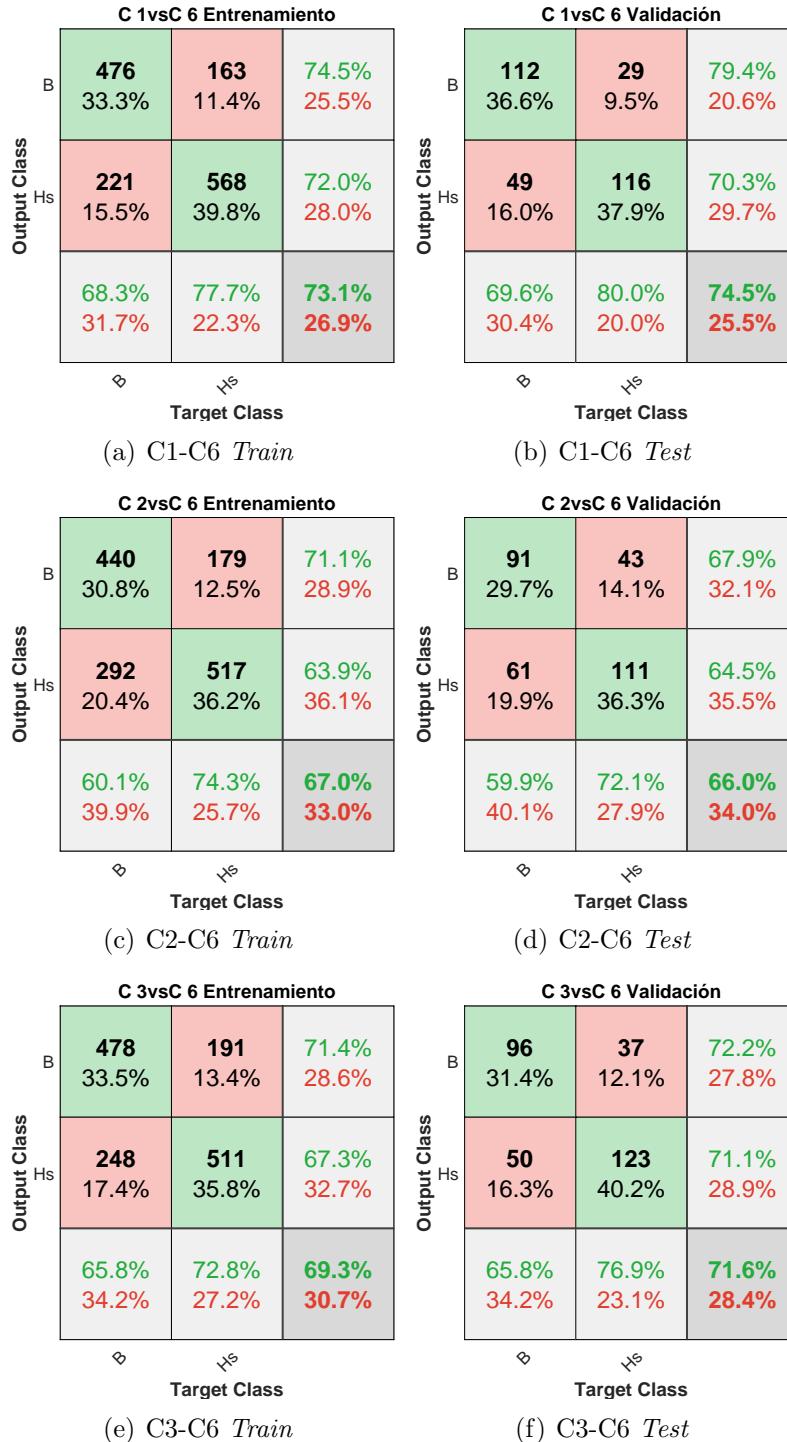


Figura 5.31: Matrices de confusión de entrenamiento y prueba para las combinaciones de características que mejor clasifican las fallas B-Hs #:10,RBP-MSE.

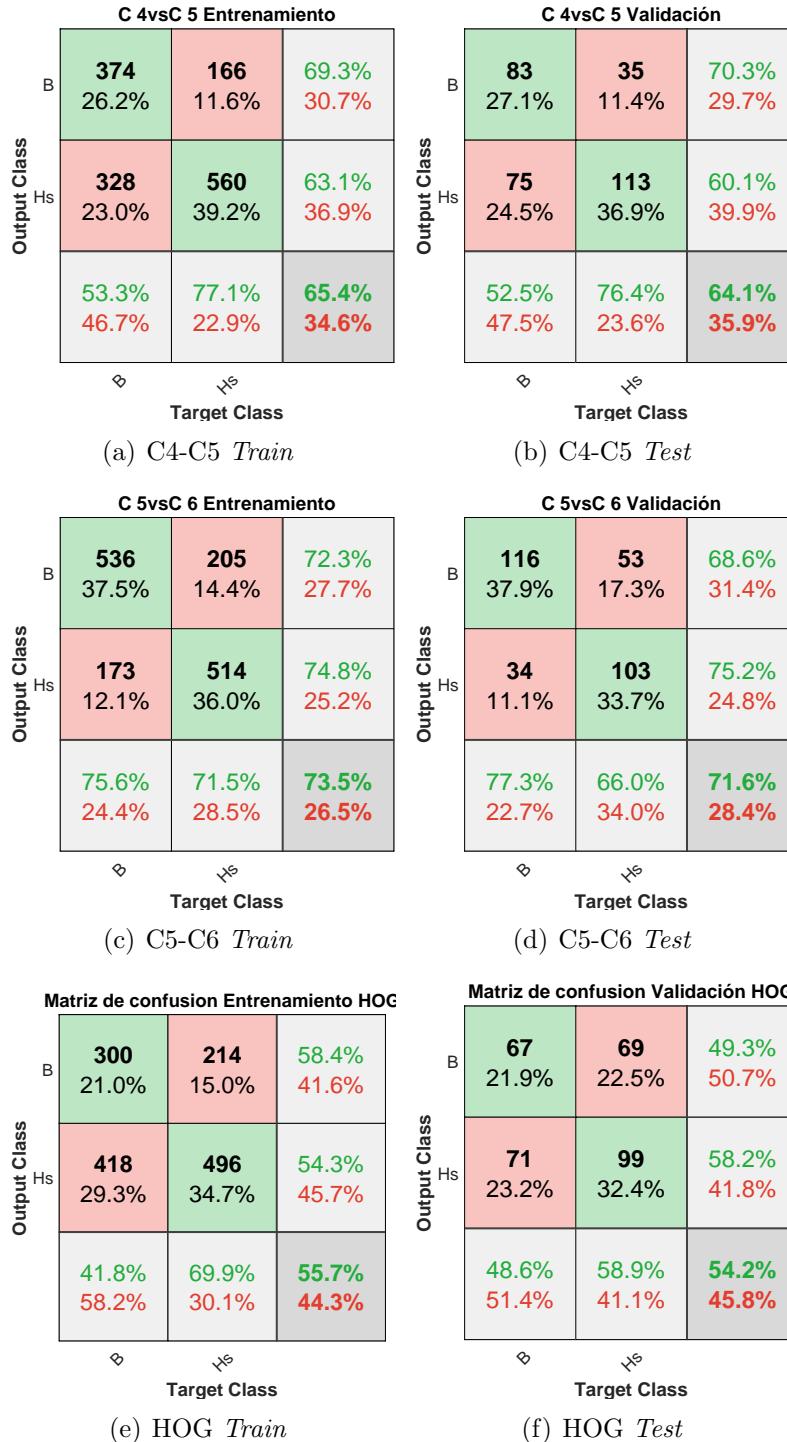


Figura 5.32: Matrices de confusión de entrenamiento y prueba para las combinaciones de características que mejor clasifican las fallas B-Hs #:10,RBP-MSE.

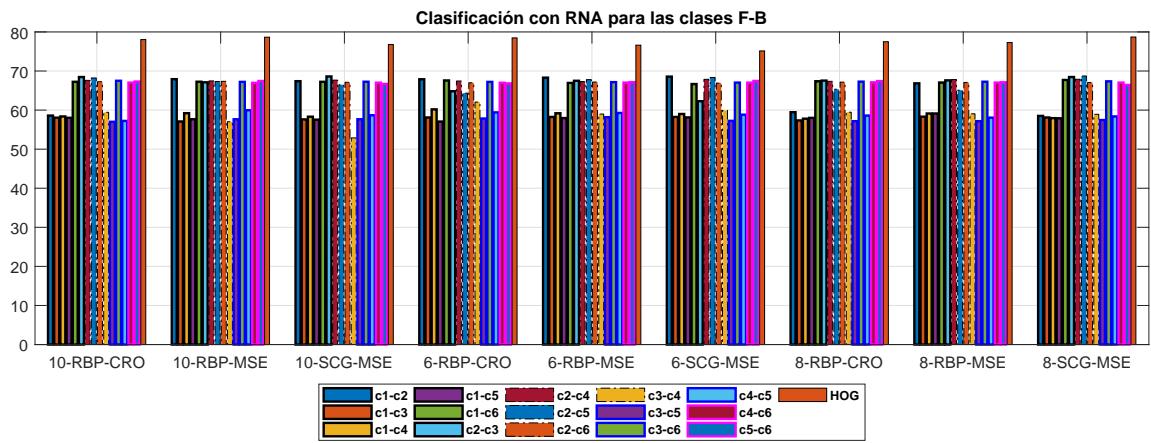


Figura 5.33: Clasificación de las celdas F-B a partir de las variaciones de la arquitectura de las RNA.

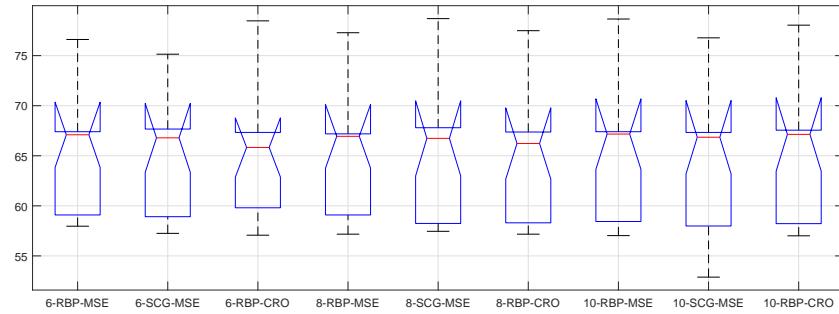


Figura 5.34: Análisis estadístico de las topologías de la RNA para la clasificación de las celdas F-B.

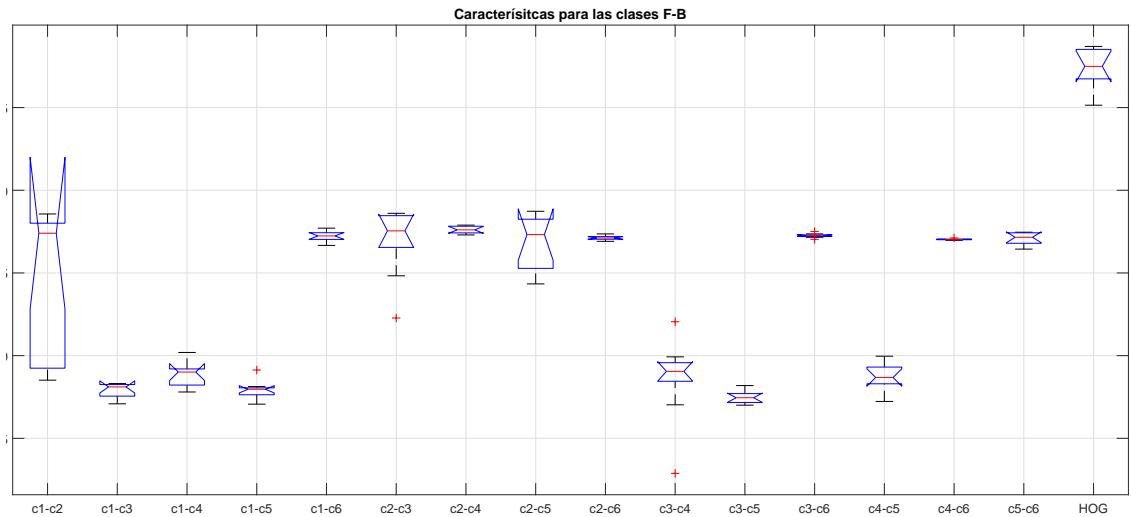


Figura 5.35: Características para la clasificación B-F.

El experimento de la clasificación de las celdas B-F, con las diferentes topologías para la RNA se presenta en la fig. 5.33. Los valores de precisión en la clasificación con los datos de prueba se mantienen en el rango entre 60 % y 70 %, por lo cual se puede seleccionar cualquiera de las topologías implementadas. Por otra parte, las características que mejor permiten discriminar las clases B-F son la HOG y se reportan en la fig. 5.35.

A continuación se presentan las matrices de confusión de entrenamiento y validación para la clasificación de las celdas B-F.

Tomando 6 neuronas en la capa oculta, función de activación SCG y función de desempeño de CRO fig. 5.36 a fig. 5.37 la mejor combinación de características estadísticas para discernir las clases B-F corresponde a las C3-C6 fig. 5.36(f) con un porcentaje de precisión de 67.2 % y con una precisión para identificar las fracturas en las celdas de 62.5 %. Por otra parte las características que mejor desempeño en la clasificación presentan corresponden al HOG fig. 5.37(f) con una precisión global del 79.2 % y un 70.4 % para la clasificación de la fractura en la celda.

Tomando 8 neuronas en la capa oculta y una arquitectura RBP-MSE fig. 5.38 fig. 5.39: la mejor combinación de características estadísticas corresponde a C2-C4 fig. 5.38(d) con una precisión global del 70.7 %, permitiendo detectar la falla celda fracturada con un acierto de 65.9 %. Por otra parte, el vector HOG fig. 5.39(f) permite alcanzar nuevamente la mejor precisión de las características estudiadas con un total de 77.8 %, la identificación de la falla usando esta configuración es del 76 %.

Tomando 10 neuronas en la capa oculta y una arquitectura RBP-MSE fig.

5.40 a fig. 5.41: la combinación de características que mejor precisión presenta para la identificación de las celdas B-F corresponde al C4-C6 fig. 5.40(d) con una precisión global del 67.7.1 % y un acierto en la clasificación de las celdas fracturadas de 60.5 %. Finalmente las características HOG fig. 5.41(f) presentan el mejor desempeño en la clasificación de las celdas fracturadas con 75.2 % de acierto en la identificación de la falla y una precisión general del 73.9 %.

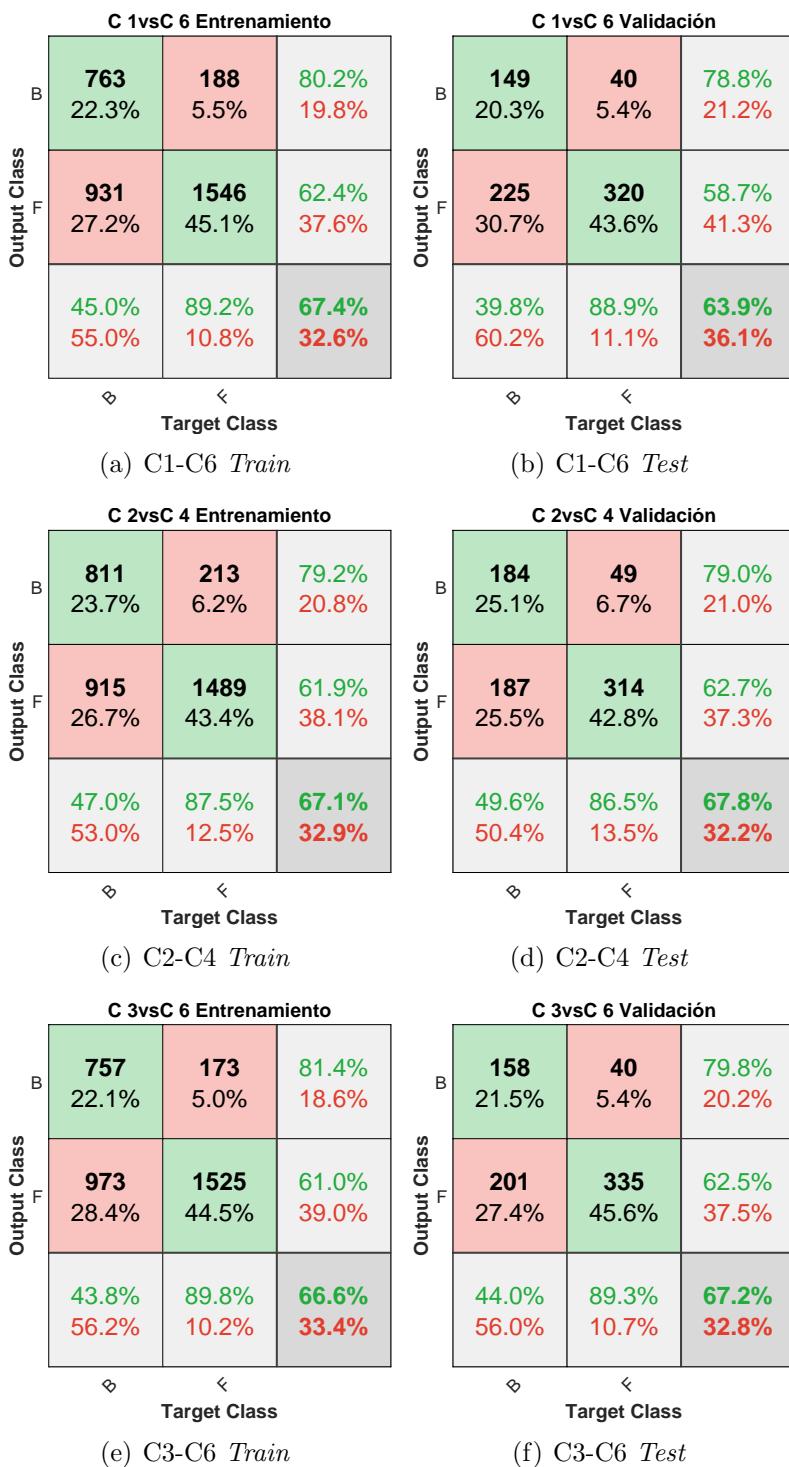


Figura 5.36: Matrices de confusión de entrenamiento y prueba para las combinaciones de características que mejor clasifican las fallas B-F #6, SCG-CRO.

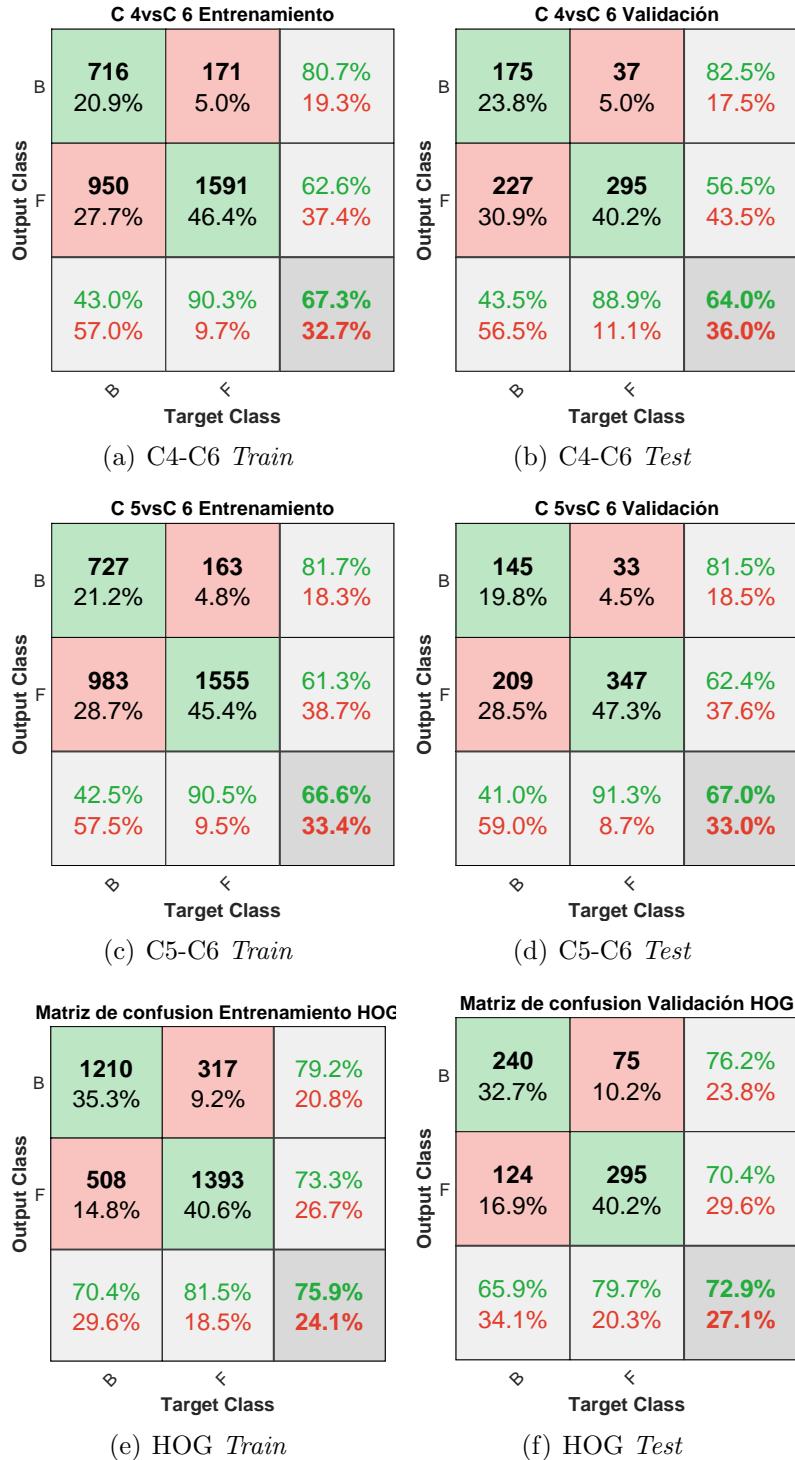


Figura 5.37: Matrices de confusión de entrenamiento y prueba para las combinaciones de características que mejor clasifican las fallas B-F #:6, SCG-CRO.

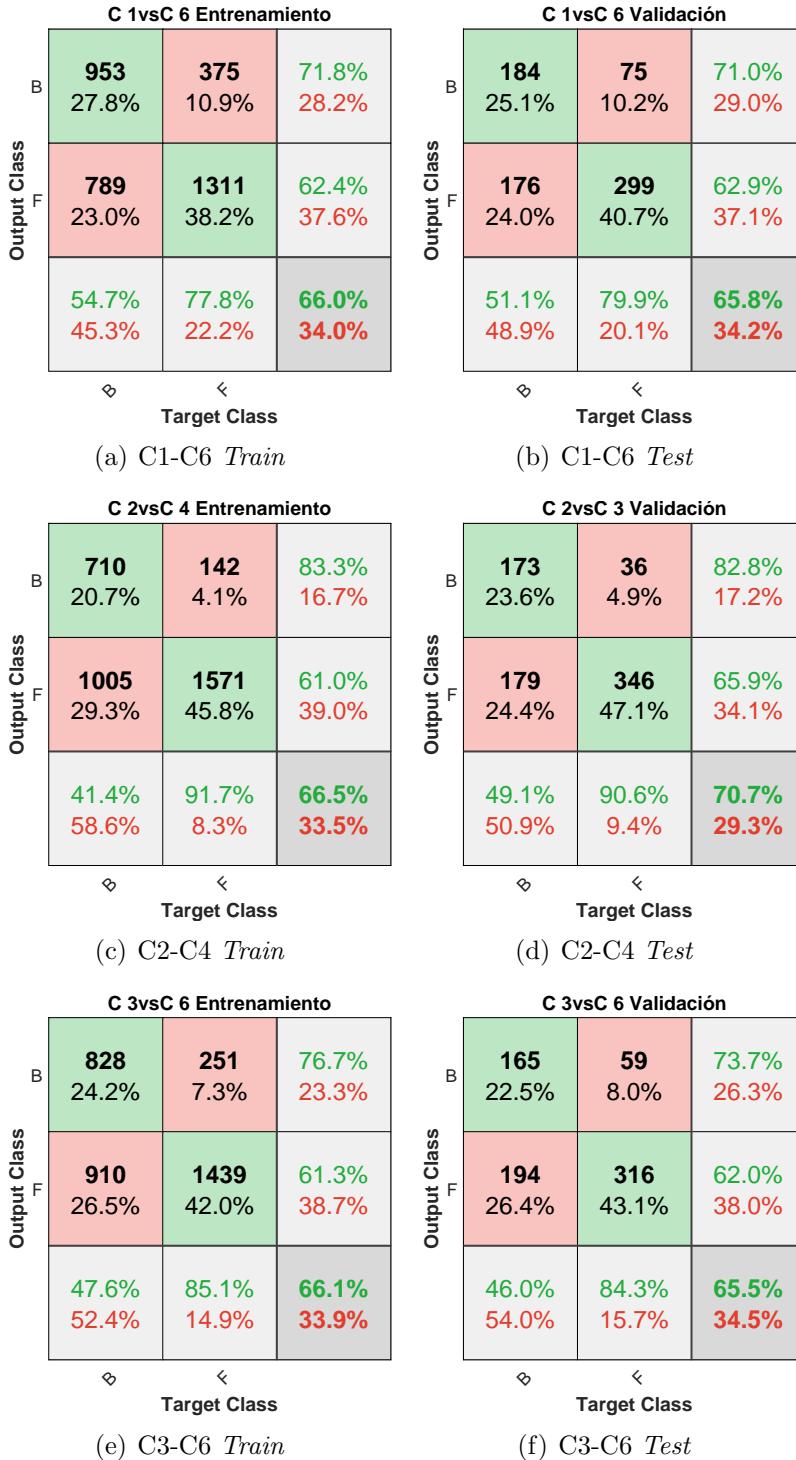


Figura 5.38: Matrices de confusión de entrenamiento y prueba para las combinaciones de características que mejor clasifican las fallas B-F #:8, RBP-MSE.

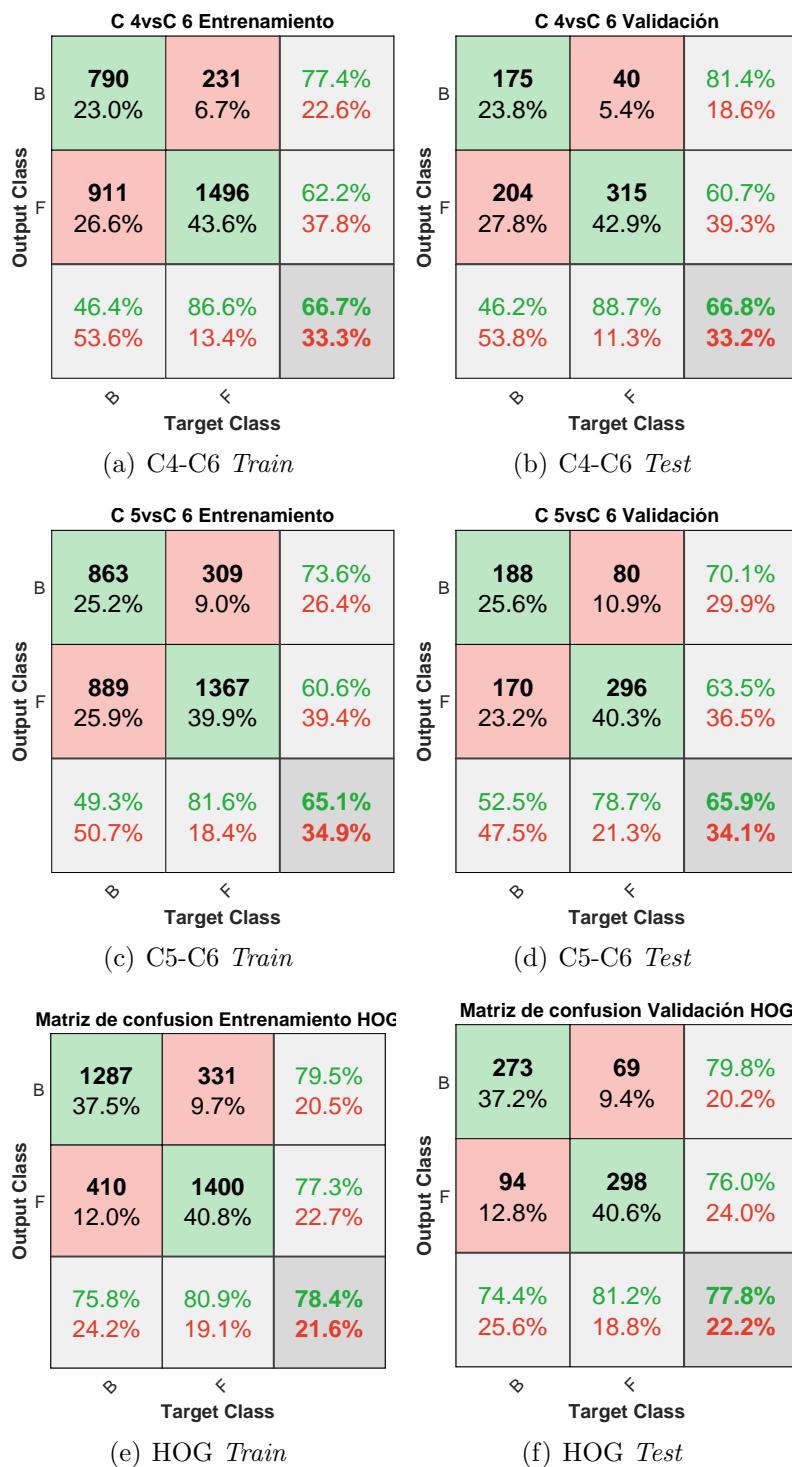


Figura 5.39: Matrices de confusión de entrenamiento y prueba para las combinaciones de características que mejor clasifican las fallas B-F #8, RBP-MSE.

C 1vsC 6 Entrenamiento			C 1vsC 6 Validación			
Output Class	B	F	B	F		
	787 23.0%	175 5.1%	81.8% 18.2%	151 20.6%	35 4.8%	81.2% 18.8%
F	935 27.3%	1531 44.7%	62.1% 37.9%	219 29.8%	329 44.8%	60.0% 40.0%
	45.7% 54.3%	89.7% 10.3%	67.6% 32.4%	40.8% 59.2%	90.4% 9.6%	65.4% 34.6%

(a) C1-C6 *Train*

(b) C1-C6 *Test*

C 2vsC 4 Entrenamiento			C 2vsC 4 Validación			
Output Class	B		B		Output Class	
	True B	False B	True B	False B		
B	824 24.0%	212 6.2%	79.5% 20.5%	189 25.7%	30 4.1%	86.3% 13.7%
F	887 25.9%	1505 43.9%	62.9% 37.1%	201 27.4%	314 42.8%	61.0% 39.0%
	48.2% 51.8%	87.7% 12.3%	67.9% 32.1%	48.5% 51.5%	91.3% 8.7%	68.5% 31.5%
	♂	♀	♂	♀	♂	♀
	Taxón Clase		Taxón Clase		Taxón Clase	

(c) C2-C4 Train

(d) C2-C4 Test

C 3vsC 6 Entrenamiento			C 3vsC 6 Validación				
Output Class	Diamond (◇)		Triangle (▽)		Square (□)		
	B	F	B	F	B	F	
B	790 23.0%	236 6.9%	77.0% 23.0%		186 25.3%	43 5.9%	81.2% 18.8%
F	904 26.4%	1498 43.7%	62.4% 37.6%		191 26.0%	314 42.8%	62.2% 37.8%
S	46.6% 53.4%	86.4% 13.6%	66.7% 33.3%		49.3% 50.7%	88.0% 12.0%	68.1% 31.9%

Target Class

(e) C3-C6 *Train*

(f) C3-C6 *Test*

Figura 5.40: Matrices de confusión de entrenamiento y prueba para las combinaciones de características que mejor clasifican las fallas B-F #:10, RBP-MSE

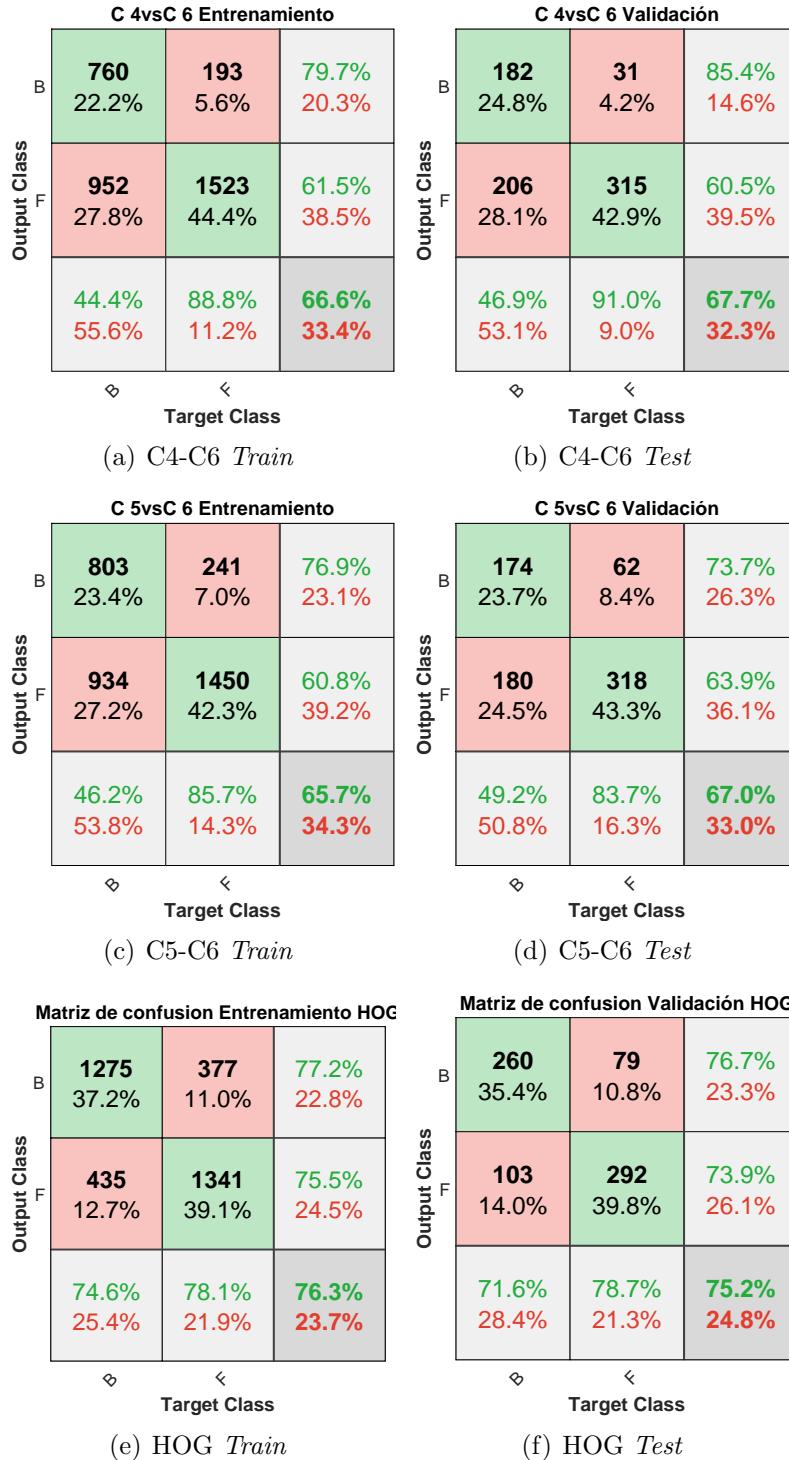


Figura 5.41: Matrices de confusión de entrenamiento y prueba para las combinaciones de características que mejor clasifican las fallas B-F #:10, RBP-MSE.

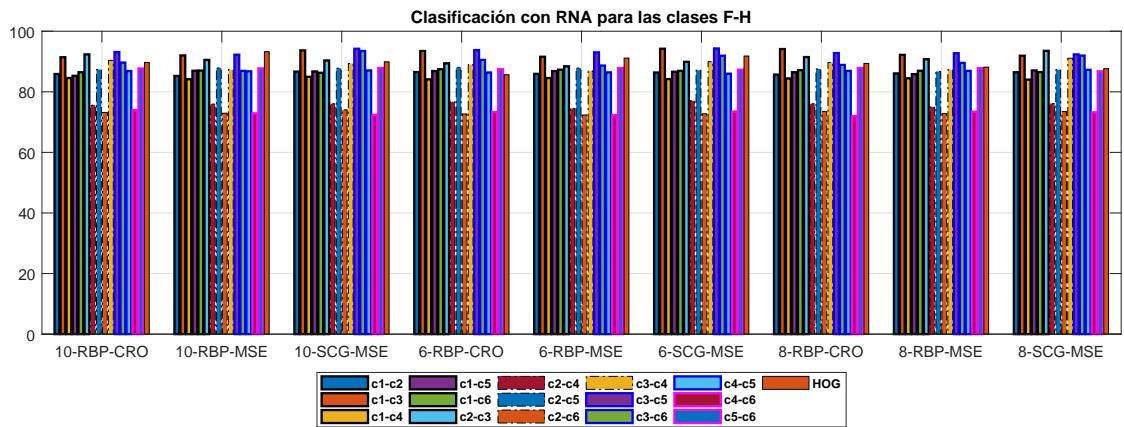


Figura 5.42: Clasificación de las celdas F-Hs a partir de las variaciones de la arquitectura RNA.

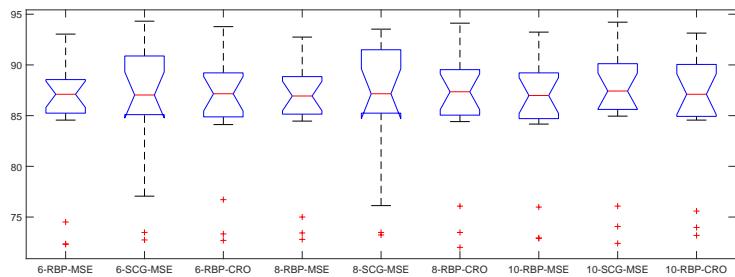


Figura 5.43: Tipos de topologías de las RNA para la clasificación de las clases F-Hs.

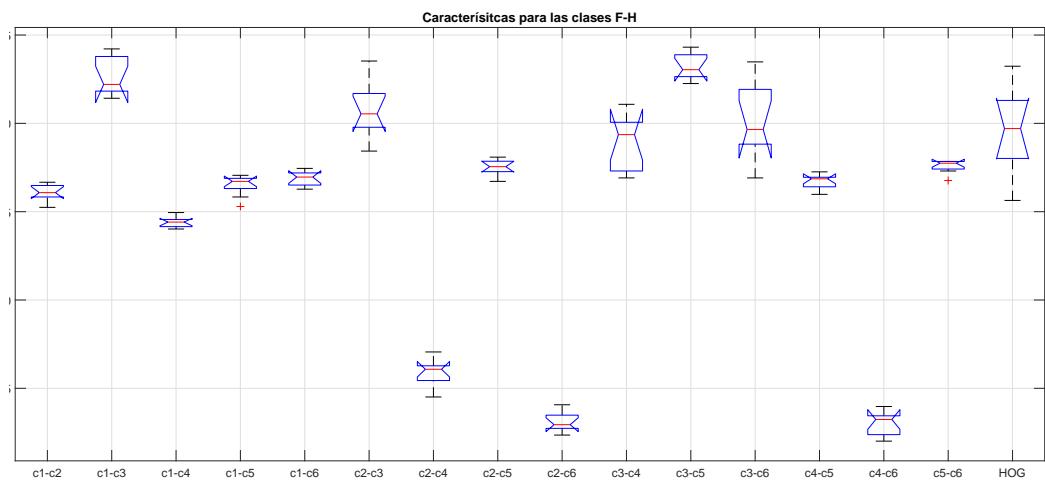


Figura 5.44: Características para la clasificación de las celdas F-Hs.

La clasificación de las fallas F-Hs, con las diferentes topologías para la RNA se presenta en la fig. 5.42. En la fig. 5.43 se analizan las variaciones entre las arquitecturas y su desempeño se encuentra en un rango entre el 80 % y 90 % entre los métodos propuestos, no se encuentran diferencias significativas estadísticas por lo cual se puede seleccionar cualquiera de las configuraciones de la RNA, aunque se presenta mayor repetibilidad para las configuraciones 8-RBP-MSE y 10-RBP-MSE. Por otra parte, las combinaciones de características fig. 5.43 de C1-C3 y C3-C5 permiten discernir mejor el tipo de fallas F-Hs.

A continuación se presentan las matrices de confusión de entrenamiento y validación para la clasificación de las celdas F-Hs.

Tomando 6 neuronas en la capa oculta y una arquitectura RBP-MSE fig. 5.45 a fig. 5.46: la combinación de características que mejor desempeño presentan son C2-C3 fig. 5.45(d) con una precisión del 89.5 % y una identificación de las celdas F de 84.9 % y de las Hs de 93.4 %. Finalmente la mejores características para discernir las fallas fracturada y Hs corresponde a C1-C3 fig. 5.45(b) con una precisión global del 95.5 %, la celda Fracturada es identificada con 96.1 % y la falla *hot spot* con un 94.8 %.

Tomando 8 neuronas y una arquitectura RBP-CRO fig. 5.47 a fig. 5.48: la combinación de características que mejor desempeño presentan son las C2-C3 fig. 5.47(d) con una precisión global del 89.5 % y un acierto en la clasificación de las celdas F del 84.9 % y del *hot spot* de 93.4 %.

Tomando 10 neuronas y una arquitectura RBP-MSE fig. 5.49 a fig. 5.50: se obtiene la mejor precisión global del clasificador con las características C3-C5 fig. 5.45(f) con 95.4 % y un acierto en la identificación de la falla celda fracturada de 96.6 % y para la celda con Hs del 93.7 %.

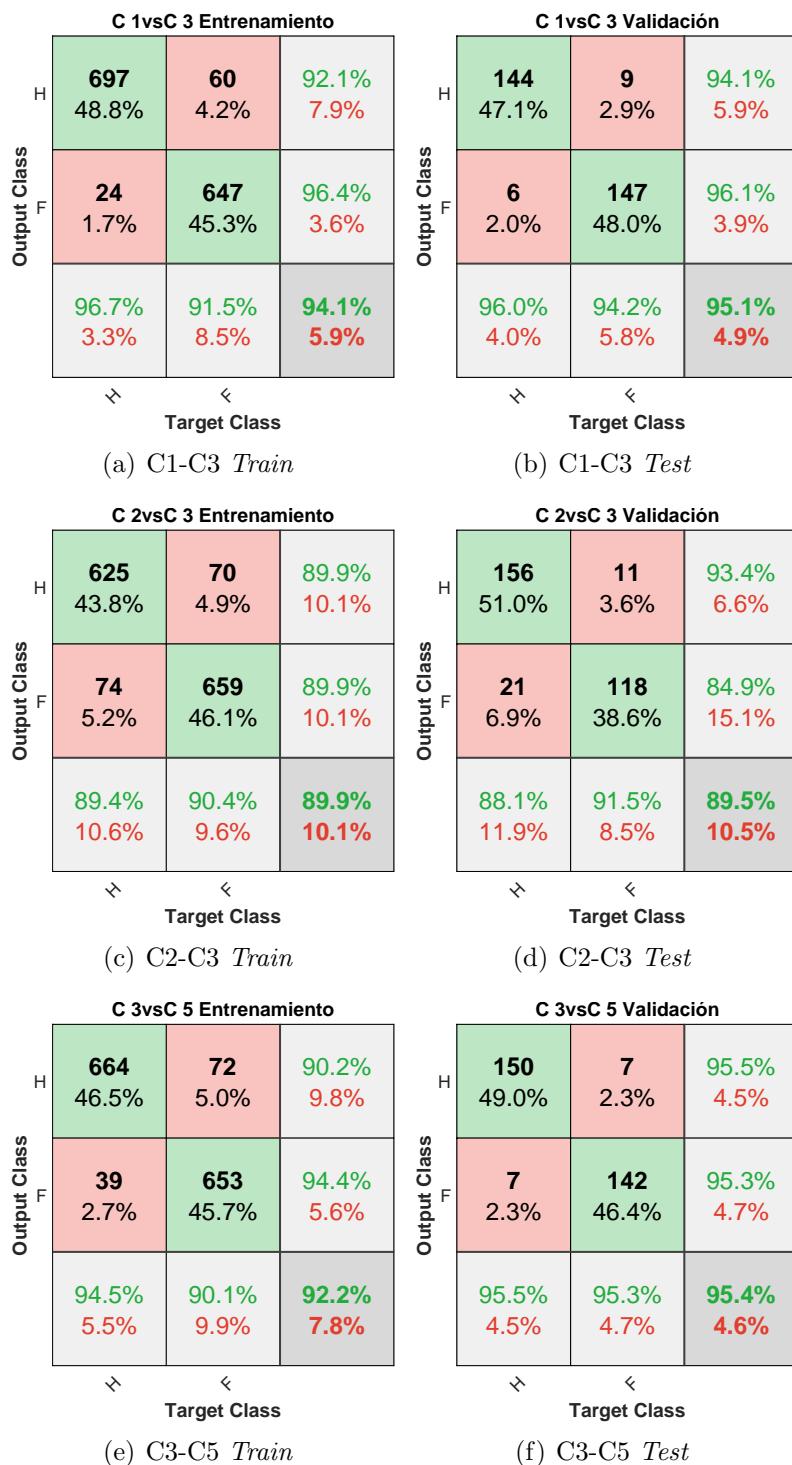


Figura 5.45: Matrices de confusión de entrenamiento y prueba para las combinaciones de características que mejor clasifican las fallas Hs-F #6 RBP-MSE.

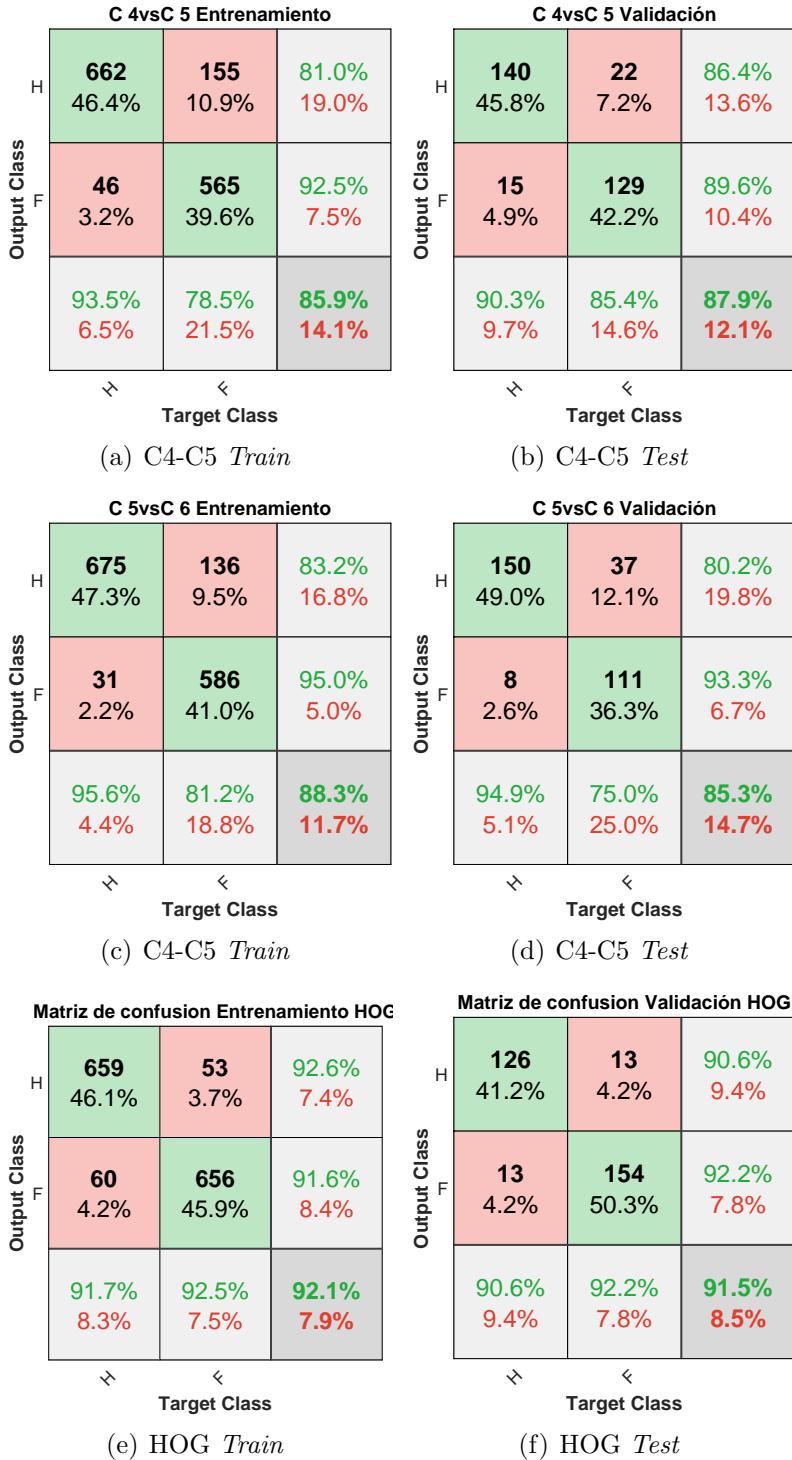


Figura 5.46: Matrices de confusión de entrenamiento y prueba para las combinaciones de características que mejor clasifican las fallas Hs-F #:6 RBP-MSE.

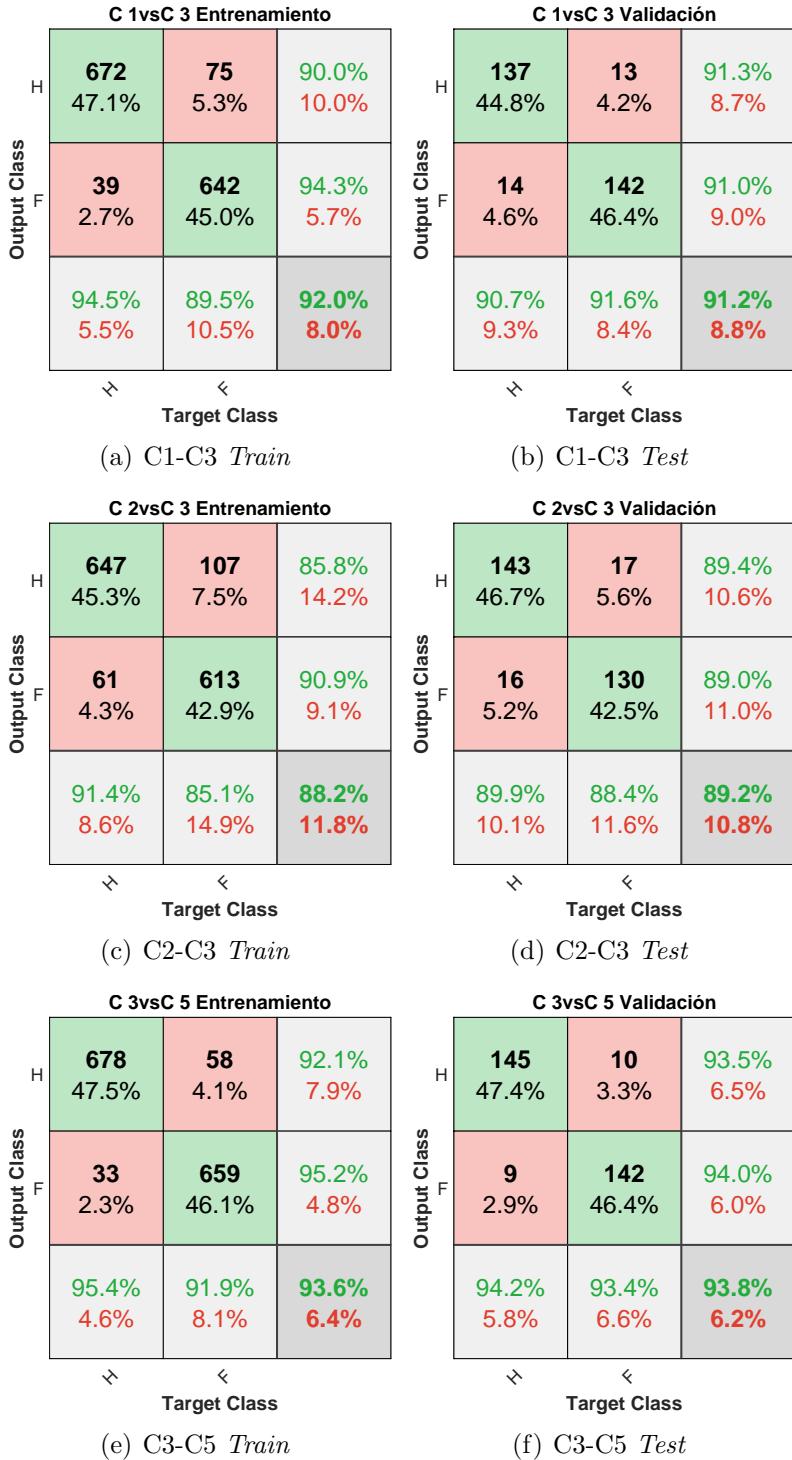


Figura 5.47: Matrices de confusión de entrenamiento y prueba para las combinaciones de características que mejor clasifican las fallas Hs-F #8 RBP-CRO.

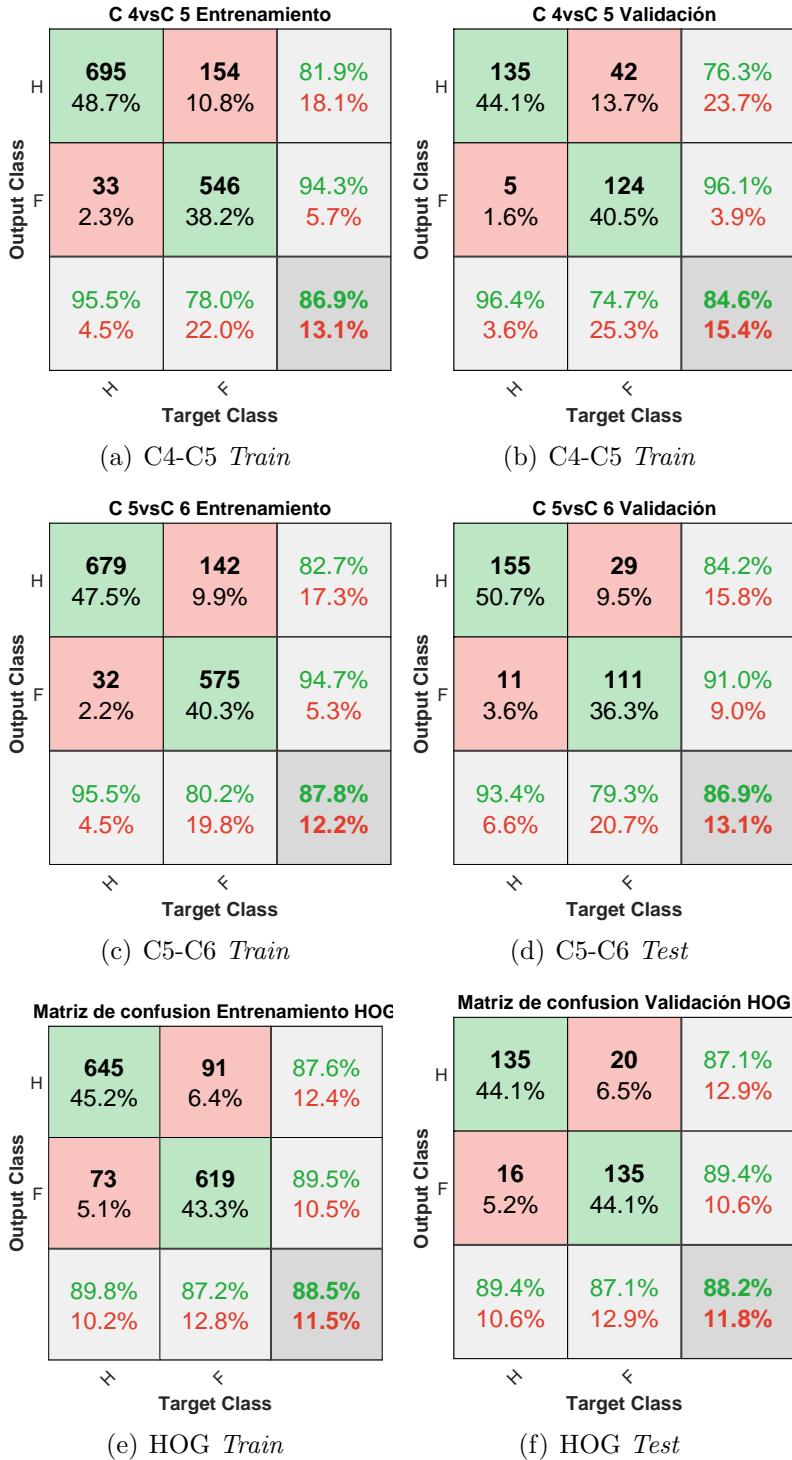


Figura 5.48: Matrices de confusión de entrenamiento y prueba para las combinaciones de características que mejor clasifican las fallas Hs-F #8 RBP-CRO.

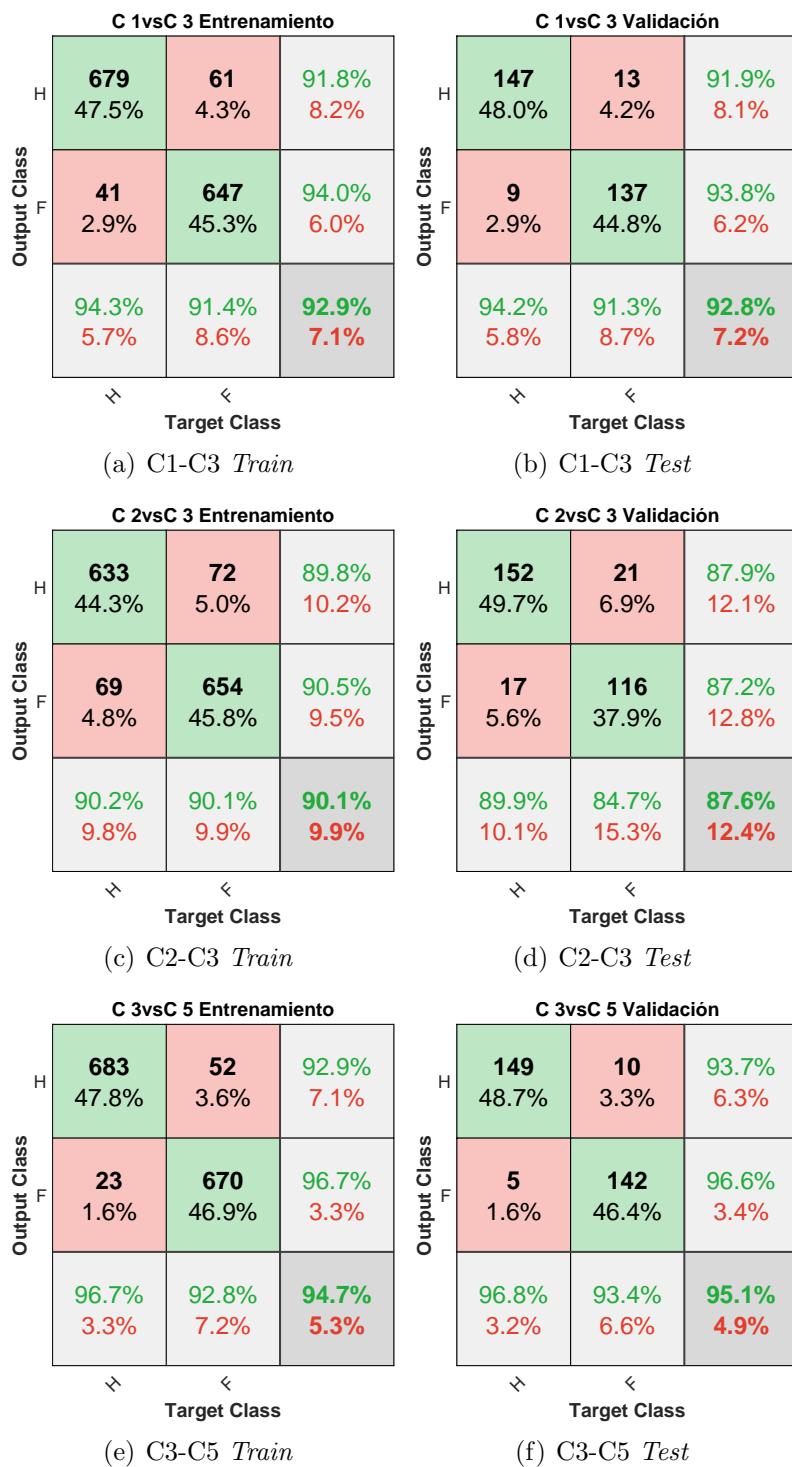


Figura 5.49: Matrices de confusión de entrenamiento y prueba para las combinaciones de características que mejor clasifican las fallas Hs-F #:10 RBP-CRO.

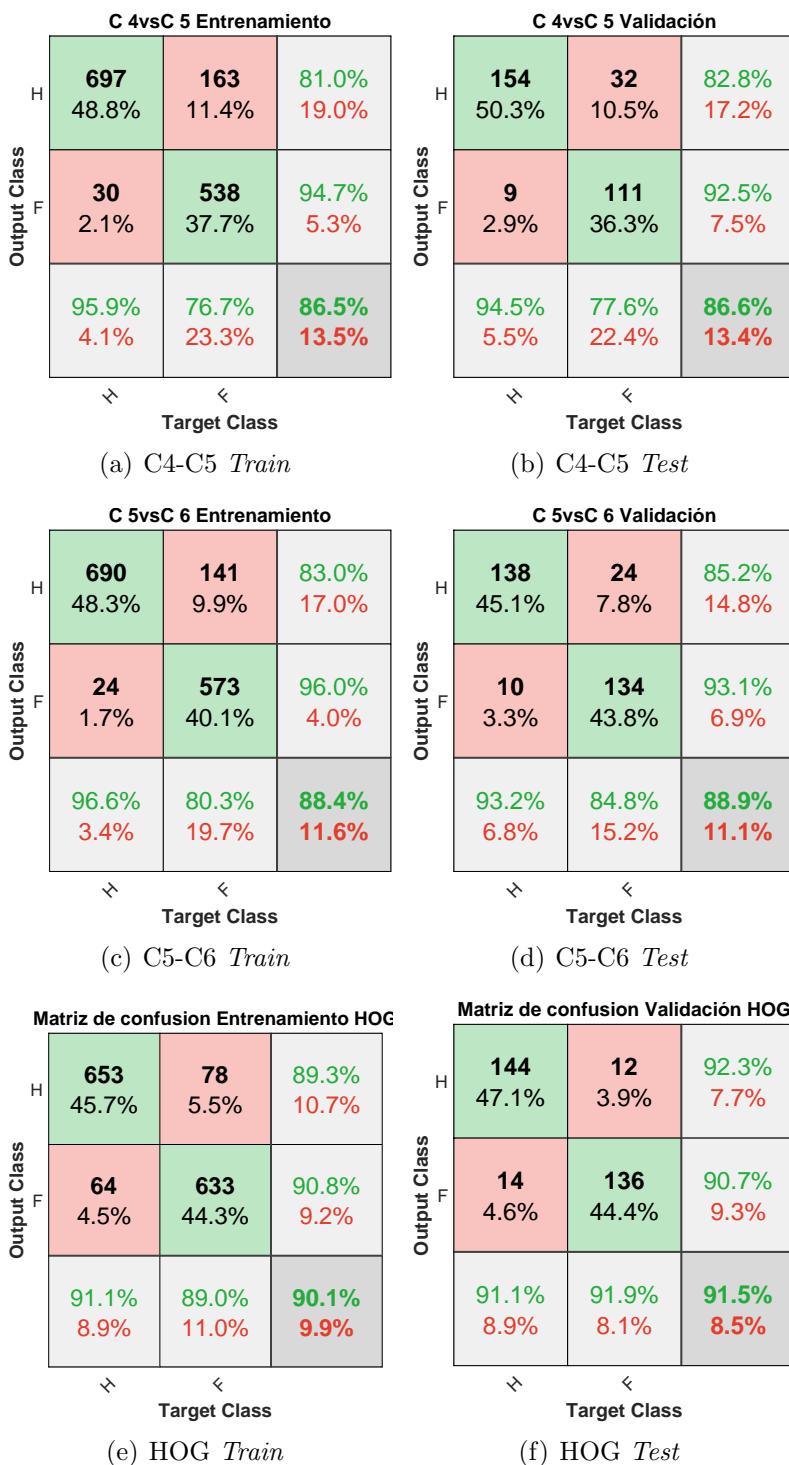


Figura 5.50: Matrices de confusión de entrenamiento y prueba para las combinaciones de características que mejor clasifican las fallas Hs-F #:10 RBP-CRO.

Una vez se finalizaron los experimentos de clasificación a partir de las combinaciones de pares de clases se plantea el estudio de las tres clases Hs-F-B. Las topologías de la RNA quedan resumidas en el diagrama de barras de la fig. 5.51, para este caso en específico no se encuentran diferencias significativas estadísticas por lo cual es posible emplear cualquiera de las topologías estudiadas para la clasificación de las tres fallas. Por otra parte, las mejores características para discernir las tres clases se encuentran con la combinación de C2-C3 como se ilustra en los diagramas de cajas de la fig. 5.53.

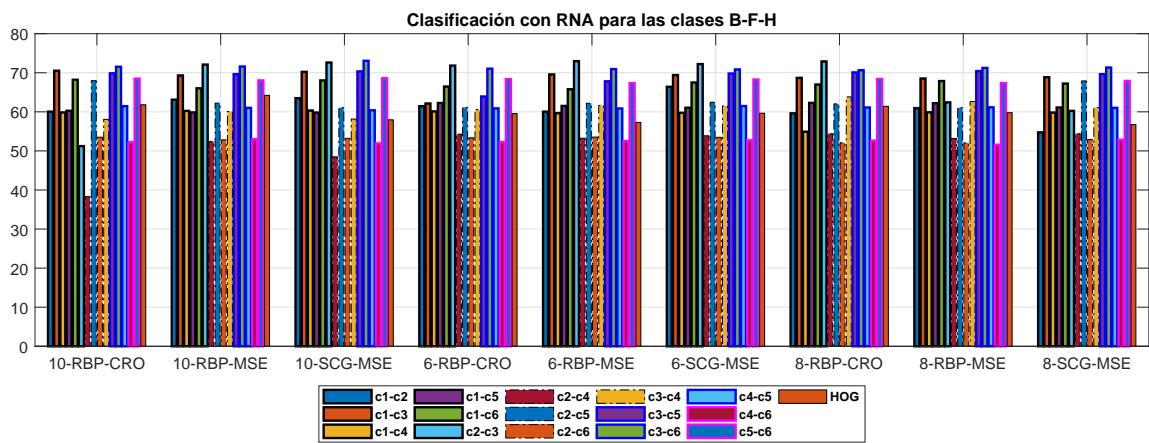


Figura 5.51: Clasificación de las celdas Hs-F-B a partir de las variaciones de las topologías RNA.

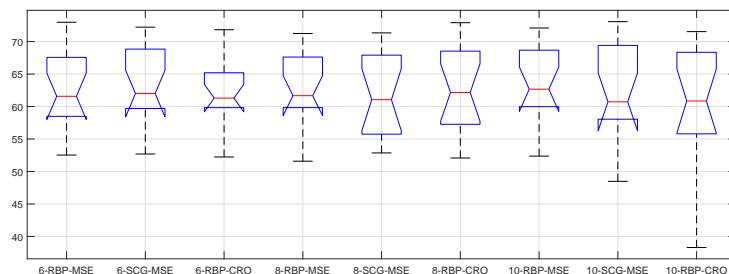


Figura 5.52: Tipos de topologías de la RNA para la clasificación de las clases Hs-F-B.

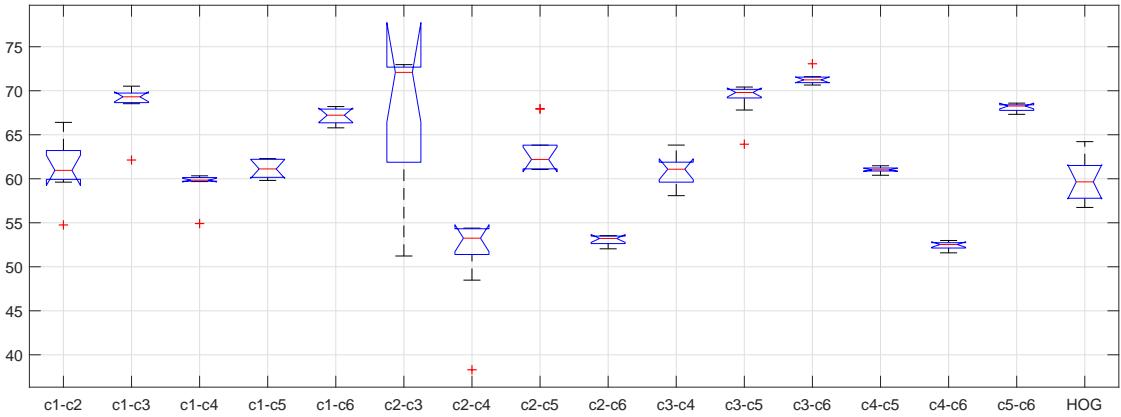


Figura 5.53: Características para la clasificación de las celdas Hs-F-B.

A continuación se presentan las matrices de confusión de entrenamiento y validación para la clasificación de las 3 clases.

Tomando 6 neuronas en la capa oculta y una arquitectura RBP-MSE fig. 5.54 a fig. 5.55: las mejores características para identificar las 3 clases corresponde a C3-C6 fig. 5.54(f) alcanzando una precisión de 74.1 %, un porcentaje de acierto en la identificación de la celda buena del 69.5 %, el *hot spot* fue identificado con un acierto de 66.9 % y finalmente la celda fracturada con un 85.8 %.

Tomando 8 neuronas en la capa oculta y una arquitectura RBP-MSE fig. 5.56 a fig. 5.57: las mejores características para identificar las 3 clases son C5-C6 fig. 5.57(d) con una precisión global del 66.9 %, un porcentaje de acierto para la clasificación de la celda buena del 56.3 %, el *hot spot* fue identificado con 66.5 % y finalmente la fracturada con un 81.6 %.

Tomando 10 neuronas en la capa oculta y una arquitectura RBP-MSE fig. 5.58 a fig. 5.59: la combinación de características para identificar las 3 clases son C3-C6 fig. 5.58(f) con la mejor precisión de los experimentos es del 69.5 %, un porcentaje de acierto para la clasificación de la celda buena del 58.3 %, el Hs se identificó con una precisión 65.6 % y la celda fracturada con un 88.00 %.

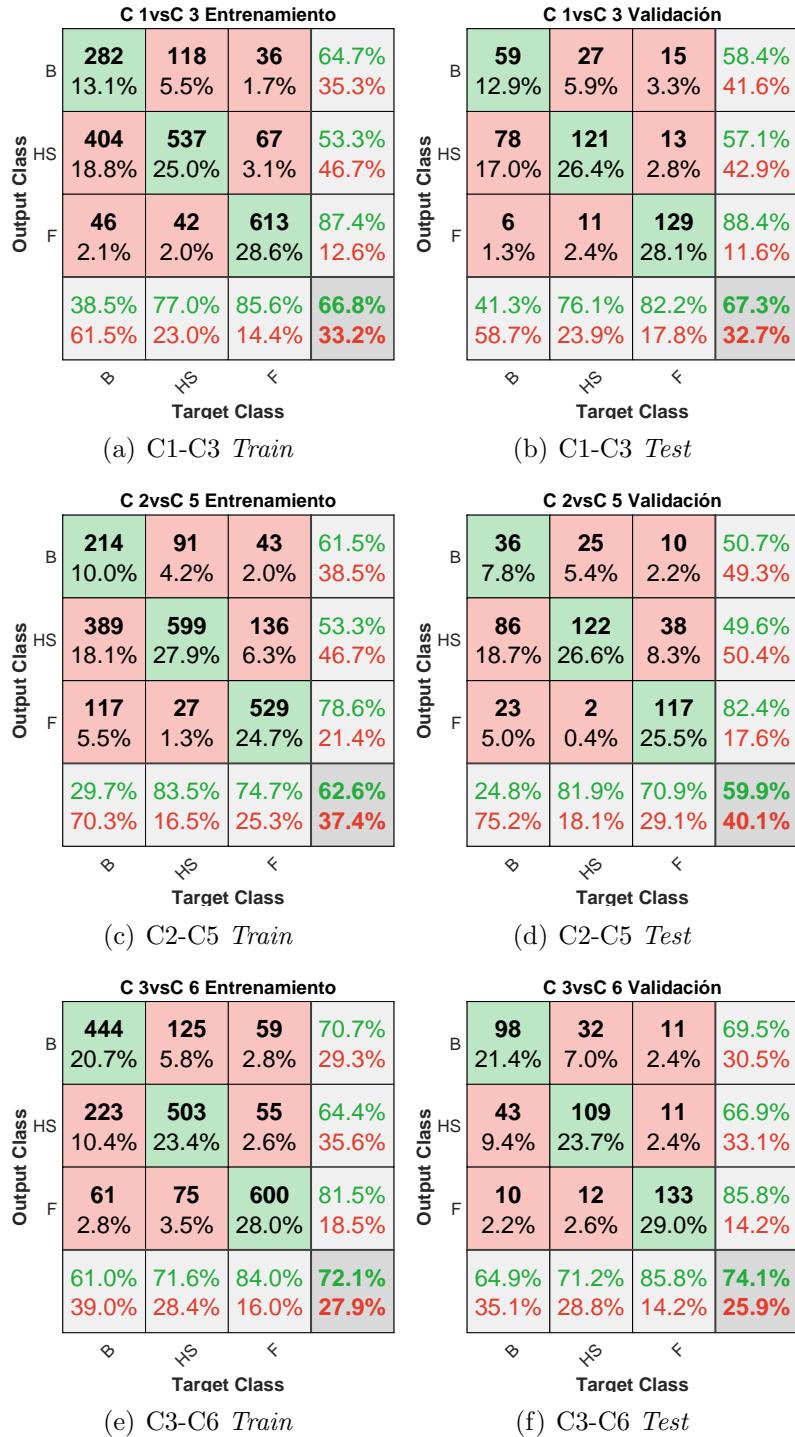


Figura 5.54: Matrices de confusión de entrenamiento y prueba para las combinaciones de características que mejor clasifican las fallas Hs-F-B #:6 RBP-MSE.

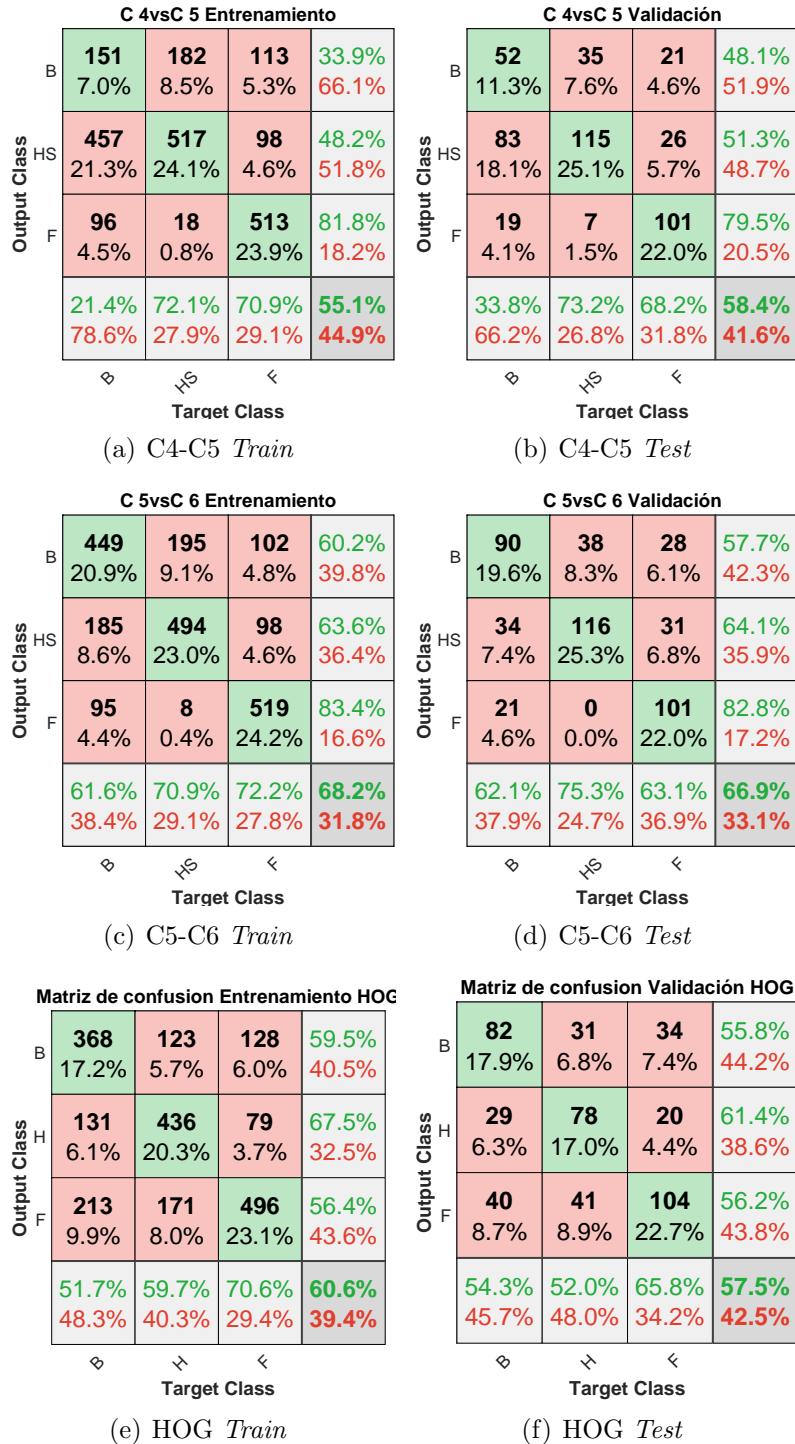


Figura 5.55: Matrices de confusión de entrenamiento y prueba para las combinaciones de características que mejor clasifican las fallas Hs-F-B #:6 RBP-MSE.

C 1vsC 3 Entrenamiento				C 1vsC 3 Validación				
Output Class	Target Class			Output Class	Target Class			
	◊	Hs	↖		◊	Hs	↖	
B	335 15.6%	172 8.0%	52 2.4%	59.9% 40.1%	86 18.7%	29 6.3%	14 3.1%	66.7% 33.3%
HS	343 16.0%	526 24.5%	50 2.3%	57.2% 42.8%	63 13.7%	117 25.5%	8 1.7%	62.2% 37.8%
F	39 1.8%	19 0.9%	609 28.4%	91.3% 8.7%	9 2.0%	4 0.9%	129 28.1%	90.8% 9.2%
	46.7% 53.3%	73.4% 26.6%	85.7% 14.3%	68.5% 31.5%	54.4% 45.6%	78.0% 22.0%	85.4% 14.6%	72.3% 27.7%

(a) C1-C3 Train (b) C1-C3 Test

C 2vsC 5 Entrenamiento				C 2vsC 5 Validación				
Output Class	Target Class			Output Class	Target Class			
	◊	Hs	↖		◊	Hs	↖	
B	155 7.2%	81 3.8%	15 0.7%	61.8% 38.2%	44 9.6%	13 2.8%	2 0.4%	74.6% 25.4%
HS	424 19.8%	619 28.9%	150 7.0%	51.9% 48.1%	91 19.8%	138 30.1%	32 7.0%	52.9% 47.1%
F	141 6.6%	18 0.8%	542 25.3%	77.3% 22.7%	27 5.9%	3 0.7%	109 23.7%	78.4% 21.6%
	21.5% 78.5%	86.2% 13.8%	76.7% 23.3%	61.4% 38.6%	27.2% 72.8%	89.6% 10.4%	76.2% 23.8%	63.4% 36.6%

(c) C2-C5 Train (d) C2-C5 Test

C 3vsC 6 Entrenamiento				C 3vsC 6 Validación				
Output Class	Target Class			Output Class	Target Class			
	◊	Hs	↖		◊	Hs	↖	
B	401 18.7%	121 5.6%	82 3.8%	66.4% 33.6%	84 18.3%	26 5.7%	18 3.9%	65.6% 34.4%
HS	249 11.6%	527 24.6%	67 3.1%	62.5% 37.5%	54 11.8%	129 28.1%	13 2.8%	65.8% 34.2%
F	66 3.1%	53 2.5%	579 27.0%	83.0% 17.0%	15 3.3%	9 2.0%	111 24.2%	82.2% 17.8%
	56.0% 44.0%	75.2% 24.8%	79.5% 20.5%	70.3% 29.7%	54.9% 45.1%	78.7% 21.3%	78.2% 21.8%	70.6% 29.4%

(e) C3-C6 Train (f) C3-C6 Test

Figura 5.56: Matrices de confusión de entrenamiento y prueba para las combinaciones de características que mejor clasifican las fallas Hs-F-B #:8 RBP-MSE.

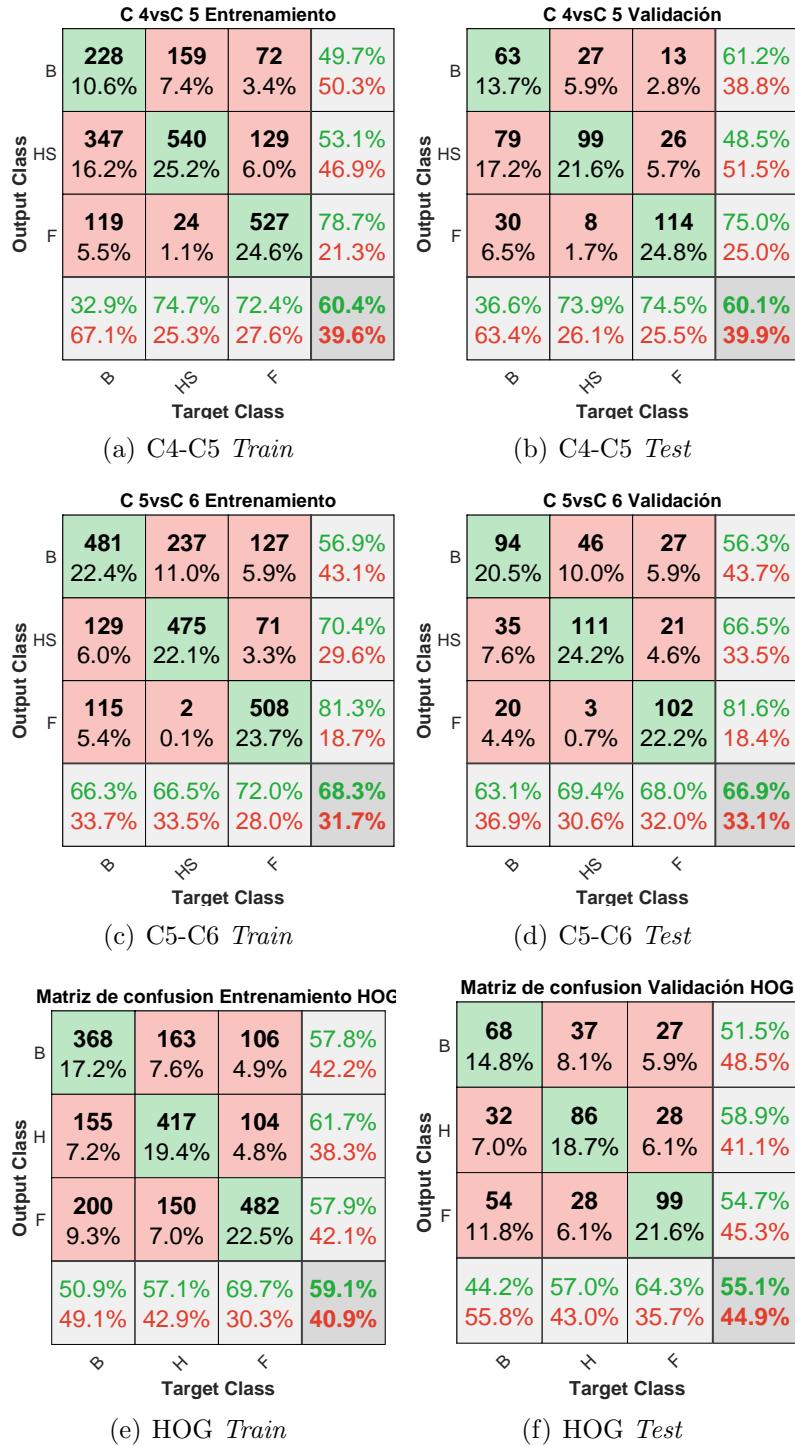


Figura 5.57: Matrices de confusión de entrenamiento y prueba para las combinaciones de características que mejor clasifican las fallas Hs-F-B #8 RBP-MSE.

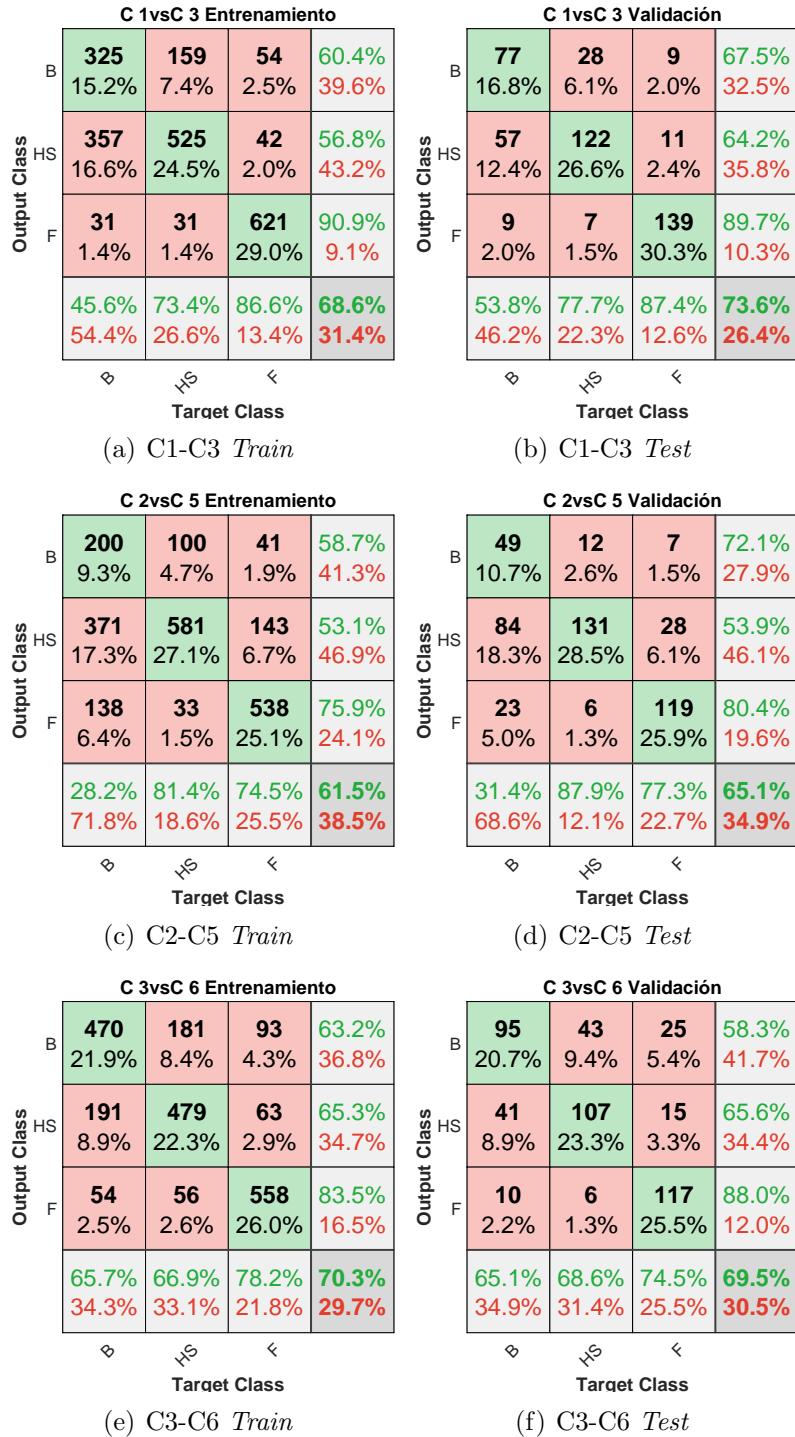


Figura 5.58: Matrices de confusión de entrenamiento y prueba para las combinaciones de características que mejor clasifican las fallas Hs-F-B #:10 RBP-MSE.

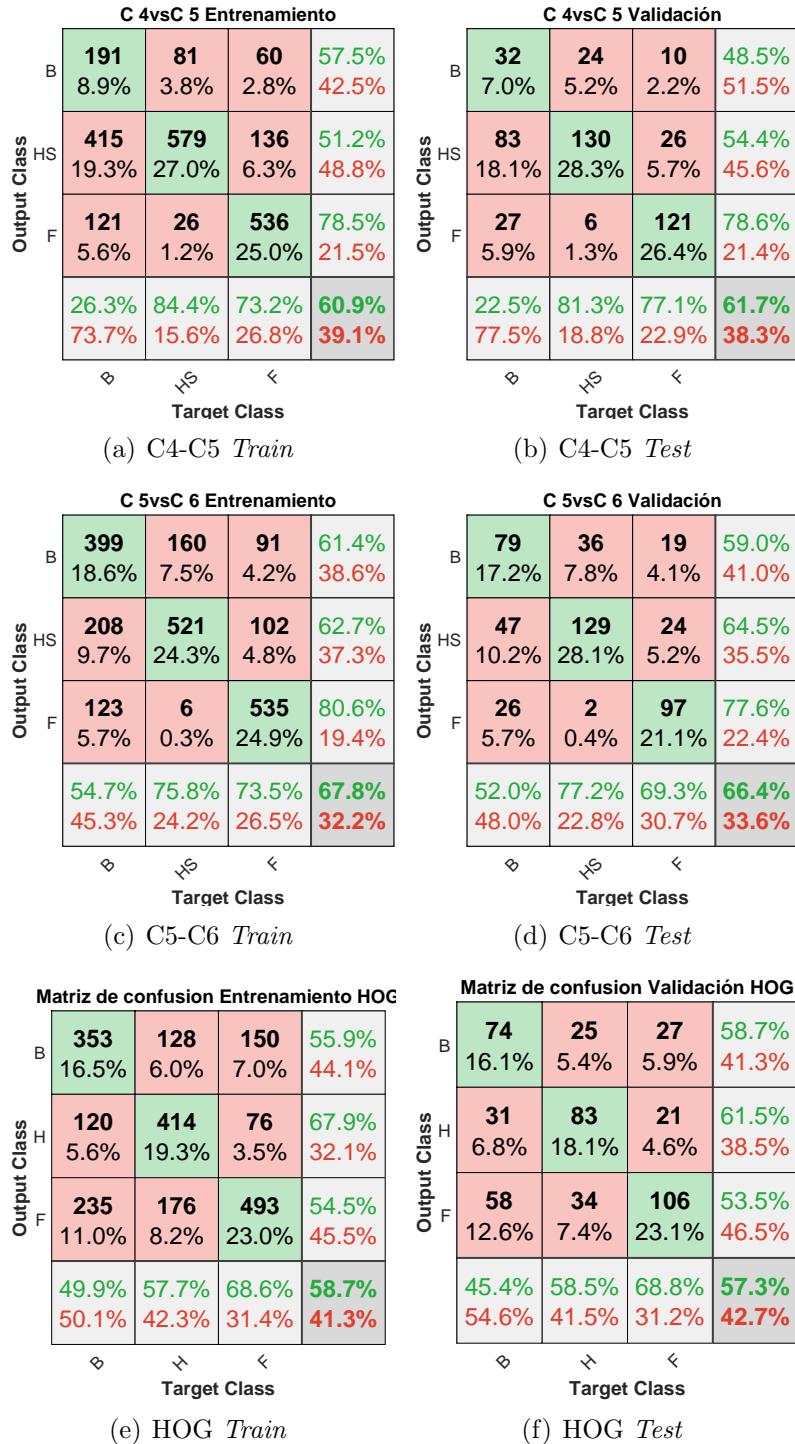


Figura 5.59: Matrices de confusión de entrenamiento y prueba para las combinaciones de características que mejor clasifican las fallas Hs-F-B #:10 RBP-MSE.

5.4. Prueba 3:Clasificación de celdas buenas *hot spot* y celdas fracturada a partir de métodos no supervisados

5.4.1. Finalidad

Clasificación del estado de las celdas Hs-F-B a partir de métodos no supervisados k-medias y sintonización de gausianas.

5.4.2. Descripción

La clasificación de las celdas Hs-F-B con el método no supervisado k-medias se hace a partir de la variación de la cantidad de clústeres $K = 2 : 5$ y las métricas de distancia euclidiana y coseno. Para cada uno de los experimentos biclase se ingresan las combinaciones de las características estadísticas, luego las 14 texturas de Haralick y los 36 HOG.

El método de mezcla de gausianas se implementa variando la cantidad de gausianas de 2 hasta 3 y el tipo de covarianza con los datos del clúster, de la misma forma a la descrita con el método k-medias.

5.4.3. Resultados

En las tablas 5.4, tab. 5.6, se resumen los mejores resultados para la clasificación en los experimentos biclase con sus posibles variantes (Hs-F, F-B y B-Hs) y las tres clases Hs-F-B.

Tipo de falla	Característica	K	Silhouette	K	Precisión
Hs-B	c1-c6	2	0,62	2	64,46
	c2-c6	3	0,76	2	65,10
	c3-c6	3	0,76	2	64,85
	c4-c6	3	0,77	2	64,80
	c5-c6	2	0,63	2	64,75
	HOG	2	0,87	2	72,21
F-B	c1-c6	2	0,64	2	65,93
	c2-c6	2	0,74	2	66,63
	c3-c6	2	0,65	2	65,36
	c4-c5	4	0,70	2	57,17
	c4-c6	2	0,74	2	65,42
	c5-c6	2	0,61	2	65,46
	HOG	2	0,85	3	53,32
F-Hs	c1-c3	2	0,72	2	84,56
	c2-c3	3	0,89	2	80,78
	c3-c5	2	0,73	2	83,48
	c3-c6	2	0,66	2	77,75
	c4-c5	2	0,81	2	79,26
	c4-c6	2	0,77	2	72,16
	c5-c6	2	0,64	2	83,82
	HOG	2	0,87	2	70,34
	c1-c6	2	0,593	3	61,02
Hs-F-B	c2-c5	4	0,712	2	54,49
	c2-c6	4	0,718	2	49,23
	c3-c6	2	0,639	3	63,27
	c4-c5	4	0,734	2	54,49
	c5-c6	3	0,592	3	61,15

Tabla 5.4: Mejores características para clasificar las celdas Hs-F-B empleando el método de k-medias con $k=1:5$ distancia euclídea.

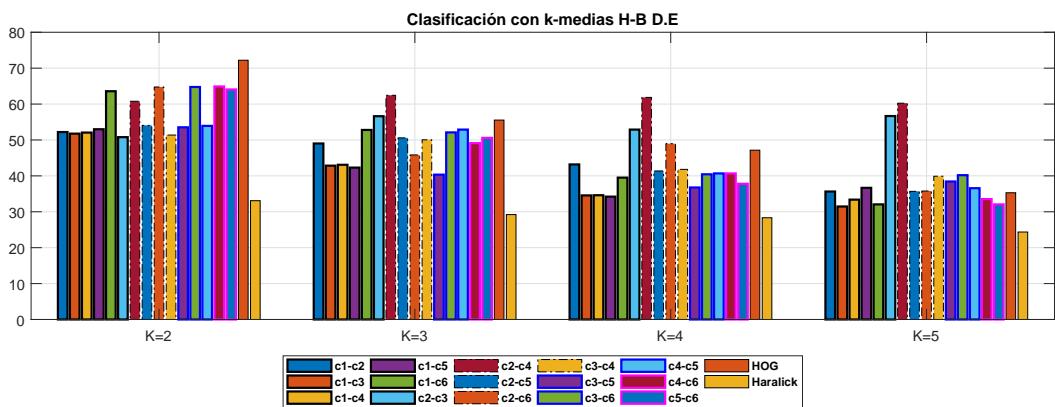


Figura 5.60: Clasificación de las celdas Hs-B con el método k-medias K:2:5 distancia E.

La clasificación de las celdas Hs-B empleando k-medias y la métrica de distancia euclíadiana (E) se reporta en la tab. 5.4. Las mejores características para discernir entre las clases Hs-B son los HOG con una precisión de 72.21 %, la cantidad de clústeres adecuada son $k = 2$, presentando una diferencia estadística significativa en las precisiones alcanzadas por otros valores de K como se ilustra en la fig. 5.61(b), de igual forma la métrica Silhouette fig. 5.62(b) muestra como mejor desempeño el de dos clúster para la agrupación de los datos.

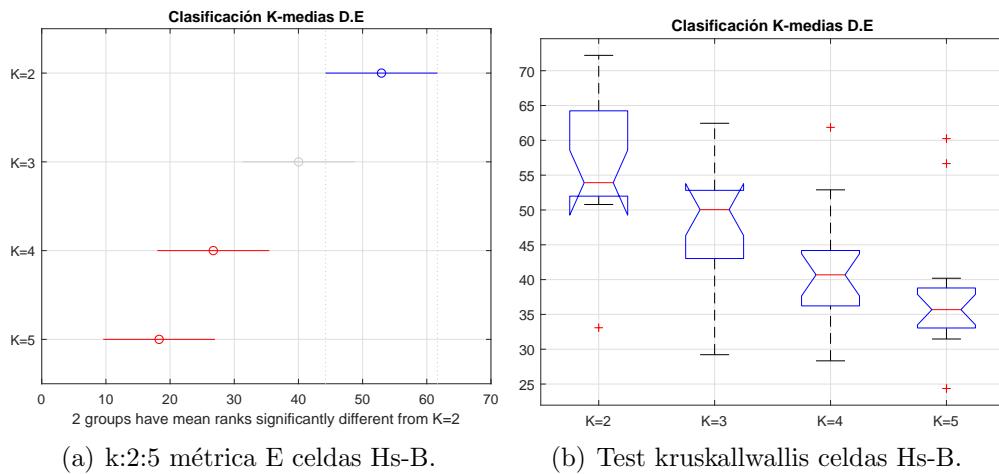


Figura 5.61: Análisis estadístico de la variación de k:2:5 para la clasificación de las celdas Hs-B distancia E.

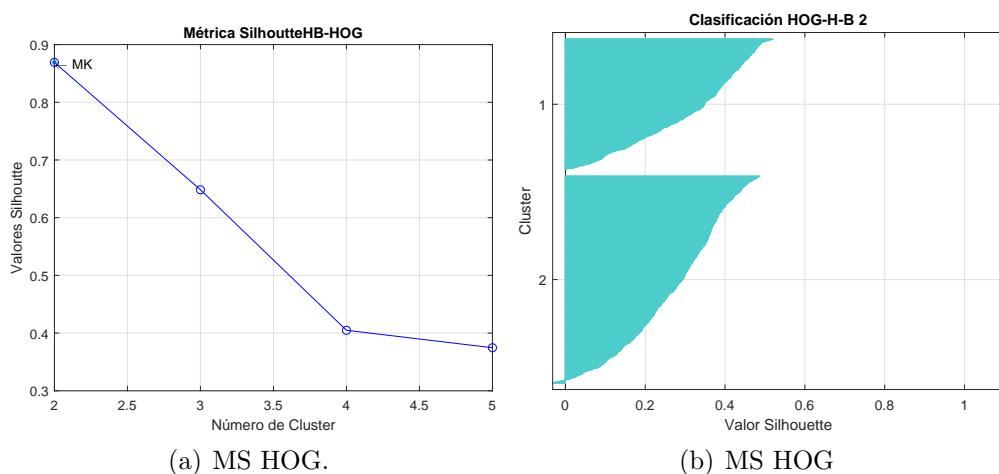


Figura 5.62: Métricas Silhouette para la clasificación de las celdas Hs-B.

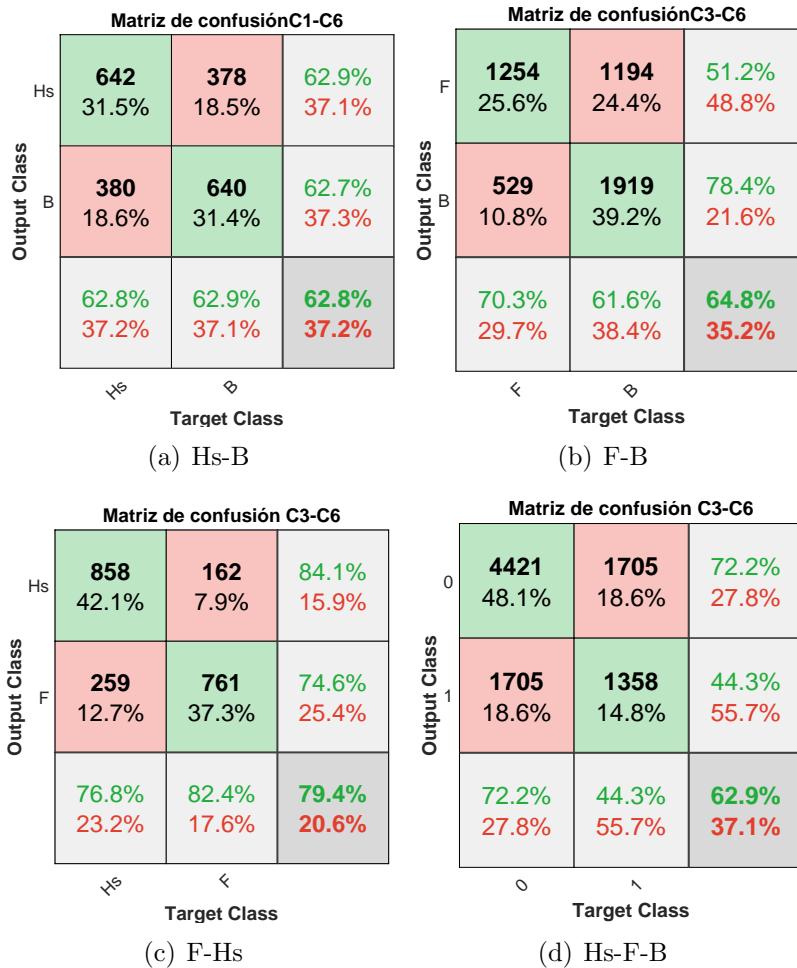


Figura 5.63: Matrices de confusión para el método no supervisado k-medias clasificación de Hs, B, F .

En las fig. 5.63(a), 5.63(b), 5.63(c) y 5.63(d) se ilustran las matrices de confusión para el método no supervisado k-medias y se presentan como mejores resultados para discernir entre las fallas Hs y B la combinación de características C1-C6. Para discernir entre las fallas F-B la combinación de características C3-C6. Finalmente, la clasificación de las tres fallas empleando como vectores de características C3-C6, permiten obtener un desempeño global de 69.2 % formando solamente dos clústeres, aunque lo ideal sería poder separarlo en tres clases correspondientes a cada tipo de falla analizada.

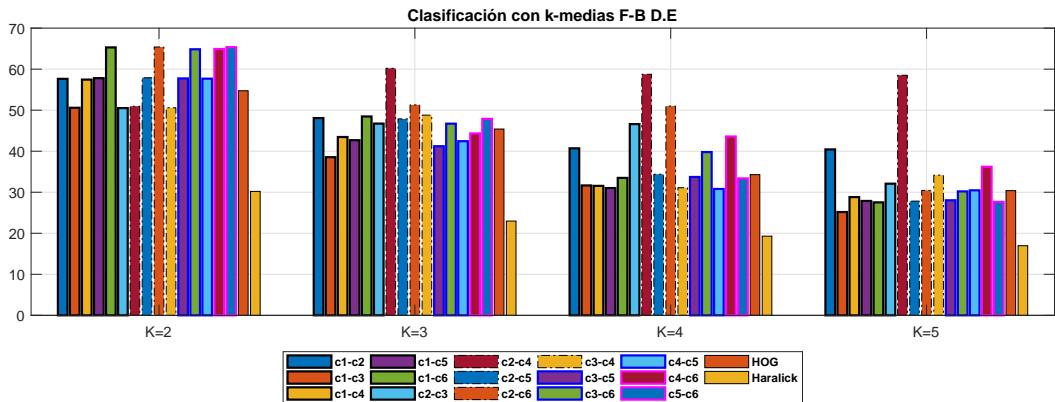


Figura 5.64: Clasificación de las celdas F-B con el método k-medias K:2:5 distancia E.

Las mejores características para clasificar las celdas F-B son los pares C2-C6 ver tab. 5.4 con una precisión del 66.63 %. Por otra parte, entre las posibles agrupaciones exploradas para la cantidad de clúster, $k=2$ presenta una diferencia significativa en las precisiones con respecto a los valores de $k = 4$ y $k = 5$ fig. 5.65(b), de igual forma la métrica Silhouette muestra $k = 2$ como la mejor cantidad de agrupaciones.

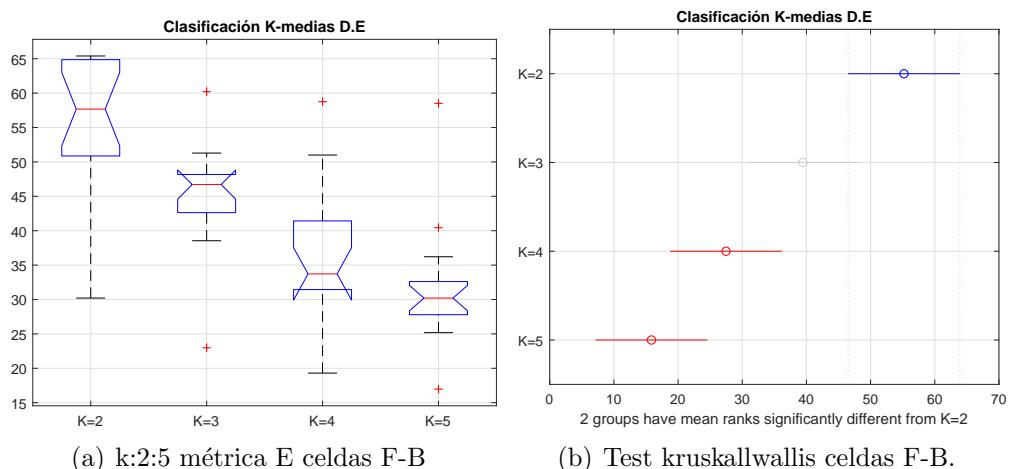


Figura 5.65: Análisis estadístico de la variación de $k=2:5$ para la clasificación de las celdas F-B distancia E.

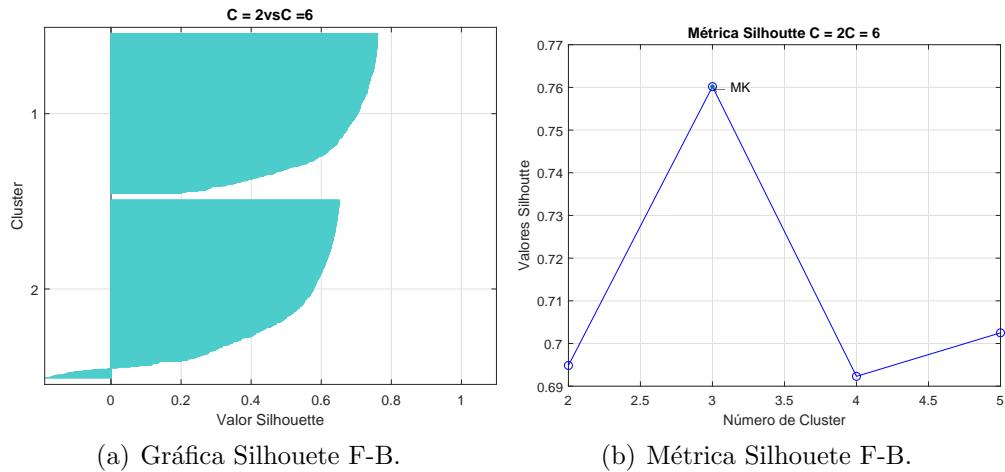


Figura 5.66: Métricas Silhouete para la clasificación de las celdas F-B.

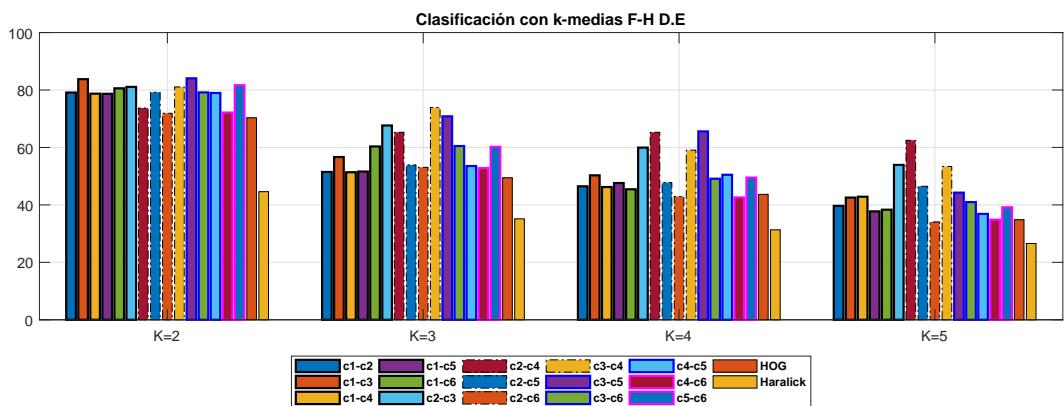


Figura 5.67: Clasificación de las celdas F-Hs con el método k-medias H:2:5 distancia E.

La clasificación de las celdas F-Hs se reporta en la tab. 5.4, las mejores características corresponden a las combinaciones C1-C3 con dos clústeres. El valor de $k = 2$ presenta una diferencia significativa estadística entre los posibles valores de k explorados fig. 5.68(a). La métrica silhouete muestra que la mejor agrupación para los datos correspondientes a las celdas F-Hs son de 2 clúster.

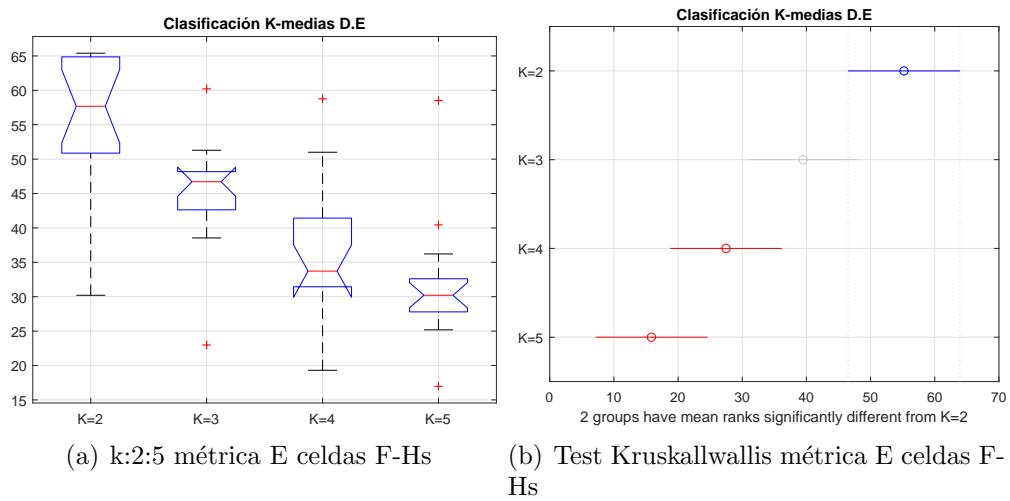


Figura 5.68: Análisis estadístico de la variación de k:2:5 para la clasificación de las celdas F-Hs distancia E.

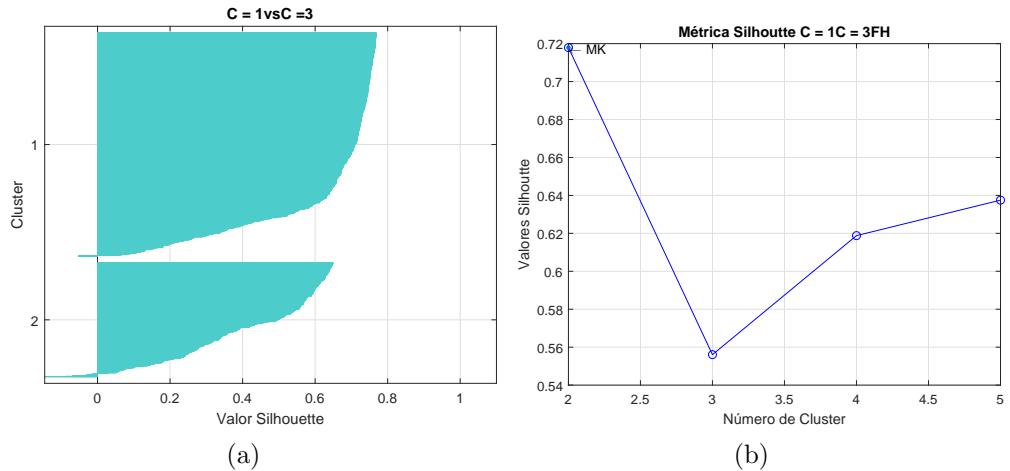


Figura 5.69: Métricas Silhouete para la clasificación de las celdas F-Hs.

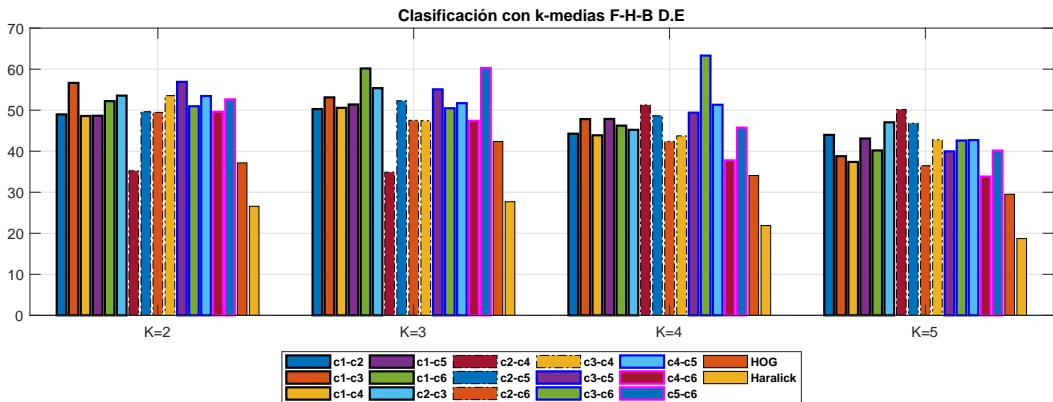


Figura 5.70: Clasificación de las celdas Hs-F-B con el método k-medias K:2:5 distancia E.

Al finalizar los experimentos biclase, inicia el experimento para tres clases con la variación k:2:5 y la métrica de distancia euclíadiana ver tab. 5.4. Las mejores características para la clasificación de las celdas Hs-F-B son las combinaciones de C3-C6, para un total de tres agrupaciones de los datos. La cantidad de clúster adecuada según la métrica silhouette corresponde a $k = 2$, por otra parte la métrica de precisión en la clasificación tiene un total de tres clúster.

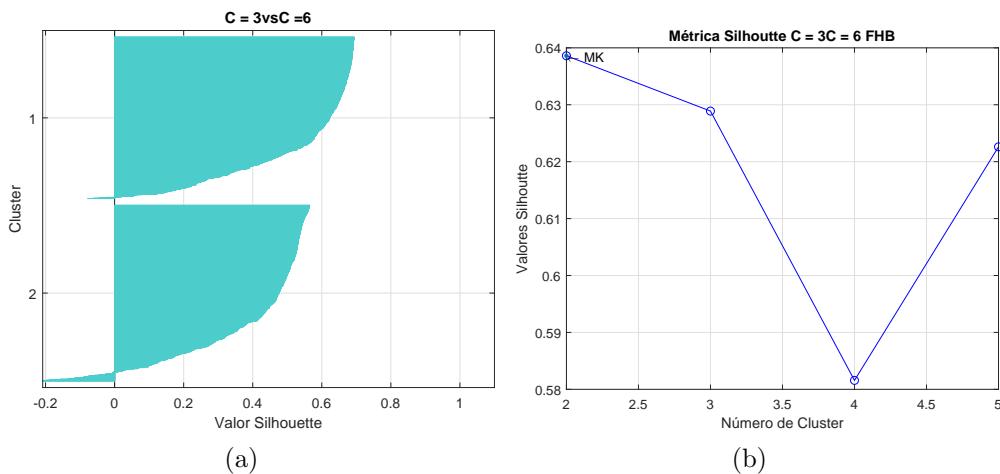


Figura 5.71: Métricas Silhouette para la clasificación de las celdas Hs-F-B.

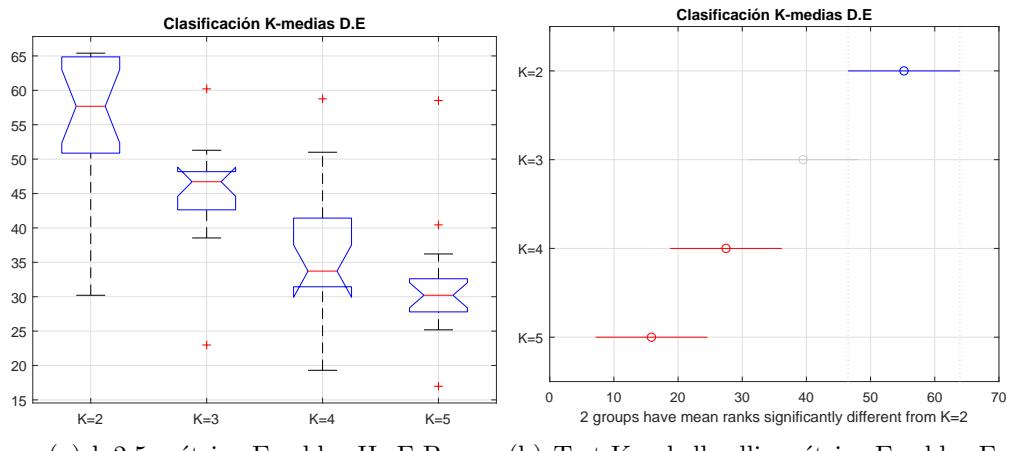


Figura 5.72: Análisis estadístico de la variación de k:2:5 para la clasificación de las celdas Hs-F-B distancia E.

Tipo de falla	Características	K	Silhouette	K	Precisión
B-Hs	c1-c6	2	0,71	2	63,51
	c2-c6	2	0,98	5	61,05
	c3-c6	2	0,74	2	65,16
	c4-c5	3	0,99	3	51,43
	c5-c6	3	0,72	2	63,47
	HOG	2	0,87	2	72,30
F-B	c1-c6	2	0,71	2	65,26
	c2-c4	2	0,99	5	57,95
	c2-c6	2	0,98	5	57,76
	c3-c6	2	0,74	2	62,85
	c4-c5	3	0,99	3	54,58
	c5-c6	3	0,72	2	64,88
F-Hs	HOG	2	0,85	2	54,73
	c1-c3	2	0,81	2	85,88
	c2-c4	5	0,82	3	73,11
	c3-c5	2	0,82	2	85,00
	c4-c5	2	1,00	5	56,74
	c5-c6	2	0,79	2	81,93
Hs-F-B	HOG	2	0,87	2	71,76
	c1-c3	2	0,756	2	59,35
	c1-c5	4	0,736	3	56,40
	c2-c4	2	0,995	5	52,33
	c2-c6	2	0,980	5	51,08
	c3-c5	2	0,792	2	57,89
	c4-c6	2	0,999	4	34,60
	c5-c6	2	0,755	2	55,78
	HOG	2	0,48	3	42,99

Tabla 5.5: Mejores características para clasificar las celdas Hs-F-B empleando el método de k-medias con $k=2:5$ distancia coseno.

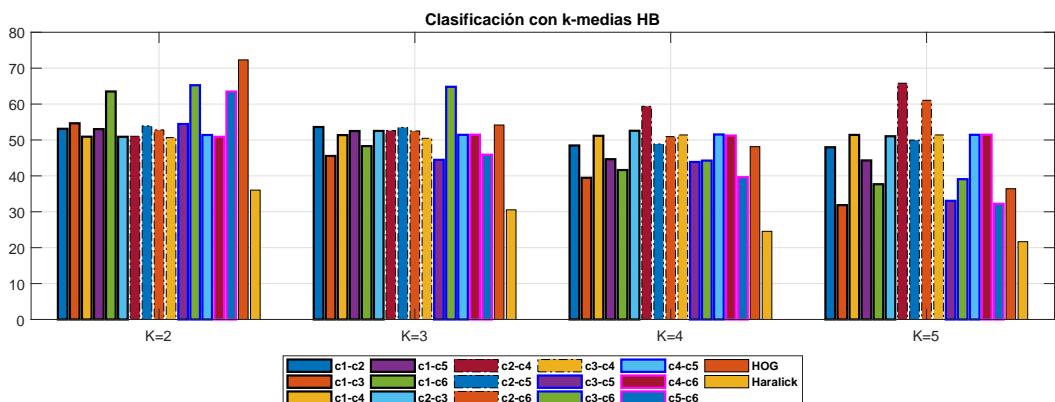


Figura 5.73: Clasificación de las celdas Hs-B con el método k-medias $K=2:5$ distancia coseno.

La clasificación de las celdas Hs-B empleando el método k-medias se hace a partir de la variación de clústeres y de la métrica de distancia establecida para los centroides y los datos. En la tab. 5.5 se resumen los mejores resultados obtenidos de la prueba con la búsqueda exhaustiva de características por experimento biclase y de tres clases.

El diagrama de barras ilustrado en la fig. 5.73 presenta la precisión en la clasificación de las características para agrupaciones de $k=2:5$ de las celdas Hs-B, con la distancia coseno. Las clases Hs-B presentan una mejor clasificación con los vectores HOG, una cantidad de $k=2$ de acuerdo con lo obtenido por las métricas de precisión y silhouette fig. 5.75 encontrándose una diferencia estadística significativa fig. 5.74(a) con respecto a los otros valores de k .

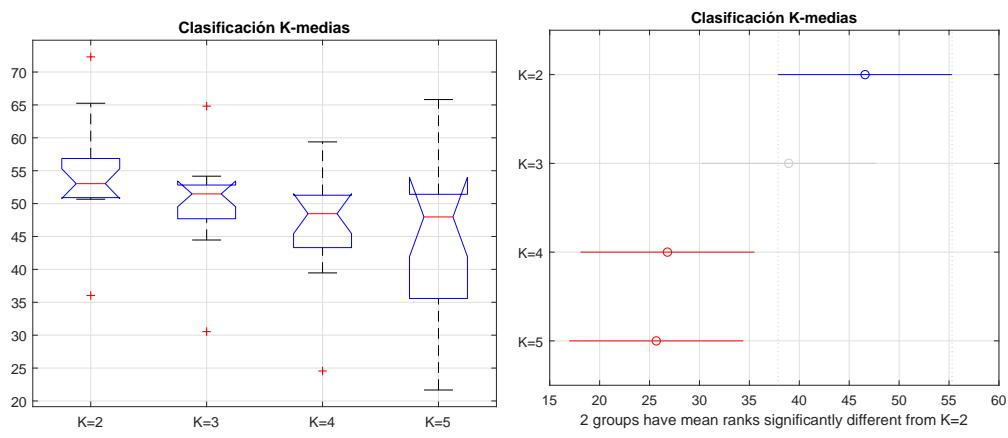


Figura 5.74: Análisis estadístico de la variación de $k=2:5$ para la clasificación de las celdas Hs-B.

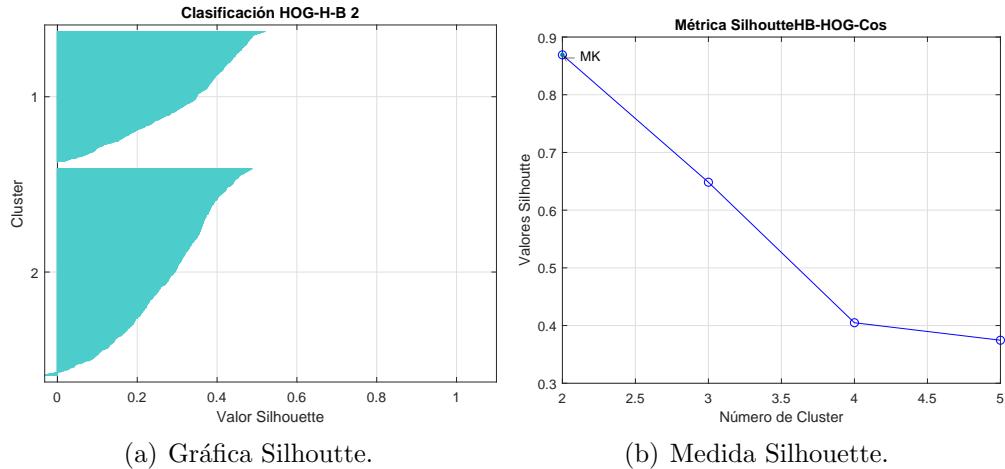


Figura 5.75: Métricas Silhouette para la clasificación de las celdas Hs-B.

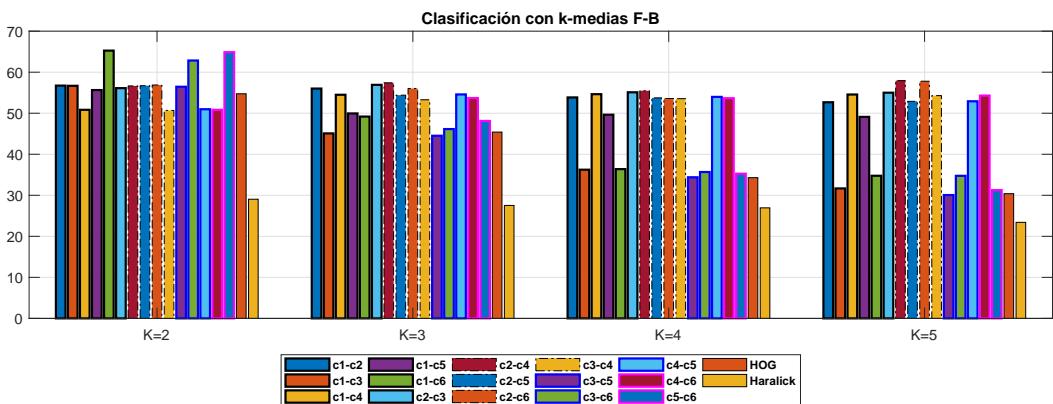


Figura 5.76: Clasificación de las celdas F-B con el método k-medias K=2:5 distancia coseno.

La clasificación de las celdas F-B se hace a partir de las variaciones de $k=2:5$ y se obtiene que la mejor precisión se alcanza con la combinación de características C5-C6 correspondiente a 64,88 % ver tab. 5.5. En la fig. 5.76 se presentan los resultados de precisión para diferentes valores de k , de acuerdo con esto se determina que para $k=2$ se presenta una diferencia significativa estadística fig. 5.77(b) con respecto a los otros valores de posibles agrupaciones. Por otra parte, la métrica silhouete muestra como mejor elección tres clústeres, pero prevalece el que mejor precisión permite que corresponde al de dos agrupaciones.

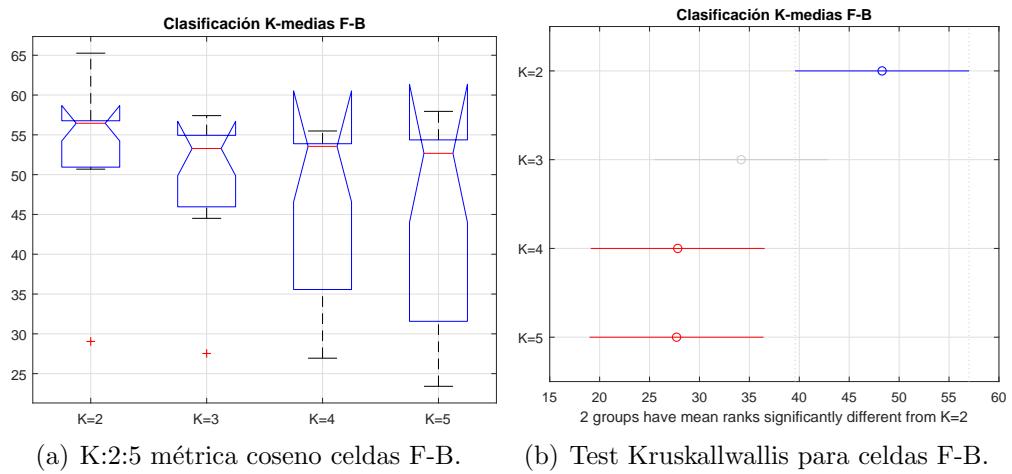


Figura 5.77: Análisis estadístico de la variación k:2:5 con métrica coseno para la clasificación de las celdas F-B.

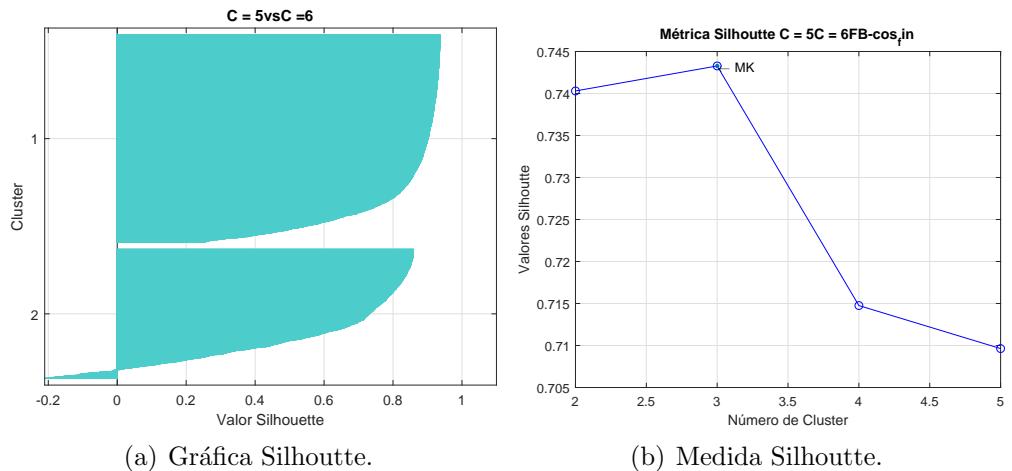


Figura 5.78: Métricas Silhouette para la clasificación de las celdas F-B.

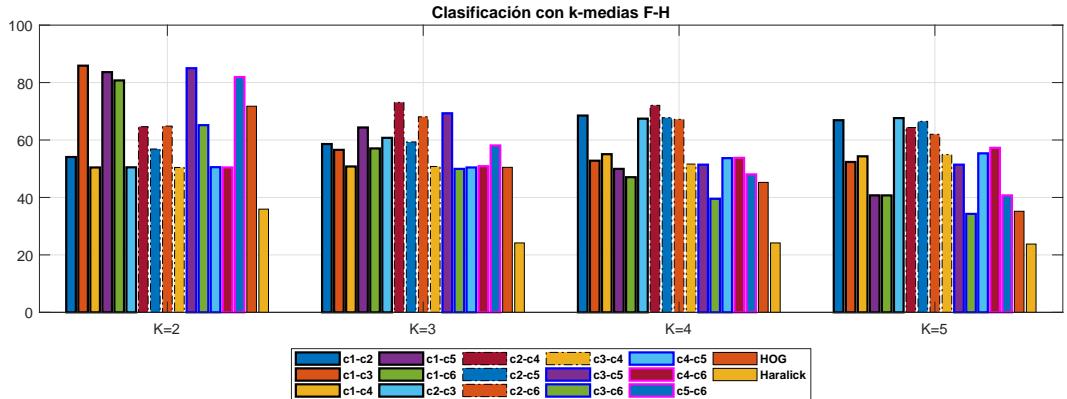


Figura 5.79: Clasificación de las celdas F-Hs con el método k-medias K=2:5 distancia coseno.

El reporte de los resultados de precisión para la clasificación de las celdas F-Hs se ilustra en la fig. 5.79 para diferentes valores de k. Las características que mejor permiten discriminar las clases F-Hs son la combinación correspondiente a C1-C3 con una precisión de 85.88 % seguidos de los HOG con 71.76 % y como las características menos adecuadas las texturas de Haralick ver tab. 5.5 . Por otra parte, k=2 corresponde a la mejor cantidad de clústeres de acuerdo con la la precisión en la clasificación reportándose diferencias significativas con los otros valores de k fig. 5.80(b). Finalmente, la métrica Silhouette da como mejor agrupación tres clústeres.

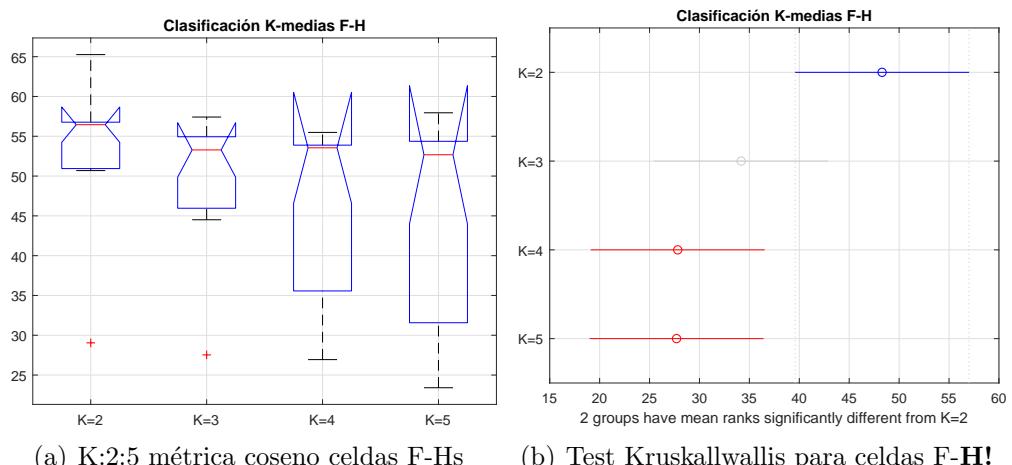


Figura 5.80: Análisis estadístico de la variación k:2:5 con métrica coseno para la clasificación de las celdas F-Hs.

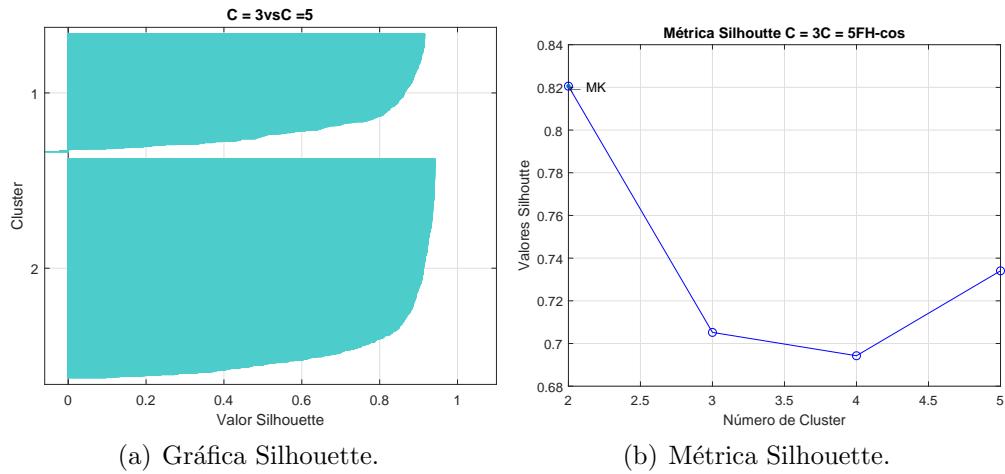


Figura 5.81: Métricas Silhouette para la clasificación de las celdas F-Hs.

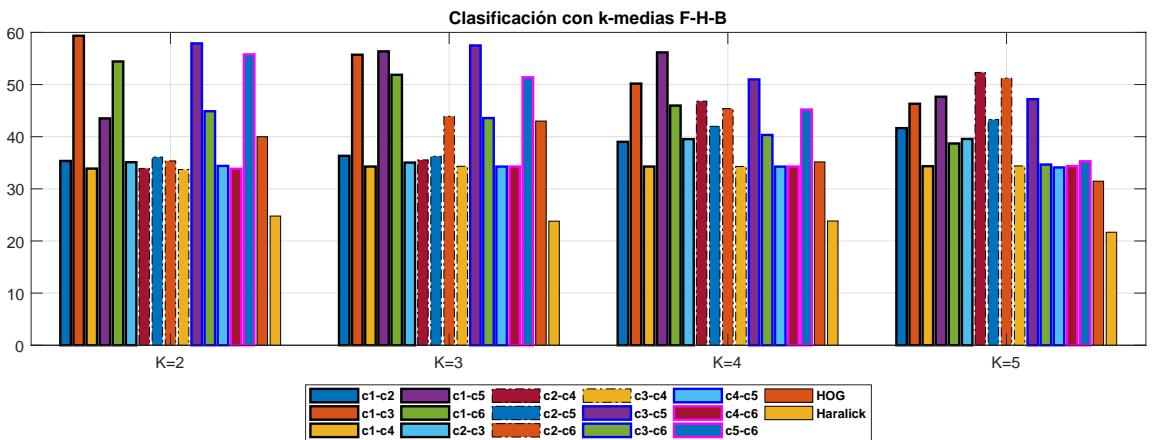


Figura 5.82: Clasificación de las celdas Hs-B-F con el método k-medias K=2:5 distancia coseno.

Una vez finalizan los experimentos de las combinaciones biclase, inicia la clasificación de las tres clases Hs-B-F la precisión en la clasificación se presenta en la fig. 5.82 de acuerdo con la cantidad de k. Las mejores características para discriminar entre las posibles tres clases corresponden a la combinación de C3-C5. Por otra parte, la selección del valor de k entre los buscados no presenta diferencias significativas estadísticas fig. 5.83(b) en cuanto a la precisión de la clasificación de las celdas F-B-Hs. Por otra parte, la métrica silhouette evalúa como mejor cantidad de dos clúster para las características analizadas.

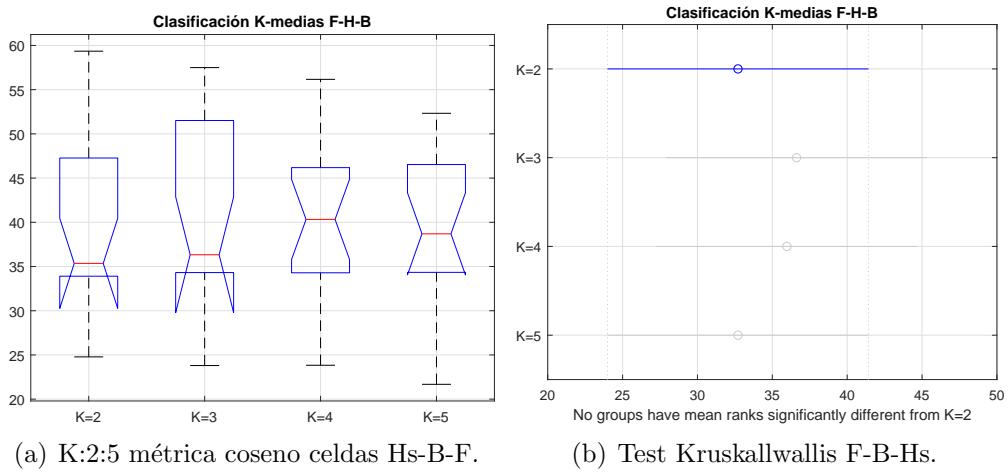


Figura 5.83: Análisis estadístico de la variación de k:2:5 con métrica coseno para la clasificación de las celdas Hs-B-F.

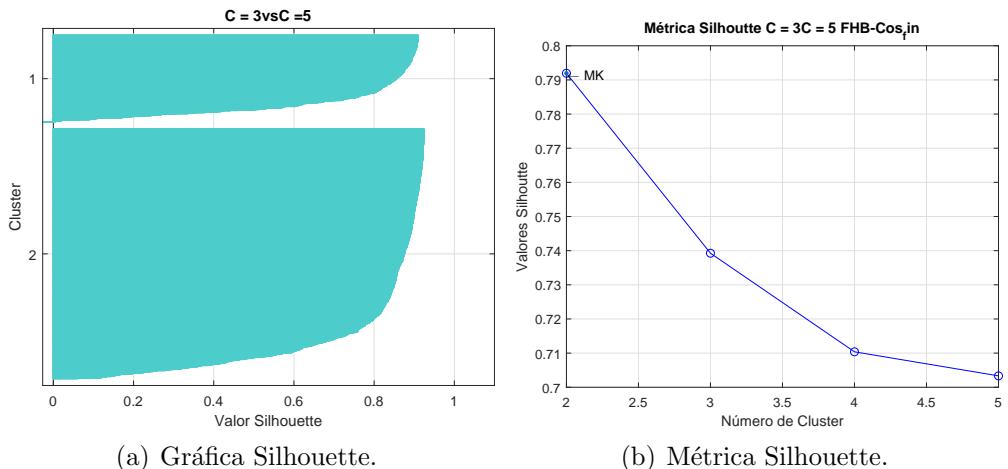


Figura 5.84: Métricas Silhouette para la clasificación de las celdas Hs-B-F.

Al finalizar los experimentos de clasificación biclase y de tres clases con los métodos k-medias se prueban las combinaciones de características con el método de mezcla de gaussianas. En la tab. 5.6 se presentan los mejores combinaciones de características para clasificar las celdas Hs-B correspondientes a C4-C5 con una precisión de 69.8 % para dos gaussianas. Las combinaciones C4-C6 y C5-C6 permiten discriminar las celdas B-F con un 55.04 %, las características permiten diferenciar las clases Hs-F son C2-C3 con una precisión de 80.98 %. Finalmente el experimento con las tres clases al tiempo arroja

que C1-C2 son las mejores características para discernir las tres clases aunque aportan un porcentaje de clasificación poco aceptable. La clusterización obtenida para $k=3$ no mejora el desempeño en la clasificación para ninguno de los bloques expertos propuestos. De acuerdo con la métrica Silhouette la mejor clusterización se obtiene para dos gausianas ver fig. 5.85.

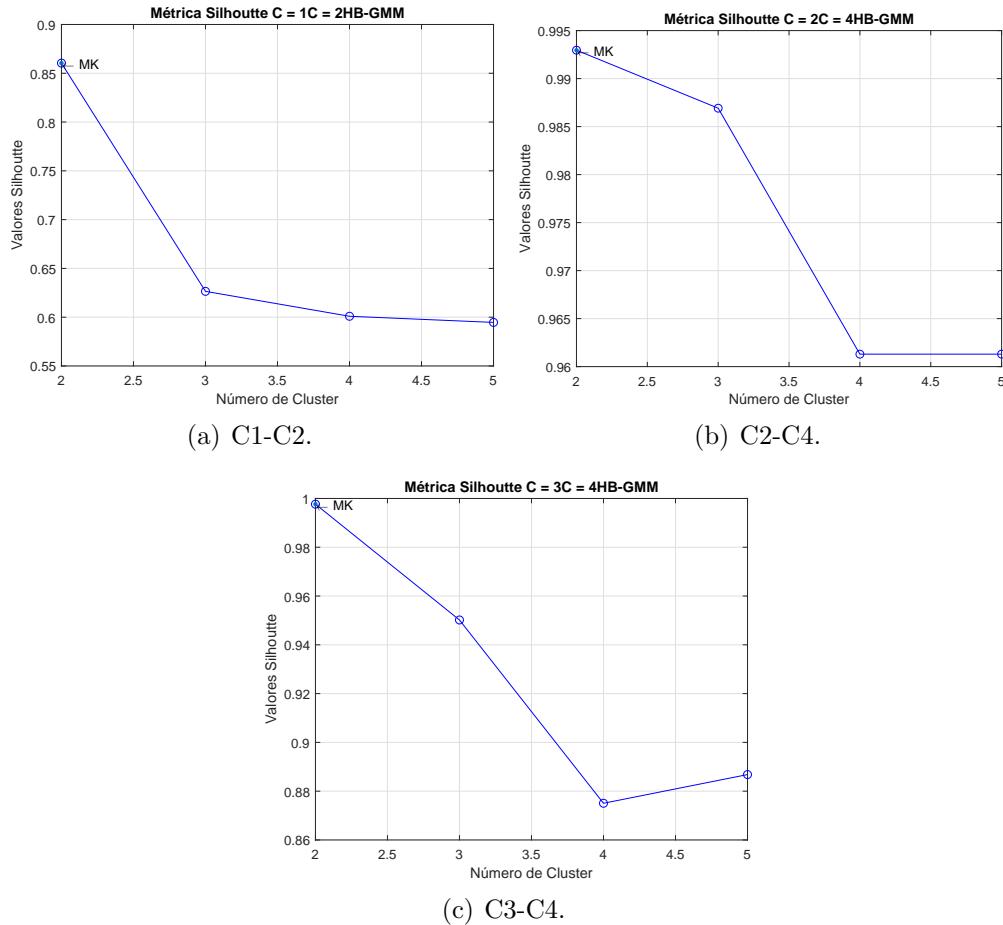


Figura 5.85: Métricas de clasificación Silhouette para la clasificación de las celdas Hs-B.

Clases	Características	Precisión K=2	Precisión K=3
B-F	C1-C2	67,93	65,68
	C2-C4	50,71	55,88
	C3-C5	69,38	51,59
	C4-C5	69,38	48,52
	C5-C6	57,76	53,67
B-Hs	C1-C2	54,41	51,83
	C2-C6	52,89	60,17
	C3-C5	54,01	57,23
	C4-C6	55,78	53,43
	C5-C6	55,78	56,00
Hs-F	C1-C6	80,93	42,54
	C2-C3	80,98	44,73
	C3-C5	70	50,56
	C4-C6	77,40	47,39
	C5-C6	78,57	47,70
Hs-B-F	C1-C2	46,70	38,86
	C2-C4	54,23	34,88
	C3-C6	63,30	38,59
	C4-C5	45,59	47,70
	C5-C6	37,70	39,01

Tabla 5.6: Mejores características para clasificar las celdas Hs-B-F con MG.

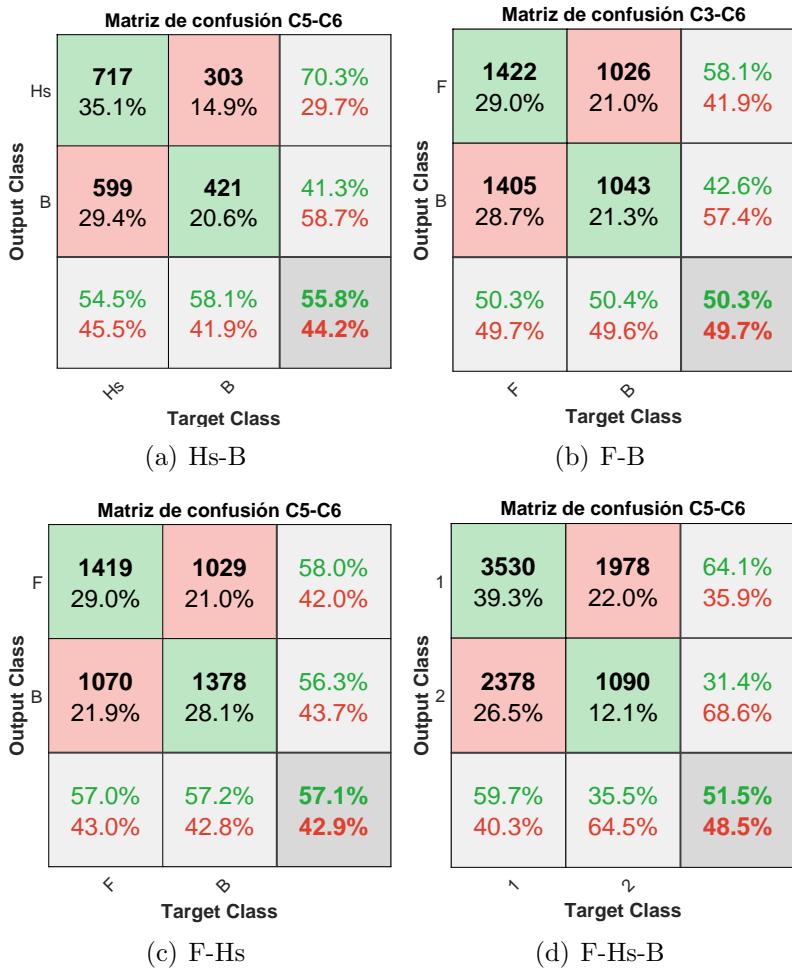


Figura 5.86: Matrices de confusión método no supervisado GMM para la clasificación de Hs-B-F.

En las fig. 5.86(a), 5.86(b), 5.86(c) y 5.86(d), se muestran las matrices de confusión obtenidas para el método no supervisado GMM y se presentan como mejores características para discernir entre las fallas Hs-B la combinación de C5-C6. Por otra parte, para diferenciar las clases F-B la combinación C3-C6. Finalmente, para discernir entre las tres clases Hs-F-B a partir de la formación de dos clústeres la combinación de características C5-C6.

5.5. Conclusiones

El método de clasificación supervisado con SVM y *kernel* RBF sintonizado, presenta una mejora máxima del 32 % y mínima del 2 % en la precisión

de la clasificación, para las fallas estudiadas con respecto a los obtenidos con el RBF-D. De acuerdo con lo anterior, las mejores características para clasificar las fallas Hs-B con el *kernel* RBF son los HOG obteniendo una precisión de 82.92 % para los valores de $c = 2.8$ y $\gamma = 0.2$. Las características menos recomendadas para clasificar las celdas Hs-B son C4-C6.

Las fallas F-B presentan una precisión en la clasificación del 77.02 % con las características HOG y los valores $c=2$ y $\gamma = 0$, superando a la clasificación por defecto en un 9.2 %. El mejor porcentaje de clasificación corresponde a 97.43 % para las celdas F-Hs y se obtiene con las características C2-C3, superando en 15.2 % al RBF-D. Finalmente con el experimento de las tres clases F-Hs-B, se reporta que las mejores características son C2-C3 y C3-C4 con una precisión en la clasificación de 64.80 %, superando al RBF-D en 32 %. Los resultados obtenidos de la variación de los *kernel* para la clasificación de las celdas Hs-B presentan el RBF sintonizado como el mejor método seguido del RBF-D en comparación con los polinómicos. De igual forma, para el caso F-B y Hs-F.

El clasificador RNA se escogió a partir de la variación de parámetros en su topología cantidad de neuronas en las capas ocultas, tipo de función de entrenamiento y desempeño. De acuerdo con lo anterior, para las celdas B-Hs la precisión en la clasificación permanece en rangos constantes por lo cual se pueden seleccionar cualquiera de las topologías estudiadas, presentándose preferencia con la topología de 10 neuronas en la capa oculta con función de activación RBP y función de desempeño MSE para las características C5-C6. La clasificación de las celdas F-B no presentan diferencias estadísticas significativas para las diferentes topologías y se obtiene que las mejores características para discernir entre las dos clases son las HOG.

En las clases F-Hs no se presentan diferencias entre las topologías estudiadas aunque se tienen mejoras para la configuración 8-RBP-MSE y las características C1-C3, C2-C3, C3-C6 y las HOG.

De acuerdo con los experimentos planteados para los métodos supervisados la SVM con *kernel* RBF sintonizado es la mejor arquitectura para la clasificación de defectos.

Los experimentos llevados a cabo con los métodos no supervisados incluyeron las variaciones de las cantidades de clústeres y las métricas de distancia y covarianza de los datos. El método k-medias en la clasificación biclase presentó los siguientes resultados: las celdas Hs-B alcanzan una mejor clasificación para una cantidad de $k=2$ con los vectores de características HOG y distancia euclidiana. Las celdas F-B tiene una mejor clusterización con las características C2-C6 y un $k = 2$ de acuerdo con las métricas de precisión y silhouette. Las celdas F-Hs presentan una mejor clasificación para la combinación de características C1-C3 y un valor de $k = 2$ con métrica de distancia euclidia-

na. Finalmente el experimento F-Hs-B presenta la mejor clasificación con la combinación de características C3-C6 y un $k=3$. Las métricas de distancia euclídea y coseno no tienen diferencias de desempeño en la clasificación superiores al 2 %, por lo cual se puede implementar la distancia euclídea que presenta un menor esfuerzo computacional.

Los resultados obtenidos con la mezcla de gausianas presentan los siguientes desempeños : para la clasificación de las celdas B-Hs una precisión de 69.80 % con las características C4-C5. Las clases F-B 55.04 % con C4-C6 y Hs-F 80.98 % C2-C3 y Hs-F-B 46.70 % C1-C2.

Finalmente se encuentra como patrón recurrente las ventajas ofrecidas de los HOG como vectores de características para discriminar el estado de las celdas tanto en los métodos supervisados como en los no supervisados, de igual forma las posibles combinaciones de C1-C3 y C1-C6 correspondientes a los valores promedio, sesgo y energía. De acuerdo con la precisión en la clasificación es más probable discernir entre las celdas fracturada y *hot spot* que entre las posibles combinaciones de las celdas en buen estado y anomalías, es decir, B-F y B-Hs. En general el tipo de defecto que fue mejor clasificado fue la celda fracturada para los enfoques supervisados y no supervisados.

Detalles de la implementación del método en los escenarios de prueba EIEE y planta solar Celsia ®

El método para detección de fallas *hot spot* y celdas fracturadas en módulos fotovoltaicos con imágenes aéreas termográficas presentado en el capítulo 4.

El primer escenario cuenta con un arreglo de paneles solares de silicio monocristalino ubicado en la EIEE, el cual sirvió para definir las condiciones del protocolo de vuelo del UAV y el ajuste de los algoritmos propuestos para la detección de fallas ilustrado en la fig .6.1.

El segundo escenario cuenta con un conjunto de paneles ubicados en la planta de generación fotovoltaica de Celsia ® como se ilustra en la fig .6.11, la inspección se hace sobre cinco arreglos de módulos fotovoltaicos cada arreglo está conformado por 60 PPV en serie de silicio policristalino. La evaluación del método propuesto en escenarios diferentes permite determinar las situaciones en las que el método sigue una generalidad y en las que se deben realizar ajustes.

6.1. Escenario de prueba 1: Generador PPV en planta piloto Universidad del Valle.

El diseño experimental para la adquisición de las imágenes esta conformado por un arreglo de PPV de silicio monocristalino descrito en el capítulo 3, el método para la detección de fallas se ajusta para el escenario de prueba de la nanored distribuida de la Universidad del Valle. A continuación, se

presenta el protocolo de adquisición y el algoritmo propuesto para el caso de estudio.

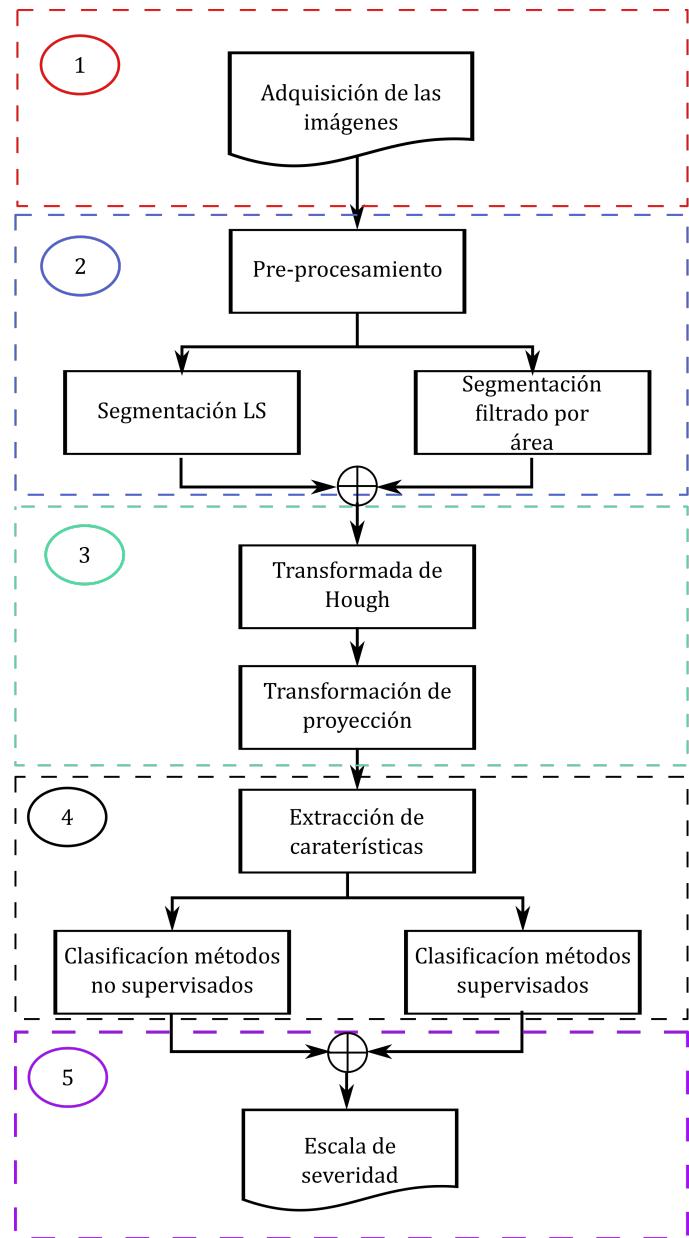


Figura 6.1: Ajuste del MDF para inspección nanored Universidad del Valle EIEE.

6.1.1. Fase 1: Adquisición de imágenes

Las imágenes IIR aéreas para la inspección de fallas *hot spot* y celdas fracturadas, adquiridas en el escenario de prueba de la EIEE presentaron ajustes en el MDF propuesto en el capítulo de 4, los ajustes se detallan a continuación.

6.1.1.1. Etapa 1: condiciones iniciales

Las imágenes termográficas aéreas fueron capturadas, únicamente en días soleados, sin lluvia ni nubosidad aparente, y se adquirieron en la franja horaria de 10:00 a 11:30 am y 1:00 a 2:00 pm.

6.1.1.2. Etapa 2: Condiciones de operación del PPV

El arreglo de paneles solares de silicio monocristalino estudiado tiene PPV de 36 celdas, no presentaba conexión real a una carga, por tal motivo se emplea una carga electrónica *B & K Precision 8514* que se configura con el 80% del voltaje nominal entregado por el *string* de paneles.

6.1.1.3. Etapa 3: medición de variables ambientales

Las mediciones de las variables ambientales se adquirieron con la estación meteorológica *Ambient Weather* ver fig. 6.2, los reportes de temperatura externa y velocidad del viento se almacenan en un archivo csv.

La irradiancia se obtiene del sistema de medición y monitorización de la nanored distribuida de la Universidad del Valle conformado por un piranómetro *SP-110* y sensores de temperatura sobre las celdas, este sistema cuenta con una aplicación desarrollada en Labview® que permite seleccionar el tiempo de muestreo, para este caso se escoge el mínimo valor permitido 30 s y el tipo de archivo .txt. Esta información permitió descartar las imágenes que no se encuentran en los rangos de las variables ambientales establecidos en la etapa 4.0.1.3.



Figura 6.2: Estación meteorológica y piránometro SP-110.

6.1.1.4. Etapa 4: protocolo de vuelo

Una vez se verifica que las condiciones ambientales son las adecuadas para la captura de imágenes térmicas, se posiciona el UAV en un rango de 2.3 a 2.7 m de distancia con respecto a los paneles. Los paneles tienen una inclinación de 8 a 13°, lo que es posible gracias a la posición geográfica de Colombia, cercana a la línea Ecuatorial. La altura de 2.3 m del suelo, se estableció para que dos paneles queden contenidos en la imagen, en este procedimiento las imágenes fueron adquiridas de forma estática, es decir, no se presentaba movimiento del UAV excepto el generado por las vibraciones propias y los efectos de recirculación de las aspas.

6.1.2. Fase 2: Pre-procesamiento

Después de adquirir las IIR aéreas para la detección de fallas, inician las operaciones de pre-procesamiento. El argumento de entrada al algoritmo es la IIR sobre la cual se emplean filtros para la reducción del ruido, al finalizar este procedimiento se selecciona el método de segmentación entre MCA *level sets* y el enfoque de filtrado por área.

A continuación se presentan los detalles para la implementación del MDF en el escenario EIEE.

6.1.2.1. Imagen de entrada

La secuencia de imágenes adquiridas usando la *Zenmuse XT*, tienen una resolución de 336×256 pixeles, la fig. 6.3, muestra dos de las seis opciones presentadas por la cámara IR para la visualización de los termogramas aplicando técnicas de pseudocolor, el formato es *jpg*. En este procedimiento se emplea la imagen en escala de grises.

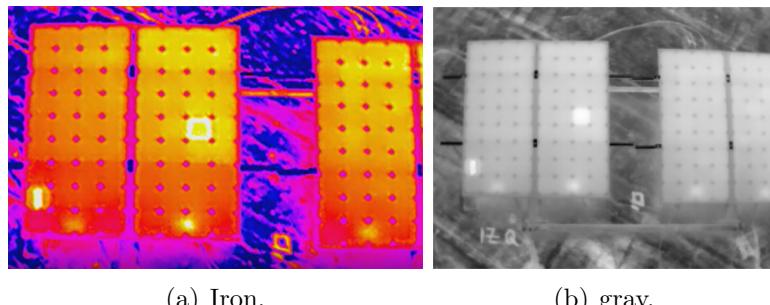


Figura 6.3: Imágenes IR de los paneles solares.

6.1.2.2. Filtrado y adecuación de las IIR

La etapa de preparación de las imágenes, permite reducir el ruido presente en las IIR, en la fig. 6.4 se muestra el algoritmo propuesto.

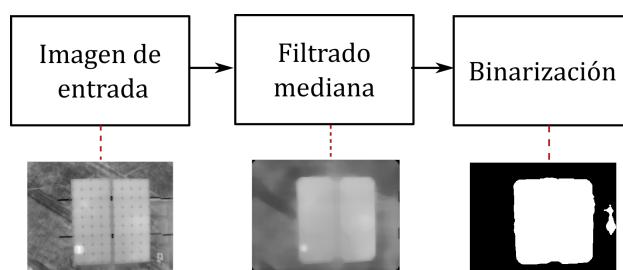


Figura 6.4: Diagrama de filtrado y adecuación de las IIR.

Esta etapa tiene como parámetro de entrada el termograma de los paneles solares. La imagen de entrada ingresa a un proceso de filtrado paso-bajo

(filtro mediana) para disminuir el ruido. La selección de la ventana es de $[25 \times 25]$ y se hace heurísticamente con una secuencia de imágenes de prueba, los parámetros escogidos se fijan debido a que el protocolo de adquisición garantiza, que la captura de las imágenes se hace bajo un rango establecido de mediciones ambientales, generando un entorno semi-controlado. Posteriormente inicia el proceso de binarización de la imagen filtrada, el parámetro de entrada de la función corresponde al umbral estimado con el método *otsu's* para diferenciar el panel del fondo.

6.1.2.3. Segmentación extracción de objetos por filtrado de área

Se abordan dos técnicas de segmentación, la primera corresponde al filtrado de área fig. 6.5 y la segunda al método de contornos activos (MCA) *Level sets* entre las opciones debe seleccionarse uno de los dos métodos. El algoritmo propuesto para el filtrado de área, inicia con la definición de los valores del área mínima $min_{area} = 0.1$ y el área máxima $max_{area} = 0.9$, como se ilustra en la fig. 6.5. Los valores L y A corresponden al tamaño en píxeles del ancho y largo de la imagen y el producto de $min_{area} \times A \times L$ y $max_{area} \times A \times L$ son el criterio para filtrar los objetos en la imagen e iniciar el procedimiento de etiquetado para obtener la región de interés.

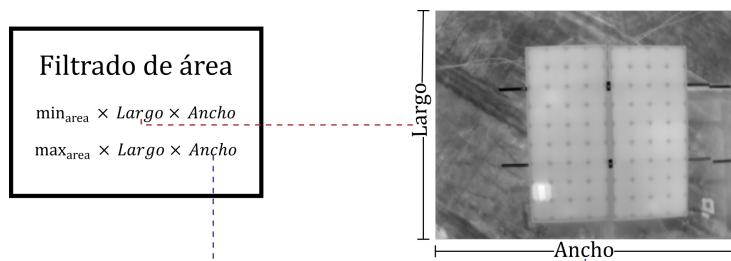


Figura 6.5: Filtrado de área.

El objeto filtrado del proceso anterior ingresa a un detector de bordes Canny fig. 6.6 para la extracción del contorno, una vez se obtienen los bordes se emplea una operación morfológica de dilatación con un elemento estructural cuadrado de dimensiones 7×7 , este procedimiento se utiliza para aumentar el borde detectado y encontrar las intersecciones de las rectas principales de la imagen, que corresponden al panel solar.

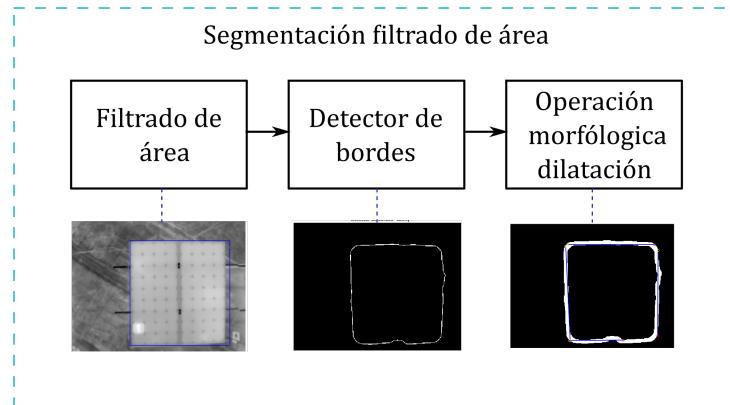


Figura 6.6: Enfoque de filtrado por área.

6.1.2.4. Método de contornos activos level sets (MCA)

El enfoque de segmentación con el MCA *level sets*, se emplea como técnica para encontrar los contornos de los paneles solares a partir de la búsqueda de los parámetros α , λ y ϵ , estos parámetros son sintonizados para los siguientes rangos $1 \leq \alpha < 2$, $7 \leq \lambda < 7$ y $-1,5 \leq \epsilon < 1,5$. La métrica de comparación de la curva generada por el MCA corresponde al mínimo error con un *ground truth* ajustado al panel. El MCA es un método de segmentación semiautomático y se automatiza definiendo como condiciones iniciales de la superficie de búsqueda, un rectángulo con las dimensiones de la imagen 336×256 .

6.1.3. fase 3: Procesamiento de las imágenes

La fase de procesamiento de las imágenes IR se concibe a partir de una serie de transformaciones que permiten llevar los vértices del panel a posiciones deseadas y a procedimientos de filtrado para la reducción del calentamiento no uniforme sobre los PPV. En la siguientes secciones se detallan los parámetros del algoritmo planteado.

6.1.3.1. Transformada de Hough

La detección de las rectas provenientes de los bordes del panel se hace con la transformada de *Hough*. Los parámetros ingresados a la función son $\theta = -90 : 0,5 : 89,5^\circ$ y un tamaño para la zona de supresión de $[101 \times 101]$ para la detección de picos.

Una vez se encuentran las ecuaciones de las rectas en forma polar, se calculan los vértices con todas las intersecciones y se transforman a las coordenadas

cartesianas propias de la imagen.

En la fig. 6.7 se ilustra el proceso de obtención de los vértices, en verde el contorno generado para la región de interés, en azul la detección de líneas usando la transformada de *Hough* y en rojo los vértices hallados.

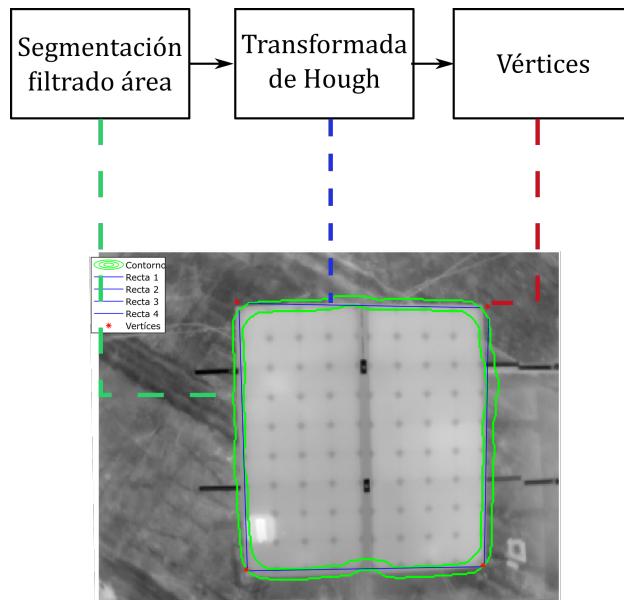


Figura 6.7: Transformada de Hough.

6.1.3.2. Transformación de proyección

Los puntos encontrados en la etapa anterior, correspondientes a las esquinas del panel, no tienen orientación. La asignación de la dirección se hace a partir del cálculo del centroide y se ubican en un nuevo sistema coordenado como se ilustra en la fig. 6.8. El centroide representa el origen y permite ubicar los vértices en uno de los cuatro cuadrantes, el procedimiento de asignación de la orientación también se hace con las coordenadas de las posiciones deseadas para el panel.

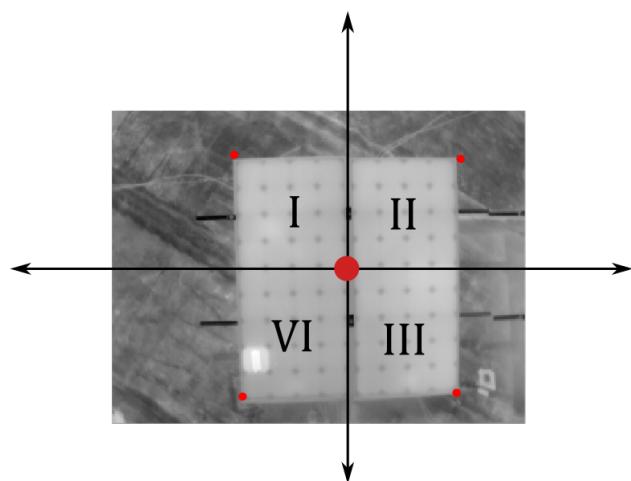


Figura 6.8: Asignación de coordenadas.

Después de asignar la orientación a los vértices, se emplea una transformación de proyección con las coordenadas (ver sección 2.7.6) y se obtiene el panel solar ilustrado en la fig. 6.9.

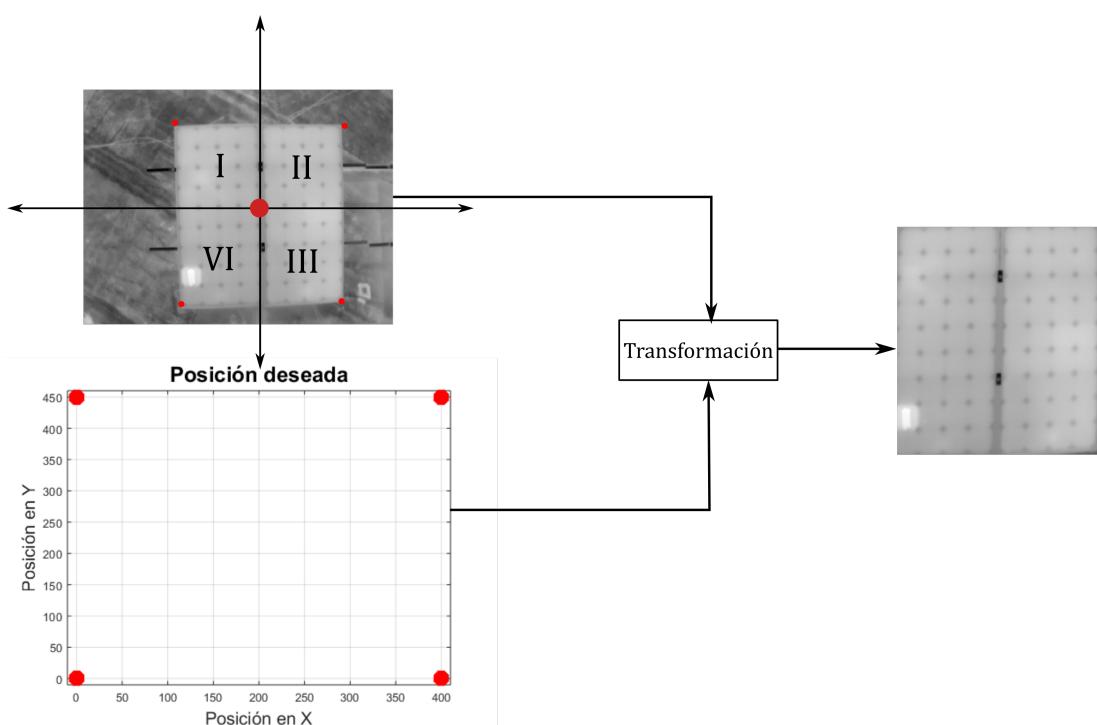


Figura 6.9: Transformación proyectiva.

6.1.4. Fase 4: Extracción de características

6.1.4.1. Extracción de características

Las celdas del PPV se subdividen en cuatro regiones y para cada segmento se obtienen los cuatro primeros momentos estadísticos, la entropía, la energía, las 14 texturas de Haralick y los 36 histogramas de gradiente (HOG) como se resume en la tab. 6.1. Las muestras fueron debidamente etiquetadas en las tres clases estudiadas

$C_{1:7}$		$T_{1:15}$	$H_{1:36}$
Estadísticas	Textura	Textura	Histograma de gradiente
$C_{1:4}$	$C_{5:6}$	1:14	1:36
Etiquetado		Etiquetado	Etiquetado
7		15	37

Tabla 6.1: Características extraídas por cada una de las celdas del panel.

6.1.4.2. Clasificación usando métodos supervisados

La clasificación de las celdas del panel solar en sana, *hot spot* y fracturada, se hace a partir de una máquina de soporte vectorial variando los tipos de kernel en : RBF por defecto, RBF sintonizado y polinómicos. El *kernel* RBF se sintoniza a partir de unos vectores de búsqueda para c y γ y solo se seleccionan aquellos en los cuales la precisión es máxima (ver capítulo 5). Por otra parte, en el caso de los polinómicos se varían sus grados en 3, 4 y 6. Las características que se ingresan a cada una de las topologías de la SVM corresponden a las posibles combinaciones de los cuatro momentos estadísticos con la energía y la entropía $[C_{n=1:5} \ C_6]$, una vez finaliza este proceso ingresan a los bloques clasificadores las 14 texturas de Haralick y los HOG como se ilustran en la fig. 6.10. De acuerdo con los resultados obtenidos en la clasificación, estos datos se procesan en el bloque de la escala de severidad (ES) para emitir el diagnóstico.

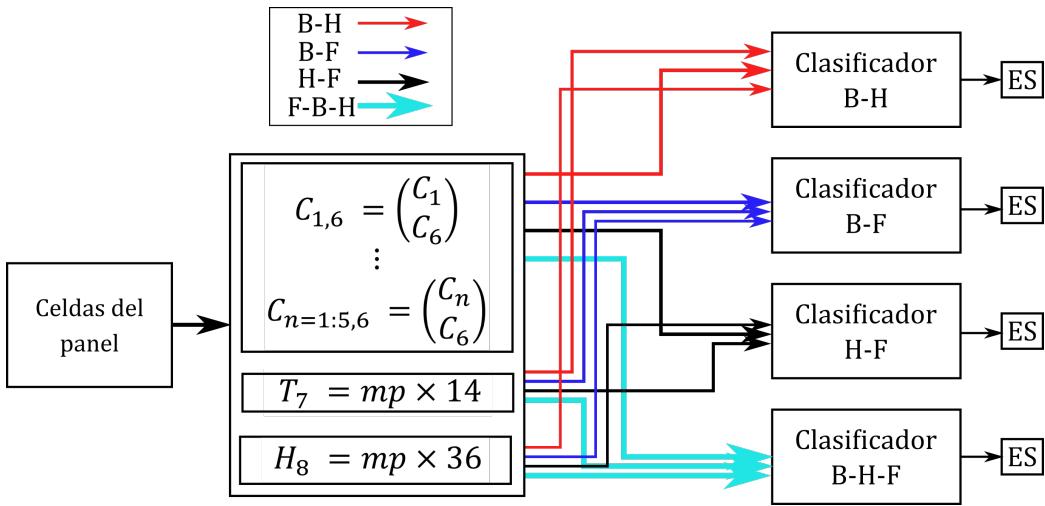


Figura 6.10: Diagrama de los clasificadores.

El otro método supervisado usado para la clasificación son las RNA variando la topología, cantidad de neuronas en la capa oculta, la función de entrenamiento y de desempeño. La forma de ingresar las características es igual que la empleada para la SVM con la diferencia de que el clasificador es una RNA, ver fig. 6.10, para los experimentos biclase y las tres clases al tiempo.

6.1.4.3. Clasificación usando métodos no supervisados

El procedimiento de clasificación con los métodos no supervisados se ilustra en la fig. 6.10, la combinatoria de los cuatro momentos estadísticos con los dos de textura (energía y entropía) se ingresan a cada uno de los bloques clasificadores no supervisados. Para el caso de K-medias se abordan los experimentos biclase y las tres clases modificando la cantidad de clústeres de $K = 2 : 5$ y variando las métricas de distancia euclídea y coseno. Una vez finaliza el experimento, se ingresan a los clasificadores los vectores de características HOG y las texturas de Haralick de forma independiente. Las métricas de desempeño usadas para medir la clusterización son la precisión en la clasificación y el *score silhouette* (ver capítulo 5).

El método de clasificación número dos no supervisado corresponde a la mezcla de gausianas, los parámetros a variar son : la cantidad de gausianas de 2 hasta 3 y el tipo de covarianza para cada uno de los experimentos biclase y las tres clases. Las características que se ingresan al clasificador son la combinación de las $C_{1:6}$ y posteriormente de forma independiente los HOG ($H_{1:36}$). La métrica de desempeño usada para medir la calidad de la clusterización es

el *score silhouette*.

6.1.5. Fase 5: escala de severidad

Los paneles solares inspeccionados de Si monocristalino ubicados en la EIEE, presentan una cantidad total de 72.5 % de celdas defectuosas de acuerdo a los resultados obtenidos del proceso de clasificación supervisado con SVM. Por lo cual se emite que el estado es **Crítico**.

A continuación se plantean las modificaciones en el algoritmo para la detección de fallas en paneles solares usando termografía aérea, propuesto para las imágenes de validación adquiridas en la planta solar de Celsia *Yumbo*.

6.2. Escenario de prueba 2: Generador PPV en generador fotovoltaico Celsia-Yumbo.

El método de detección de fallas en paneles solares propuesto en la sección 4 (ver fig. 4.1), presentó variaciones en la etapa de adquisición de las imágenes, generadas por las siguientes particularidades en el escenario de prueba; la cercanía de las líneas de alta tensión, el hundimiento del terreno en el campo solar y la altura de los soportes metálicos de las mesas de paneles. Para este caso de estudio, la composición de las imágenes cambió y la nueva altura H se calculó con la ecuación 4.12 desarrollada para el protocolo de vuelo 4.0.1.4, generando modificaciones en el pre-procesamiento y extracción de la región de interés ver fig. 6.11.

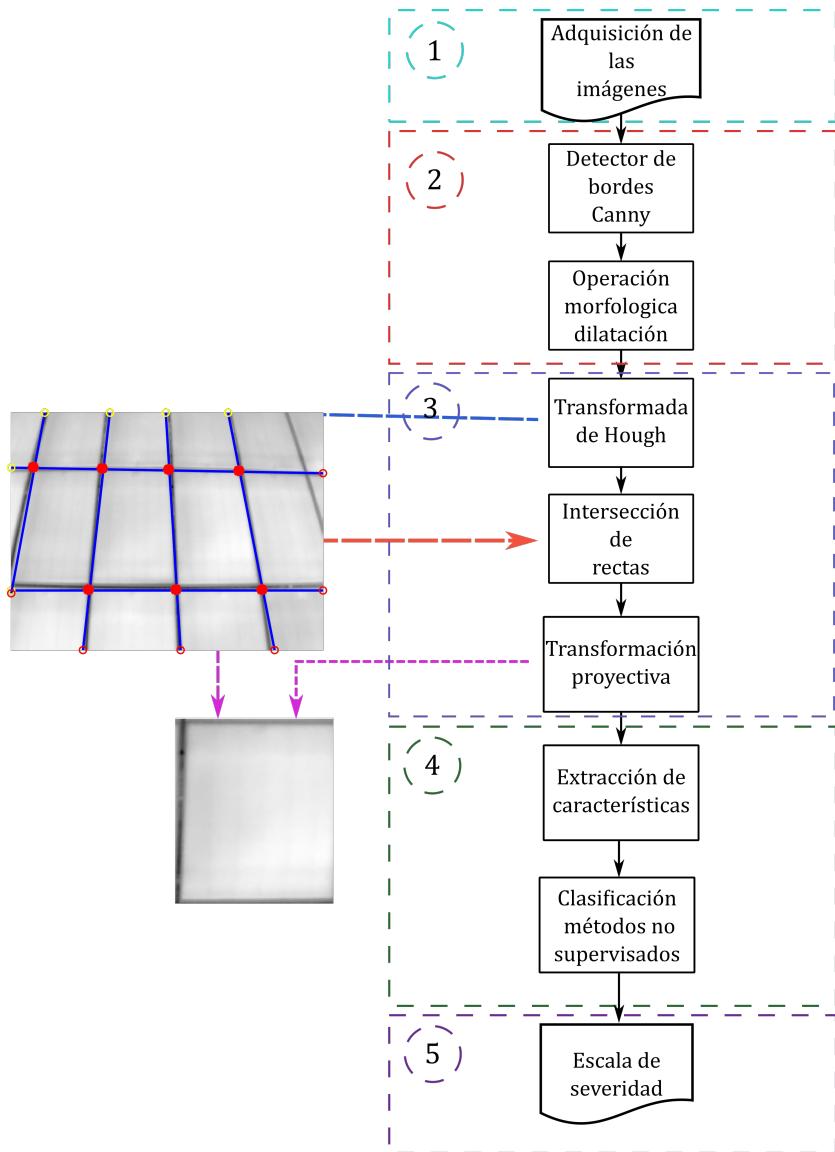


Figura 6.11: Método propuesto para la detección de anomalías en PPV escenario de inspección planta solar Celsia ® MDF1.

6.2.1. Fase 1: Adquisición de imágenes

Las condiciones iniciales para la captura de las IIR planteadas en la sección 4.0.1.1 permanecen sin alteración, es decir, solo se inicia el procedimiento de adquisición siempre y cuando no se presenten lluvias ni nubosidad aparente. Por otra parte, la franja horaria en la que se desarrolla el experimento se extendió desde la 1:00 pm hasta las 3:00 pm.

Al finalizar la etapa 4.0.1.1 del protocolo de adquisición, se verifican las condiciones de operación de los PPV inspeccionados y no se emula con una carga resistiva, debido a que el sistema de generación fotovoltaica presenta conexión a una carga real para suplir los requerimientos eléctricos de la planta Postobon ®.

La verificación de los rangos de las variables ambientales se hace a partir de los reportes de velocidad del viento y la medición de irradiancia obtenidos del sistema SCADA de Celsia ®.

Una vez se verifican los pasos anteriores del MDF (ver sección 4.0.1), la adquisición de las imágenes se hace posicionando el UAV en un rango de altura H de 4.6 a 5 m estimado con la ec. 4.12 y el ángulo de la cámara se fija entre 45 a 50 °. En la fig. 6.12 se ilustran algunas de las imágenes obtenidas, en la fig. 6.12(a) se observan dos PPV completos que se pueden segmentar, en la fig. 6.12(b) se pueden segmentar tres PPV, finalmente en la fig .6.12(c) se pueden segmentar tres de los cinco paneles capturados.

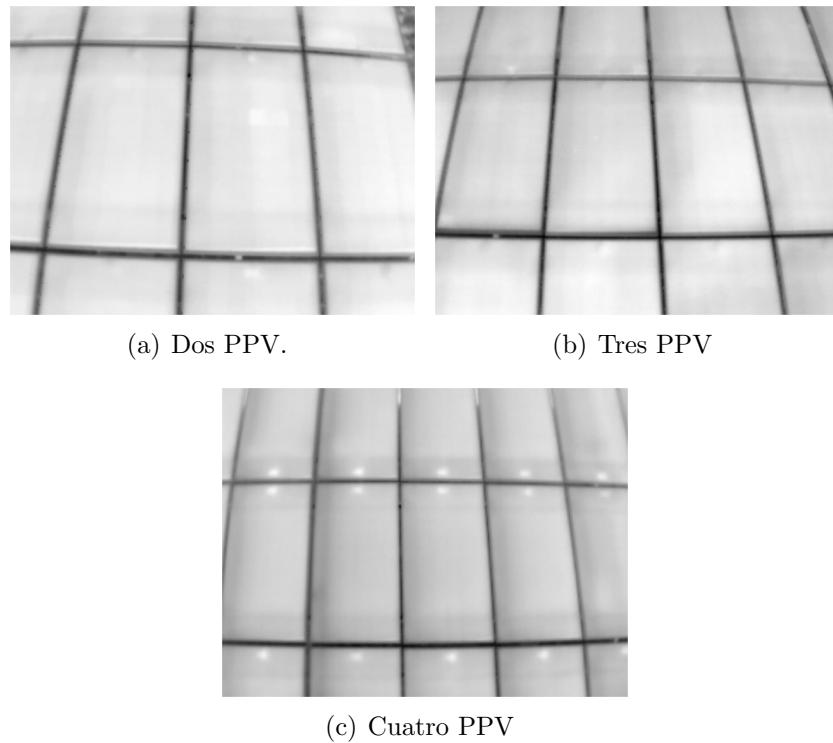


Figura 6.12: Imágenes adquiridas en la planta solar Celsia ®.

6.2.2. Fase 2: Pre-procesamiento y segmentación

Después de capturar las IIR se usa el detector de bordes Canny y se emplea una operación morfológica de dilatación con un elemento estructural cuadrado de $[5 \times 5]$ para aumentar el tamaño de los bordes detectados en la imagen.

6.2.3. Fase 3: Procesamiento de las imágenes

Los bordes extraídos de la fase anterior son procesados a partir de la transformada de Hough estableciendo la cuadricula del ángulo en $\theta = -90:0.5:89.5$ y un tamaño para la zona de supresión de $[101 \ 101]$ en la detección de picos. Una vez se detectan los vértices por panel, a partir de las intersecciones se utiliza una transformación de proyección para llevar a las posiciones deseadas los puntos encontrados.

6.2.4. Fase 4: Extracción de las características

El procesamiento llevado en la fase tres, garantiza que el PPV ocupa toda la imagen, en este momento inicia el proceso de extracción de características por cada celda, en una región cuadrada de 40×40 píxeles se subdivide en cuatro regiones y se extraen los momentos estadísticos, las 14 características de textura y los 36 histogramas de orientación de gradiente.

6.2.4.1. Clasificación usando métodos no supervisados

La clasificación de las celdas B, F y H de las imágenes obtenidas de Celsia se hace a partir de los métodos no supervisados k-medias y mezcla de gausianas. Para el método k-medias se varían: los valores de K de dos hasta cinco y las métricas de distancia euclídea y coseno. Las características que ingresan a cada uno de los bloques clasificadores ver fig. 6.10 son : las posibles combinatorias de los cuatro momentos estadísticos con las dos de textura, las 14 texturas de Haralick y los vectores HOG para los experimentos biclase y las tres clases al tiempo. Cada vector de características como se ilustra en la fig. 6.10 se ingresa de forma independiente, por lo cual son tres experimentos diferentes en cada uno de los bloques clasificadores. El otro método utilizado corresponde a la mezcla de gausianas y los parámetros a variar son : la cantidad de gausianas de dos hasta tres y el tipo de covarianza, para cada uno de los experimentos biclase y tres clases, se ingresan al bloque clasificador únicamente las combinaciones de características estadísticas con las dos textura.

6.2.5. Fase 5: Asignación de la escala de severidad

El diagnóstico de los módulos fotovoltaicos para los cinco arreglos de PPV conectados en serie, generó como reporte Alerta con el método no supervisado k-medias.

6.3. Conclusiones

El método para la detección de las fallas celdas fracturadas y *hot spot* en paneles solares a partir de IIR, se ajusta de acuerdo a las particularidades presentadas en los dos escenarios de estudio, en las fases de adquisición de las imágenes y pre-procesamiento. La altura a la que se posiciona el UAV en el escenario de prueba EIEE corresponde a 2.3 a 3 m, generando una composición de las imágenes de dos paneles por IIR. Para el caso de estudio de Celsia ® se calculó una altura H de 4.6 a 5 m con la ecuación 4.12 desarrollada. En la fase de pre-procesamiento para el caso de estudio EIEE, se proponen dos métodos para la segmentación a partir del método MCA *level sets* y el enfoque por filtrado de área. Para el caso de estudio de Celsia ® se emplea un detector de bordes de canny seguido de una operación morfológica de dilatación, estos bloques también hacían parte del proceso propuesto para el método general y fueron usados en el escenario de prueba de la EIEE.

En el caso de estudio número uno se extraen las características y se emplean métodos de clasificación supervisados y no supervisados para identificar las fallas celda fracturada y *hot spot*. En el caso de estudio número dos solo se emplean técnicas no supervisadas. Las pruebas en los dos escenarios de estudio permitieron el ajuste del MDF en las fases uno y dos, generando como recomendación en cada escenario inspeccionado determinar las alturas con la ecuación propuesta en la etapa del protocolo de vuelo 4.0.1.4 y los ángulos entre 40 y 60 ° de acuerdo con la ubicación de los módulos fotovoltaicos.

Los paneles solares de la EIEE presentan daños de tipo crítico de acuerdo con los resultados obtenidos en la escala de severidad, por otra parte, los arreglos inspeccionados en el escenario de Celsia ® presentan un nivel de Alerta por lo cual se emite como recomendación monitorear y verificar las condiciones del panel hasta la próxima revisión programada.

Capítulo 7

Conclusiones

7.1. Conclusiones generales

La revisión en la literatura de los equipos empleados para inspección termográfica aérea en sistemas fotovoltaicos, permitió extraer las características relevantes de los UAV y las cámaras IR, de acuerdo con lo obtenido se adquieren el UAV *Matrice 100* y *Zenmuse XT*.

Se desarrolló un método para la inspección de las fallas *hot spot* y fracturas a nivel de las celdas del panel solar a diferencia de la inspección a nivel global del PV que proponen en [21],[13] y [16], el método estaba conformado por 5 fases estas son : pre-procesamiento y segmentación; transformaciones; clasificación del estado de las celdas y finalmente la escala de severidad.

En la etapa de clasificación de las fallas se estudia la configuración del clasificador y su topología para cada experimento biclase y la tres clases al tiempo. Entre las técnicas propuestas se seleccionan las SVM con *kernel RBF* sintonizado y se escogen los clasificadores biclase debido a que el desempeño del clasificador de tres clases no supera una precisión en la clasificación de 64.8 %. Finalmente el sistema de clasificación de fallas (CF) queda conformado por tres bloques de clasificador biclase para las celdas H-B, F-B y H-F. El bloque H-B tiene como parámetros de entrada los vectores de características HOG para los valores de $c=2.8$ y $\gamma = 0.2$. El bloque F-B tiene como características de entrada los HOG con los valores de $c=2$ y $\gamma = 0$. El bloque H-F tiene como parámetros de entrada la combinación de características de C2-C3 con los valores de $c=10$ y $\gamma = 10$.

Inicialmente se hicieron pruebas con métodos no supervisados para analizar la distribución de los datos, debido a que no se contaba con las etiquetas de las muestras. La conformación de dos cluster para los experimentos biclase arrojaron la mejor puntuación de acuerdo a la métrica Silhouette y a

la precisión en la clasificación, alcanzando precisiones para H-B de 72.21 % empleando los HOG, F-B para un total de dos clústeres con una precisión en la clasificación de 66.63 % y H-F para dos clústeres 84.56 %.

Los resultados de la escala de severidad para la EIEE se obtuvieron a partir del bloque clasificador supervisado CF. El escenario de prueba Celsia se probó con los bloques clasificadores biclase para $k=2$ distancia euclidiana como sigue: H-B con los vectores de características HOG, F-B con la combinación de C2-C6, la F-H con las características C1-C3.

Finalmente se validó el método propuesto a partir de la prueba en dos escenarios la nanored de la EIEE y Celsia. Estas pruebas permitieron los ajustes en la siguientes etapas: protocolo de vuelo estimando la altura H con la ec. 4.12. En el pre-procesamiento y segmentación se adecuaron los algoritmos para la extracción de los PV debido a que la composición de la imagen cambió de $\sim 2.3\text{ m}$ a $\sim 4.6\text{ m}$ para los escenarios de prueba. Finalmente, el proceso de clasificación para el escenario de Celsia se hace únicamente con métodos no supervisados debido al desconocimiento de los etiquetados en cada prueba.

Capítulo 8

Perspectivas futuras de trabajo

Los métodos propuestos en este trabajo, representan la primera aproximación al diagnóstico de fallas en paneles solares a partir de imágenes termográficas aéreas, empleando técnicas de visión artificial y clasificación. Para dar continuidad con la investigación en esta temática se presentan a continuación los trabajos futuros, que permitirán mejoras, en la metodología desarrollada.

El método planteado requiere de un procesamiento *offline*, es decir inicia el proceso de captura de las imágenes para la posterior ejecución de los algoritmos en una estación en tierra, por lo tanto desarrollar un procedimiento en linea permitirá emitir un diagnóstico inmediato del estado de los módulos fotovoltaicos, mejorando los tiempos de las intervenciones y en el mantenimiento de los sistemas.

La adquisición de las imágenes térmicas presenta limitaciones, debidas a la definición de rangos de las variables ambientales para iniciar la captura, por lo cual proponer un coeficiente de contraste o de ajuste para la irradiancia, permitirá obtener una mayor cantidad de imágenes para su posterior procesamiento.

La sintonización de la SVM mejoró el desempeño de los resultados obtenidos con la RBF por defecto, por lo cual optimizar las otras técnicas de clasificación permitirá las mejoras en los resultados.

La TIR es una técnica para la inspección de anomalías en paneles solares, pero no es definitiva para el diagnóstico de fallas, por lo cual proponer combinaciones entre las técnicas eléctricas (curva I-V) y de imágenes (EL, PL, TIR, etc.) para obtener indicadores que puedan utilizarse en conjunto y enriquecer la información, puede mejorar la tarea de diagnóstico.

Finalmente proponer una escala de severidad, que relacione los resultados obtenidos de los clasificadores implementados para las fallas en paneles sola-

res, con la potencia perdida en el módulo fotovoltaico permitirá cuantificar mejor los daños evidenciados en los paneles.

Capítulo 9

Contribuciones

El trabajo de investigación “Detección y determinación de severidad de fallas en paneles solares a partir de imágenes aéreas termográficas”, presentó los siguientes resultados:

- Construcción de un *dataset* para la detección de las fallas celda fracturada y *hot spot* en paneles solares.
- Diseño de un protocolo de vuelo para la inspección de fallas en paneles solares.
- Se desarrolló un método para el procesamiento de los datos adquiridos, pre-procesamiento, segmentación, extracción de características y clasificación de las fallas presentadas en las celdas.
- Se propuso una escala de severidad con niveles alerta, severo y crítico, que asociaba los resultados de los clasificadores implementados con temporalidades en la intervención.

En el desarrollo de este trabajo de investigación se hizo una publicación relacionada con la temática de inspección de fallas en paneles solares a partir de las imágenes termográficas aéreas

- *Aerial Thermographic inspection of photovoltaic plants: analysis and selection of the equipment* el cual fue presentado en el ISES Solar World Congress 2017 y la versión extendida fue publicada en el *proceedings ISES*, en el artículo se describen los equipos utilizados a nivel investigativo y comercial para la inspección de fallas en paneles solares a partir de una revisión de artículos en donde se describen las características de mayor relevancia de los UAV y las cámaras termográficas.

- El *dataset* adquirido de las imágenes aéreas termográficas.
- El *dataset* publicado fue compartido en la base de datos de mendeley
<https://data.mendeley.com/datasets/82vzccxb6y/1>.

Se encuentra en construcción el artículo de

- Clasificación de las fallas *hot spot* y celda fracturada en paneles solares.

Bibliografía

- [1] G. Dudek and S. Dudzik, “Classification tree for material defect detection using active thermography,” in *Information Systems Architecture and Technology: Proceedings of 38th International Conference on Information Systems Architecture and Technology – ISAT 2017*. Springer International Publishing, Sep. 2017, pp. 118–127. [Online]. Available: https://doi.org/10.1007/978-3-319-67220-5_11
- [2] L. Wu, Z. Chen, C. Long, S. Cheng, P. Lin, Y. Chen, and H. Chen, “Parameter extraction of photovoltaic models from measured i-v characteristics curves using a hybrid trust-region reflective algorithm,” *Applied Energy*, vol. 232, pp. 36–53, dec 2018. [Online]. Available: <https://doi.org/10.1016/j.apenergy.2018.09.161>
- [3] J. Jordan. (2019) Evaluating image segmentation models. [Online]. Available: <https://unmundointelectualblog.wordpress.com/2017/03/08/espectro-electromagnetico/>
- [4] S. S. Haykin, *Neural networks and learning machines*, 3rd ed. Upper Saddle River, NJ: Pearson Education, 2009.
- [5] A. Jabeen, N. Ahmad, and K. Raza, “Machine learning-based state-of-the-art methods for the classification of RNA-seq data,” mar 2017. [Online]. Available: <https://doi.org/10.1101/120592>
- [6] B. Precision. (2015) Evaluating image segmentation models. [Online]. Available: <https://www.bkprecision.com/products/dc-electronic-loads/8500-300-w-programmable-dc-electronic-load.html>
- [7] H. M. Pereira, P. W. Leadley, V. Proen  a, R. Alkemade, J. P. W. Scharlemann, J. F. Fernandez-Manjarr  s, M. B. Ara  jo, P. Balvanera, R. Biggs, W. W. L. Cheung, L. Chini, H. D. Cooper, E. L.

- Gilman, S. Guénette, G. C. Hurttt, H. P. Huntington, G. M. Mace, T. Oberdorff, C. Revenga, P. Rodrigues, R. J. Scholes, U. R. Sumaila, and M. Walpole, "Scenarios for global biodiversity in the 21st century," *Science*, vol. 330, no. 6010, pp. 1496–1501, oct 2010. [Online]. Available: <https://doi.org/10.1126/science.1196624>
- [8] M. Höök and X. Tang, "Depletion of fossil fuels and anthropogenic climate change—a review," *Energy Policy*, vol. 52, pp. 797–809, jan 2013. [Online]. Available: <https://doi.org/10.1016/j.enpol.2012.10.046>
- [9] E. Pursiheimo, H. Holttinen, and T. Koljonen, "Inter-sectoral effects of high renewable energy share in global energy system," *Renewable Energy*, vol. 136, pp. 1119–1129, Jun. 2019. [Online]. Available: <https://doi.org/10.1016/j.renene.2018.09.082>
- [10] S. Sundaram, D. Benson, and T. K. Mallick, *Overview of the PV Industry and Different Technologies*. Elsevier, 2016. [Online]. Available: <https://doi.org/10.1016/b978-0-12-802953-4.00002-0>
- [11] A. Mellit, G. Tina, and S. Kalogirou, "Fault detection and diagnosis methods for photovoltaic systems: A review," *Renewable and Sustainable Energy Reviews*, vol. 91, pp. 1–17, Aug. 2018. [Online]. Available: <https://doi.org/10.1016/j.rser.2018.03.062>
- [12] M. Abdelhamid, R. Singh, and M. Omar, "Review of microcrack detection techniques for silicon solar cells," *IEEE Journal of Photovoltaics*, vol. 4, no. 1, pp. 514–524, Jan. 2014. [Online]. Available: <https://doi.org/10.1109/jphotov.2013.2285622>
- [13] P. Zhang, L. Zhang, T. Wu, H. Zhang, and X. Sun, "Detection and location of fouling on photovoltaic panels using a drone-mounted infrared thermography system," *Journal of Applied Remote Sensing*, vol. 11, no. 1, p. 016026, feb 2017. [Online]. Available: <https://doi.org/10.1117/1.jrs.11.016026>
- [14] P. Addabbo, A. Angrisano, M. L. Bernardi, G. Gagliarde, A. Mennella, M. Nisi, and S. Ullo, "A UAV infrared measurement approach for defect detection in photovoltaic plants," jun 2017. [Online]. Available: <https://doi.org/10.1109/metroaerospace.2017.7999594>
- [15] X. Li, Q. Yang, Z. Chen, X. Luo, and W. Yan, "Visible defects detection based on UAV-based inspection in large-scale photovoltaic systems," *IET Renewable Power Generation*, vol. 11, no. 10, pp. 1234–1244, aug 2017. [Online]. Available: <https://doi.org/10.1049/iet-rpg.2017.0001>

- [16] M. Aghaei, A. Gandelli, F. Grimaccia, S. Leva, and R. E. Zich, “IR real-time analyses for PV system monitoring by digital image processing techniques,” jun 2015. [Online]. Available: <https://doi.org/10.1109/ebccsp.2015.7300708>
- [17] M. Aghaei, F. Grimaccia, C. A. Gonano, and S. Leva, “Innovative automated control system for PV fields inspection and remote control,” *IEEE Transactions on Industrial Electronics*, vol. 62, no. 11, pp. 7287–7296, nov 2015. [Online]. Available: <https://doi.org/10.1109/tie.2015.2475235>
- [18] F. Grimaccia, M. Aghaei, M. Mussetta, S. Leva, and P. B. Quater, “Planning for PV plant performance monitoring by means of unmanned aerial systems (UAS),” *International Journal of Energy and Environmental Engineering*, vol. 6, no. 1, pp. 47–54, 2015.
- [19] S. Dotenco, M. Dalsass, L. Winkler, T. Wurzner, C. Brabec, A. Maier, and F. Gallwitz, “Automatic detection and analysis of photovoltaic modules in aerial infrared imagery,” mar 2016. [Online]. Available: <https://doi.org/10.1109/wacv.2016.7477658>
- [20] C. Buerhop-Lutz, H. Scheuerpfug, and R. Weißmann, “The role of infrared emissivity of glass on ir-imaging of pv-plants,” *26th European Photovoltaic Solar Energy Conference and Exhibition; 3413-3416*, 2011. [Online]. Available: <http://www.eupvsec-proceedings.com/proceedings?paper=12840>
- [21] Y. Zefri, A. ElKettani, I. Sebari, and S. A. Lamallam, “Thermal infrared and visual inspection of photovoltaic installations by UAV photogrammetry—application case: Morocco,” *Drones*, vol. 2, no. 4, p. 41, Nov. 2018. [Online]. Available: <https://doi.org/10.3390/drones2040041>
- [22] Y. J. Salas, S. P. Vera-Monroy, A. Mejia-Camacho, and W. Rivera, “Correlation between the thermal performance and the microstructure of the material used in medium and high voltage transformer terminals,” *Journal of Physics: Conference Series*, vol. 935, p. 012058, dec 2017. [Online]. Available: <https://doi.org/10.1088/1742-6596/935/1/012058>
- [23] A. D. Restrepo-Girón and H. Loaiza-Correa, “Background thermal compensation by filtering for contrast enhancement in active thermography,” *Journal of Nondestructive Evaluation*, vol. 35, no. 1, mar 2016. [Online]. Available: <https://doi.org/10.1007/s10921-016-0336-x>

- [24] R. Gutierrez Vargas, J. A. Ugalde Ramirez, D. Rojas Valverde, J. Salas Cabrera, and A. Rodriguez Montero, “La termografía infrarroja como herramienta efectiva para detectar áreas musculares dañadas después de correr una maratón,” vol. 65, no. 4, pp. 601–607, 2017.
- [25] O. Barrero and S. A. Perdomo, “RGB and multispectral UAV image fusion for gramineae weed detection in rice fields,” *Precision Agriculture*, vol. 19, no. 5, pp. 809–822, jan 2018. [Online]. Available: <https://doi.org/10.1007/s11119-017-9558-x>
- [26] C. Albornoz and L. F. Giraldo, “Trajectory design for efficient crop irrigation with a UAV,” oct 2017. [Online]. Available: <https://doi.org/10.1109/ccac.2017.8276401>
- [27] S. G. Saavedra, E. A. Mejia, L. H. Callejo, Ó. D. Pérez, H. L. Correa, and E. F. Mejia, “Aerial thermographic inspection of photovoltaic plants: Analysis and selection of the equipment,” in *Proceedings of SWC2017/SHC2017*. International Solar Energy Society, 2017. [Online]. Available: <https://doi.org/10.18086/swc.2017.20.03>
- [28] C. Castiblanco, J. Rodriguez, I. Mondragon, C. Parra, and J. Colorado, “Air Drones for Explosive Landmines Detection,” no. 40, 2014.
- [29] Y. R. Tzeng, C. che Ho, M. H. Sheu, and C.-C. Sun, “Application of thermal camera in PV plants shelter detection,” jun 2017. [Online]. Available: <https://doi.org/10.1109/icce-china.2017.7991170>
- [30] D. Kim, J. Youn, and C. Kim, “Authomatic fault recognition of photovoltaic modules based on statistical analysis of uav thermography,” *ISPRS - International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences*, vol. XLII-2/W6, pp. 179–182, aug 2017. [Online]. Available: <https://doi.org/10.5194/isprs-archives-xlii-2-w6-179-2017>
- [31] A. Blakers, N. Zin, K. R. McIntosh, and K. Fong, “High efficiency silicon solar cells,” *Energy Procedia*, vol. 33, pp. 1–10, 2013. [Online]. Available: <https://doi.org/10.1016/j.egypro.2013.05.033>
- [32] C. Ferrara and D. Philipp, “Why do PV modules fail?” *Energy Procedia*, vol. 15, pp. 379–387, 2012. [Online]. Available: <https://doi.org/10.1016/j.egypro.2012.02.046>
- [33] J. Wohlgemuth, “Reliability testing of PV modules.” [Online]. Available: <https://doi.org/10.1109/wcpec.1994.520104>

- [34] M. Simon and E. L. Meyer, "Detection and analysis of hot-spot formation in solar cells," *Solar Energy Materials and Solar Cells*, vol. 94, no. 2, pp. 106–113, feb 2010. [Online]. Available: <https://doi.org/10.1016/j.solmat.2009.09.016>
- [35] P. Guerriero, P. A. Cennamo, I. Matacena, and S. Daliento, "Avoiding the hot spot occurrence in PV modules," jun 2018. [Online]. Available: <https://doi.org/10.1109/eeeic.2018.8494415>
- [36] Terrascan. (2016) Solar panels thermal and visual inspection. [Online]. Available: www.google.com/search?q=hot+spot+on+pv+system+thermography&tbs=isz:m&tbo=isch&source=lnl&sa=X&ved=0ahUKEwjZr5navOffAhXts1kKHW7bCrUQpwUIHw&biw=960&bih=493&dpr=1.5#imgrc=fKk1dmXxI4oOpM
- [37] K. G. Bedrich, M. Bliss, T. R. Betts, and R. Gottschalg, "Electroluminescence imaging of pv devices: single-time-effect statistics and removal," 2016.
- [38] T. Trupke, B. Mitchell, J. Weber, W. McMillan, R. Bardos, and R. Kroese, "Photoluminescence imaging for photovoltaic applications," *Energy Procedia*, vol. 15, pp. 135–146, 2012. [Online]. Available: <https://doi.org/10.1016/j.egypro.2012.02.016>
- [39] A. Ndiaye, A. Charki, A. Kobi, C. M. Kébé, P. A. Ndiaye, and V. Sambou, *Degradations of silicon photovoltaic modules: A literature review*. Elsevier BV, oct 2013, vol. 96. [Online]. Available: <https://doi.org/10.1016/j.solener.2013.07.005>
- [40] J. A. Tsanakas, L. Ha, and C. Buerhop, "Faults and infrared thermographic diagnosis in operating c-si photovoltaic modules: A review of research and future challenges," *Renewable and Sustainable Energy Reviews*, vol. 62, pp. 695–709, sep 2016. [Online]. Available: <https://doi.org/10.1016/j.rser.2016.04.079>
- [41] S. Ostapenko, W. Dallas, D. Hess, O. Polupan, and J. Wohlgemuth, "Crack detection and analyses using resonance ultrasonic vibrations in crystalline silicon wafers," 2006. [Online]. Available: <https://doi.org/10.1109/wcpec.2006.279606>
- [42] H. Yang, J. Chang, H. Wang, and D. Song, "Power degradation caused by snail trails in urban photovoltaic energy systems," *Energy Procedia*, vol. 88, pp. 422–428, jun 2016. [Online]. Available: <https://doi.org/10.1016/j.egypro.2016.06.018>

- [43] (2017) Espectro electromagnético. [Online]. Available: <https://unmundointelectualblog.wordpress.com/2017/03/08/espectro-electromagnetico/>
- [44] F. Mercuri, N. Orazi, S. Paoloni, C. Cicero, and U. Zammit, “Pulsed thermography applied to the study of cultural heritage,” *Applied Sciences*, vol. 7, no. 10, p. 1010, sep 2017. [Online]. Available: <https://doi.org/10.3390/app7101010>
- [45] M. Vollmer and K.-P. Möllmann, *Infrared Thermal Imaging*. Wiley-VCH Verlag GmbH & Co. KGaA, dec 2017. [Online]. Available: <https://doi.org/10.1002/9783527693306>
- [46] G. Álvarez-Tey, R. Jiménez-Castañeda, and J. Carpio, “Analysis of the configuration and the location of thermographic equipment for the inspection in photovoltaic systems,” *Infrared Physics & Technology*, vol. 87, pp. 40–46, dec 2017. [Online]. Available: <https://doi.org/10.1016/j.infrared.2017.09.022>
- [47] L. Muzika, M. Švantner, and M. Kučera, “Lock-in and pulsed thermography for solar cell testing,” *Applied Optics*, vol. 57, no. 18, p. D90, apr 2018. [Online]. Available: <https://doi.org/10.1364/ao.57.000d90>
- [48] B. Park and P. O. Box, “NFPA 70B Recommended Practice for Electrical Equipment Maintenance 2002 Edition,” 2002.
- [49] T. T. Inc. (2013, apr) Solar pv system maintenance guide guyana hinterlands stand-alone solar pv installations. [Online]. Available: http://www.poweringhealth.org/Pubs/Guyana_Solar_PV_Systems_Maintenance_Guide.pdf
- [50] P. N. T. C. GR. (apr) Photovoltaic system maintenance. [Online]. Available: http://www.labri.fr/perso/billaud/Helios2/resources/en13/Chapter_13_EN.pdf
- [51] M. O. D. MORA, *La regulación civil y militar de las aeronaves civiles pilotadas por control remoto*.
- [52] T. Acharya and A. K. Ray, *Image Processing - Principles and Applications*. New York, NY, USA: Wiley-Interscience, 2005.
- [53] G. Blanchet and M. Charbit, *Digital Signal and Image Processing using MATLAB®*. ISTE, jan 2006. [Online]. Available: <https://doi.org/10.1002/9780470612385>

- [54] *Image Segmentation*. John Wiley & Sons, Inc., sep 2005. [Online]. Available: <https://doi.org/10.1002/0471745790.ch7>
- [55] P. Swierczynski, B. W. Papież, J. A. Schnabel, and C. Macdonald, “A level-set approach to joint image segmentation and registration with application to CT lung imaging,” *Computerized Medical Imaging and Graphics*, vol. 65, pp. 58–68, apr 2018. [Online]. Available: <https://doi.org/10.1016/j.compmedimag.2017.06.003>
- [56] T. Liu, H. Xu, W. Jin, Z. Liu, Y. Zhao, and W. Tian, “Medical image segmentation based on a hybrid region-based active contour model,” in *Comp. Math. Methods in Medicine*, 2014.
- [57] Q. Zhongyuan, M. Xuanqin, W. Ping, and C. Yuanlong, “An adaptive snake algorithm for contour detection.” [Online]. Available: <https://doi.org/10.1109/icosp.2002.1181134>
- [58] R. C. Gonzalez and R. E. Woods, “Digital image processing,” Upper Saddle River, N.J., 2008. [Online]. Available: <http://www.amazon.com/Digital-Image-Processing-3rd-Edition/dp/013168728X>
- [59] D. S. Prabha and J. S. Kumar, “Performance evaluation of image segmentation using objective methods,” *Indian Journal of Science and Technology*, vol. 9, no. 8, Feb. 2016. [Online]. Available: <https://doi.org/10.17485/ijst/2016/v9i8/87907>
- [60] H. Rezatofighi, N. Tsoi, J. Gwak, A. Sadeghian, I. Reid, and S. Savarese, “Generalized intersection over union,” June 2019.
- [61] N. Aggarwal and R. K. Agrawal, “First and second order statistics features for classification of magnetic resonance brain images,” *Journal of Signal and Information Processing*, vol. 03, no. 02, pp. 146–153, 2012. [Online]. Available: <https://doi.org/10.4236/jsip.2012.32019>
- [62] N. Dalal and B. Triggs, “Histograms of oriented gradients for human detection,” in *2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition*. IEEE. [Online]. Available: <https://doi.org/10.1109/cvpr.2005.177>
- [63] R. M. Haralick, K. Shanmugam, and I. Dinstein, “Textural features for image classification,” *IEEE Transactions on Systems, Man, and Cybernetics*, vol. SMC-3, no. 6, pp. 610–621, nov 1973. [Online]. Available: <https://doi.org/10.1109/tsmc.1973.4309314>

- [64] K. Dunne, P. Cunningham, and F. Azuaje, “Solutions to instability problems with sequential wrapper-based approaches to feature selection,” 2002.
- [65] G. C. Ngo and E. Q. B. Macabebe, “Image segmentation using k-means color quantization and density-based spatial clustering of applications with noise (DBSCAN) for hotspot detection in photovoltaic modules,” nov 2016. [Online]. Available: <https://doi.org/10.1109/tencon.2016.7848290>
- [66] P. P. Angelov and X. Gu, *Brief Introduction to Statistical Machine Learning*. Springer International Publishing, oct 2018. [Online]. Available: https://doi.org/10.1007/978-3-030-02384-3_2
- [67] Q. hua Chen, X. fang Xie, T. jie Guo, and S. zhi Yuan, “An efficient approach to extraction ROI from infrared image sequence,” jul 2009. [Online]. Available: <https://doi.org/10.1117/12.835140>
- [68] A. Shariff, J. Kangas, L. P. Coelho, S. Quinn, R. F. Murphy, S. Quinn, and R. F. Murphy, “Journal of Biomolecular Screening,” 2010.
- [69] D. Sera, L. Mathe, T. Kerekes, R. Teodorescu, and P. Rodriguez, “A low-disturbance diagnostic function integrated in the PV arrays MPPT algorithm,” in *IECON 2011 - 37th Annual Conference of the IEEE Industrial Electronics Society*. IEEE, Nov. 2011. [Online]. Available: <https://doi.org/10.1109/iecon.2011.6119695>
- [70] A. M. Karimi, J. S. Fada, J. Liu, J. L. Braid, M. Koyuturk, and R. H. French, “Feature extraction, supervised and unsupervised machine learning classification of PV cell electroluminescence images,” jun 2018. [Online]. Available: <https://doi.org/10.1109/pvsc.2018.8547739>
- [71] S. Leva, M. Aghaei, and F. Grimaccia, “PV power plant inspection by UAS: Correlation between altitude and detection of defects on PV modules,” jun 2015. [Online]. Available: <https://doi.org/10.1109/eeeic.2015.7165466>
- [72] E. Workswell. Thermo diagnosis of photovoltaic power plants. [Online]. Available: https://www.drone-thermal-camera.com/wp-content/uploads/Workswell-WIRIS_photovoltaic.pdf
- [73] S. Gallardo-Saavedra, L. Hernandez-Callejo, and O. Duque-Perez, “Image resolution influence in aerial thermographic inspections of photovoltaic plants,” *IEEE Transactions on Industrial Informatics*,

vol. 14, no. 12, pp. 5678–5686, Dec. 2018. [Online]. Available: <https://doi.org/10.1109/tii.2018.2865403>

- [74] D. D. J. Innovations, *DJI Matrice 100 User Manual*, DJI Da Jiang Innovations, mar 2017.
- [75] C. Buerhop, T. Pickel, M. Dalsass, H. Scheuerpflug, C. Camus, and C. J. Brabec, “aIR-PV-check: A quality inspection of PV-power plants without operation interruption,” jun 2016. [Online]. Available: <https://doi.org/10.1109/pvsc.2016.7749909>
- [76] D. GO. (2017) Zenmuse xt specs. [Online]. Available: <https://www.dji.com/zenmuse-xt/specs>
- [77] B. Precision. (2016) ambient weather. [Online]. Available: <https://www.ambientweather.com/amws2902.html>
- [78] A. K. V. d. O. Mohammadreza Aghaei, Uzoma Edward Madukanya, “Fault inspection by aerial infrared thermography in a pv plant after a meteorological tsunami,” apr 2018.
- [79] C. Buerhop-Lutz, H. Scheuerpflug, and R. Weißmann, “The role of infrared emissivity of glass on ir-imaging of pv-plants,” *26th European Photovoltaic Solar Energy Conference and Exhibition; 3413-3416*, 2011. [Online]. Available: <http://www.eupvsec-proceedings.com/proceedings?paper=12840>
- [80] “THERMAL IMAGING GUIDEBOOK FOR BUILDING and renewable energy APPLICATIONS.”
- [81] J. Gosumbonggot and G. Fujita, “Partial shading detection and global maximum power point tracking algorithm for photovoltaic with the variation of irradiation and temperature,” *Energies*, vol. 12, no. 2, p. 202, Jan. 2019. [Online]. Available: <https://doi.org/10.3390/en12020202>
- [82] P. Zhang, L. Zhang, T. Wu, H. Zhang, and X. Sun, “Detection and location of fouling on photovoltaic panels using a drone-mounted infrared thermography system,” *Journal of Applied Remote Sensing*, vol. 11, no. 1, p. 016026, feb 2017. [Online]. Available: <https://doi.org/10.1117/1.jrs.11.016026>
- [83] A. M. Salazar and E. Q. B. Macabebe, “Hotspots detection in photovoltaic modules using infrared thermography,” *MATEC Web of Conferences*, vol. 70, p. 10015, 2016. [Online]. Available: <https://doi.org/10.1051/matecconf/20167010015>

Apéndice A

En las tablas 1, 2, 3, 4, 5, 6, se presentan las selecciones por carpetas las imágenes de prueba para obtener los coeficiente DICE e IOU para medir el desempeño de la segmentación, de las técnicas implementadas.

Carpeta	Imágenes	Dice	IOU	Precisión	Sensitividad
4-may-2018	DJI_0009.jpg	0,9880	0,9763	0,9309	0,9247
	DJI_0010.jpg	0,9812	0,9632	0,9150	0,9039
	DJI_0011.jpg	0,9824	0,9654	0,9101	0,9019
	DJI_0012.jpg	0,9446	0,8950	0,6541	0,6768
	DJI_0013.jpg	0,9680	0,9381	0,6434	0,6550
	DJI_0014.jpg	0,9696	0,9410	0,7087	0,7267
	DJI_0094.jpg	0,9703	0,9424	0,6630	0,6388
	DJI_0095.jpg	0,9757	0,9526	0,7348	0,7191
	DJI_0096.jpg	0,9765	0,9541	0,7441	0,7282
	DJI_0097.jpg	0,9811	0,9628	0,7982	0,7974
	DJI_0098.jpg	0,9738	0,9489	0,6997	0,6804
	DJI_0099.jpg	0,9777	0,9564	0,7805	0,7698
	DJI_0101.jpg	0,9797	0,9602	0,8545	0,8497
	DJI_0102.jpg	0,9812	0,9632	0,7552	0,7433
	DJI_0109.jpg	0,9814	0,9635	0,8039	0,7966
	DJI_0110.jpg	0,9800	0,9609	0,7718	0,7630
	DJI_0111.jpg	0,9788	0,9585	0,7992	0,7965
	Promedio	0,9758	0,9530	0,7745	0,7689

Tabla 1: Resultados segmentación carpeta 4 Mayo 2018 LS.

Carpeta	Imágenes	Dice	IOU	Precisión	Sensitividad
4-may-2018	DJI_0009.jpg	0,9705	0,9428	0,6864	0,6746
	DJI_0010.jpg	0,9854	0,9712	0,9512	0,9447
	DJI_0011.jpg	0,98	0,9608	0,8246	0,8248
	DJI_0012.jpg	0,9824	0,9655	0,8694	0,871
	DJI_0013.jpg	0,9799	0,9605	0,9165	0,9222
	DJI_0014.jpg	0,9765	0,954	0,808	0,819
	DJI_0094.jpg	0,9808	0,9624	0,7529	0,7632
	DJI_0095.jpg	0,9794	0,9596	0,9215	0,9266
	DJI_0096.jpg	0,9802	0,9612	0,8162	0,8075
	DJI_0097.jpg	0,9717	0,9449	0,6367	0,6323
	DJI_0098.jpg	0,9767	0,9544	0,7539	0,7415
	DJI_0099.jpg	0,9737	0,9487	0,6783	0,6735
	DJI_0101.jpg	0,9739	0,9491	0,7067	0,6865
	DJI_0102.jpg	0,9749	0,9509	0,7293	0,7181
	DJI_0109.jpg	0,976	0,953	0,7549	0,7426
	DJI_0110.jpg	0,973	0,9474	0,7068	0,6987
	DJI_0111.jpg	0,9805	0,9617	0,869	0,8655
	Promedio	0,9773	0,9557	0,7871	0,7830

Tabla 2: Resultados segmentación carpeta 4 Mayo 2018 área.

Carpeta	Imágenes	Dice	Jaccard	Precisión	Sensitividad
18-abr-18	DJI_0676.jpg	0,7546	0,6059	0,0238	0,0221
	DJI_0677.jpg	0,8091	0,6793	0,0231	0,0219
	DJI_0678.jpg	0,9600	0,9231	0,5994	0,5870
	DJI_0679.jpg	0,9054	0,8272	0,2804	0,2647
	DJI_0680.jpg	0,9547	0,9133	0,5183	0,4992
	DJI_0681.jpg	0	0	0	0
	DJI_0682.jpg	0,9288	0,8671	0,3718	0,3556
	DJI_0683.jpg	0,9076	0,8308	0,4673	0,4698
	DJI_0684.jpg	0,9560	0,9157	0,5877	0,5837
	DJI_0685.jpg	0,9684	0,9387	0,7306	0,7237
	DJI_0686.jpg	0,9479	0,9009	0,4133	0,4000
	DJI_0687.jpg	0,9612	0,9253	0,5593	0,5444
	Promedio	0,8378	0,772	0,3812	0,3726

Tabla 3: Resultados segmentación carpeta 18 de abril 2018 ls.

Carpeta	Imágenes	Dice	IOU	Precisión	Sensitividad
18-abr-18	DJI_0676.jpg	0,9756	0,9524	0,9968	0,9921
	DJI_0677.jpg	0,9820	0,9645	0,9395	0,9280
	DJI_0678.jpg	0,9814	0,9636	0,9306	0,9255
	DJI_0679.jpg	0,9826	0,9659	0,9732	0,9644
	DJI_0680.jpg	0,9827	0,9660	0,9797	0,9800
	DJI_0681.jpg	0,9786	0,9581	0,9797	0,9739
	DJI_0682.jpg	0,9803	0,9613	0,9636	0,9565
	DJI_0683.jpg	0,9749	0,9509	0,9251	0,9175
	DJI_0684.jpg	0,9834	0,9673	1,0000	1,0000
	DJI_0685.jpg	0,9765	0,9541	0,8003	0,7916
	DJI_0686.jpg	0,9832	0,9669	0,9278	0,9210
	DJI_0687.jpg	0,9734	0,9482	0,8079	0,7884
	Promedio	0,9795	0,9599	0,9356	0,9282

Tabla 4: Resultados segmentación carpeta 18 de abril 2018 área.

Carpeta	Imágenes	Dice	IOU	Precisión	Sensitividad
28-abr-18	DJI_0898.jpg	0,9659	0,9340	0,7419	0,7272
	DJI_0900.jpg	0,9736	0,9485	0,7445	0,7347
	DJI_0905.jpg	0,9662	0,9346	0,5732	0,5618
	DJI_0908.jpg	0,9670	0,9360	0,6565	0,6388
	DJI_0909.jpg	0,9766	0,9542	0,8357	0,8281
	DJI_0910.jpg	0,9759	0,9529	0,7885	0,7822
	DJI_0911.jpg	0,9742	0,9496	0,6503	0,6330
	DJI_0912.jpg	0,9707	0,9430	0,7616	0,7507
	DJI_0913.jpg	0,9734	0,9482	0,7828	0,7785
	DJI_0914.jpg	0,9733	0,9479	0,8230	0,8179
	Promedio	0,9716	0,9449	0,7357	0,7252

Tabla 5: Resultados segmentación carpeta 28 de abril 2018 ls.

Carpeta	Imágenes	Dice	IOU	Precisión	Sensitividad
28-abr-18	DJI_0898.jpg	0,9789	0,9587	0,8483	0,8423
	DJI_0900.jpg	0,9797	0,9601	0,8684	0,8571
	DJI_0905.jpg	0,9749	0,9510	0,7214	0,7105
	DJI_0908.jpg	0,9718	0,9451	0,7773	0,7628
	DJI_0909.jpg	0,9878	0,9759	0,9087	0,9010
	DJI_0910.jpg	0,9795	0,9599	0,8852	0,8795
	DJI_0911.jpg	0,9864	0,9733	0,9191	0,9127
	DJI_0912.jpg	0,9821	0,9648	0,9130	0,9055
	DJI_0913.jpg	0,9851	0,9707	0,9209	0,9202
	DJI_0914.jpg	0,9849	0,9702	0,9493	0,9426
		Promedio	0,98711	0,9629	0,8711
					0,8634

Tabla 6: Resultados segmentación carpeta 28 de abril 2018 área.

Carpeta	Imágenes	Dice	IOU	Precisión	Sensitividad
20-dic-18	DJI_0655.jpg	0,9782	0,9575	1	1
	DJI_0656.jpg	0,9763	0,9537	0,9604	0,9498
	DJI_0657.jpg	0,9742	0,9498	0,9254	0,9135
	DJI_0782.jpg	0,9499	0,9047	0,4865	0,4772
	DJI_0783.jpg	0,8533	0,7441	0,3743	0,4227
	DJI_0788.jpg	0,9460	0,8976	0,4136	0,4025
	DJI_0789.jpg	0,9430	0,8922	0,3639	0,3576
	DJI_0795.jpg	0,9331	0,8747	0,3180	0,3183
	DJI_0802.jpg	0,8564	0,7488	0,1907	0,2186
	DJI_0836.jpg	0,9265	0,8631	0,5283	0,5592
		DJI_0837.jpg	0,8923	0,8056	0,428
					0,4588

Tabla 7: Resultados segmentación carpeta 20 de diciembre 2018 área.

Apéndice B

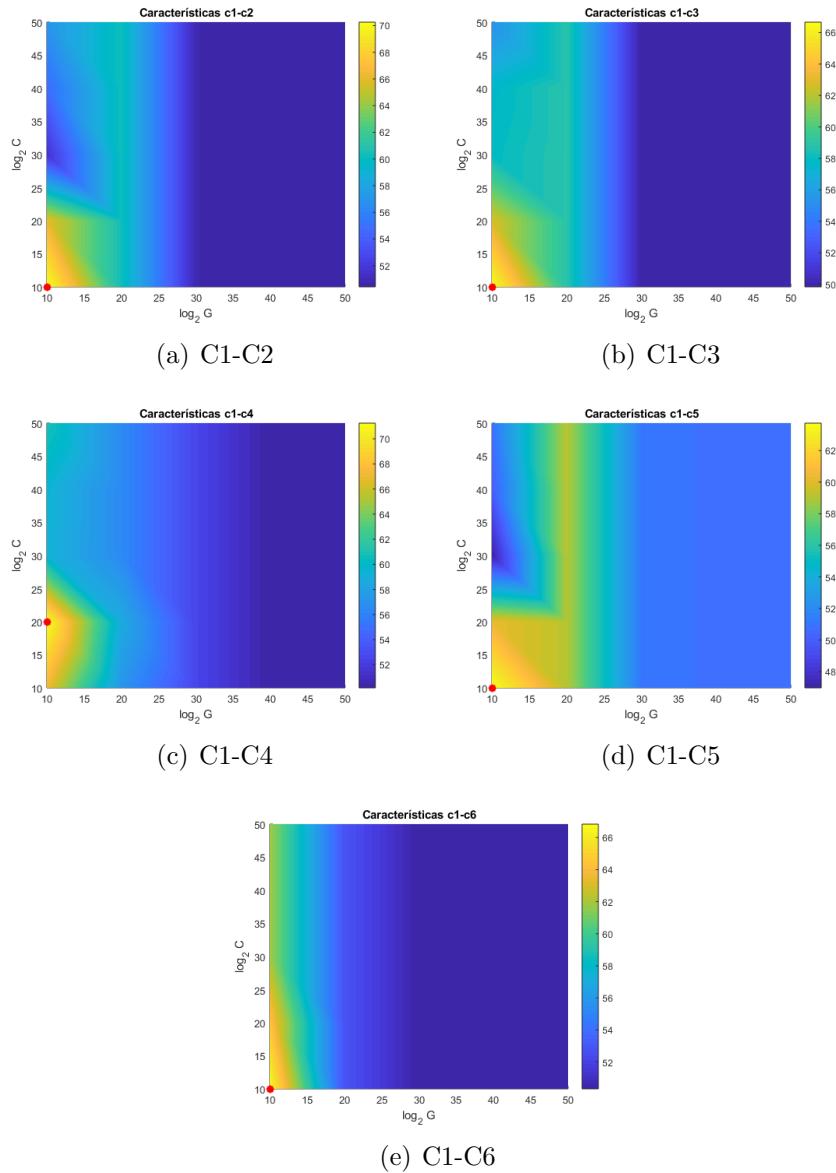


Figura 1: Superficies de precisión características C1 con todas.

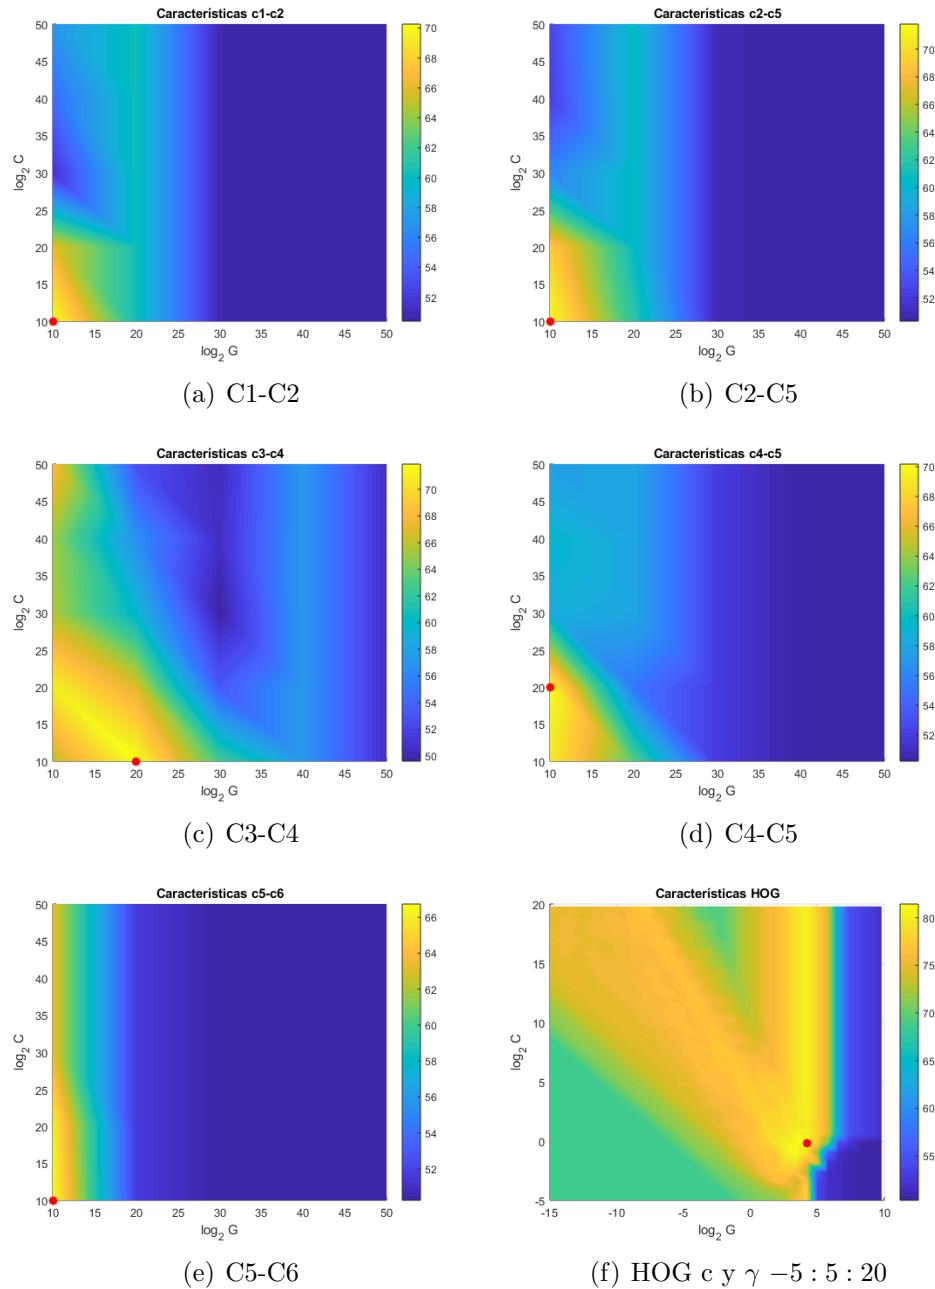


Figura 2: Mejores superficies de precisión.

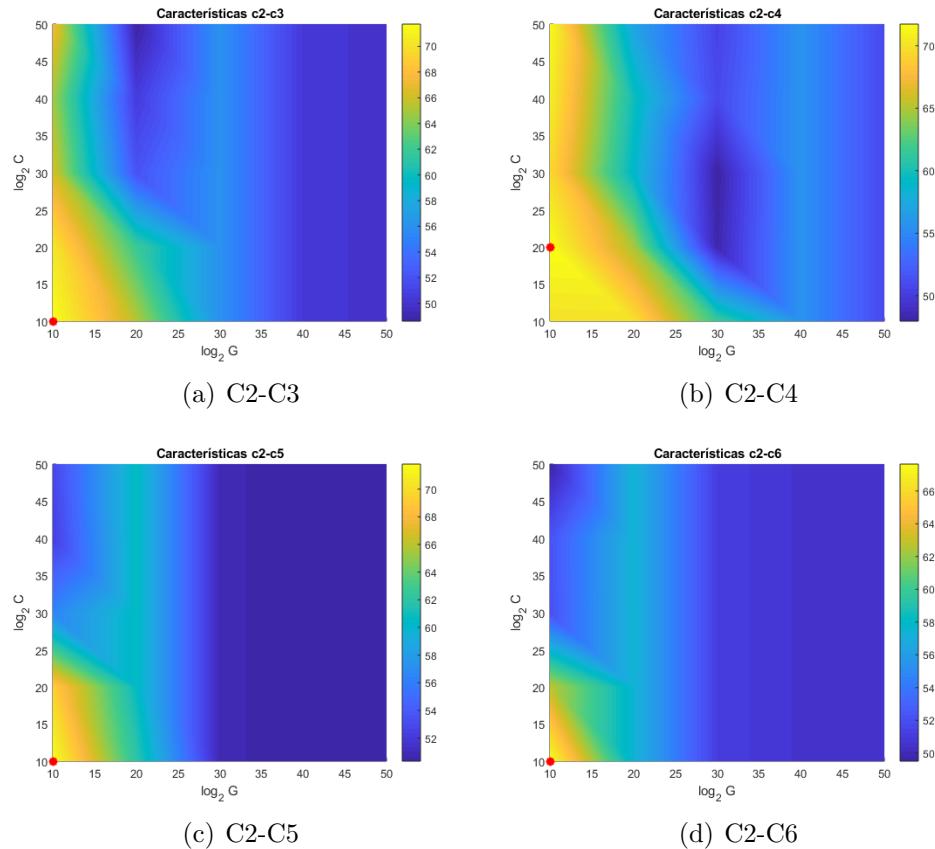


Figura 3: Superficies de precisión características C2 con todas.

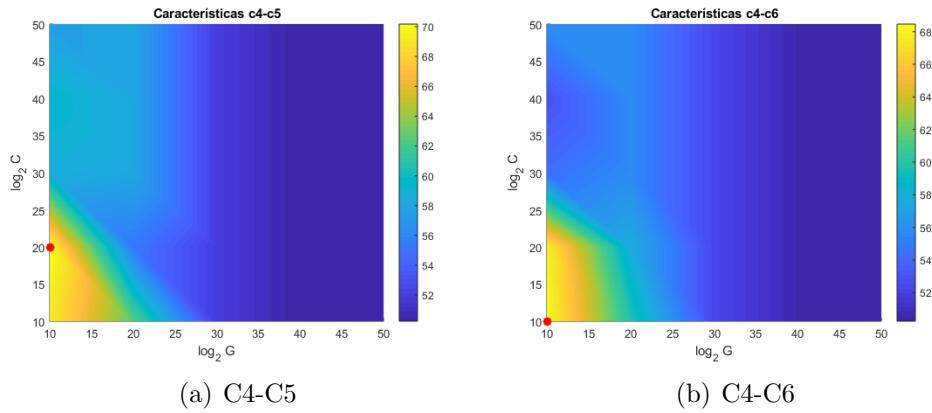


Figura 5

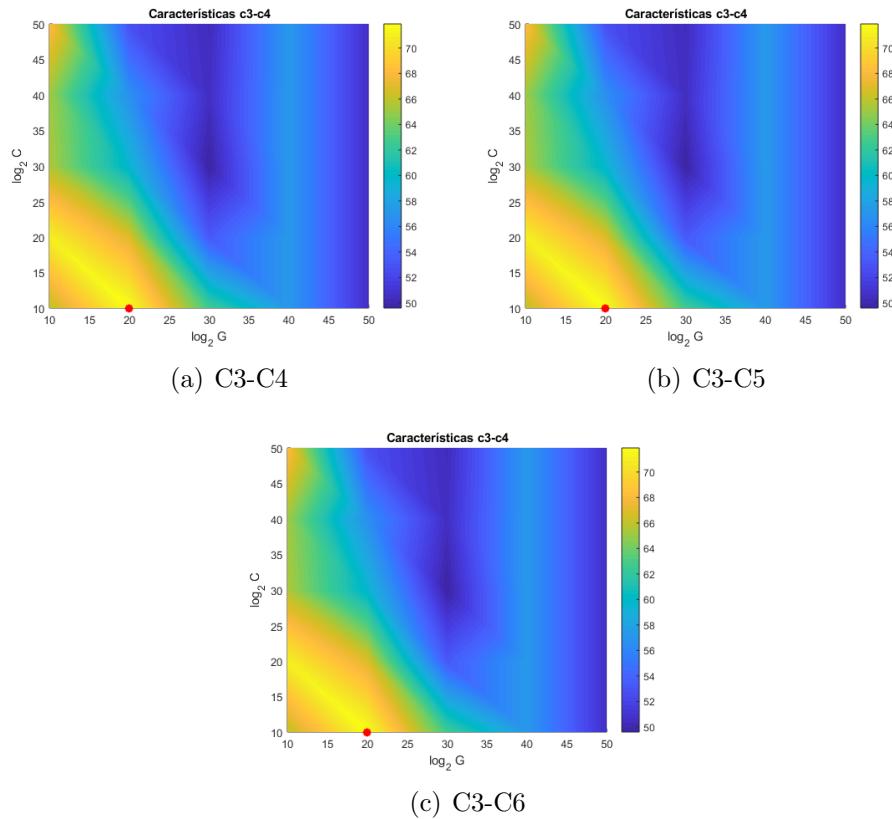


Figura 4: Superficies de precisión características C3 con todas.

Apéndice C

En las siguientes tablas se presentan

	C1	Precisión en la clasificación	C	γ	Precisión en la clasificación	<i>Default</i>
C2	✓	73,90244	10	10	50,4848	✓
C3	✓	65,93647	10	10	48,1542	✓
C4	✓	71,33094	20	10	48,3981	✓
C5	✓	61,58032	10	10	50,6113	✓
C6	✓	69,12074	10	10	48,2761	✓

Tabla 8: Clasificación usando las características C1 a C6 con parámetros por defecto y con búsqueda de hiperparámetros.

	C2	Precisión en la clasificación	C	γ	Precisión en la clasificación	<i>Default</i>
C3	✓	75,36434	10	10	51,9587	✓
C4	✓	75,96957	20	10	52,0822	✓
C5	✓	76,21649	10	10	52,3291	✓
C6	✓	70,09636	10	10	66,4182	✓

Tabla 9: Clasificación usando las características C2 a C6 con parámetros por defecto y con búsqueda de hiperparámetros.

	C3	Precisión en la clasificación	C	γ	Precisión en la clasificación	<i>Default</i>
C4	✓	72,42998	10	20	51,2225	✓
C5	✓	72,9193	10	10	51,3445	✓
C6	✓	68,75643	10	10	63,5938	✓

Tabla 10: Clasificación usando las características C3 a C6 con parámetros por defecto y con búsqueda de hiperparámetros.

	C4	Precisión en la clasificación	C	γ	Precisión en la clasificación	Default
C5	✓	71,206447	20	10	50,8612	✓
C6	✓	68,26709	10	10	64,5905	✓

Tabla 11: Clasificación usando las características C4 a C6 con parámetros por defecto y con búsqueda de hiperparámetros.

	C5	Precisión en la clasificación	C	γ	Precisión en la clasificación	Default
C6	✓	68,38452	10	10	61,6652	✓

Tabla 12: Clasificación usando las características C5 y C6 con parámetros por defecto y con búsqueda de hiperparámetros.

HOG	Precisión en la clasificación	C	γ	Precisión en la clasificación	Default
Todas	82,92	2,8	0,6	75,249	✓

Tabla 13: Clasificación usando las características H8 con parámetros por defecto y con búsqueda de hiperparámetros.

Apéndice D

Características k-medias

c1	c2	c3	c4	c5	c6	Precisión	Rand index
✓	✓					57,3611111	51,0740116
✓		✓				57,1626984	51,016366
✓			✓			57,2420635	51,0392352
✓				✓		56	50,7615913
✓					✓	64,2261905	54,0385706

Tabla 14: Clasificación usando k-medias celda sana y fracturada *wrapper* C1 vs CT.

c2	c3	c4	c5	c6	Precisión	Rand Index
✓	✓				51,2103175	50,0193806
✓		✓			50,6944444	49,9997244
✓			✓		56,1904762	50,7566694
✓				✓	64,4444444	54,163745

Tabla 15: Clasificación usando k-medias celda sana y fracturada *wrapper C2* vs CT.

c3	c4	c5	c6	Precisión	Rand Index
✓	✓			50,218254	49,9910303
✓		✓		55,9126984	50,6894162
✓			✓	63,2738095	53,5146571

Tabla 16: Clasificación usando k-medias celda sana y fracturada *wrapper C3* vs CT.

c4	c5	c6	Precisión	Rand Index
✓	✓		55,9325397	50,6941176
✓		✓	63,452381	53,6101267

Tabla 17: Clasificación usando k-medias celda sana y fracturada *wrapper C4* vs CT.

c5	c6	Precisión	Rand Index
✓	✓	64,0079365	53,9153019

Tabla 18: Clasificación usando k-medias celda sana y fracturada *wrapper C5* vs CT.

Tablas k-medias celda sana y *hot spot*

c1	c2	c3	c4	c5	c6	Precisión	Rand index
✓	✓					53,7745	50,2606
✓		✓				53,0882	50,1613
✓			✓			53,8235	50,268
✓				✓		54	50,268
✓					✓	64,4608	54,1589

Tabla 19: Clasificación usando k-medias celda sana y *hot spot wrapper C1* vs CT.

c2	c3	c4	c5	c6	Precisión	Recall
✓	✓				50,9803922	49,994711
✓		✓			50,7843137	49,9877872
✓			✓		54,3627451	50,3563358
✓				✓	65,0980392	54,5367298

Tabla 20: Clasificación usando k-medias celda sana y *hot spot wrapper* C2 vs CT.

c3	c4	c5	c6	Precisión	Rand index
✓	✓			50,7843137	49,9877872
✓		✓		54,1666667	50,3228707
✓			✓	64,8529412	54,3898393

Tabla 21: Clasificación usando k-medias celda sana y *hot spot wrapper* C3 vs CT.

c4	c5	c6	Precisión	Rand Index
✓	✓		54,3627451	50,3563358
✓		✓	64,8529412	54,3898393

Tabla 22: Clasificación usando k-medias celda sana y *hot spot wrapper* C4 vs CT.

c5	c6	Precisión	Recall
✓	✓	64,754902	54,3317562

Tabla 23: Clasificación usando k-medias celda sana y *hot spot wrapper* C5 vs CT.

Tablas de clasificación celda fracturada y *hot spot*

c1	c2	c3	c4	c5	c6	Precisión	Rand index
✓	✓					80,6862745	68,8176634
✓		✓				84,5588235	73,8734385
✓			✓			80,6862745	68,8176634
✓				✓		80	67,7496658
✓					✓	82,1568627	70,6668975

Tabla 24: Clasificación usando k-medias celda fracturada y *hot spot wrapper* C1 vs CT.

c2	c3	c4	c5	c6	Precisión	Recall
✓	✓				80,7843137	68,9382531
✓		✓			50,3921569	49,9785554
✓			✓		79,2647059	67,1123388
✓				✓	72,1568627	59,7988249

Tabla 25: Clasificación usando k-medias celda fracturada y *hot spot wrapper* C2 vs CT.

c3	c4	c5	c6	Precisión	Recall
✓	✓			80,9803922	69,1805864
✓		✓		83,4803922	72,4052063
✓			✓	77,745098	65,3788381

Tabla 26: Clasificación usando k-medias celda fracturada y *hot spot wrapper* C3 vs CT.

c4	c5	c6	Precisión	Rand Index
✓	✓		79,2647059	67,1123388
✓		✓	72,1568627	59,7988249

Tabla 27: Clasificación usando k-medias celda fracturada y *hot spot wrapper* C4 vs CT.

c5	c6	Precisión	Rand Index
✓	✓	83,8235294	72,8673225

Tabla 28: Clasificación usando k-medias celda fracturada y *hot spot wrapper* C5 vs CT.

Clasificación a partir de métodos no supervisados para la celda fracturada y *hot spot*.

c1	c2	c3	c4	c5	c6	Precisión	Rand index
✓	✓					42,4242424	50,3784453
✓		✓				39,3939394	50,0092081
✓			✓			41,1876114	49,8301953
✓				✓		41	49,7131689
✓					✓	42,7361854	50,5231481

Tabla 29: Clasificación usando k-medias celda fracturada y *hot spot wrapper* C3 vs CT.

c2	c3	c4	c5	c6	Precisión	Rand Index
✓					46,5129234	50,2972408
✓	✓				65,1180927	54,8872313
✓		✓			43,1038324	50,3495375
✓			✓		47,894385	51,3649348

Tabla 30: Clasificación usando k-medias celda fracturada y *hot spot wrapper* C3 vs CT.

c3	c4	c5	c6	Precisión	Rand Index
✓	✓			47,2259358	50,1956738
✓		✓		39,6613191	49,9971127
✓			✓	44,6524064	52,6006658

Tabla 31: Clasificación usando k-medias celda fracturada y *hot spot wrapper* C3 vs CT.

c4	c5	c6	Precisión	Rand Index
✓	✓		40,9759358	49,6387643
✓		✓	40,0846702	50,4509059

Tabla 32: Clasificación usando k-medias celda fracturada y *hot spot wrapper* C4 vs CT.

c5	c6	Precisión	Rand Index
✓	✓	37,7116756	49,3030477

Tabla 33: Clasificación usando k-medias celda fracturada y *hot spot wrapper* C5 vs CT.

Clasificación a partir de métodos no supervisados a partir de mezcla de Gausianas

c1	c2	c3	c4	c5	c6	Precisión	Rand index
✓	✓					58,2924837	51,3653722
✓		✓				57,7614379	51,19483
✓			✓			58,3333333	51,3789581
✓				✓		58	51,19483
✓					✓	58,2924837	51,3653722

Tabla 34: Clasificación usando mezcla de gausianas celda fracturada y sana *wrapper* C1 vs CT.

c2	c3	c4	c5	c6	Precisión	Rand Index
✓	✓				57,7614379	51,19483
✓		✓			58,2924837	51,3653722
✓			✓		57,9452614	51,252587
✓				✓	58,2924837	51,3653722

Tabla 35: Clasificación usando mezcla de gausianas celda fracturada y sana *wrapper C2 vs CT*.

c4	c5	c6	Precisión	Rand index
✓	✓		69,3831699	57,5054661
✓		✓	57,1486928	51,0120705

Tabla 36: Clasificación usando mezcla de gausianas celda fracturada y sana *wrapper C4 vs CT S1*.

c5	c6	Precisión	Rand Index
✓	✓	57,7614379	51,19483

Tabla 37: Clasificación usando mezcla de gausianas celda fracturada y sana *wrapper C5 vs CT S1*.

Clasificación de Celdas *hot spot* y celda sana.

c1	c2	c3	c4	c5	c6	Precisión	Rand index
✓	✓					54,8039216	50,4372578
✓		✓				50,7352941	49,9862966
✓			✓			54,8039216	50,4372578
✓				✓		51	49,9862966
✓					✓	54,9509804	50,4659627

Tabla 38: Clasificación usando mezcla de gausianas celda *hot spot* y sana *wrapper C1 vs CT*.

c2	c3	c4	c5	c6	Precisión	Rand Index
✓	✓				53,0392157	50,1603054
✓		✓			55,0490196	50,4855802
✓			✓		53,0392157	50,1603054
✓				✓	55,0490196	50,4855802

Tabla 39: Clasificación usando mezcla de gausianas celda *hot spot* y sana *wrapper C2 vs CT*.

c3	c4	c5	c6	Precisión	<i>Rand Index</i>
✓	✓			52,8921569	50,1428516
✓		✓		51,2745098	50,0079816
✓			✓	54,4117647	50,3649424

Tabla 40: Clasificación usando mezcla de gausianas celda *hot spot* y sana *wrapper* C3 vs CT.

c4	c5	c6	Precisión	<i>Rand Index</i>
✓	✓		51,7647059	50,0377925
✓		✓	54,4117647	50,3649424

Tabla 41: Clasificación usando mezcla de gausianas celda *hot spot* y sana *wrapper* C4 vs CT.

c5	c6	Precisión	<i>Rand Index</i>
✓	✓	51,7647059	50,0377925

Tabla 42: Clasificación usando mezcla de gausianas celda *hot spot* y sana *wrapper* C5 vs CT.