

Detección de Anomalías por Termografía en Equipos Eléctricos Usando Técnicas de Visión Artificial



Autor: Jorge H. Erazo Aux

Director: Humberto Loaiza Ph.D

Una tesis presentada para optar al título de
Maestría en Ingeniería con énfasis en Electrónica

Programa de Posgrados en Ingeniería Eléctrica y Electrónica
Facultad de Ingeniería
Universidad del Valle
2009

Índice general

1. Introducción	1
2. Marco Teórico	5
2.1. Introducción	5
2.2. Antecedentes	5
2.2.1. Antecedentes Regionales	6
2.2.2. Antecedentes Nacionales	8
2.2.3. Antecedentes Internacionales	9
2.3. Transferencia de Calor	18
2.4. Termografía	19
2.4.1. Termografía Activa	23
2.4.2. Termografía Pasiva	23
2.5. Equipo de Inspección	25
2.6. Imágenes Infrarrojas	29
2.7. Procesamiento Digital de Imágenes	30
2.8. Conclusiones	36
3. Adquisición de termografías y descripción de la plataforma experimental	37
3.1. Introducción	37
3.2. Procedimiento de adquisición	37
3.2.1. Captura de la imagen	38

ÍNDICE GENERAL

3.2.1.1.	Rango de temperatura	38
3.2.1.2.	Enfoque óptico	41
3.2.1.3.	Composición de la imagen	42
3.2.2.	Parámetros adicionales	43
3.2.2.1.	Distancia, Temperatura, Humedad Relativa	44
3.2.2.2.	Temperatura reflejada	45
3.2.2.3.	Emisividad	46
3.2.2.4.	Velocidad del viento	48
3.2.2.5.	Carga eléctrica	52
3.3.	Plataforma experimental	52
3.4.	Conclusiones	61
4.	Sistema para el análisis de imágenes termográficas	63
4.1.	Introducción	63
4.2.	Software del sistema	63
4.2.1.	Módulo de entrada	64
4.2.2.	Módulo de procesamiento con máquinas de aprendizaje . .	65
4.2.2.1.	Filtrado	66
4.2.2.2.	Segmentación	69
4.2.2.3.	Extracción de características	69
4.2.2.4.	Normalización de datos	71
4.2.2.5.	Máquinas de aprendizaje	74
4.2.3.	Módulo de procesamiento basado en información del gradiente	77
4.2.3.1.	Filtrado	78
4.2.3.2.	Segmentación	79
4.2.3.3.	Extracción de características	80
4.2.3.4.	Clasificación	81
4.2.4.	Módulo de salida	82
4.3.	Conclusiones	83

5. Pruebas y resultados	85
5.1. Introducción	85
5.2. Módulo procesamiento basado en máquinas de aprendizaje	85
5.2.1. Prueba No.1	85
5.2.1.1. Objetivo	85
5.2.1.2. Descripción	85
5.2.1.3. Resultados	86
5.2.2. Prueba No.2	89
5.2.2.1. Objetivo	89
5.2.2.2. Descripción	89
5.2.2.3. Resultados	90
5.2.3. Prueba No.3	91
5.2.3.1. Objetivo	91
5.2.3.2. Descripción	91
5.2.3.3. Resultados	93
5.2.4. Prueba No.4	97
5.2.4.1. Objetivo	97
5.2.4.2. Descripción	97
5.2.4.3. Resultados	97
5.2.5. Prueba No.5	98
5.2.5.1. Objetivo	98
5.2.5.2. Descripción	98
5.2.5.3. Resultados	99
5.3. Módulo de procesamiento basado en información del gradiente . .	105
5.3.1. Prueba No.1	105
5.3.1.1. Objetivo	105
5.3.1.2. Descripción	105
5.3.1.3. Resultados	105
5.3.2. Prueba No.2	106
5.3.2.1. Objetivo	106

ÍNDICE GENERAL

5.3.2.2.	Descripción	106
5.3.2.3.	Resultados	107
5.3.3.	Prueba No.3	114
5.3.3.1.	Objetivo	114
5.3.3.2.	Descripción	114
5.3.3.3.	Resultados	115
5.4.	Conclusiones	117
6.	Conclusiones Generales	120
7.	Perspectivas Futuras	123
	Referencias	134

Índice de figuras

2.1. Ley de Fourier	18
2.2. Espectro Electromagnético	20
2.3. Radiacion Cuerpo Negro	21
2.4. Esquema de configuración típico para implementación de Termografía Activa	22
2.5. Ejemplos de aplicación de Termografía: (a) Espectro visible de un tanque de almacenamiento industrial. (b) Termografía de a. (c) Espectro visible de un transformador. (d) Termografía de c.	24
2.6. Esquema de un sistema de imágenes infrarrojas basado en FPA no refrigerado.	26
2.7. Cámara Thermovision TM A20M.	28
2.8. Pieza de fibra de vidrio. (a) Espectro visible. (b) Termografía en escala de grises. (c) Termografía en falso color.	30
2.9. Etapas fundamentales en Procesamiento Digital de Imágenes.	32
3.1. Rango de una imagen.	39
3.2. Variaciones del contraste térmico o campo en una imagen IR. (a) Espectro visible del componente eléctrico. (b) Termografía de a con campo 1. (c) Termografía de a con campo 2. (d) Termografía de a con campo 3.	40

ÍNDICE DE FIGURAS

3.3. Ejemplo del enfoque óptico. (a) Espectro visible de la escena. (b) Termografía con mal enfoque óptico. (c) Termografía con un enfoque óptico correcto.	41
3.4. Ilustración gráfica del criterio de composición. (a) Variación IFOV con la distancia. (b) Criterio de composición.	42
3.5. Radiación que llega a la cámara IR.	45
3.6. Metodo del reflector para estimación de la temperatura reflejada.	46
3.7. Comparación entre la radiación de un cuerpo real y la de un cuerpo negro	47
3.8. Efectos de una baja emisividad. (a) Imagen en espectro visible de un objeto con baja emisividad. (b) Termografía del objeto a (60 °C) con ajuste térmico automático. (c) Termografía del objeto a (27 °C) a temperatura ambiente con ajuste térmico automático. (d) Termografía del objeto a (2 °C) con ajuste térmico automático. (e) Termografía del objeto a (60 °C) con campo estático. (f) Termografía del objeto a (27 °C) a temperatura ambiente con campo fijo. (g) Termografía del objeto a (2 °C) con campo fijo.	49
3.9. Estimación de la emisividad usando una superficie de emisividad conocida. (a) T1 temperatura zona con emisividad conocida. (b) T1 temperatura zona con emisividad ajustada.	50
3.10. Ejemplos de compensación. (a) Espectro visible de la escena. (b) Termografía de a con compensación 1. (c) Termografía de a con compensación 2.	51
3.11. Conversor Video-USB X10-VA11A	53
3.12. Cámara FLIR ThermoCAM E320	54
3.13. Comparación parámetros IFOV, HFOV y VFOV para Camaras ThermoVision A20 y ThermoCAM E320. (a) IFOV. (b) HFOV. (c) VFOV.	56

ÍNDICE DE FIGURAS

3.14. Instrumentos básicos. (a) Medidor de distancia láser Estanley TLM100. (b) Medidor de variables ambientales Kestrel 4000. (c) Medidor de temperatura IR FLUKE 62. (d) Cámara SONY DSCW55.	57
3.15. Equipos Inspeccionados. (a) Seccionador ALSTOM. (b) Transformador de corriente BALTEAU. (c) Buje capacitivo MITSUBISHI.	59
3.16. Fuente de corriente.	60
3.17. Motor unidad Feedback ES151	61
4.1. Software del sistema.	64
4.2. Funcionamiento del módulo de entrada. (a) Termografía del motor con paleta de color <i>Iron de alta definición</i> . (b) Termografía de motor en escala de grises	65
4.3. Módulo de procesamiento con máquinas de aprendizaje.	66
4.4. Etapa de filtrado. (a) Termografía de un motor sin filtrado. (b) Filtrado mediana de a con máscara 3×3 . (c) Filtrado mediana de a con máscara 5×5 . (d) Espectro de Fourier de a . (e) Espectro de Fourier de b . (f) Espectro de Fourier de c	67
4.5. Diagramas de flujo. (a) Modulo de entrada. (b) Etapa de filtrado. (c) Etapa de segmentación.	68
4.6. Segmentación manual de una imagen en el módulo de procesamiento basado en máquinas de aprendizaje.	69
4.7. Ejemplos normalización lineal (a) Relación lineal rango $[0 \ 500]$. (b) Relación lineal min max rango $[-1 \ 1]$. (c) Relación lineal mean std media = 0 y varianza = 1.	72
4.8. Normalización: (a) Whitening. (b) PCA.	74
4.9. Ejemplos normalización logarítmica (a) Relación lineal rango $[0 \ 500]$. (b) Relación logarítmica rango $[0 \ 50]$. (c) Relación logarítmica rango $[0 \ 1]$	75
4.10. Diagramas de flujo. (a) Etapa de extracción de características. (b) Etapa de normalización.	75

ÍNDICE DE FIGURAS

4.11. Diagrama de flujo de la etapa de clasificación.	77
4.12. Módulo de procesamiento con información del gradiente.	78
4.13. Imagen con información del ángulo del gradiente de un motor: (a) Sin filtrar. (b) Filtrada.	79
4.14. Segmentación de una ROI rectangular: (a) Whitening. (b) PCA. .	80
4.15. Extracción de información del gradiente sobre una imagen térmica: (a) Imágen térmica con una ROI seleccionada. (b) Perfil de intensidad de la ROI. (c) Información de magnitud del gradiente de la ROI. (d) Información de ángulo del gradiente de la ROI. . .	81
4.16. Diagrama de flujo Etapa de clasificación del módulo del gradiente.	82
5.1. Imágenes térmicas del motor eléctrico de la unidad FeedBack ES151 bajo distintos niveles de operación.	87
5.2. Imágenes térmicas del motor eléctrico de la unidad FeedBack ES151 bajo distintos niveles de operación aplicando a cada uno de ellos una carga magnética adicional (disturbio).	88
5.3. Número de neuronas en la capa oculta vs MSE para 20.000 iteraciones de entrenamiento: (a) MSE acumulado. (b) MSE.	91
5.4. Número de neuronas en la capa oculta vs MSE para 40.000 iteraciones de entrenamiento: (a) MSE acumulado. (b) MSE.	92
5.5. Desempeño de los clasificadores. (a) Bayesiano. (b) MLP. (c) RBF. (d) Comparación conjunta de desempeño de los clasificadores. . .	95
5.6. Representación gráfica de la capacidad de generalización de los clasificadores implementados. (a) Estado normal: Sensibilidad (azul), especificidad (rojo). (b) Estado anómalo: Sensibilidad (rojo), especificidad (azul). (c) Índice del elemento de validación Vs Clase de pertenencia.	99
5.7. Desempeño del clasificador <i>Bayesiano</i> ante distintos métodos de normalización: (a) Método de normalización Vs Porcentaje de acierto. (b) Número del grupo de validación Vs Porcentaje de acierto. .	100

ÍNDICE DE FIGURAS

5.8. Desempeño del clasificador <i>Bayesiano</i> ante distintos métodos de normalización: (a) Método de normalización Vs Porcentaje de acierto. (b) Número del grupo de validación Vs Porcentaje de acierto. .	101
5.9. Desempeño del clasificador <i>RBF</i> ante distintos métodos de normalización: (a) Método de normalización Vs Porcentaje de acierto. (b) Número del grupo de validación Vs Porcentaje de acierto	102
5.10. Imágenes equipos eléctricos sin fallas de contacto en los cables de alimentación.	106
5.11. Imágenes equipos eléctricos con fallas de contacto en los cables de alimentación.	107
5.12. Imagen sintética con distribución lineal de niveles de gris. (a) Distribución de intensidad lineal. (b) Perfil de intensidad. (c) Magnitud del gradiente. (d) Angulo del gradiente. (e) Perfil de intensidad ordenado ascendente y descendientemente. (f) Error entre el perfil de intensidad original y el ordenado ascendente y descendientemente.	108
5.13. Imagen sintética con distribución constante de niveles de gris. (a) Distribución de intensidad constante. (b) Perfil de intensidad. (c) Magnitud del gradiente. (d) Angulo del gradiente. (e) Perfil de intensidad ordenado ascendente y descendientemente. (f) Error entre el perfil de intensidad original y el ordenado ascendente y descendientemente.	109
5.14. Imagen sintética con distribución exponencial de niveles de gris. (a) Distribución de intensidad exponencial. (b) Perfil de intensidad. (c) Magnitud del gradiente. (d) Angulo del gradiente. (e) Perfil de intensidad ordenado ascendente y descendientemente. (f) Error entre el perfil de intensidad original y el ordenado ascendente y descendientemente.	110

ÍNDICE DE FIGURAS

5.15. Imagen sintética con distribución logarítmica de niveles de gris. (a) Distribución de intensidad logarítmica. (b) Perfil de intensidad. (c) Magnitud del gradiente. (d) Angulo del gradiente. (e) Perfil de intensidad ordenado ascendente y descendientemente. (f) Error entre el perfil de intensidad original y el ordenado ascendente y descendientemente.	112
5.16. Imagen sintética con distribución radial lineal de niveles de gris. (a) Distribución de intensidad radial. (b) Perfil de intensidad. (c) Magnitud del gradiente. (d) Angulo del gradiente. (e) Perfil de intensidad ordenado ascendente y descendientemente. (f) Error entre el perfil de intensidad original y el ordenado ascendente y descendientemente.	113

Índice de cuadros

2.1. Algunas ventajas y limitaciones de la Termografía	25
2.2. Especificaciones técnicas Thermovision TM A20M.	27
2.3. Thermovision TM A20M. Campo de vision horizontal, vertical e instantáneo (HFOV, VFOV, IFOV) sobre algunas distancias D al objeto de inspección, para lentes IR de 17 mm.	27
3.1. Factor de corrección para velocidad del viento FCVV.	50
3.2. Factor de corrección de carga FCC.	52
3.3. Especificaciones técnicas ThermaCAM TM E320.	54
3.4. ThermaCAM TM E320. Campo de vision horizontal, vertical e instantáneo (HFOV, VFOV, IFOV) sobre algunas distancias D al objeto de inspección, para lentes IR de 14,7 mm.	55
3.5. Estanley TLM 100. Características principales del medidor de distancia láser Estanley TLM 100.	55
3.6. Características principales del medidor de variables ambientales Kestrel K4000.	57
3.7. Especificaciones técnicas del Seccionador ALSTOM.	58
3.8. Especificaciones técnicas del Transformador de Corriente BALTEAU.	59
3.9. Especificaciones técnicas del Buje Capacitivo MITSUBISHI.	60
3.10. Especificaciones técnicas del equipo de cómputo DELL OptiPlex 755.	60

ÍNDICE DE CUADROS

4.1. Momentos invariantes de Hu	71
4.2. Criterios para clasificación de anomalías usando varios estándares.	83
5.1. Matriz de confusión.	93
5.2. Indices de desempeño para el clasificador <i>Bayesiano</i>	95
5.3. Indices de desempeño para el clasificador <i>MLP</i>	96
5.4. Indices de desempeño para el clasificador <i>RBF</i>	96
5.5. Comparación de Indices de desempeño para clasificadores <i>Bayesiano</i> , <i>MLP</i> y <i>RBF</i>	96
5.6. Indices de desempeño para clasificador <i>MLP</i> ante distintos méto- dos de normalización.	100
5.7. Indices de desempeño para clasificador <i>MLP</i> ante distintos méto- dos de normalización.	101
5.8. Indices de desempeño para clasificador <i>RBF</i> ante distintos métodos de normalización.	102
5.9. Comparación Indices de desempeño para clasificadores <i>Bayesiano</i> , <i>MLP</i> y <i>RBF</i> de los datos <i>SN</i> frente al mejor método de normal- ización alcanzado.	103
5.10. Datos extraídos de la información del gradiente aplicada a <i>ROI</i> 's de imágenes sintéticas.	114
5.11. Indices de desempeño umbrales $U1$	115
5.12. Indices de desempeño umbrales $U2$	115
5.13. Indices de desempeño umbrales $U3$	116
5.14. Comparación de Indices de desempeño para Umbrales $U1$, $U2$ y $U3$	116
5.15. Resultados clasificacion niveles de severidad.	117

Capítulo 1

Introducción

La finalidad de este documento es dar a conocer los resultados, diseño e implementación de una propuesta para la detección de anomalías en equipo eléctrico usando técnicas de procesamiento digital de imágenes conjuntamente con sistemas de aprendizaje como redes neuronales tipo RBF y MLP.

El ensayo no destructivo (NDT Nondestructive Testing), se define como una compresión de todos aquellos métodos usados para examinar o inspeccionar parte de un material o sistema sin deteriorar su uso futuro. A inicios del siglo XX esta metodología se desarrolló como parte de una simple curiosidad dentro de laboratorios hasta convertirse hoy en día en una herramienta indispensable en procesos de producción, usándose para detectar variaciones en estructuras, pequeños cambios en el acabado de superficies, presencia de fisuras u otra clase de imperfecciones físicas, medir el grosor de materiales y determinar otras características de productos industriales. El ensayo no destructivo actualmente es utilizado por los fabricantes principalmente para: asegurar la integridad y confiabilidad de un producto, evitar fallas, prevenir accidentes y salvar vidas humanas, asegurar la satisfacción del cliente y mantener la reputación del fabricante, ayudar a mejorar en el diseño de un producto, controlar procesos de fabricación, mantener niveles uniformes de calidad y agilizar los procesos operacionales entre otros.

La termografía es una técnica de ensayo no destructivo sin contacto, que obtiene la temperatura de la superficie de un cuerpo a través de la captación de la radiación infrarroja que ésta emite usando un dispositivo específicamente diseñado para tal fin. El mapa térmico de la superficie obtenido es llamado termografía (termograma). La temperatura es comúnmente considerada como la clave del éxito en el mantenimiento de un sistema y es una de las cantidades que con mayor frecuencia es medida en el control de procesos industriales [Mal01a].

Cuando se tiene en cuenta el campo de la distribución y generación de energía eléctrica, la utilización de termografía resulta favorable por su gran variedad de aplicaciones, que abarcan desde el monitoreo de conexiones eléctricas, tableros o switches hasta la evaluación de equipos mecánicos y sistemas de transferencia de fluidos. Desde el punto de vista de mantenimiento la termografía es de crucial importancia, ya que ésta ayuda a reducir costos y pérdidas materiales debido a causas como el envejecimiento de los dispositivos, sobrecargas eléctricas y condiciones ambientales. Es aquí donde la termografía empieza a jugar un papel muy significativo como método de inspección, éste generalmente se ejecuta por medio de la comparación visual de distintas termografías tomadas al mismo elemento en distintos períodos de tiempo o comparando diferenciales de temperatura existentes en un objeto de interés en una misma termografía. Errores de diagnóstico se pueden presentar fácilmente debido a la alta dependencia e intervención humana en el proceso.

Desde sus inicios el rango de acción que se le ha dado a la termografía ha sido muy amplio, siendo la inspección de equipo eléctrico una de las aplicaciones más importantes a nivel industrial. A este nivel las inspecciones termográficas pueden brindar una herramienta de soporte como acercamiento al estado de funcionamiento de un componente que forma parte de un sistema eléctrico, la ejecución de la inspección no necesita poner fuera de trabajo los equipos de interés lo cual no afecta la actividad del sistema del cual estos forman parte.

Actualmente el mantenimiento de equipo eléctrico mediante inspección termográfica carece de objetividad y soporte estadístico. El diagnóstico se ejecuta en

algunos casos mediante la comparación visual de varias termografías tomadas al mismo equipo en distintos periodos de tiempo o en casos más frecuentes por medio de la comparación directa de la temperatura aparente entre componentes similares que se encuentren en una misma termografía. El desempeño de este proceso depende en gran parte de la intervención humana y de los múltiples factores que potencialmente pueden influenciar lo que se puede observar en una imagen termográfica lo que afectará directamente la calidad de la inspección. Esto conlleva a que el diagnóstico sea susceptible a errores presentes en su proceso de desarrollo [Sne03]. Un experto requiere de una cantidad considerable de entrenamiento y experiencia para generar una interpretación confiable de una termografía. Por consiguiente afirmar que diferencias de temperatura de un componente o entre diferentes partes de una instalación eléctrica, son normales o debidas a algún error o efecto de su mal funcionamiento se convierte en una tarea difícil.

Disponer de termografías adquiridas mediante un protocolo validado [PNS94] facilitará la posibilidad de analizar imágenes termográficas confiablemente con ayuda de herramientas computacionales. Así se podrá inferir sobre el estado de un equipo bajo inspección. La utilización de herramientas computacionales para apoyar el diagnóstico de termografías presentará ventajas evidentes respecto a los procedimientos convencionales de comparación visual que se realizan actualmente.

Con base en lo anterior, el objetivo general planteado para éste proyecto es: *Aplicar técnicas de visión artificial e inteligencia computacional a imágenes termográficas con el fin de detectar condiciones de funcionamiento en equipos eléctricos, en busca de facilitar el diagnóstico y posterior mantenimiento de estos equipos sin necesidad de interferir en su operación normal.* Y como objetivos específicos:

- Especificar y seleccionar el equipo eléctrico a inspeccionar.
- Validar el procedimiento de inspección para el equipo eléctrico seleccionado.
- Recolectar imágenes termográficas acorde al procedimiento de inspección.
- Identificar y caracterizar regiones de interés en la imagen termográfica.

-
- Definir descriptores suficientemente discriminantes y relevantes a partir de las termografías adquiridas para lograr identificar estados de funcionamiento normal o anormal del equipo seleccionado.
 - Seleccionar, especificar y validar las máquinas de aprendizaje a utilizar.

Es así como se implementó una herramienta computacional que utiliza técnicas de visión artificial e inteligencia computacional para analizar imágenes térmicas adquiridas usando un protocolo de captura reconocido. Esta herramienta está compuesta por dos módulos de procesamiento, el funcionamiento del primero se basa en máquinas de aprendizaje y el segundo en información del gradiente de las imágenes. A partir del análisis de las termografías se puede generar el posible estado de funcionamiento del equipo inspeccionado y se especifica un indicativo del nivel de severidad de falla de acuerdo a estándares internacionalmente reconocidos.

El documento se organiza de la siguiente forma: en el capítulo 1 se realiza un introducción además del planteamiento de los objetivos del trabajo de investigación. En el capítulo 2 se presenta un marco teórico que contiene la información más relevante bajo la cual se ha fundamentado el desarrollo del proyecto, se incluyen antecedentes regionales, nacionales e internacionales además de conceptos como transferencia de calor, técnicas para la aplicación de termografía, principios básicos de los equipos de inspección termográfica, imágenes infrarrojas y visión artificial. En el capítulo 3 se mencionan los principios básicos para la adquisición de imágenes térmicas y además se hace una descripción de la plataforma experimental utilizada. En el capítulo 4 se describe la solución software implementada y en el capítulo 5 se presentan las pruebas diseñadas y los resultados obtenidos para la validación del sistema. Por último en el capítulo 6 se encuentran las conclusiones generales del trabajo desarrollado y en el capítulo 7 se plantean las perspectivas para los futuros trabajos en esta línea de investigación.

Capítulo 2

Marco Teórico

2.1. Introducción

El propósito de este capítulo es dar a conocer algunos conceptos fundamentales que servirán como base para el desarrollo del presente proyecto. La sección 2.2 es una recopilación de los principales antecedentes encontrados a nivel regional, nacional e internacional. En 2.3 se trata brevemente la teoría de transferencia de calor. La sección 2.4 sirve como introducción a las nociones básicas de termografía, principios físicos y técnicas más comunes. En la sección 2.5 se introducen conceptos fundamentales acerca del equipo necesario para realizar una inspección termográfica. En 2.6 se habla acerca de las imágenes infrarrojas y en la sección 2.7 se describen los bloques principales que componen una aplicación de procesamiento digital de imágenes.

2.2. Antecedentes

Para muchas aplicaciones, un cambio de temperatura en un objeto puede significar un cambio en su condición de operación. Por medio del monitoreo de la temperatura de un objeto, se puede inferir acerca de su estado. Cualquier

anomalía térmica, como puede ser la presencia de calor o la ausencia del mismo, sugiere la existencia de un problema [Hol00].

Un sistema de inspección de Ensayo no Destructivo por Termografía, generalmente está compuesto por diferentes subsistemas entre los cuales se incluye, la cámara infrarroja, el sistema de adquisición y análisis de las termografías y/o un sistema de estimulación térmica (según la técnica de termografía utilizada), además de dispositivos propios necesarios de acuerdo a la aplicación o tipo de inspección a realizar [Mal01a][Mal01b][Hol00].

2.2.1. Antecedentes Regionales

En nuestra región la institución educativa que muestra un mayor adelanto en temas relacionados con el estudio de la termografía y sus aplicaciones es la Universidad del Valle. En esta se encontraron los siguientes trabajos producto de varios años de investigación: Entre los proyectos inscritos a COLCIENCIAS están: con el grupo de Percepción y Sistemas Inteligentes (PSI) “Laboratorio para Procesamiento de Imágenes Infrarrojas Ensayo No Destructivo”, que hace parte de los proyectos de investigación COLCIENCIAS 2003, su finalidad fue el diseño e implementación de una plataforma de experimentación para el procesamiento y análisis de imágenes infrarrojas. Entre los grupos PSI, CONVERGIA y GRALTA, los cuales también forman parte de la Universidad del Valle, “Herramienta para el Mantenimiento de Equipo Eléctrico por Inspección Termográfica” convocatoria ISA - COLCIENCIAS 2004, su objetivo fue la implementación y validación de una herramienta computacional para la captura, procesamiento y análisis automatizado de imágenes termográficas que permita generar diagnósticos sobre la condición de equipos de subestaciones.

Además de los proyectos anteriormente descritos, en PSI también se han desarrollado varios trabajos importantes que tratan temas afines al planteado en la presente propuesta de investigación, algunos de estos trabajos se han llevado

a cabo conjuntamente con la colaboración del Laboratorio de Visión y Sistemas Digitales de la Universidad Laval de Québec, Canadá.

En [HBL⁺07] se sugiere un procedimiento para calcular las pérdidas de calor a través de las paredes de aislamiento del hogar de una caldera acuotubular, utilizando el procesamiento de imágenes térmicas. Para esto, se diseñó una herramienta software, la cual permite calcular el flujo térmico a través de una superficie usando un termograma, información de la superficie analizada, información característica de la cámara IR utilizada y un modelo unidimensional estable de transferencia de calor. La validación del procedimiento propuesto y de la herramienta software fue realizada comparando los datos calculados, con las mediciones hechas utilizando un flujómetro.

En [BLBA06] se presenta el diseño, implementación y aplicación de un sistema de visión artificial para imágenes infrarrojas el cual permite el procesamiento y análisis de esas imágenes a través de una interfaz gráfica, capaz de generar reportes de inspección y el almacenamiento de resultados en una base de datos. Los componentes hardware del sistema son un PC, una tarjeta de adquisición y una cámara infrarroja. El componente software ha sido desarrollado en JAVA y fue diseñado teniendo en consideración criterios de modularidad, flexibilidad y portabilidad. Con la finalidad de presentar el desempeño de la herramienta, se discuten los resultados obtenidos al ejecutar una inspección con termografía pasiva.

En [BIL⁺06] se presenta la aplicación de redes neuronales artificiales y coeficientes TSR (Reconstrucción de Señal Termográfica) como conjunto de datos de aprendizaje y validación para caracterizar defectos en materiales compuestos.

En [BIB⁺06] se propone una versión modificada de la técnica de Contraste Absoluto Diferencial (DAC), explícitamente introduciendo el grosor de la muestra a analizar usando la teoría de cuatripolos térmicos. Se demuestra que teniendo en cuenta el grosor de la muestra el rango de validez de DAC se extiende considerablemente para periodos de tiempo prolongados después de la excitación a la vez que preserva su desempeño para periodos de tiempo cortos.

En [BLC05] se presenta el diseño y aplicación de un sistema basado en redes neuronales para detectar y cuantificar defectos en muestras compuestas por plástico y vidrio usando técnicas de Ensayo Térmico no Destructivo.

En [BLC04] se exponen un par de técnicas para supresión de ruido en termografías, se exponen varias formas para calcular el contraste térmico lo cual permite incrementar la visibilidad de defectos y se explica un algoritmo de segmentación automática para la detección de los mismos en termografías. Por último se explican algunas etapas fundamentales en el procesamiento de imágenes termográficas las cuales son aplicadas a termogramas ruidosos y con pobre contraste.

En [SBI⁺06] se propone la implementación del método de contraste absoluto diferencial (DAC) eliminando la necesidad de definir áreas sanas. La metodología PPT-DAC propuesta, permite calcular el contraste de fase sustrayendo el valor de fase ideal de un píxel de su fase medida.

En [IGB⁺06] se hace referencia de como la termografía infrarroja (IR) tiene dentro de sus objetivos principales la detección y/o caracterización de defectos internos en materiales, a partir de termografía activa. El Laboratorio de Visión y Sistemas Digitales de la Universidad Laval de Québec, Canadá, ha contribuido al desarrollo de un gran número de técnicas de análisis de señales e imágenes, En el artículo se hace una revisión de los principales métodos utilizados actualmente en el área de termografía pulsada.

Es así como siendo parte activa de la universidad y del grupo PSI; se hace importante un trabajo de Maestría como esfuerzo por adelantar, aportar y complementar en los temas de investigación afines que estas entidades se encuentran desarrollando y que hacen parte de la formación propia de estudios a nivel de Maestría.

2.2.2. Antecedentes Nacionales

A nivel nacional se exploró en los sitios WEB de las universidades que tienen un marcado progreso en investigación y desarrollo, encontrando una clara ausencia

de investigación en la temática propuesta. Sin embargo se encontraron trabajos de la Universidad Industrial de Santander como [FGO06] en el cual se busca determinar de forma confiable el modo de operación de equipos de alta tensión, lo que se manifiesta por alteraciones térmicas superficiales, la metodología propuesta para tal fin, comprende técnicas de tratamiento digital de imágenes y un algoritmo de clasificación. En [AM06] se plantea un algoritmo de segmentación automática para resaltar zonas susceptibles de falla en equipos eléctricos de alta potencia. Por último la Universidad San Buenaventura de Medellin presenta con [FM04] la problemática existente en los conectores de alta tensión y específicamente de la pérdida de propiedades mecánicas de los mismos debido a las condiciones severas de operación a que están sometidos; se afirma además que aunque las termografías muestran efectivamente que la temperatura de los componentes ha sobrepasado la temperatura del tratamiento térmico aplicado a las aleaciones que componen estos elementos, no dan una idea real del grado de deterioro que estos presentan y de la acción pertinente a seguir.

2.2.3. Antecedentes Internacionales

Son muchos los trabajos que se han realizado a nivel internacional relacionados con inspección termográfica para equipos eléctricos. Todos estos trabajos se encuentran repartidos en distintas áreas las cuales están estrechamente ligadas al ejercicio de la inspección termográfica. Estos tópicos abordan aspectos como: metodologías para la ejecución de una inspección y toma de termografías, desarrollo de estándares, guías prácticas para la aplicación de la técnica, interpretación analítica de las imágenes entre otros. A continuación se hace una breve descripción de algunos de los trabajos encontrados.

El trabajo [Mad82] hace énfasis acerca de la importancia de entender los principios físicos de la radiación electromagnética lo cual ayudará a prevenir fallas y a desarrollar y fortalecer un enfoque científico para resolver problemas en nuevas aplicaciones en el campo de la termografía. Este trabajo pretende unir el trabajo

de campo con la teoría formal, ilustrando y entendiendo el origen de algunas aproximaciones que pueden ser cruciales para el éxito al aplicar la técnica.

En [Gri78] se habla de cómo a comienzos de los años 70, la termografía infrarroja se utilizó como herramienta para implementar programas de manejo de energía en compañías americanas. Si bien muchas ventajas se obtuvieron de la utilización de esta técnica, se puso también en evidencia la influencia directa que la capacidad de interpretación de los termogramas por parte del personal responsable de ésta tarea. Buenos resultados dependen y están directamente influenciados por la experiencia, entrenamiento y capacidad de interpretación del operario.

El procesamiento e interpretación de termografías es un campo que se ha desarrollado con la aparición y evolución de la tecnología, en [Fri81] se expresa como a medida que los sistemas de termografía se fueron haciendo portátiles, la evolución de los computadores y la aparición de hardware para digitalización, se pudieron obtener imágenes termográficas, en un formato adecuado para efectuar un procesamiento digital de las mismas. Este procesamiento buscaba en sus inicios (finales de la década de 1970) principalmente: resaltar áreas de interés específico, obtener una mejor calidad de imagen, eliminar ruido, transformar la imagen de una señal radiométrica a una representación de temperatura real, estudiar, documentar y tratar de estandarizar la información de imágenes de base para realizar una futura comparación de termogramas. En esta época el procesamiento de imágenes consumía grandes cantidades de tiempo de procesamiento y era costoso debido al alto número de manipulaciones software requeridas.

En [Mar81] se menciona que existen materiales para los cuales los valores de emisividad varían ampliamente ante efectos como temperatura, textura del material y longitudes de onda. Este efecto se puede presentar también en materiales existentes en inspección de equipos eléctricos por lo cual vale la pena tener en cuenta estas observaciones. Se propone un método para determinar la emisividad en el sitio mismo de la inspección.

En [Ste82] se utiliza termografía para ubicar regiones calientes en el estator de un generador eléctrico. En esta inspección se detectan problemas de emisividad en el objeto inspeccionado, lo cual genera falsas alarmas sobre regiones calientes, por lo cual se decide no hacer un estudio cuantitativo.

En [Bai82] se hace una inducción a los programas de mantenimiento predictivo usando termografía. Se habla acerca de dos enfoques existentes para este tipo de programas: análisis estadístico basado en un historial para predecir futuras fallas y análisis instrumental en tiempo real para diagnosticar la condición actual de un equipo y sus potenciales fallas. Además se enumeran algunos ejemplos de problemas industriales y sus diagnósticos que han sido grabados en el curso de una inspección de rutina en una planta. Se hace referencia a la elaboración minuciosa de un reporte escrito producto de la inspección, el cual debe ser lo más completo y detallado posible. Se hace una primera aproximación de cómo deben clasificarse las posibles fallas de acuerdo a la temperatura encontrada (atención inmediata $>50^{\circ}\text{C}$, necesitan atención entre 20°C y 50°C , fallas de rutina entre 4°C y 20°C). Se aborda además el tema de inspección desde el punto de vista económico y se hace algunas recomendaciones acerca de la frecuencia con la cual se deben desarrollar las inspecciones.

En [Eis82] se hace una breve descripción de las áreas de principal importancia durante la inspección de equipos eléctricos y se sugiere un posible orden para la realización de la inspección (líneas de entrada, transformadores, equipo primario de switches, etc...). Se enfatiza en la complejidad de los sistemas eléctricos por lo cual se recomienda iniciar siempre en cada subsistema desde los puntos más externos. Se concluye que virtualmente no existe otra forma de inspección de un sistema energizado que sea tan rápido y preciso para identificar problemas como el método de termografía infrarroja.

En [Orl82] se presentan principios fundamentales para la utilización de termografía en estudios cuantitativos, se hace una descripción paso a paso de técnicas de medición en campo básicas sin necesidad de una gran cantidad de equipo

auxiliar. Mediciones de temperatura y emisividad son discutidas e introduce una técnica de medición gráfica.

En [BB82] se hace una revisión de los elementos que componen un sistema de inspección termográfica, se desarrolla la base para una ecuación radiométrica generalizada, con expresiones para cuatro casos especiales simples. Además se presenta un método para medir la emisividad de una superficie. La utilización de técnicas de procesamiento digital de imágenes básicas ilustra estadísticamente algunas incertidumbres encontradas en termografías.

En [Bai84] se muestra como el análisis de una base de datos conformada por problemas encontrados durante inspecciones termográficas, permite determinar relaciones de costo beneficio de este ejercicio, y presenta algunos datos económicos en materia de ahorro para la compañía o empresa ejecutora.

En [Bai86b] se habla acerca de las manifestaciones y causas de una pobre calidad en los servicios de inspección termográfica, y sugiere algunas posibles soluciones.

En [Bai86a] se afirma que la inspección termográfica de sistemas eléctricos es un procedimiento bien establecido, éste procedimiento aparece como simple y robusto, lo cual en ocasiones conduce a inspecciones deficientes y pobres. Algunos factores deben ser considerados para alcanzar buenos resultados como: incidencia solar, carga en los circuitos, tamaño y emisividad del objeto a inspeccionar. Estos factores y algunos de sus efectos sobre inspecciones en varios sistemas son discutidos.

En [Fac86] la inspección termográfica es aplicada a equipos de subestaciones lo cual provee una invaluable herramienta para el mantenimiento predictivo y preventivo. Este trabajo está enfocado a la aplicación de la técnica para inspeccionar transformadores y se describe las metodologías aplicadas para el desarrollo del estudio.

En [Bai87] se discute como la temperatura de un problema en un circuito eléctrico está determinada por la relación entre la potencia de entrada y la potencia de salida. La potencia de salida depende de tres modos de transferencia

de calor. El artículo presenta datos experimentales que definen la relación entre temperatura y potencia para dos casos específicos.

En [Luc87] se plantea una discusión acerca del riguroso cuidado que se debe tener al momento de identificar los comúnmente denominados “problemas” durante el desarrollo de una inspección termográfica. Expresa que los problemas no pueden ser tratados genéricamente. Cada uno de éstos es específico a cada pieza o equipo particular inspeccionado, localización y/o medio donde éste se encuentre. Por lo cual debe ser tratado específicamente.

En [Hur90] se menciona como resistencia eléctrica excesiva, fugas de voltaje, voltajes inducidos y disturbios magnéticos solares son desviaciones que se pueden presentar en sistemas eléctricos de alto voltaje. Se presentan métodos, hallazgos, variables y guías basados en la recopilación de varios años de trabajo práctico de la compañía I.S.S. Thermographic Testing Inc., que pueden ayudar en el desarrollo de programas de inspección termográfica para plantas eléctricas.

En [Gro92] se mencionan algunas de las fortalezas y debilidades del sistema Delta-T de clasificación de severidad en el calentamiento de equipo eléctrico y se explica un método alternativo para dar prioridad a problemas potenciales. Este sistema es referenciado a estándares de temperatura de equipo eléctrico reconocidos en Estados Unidos los cuales tienen en cuenta factores como temperatura ambiente y condiciones de carga.

Las guías propuestas por [PNS94] describen como se debe llevar a cabo prácticamente una inspección termográfica en plantas eléctricas de gran tamaño. Incluye aspectos como: acuerdos entre el cliente y la contratista de termografía, elaboración de reportes y como los diferentes tipos de defectos son interpretados. Además hace una crítica constructiva acerca de la gran deficiencia acerca de la existencia de estándares y métodos documentados para la interpretación de defectos térmicos detectados.

En [Kap95] se hace referencia de como los mejoramientos en sistemas infrarrojos comerciales y los avances en herramientas y capacidades para el procesamiento

de datos e imágenes hacen que la técnica de termografía diferencial sea una herramienta muy promisorio para la condición, monitoreo y mantenimiento predictivo de elementos electrónicos, eléctricos y mecánicos. Al final se hace un resumen con las ventajas y limitaciones de la termografía diferencial.

En [Sne95a] se afirma que el principal valor de usar termografía para inspeccionar sistemas eléctricos es encontrar problemas aparentes por medio de diferencias térmicas. Con la evolución de los sistemas infrarrojos su portabilidad y confiabilidad ha aumentado, lo que ha permitido usar los datos de temperatura como una medida primaria para priorizar la gravedad de un problema. La validez de esta afirmación es sospechosa por algunas razones: la ausencia de métodos estándar para la recolección de datos, el frecuente pobre entendimiento de la técnica por parte de los ejecutores, las condiciones de campo varían ampliamente entre inspecciones, y la gran ausencia de investigación que relacione la temperatura con el tiempo y consecuentemente con la posibilidad de falla del componente a ser inspeccionado.

En [LOP00] se plantea que si bien la temperatura es un factor importante en la evaluación de la condición de un equipo eléctrico, no debe ser el único tenido en cuenta; de ser así se corre el riesgo de diagnosticar erráticamente un problema. El entendimiento de factores adicionales involucrados en un diagnóstico es esencial para obtener resultados productivos.

En [ML00] se resalta la importancia sobre tener en cuenta el efecto del viento en el enfriamiento de zonas calientes encontradas en una inspección termográfica. Afirma que la mayoría de termógrafos no conocen como compensar el enfriamiento por efecto de convección. En el artículo se presentan datos experimentales de cómo velocidades bajas de viento afectan dramáticamente la temperatura de una zona caliente. El enfriamiento continúa a medida que la velocidad del viento aumenta pero a una tasa más lenta es así como se encuentra una curva de decaimiento exponencial de la velocidad del viento frente a temperatura.

En [OC] se enseña la revisión de métodos publicados por dos organizaciones estándar en la estimación de la temperatura de regiones calientes en transfor-

madores, se discute también sobre la utilización de sistemas de inteligencia artificial (AI) sobre los resultados de la técnica de análisis de gas disuelto (DGA) en el aceite de un transformador y cómo estos sistemas son utilizados para estimar temperaturas de las zonas calientes. Por último se mencionan algunas limitaciones de las técnicas y se enfatiza en algunas implicaciones económicas y de seguridad.

En [SML01b] se presenta un circuito equivalente simple el cual representa el flujo de calor térmico para un transformador de potencia. Se utilizan un par de analogías claves (fuente de corriente y resistencia no lineal) para representar calentamiento causado por pérdidas y efectos de enfriamiento por convección causado por el flujo de corrientes de aire o aceite respectivamente. [SML01a] Busca validar el modelo propuesto en el artículo anterior y además mostrar que existe una manera conveniente de estimar los parámetros del modelo sin necesidad de sacar de servicio el transformador.

En [PTLK02] se introduce una técnica de monitoreo en planta que permite gradualmente analizar las condiciones de operación. Se efectúan transmisiones en línea de algunos valores del sistema de potencia hacia un centro de control continuamente, lo cual permite calcular el estado térmico interno del transformador y extender o no la duración de condiciones de sobrecarga bajo unas condiciones dadas.

En [KF01] se demuestra el funcionamiento de una herramienta de análisis de termografías y un algoritmo para medir la condición de equipo de potencia. Se destacan las capacidades y limitaciones de la técnica. Y se presenta un *toolbox* con una revisión de sus características.

En [CSL00] se emplean técnicas de realidad virtual para producir termografías tridimensionales, tal que un usuario pueda manipular el objeto en las tres dimensiones en pantalla bajo su modo geométrico y térmico. El sistema puede proveer indicaciones vitales acerca de la condición del equipo, proporcionando alarmas de problemas potenciales.

En [Hou98] se afirma que las fallas en los equipos eléctricos pueden dividirse en dos clases: internas y externas. Las fallas externas son simples y las internas

son complejas. Por lo cual las externas son fáciles de ubicar y las otras son más difíciles. El propósito de éste artículo es el de discutir algunos problemas técnicos en el diagnóstico de equipo eléctrico con fallas internas por medio de termografía, y mostrar algunos ejemplos típicos de termografías de equipos eléctricos con fallas internas.

En [SL95] se describe como la National Grid Company (NGC) maximiza las capacidades térmicas de sus transformadores sin sacrificar confiabilidad. Para esto utilizan un software llamado TEFLOW2 que ha sido desarrollado para modelar transferencias de calor y calcular distribuciones de temperatura para una amplia cantidad de devanados.

En [EHE87] se presenta una visión general de la tecnología de termografía, su potencial y debilidades y proporcionan algunas recomendaciones a tener en cuenta para equipos de inspección entrenamiento y certificación. Se presentan también algunos casos ilustrativos de una variedad de aplicaciones en donde la termografía ha sido empleada para el desarrollo, operación y fases de mantenimiento para prevenir fallas en equipos.

En [PM83] se afirma como el filtro mediano tiene algunas ventajas sobre métodos de filtrado lineal pero debe ser aplicado con cuidado. Cuando la distribución del ruido es de forma gaussiana, el filtro mediano provee una buena estimación de la señal sin contaminación. Este filtro y una ventana triangular reducen el ruido sobre la desviación estándar aproximadamente en un 45 %. Además el filtro mediano puede reducir ruido sin degradar los bordes. Estas características son atractivas para mejorar termografías.

El propósito de [MM84] es el de formalizar el proceso de análisis de la escena de una termografía usando un modelo que tiene en cuenta las características superficiales e internas que pueden ser percibidas en una escena. El modelo es presentado a través de la comparación de las diferencias entre la escena visual y térmica bajo análisis y se busca complementarlo con el uso de técnicas de inteligencia artificial para el reconocimiento automático de termografías.

Un sistema de procesamiento de imágenes típico presenta tres etapas bien definidas (pre-procesamiento, procesamiento y análisis). Cuando se desea trabajar con termografías, la calidad de las imágenes termográficas está principalmente degradada por efectos como: vignetting, patrón de ruido fijo, presencia de píxeles muertos y distorsión radial, por lo cual se hace recomendable una etapa de pre-procesamiento que reduzca y/o elimine estos efectos. En [Mal01a][Mal01b] se hace una descripción acerca de la corrección por efecto de vignetting y supresión de ruido.

Dentro de la etapa de procesamiento según el tipo de técnica utilizada (termografía activa o pasiva), se deben tener en cuenta distintos tipos de metodologías (cálculo de contraste térmico, normalización, termografía de fase pulsada, termografía de componentes principales etc. . .). En este campo se han desarrollado trabajos importantes como se describe en [Mal01b].

Cuando la imagen termográfica ha pasado por las etapas de pre-procesamiento y procesamiento, ésta se encuentra lista para poder efectuar un análisis de su contenido, para el desarrollo de esta fase se ha propuesto el uso de redes neuronales y sistemas expertos como métodos de evaluación de información, la utilización de lógica Fuzzy en conjunto con redes neuronales para ejecutar tareas similares. El análisis de los datos por diferentes métodos: estadísticos, inversión de datos, uso de redes neuronales, uso de transformadas Wavelets, entre otros, son también tratados en [Mal93]. Todos estos métodos se benefician y generan mejores resultados gracias a los desarrollos de herramientas computacionales con que se cuenta en la actualidad.

La existencia de una variedad supremamente amplia de algoritmos que pueden hacer un aporte significativo en mayor o menor grado en cada una de las etapas necesarias para el procesamiento de imágenes termográficas hace indispensable el planteamiento como una tarea de relevante importancia del estudio, implementación y selección de las mejores técnicas que se adapten a las necesidades de diseño inherentes al desarrollo de esta investigación.

2.3. Transferencia de Calor

La transferencia de calor ocurre en un medio o entre cuerpos de tres distintas formas [Mal01a] [Mal01b] [Hol00]: *conducción*, *convección* y *radiación*. Los dispositivos de captura termográficos aprovechan el fenómeno de *radiación* en el espectro infrarrojo para generar sus imágenes, una explicación mas detallada de éste fenómeno se verá en la siguiente sección (2.4).

La transferencia de calor por *conducción* también conocida como ley de Fourier, ver ecuación (2.1), afirma que el cambio del flujo de calor a través de la porción de un material es proporcional a la variación de su temperatura. Donde Q es el calor transferido, k es la constante de conductividad propia del material, A es el área transversal del material, ΔT es la variación de temperatura presente en el material y Δx es la distancia medida en dirección normal a la superficie A ,

$$\frac{\Delta Q}{\Delta t} = -k \cdot A \frac{\Delta T}{\Delta x} \quad (2.1)$$




Figura 2.1: Ley de Fourier

La figura 2.1 muestra gráficamente lo enunciado por la ley de Fourier. Es así como la transferencia de calor por conducción puede ser identificada con ayuda de cierto tipo de procesamiento a nivel de los termogramas.

2.4. Termografía

Los átomos son los componentes fundamentales de la materia, estos se componen de partículas eléctricamente cargadas (electrones, protones) y partículas neutras (neutrones). Electrones, protones y neutrones permanecen siempre en continuo movimiento. Ellos están vibrando, rotando y en un estado general de conmoción. La temperatura es una medida del grado de este movimiento. El cero absoluto es el nivel más bajo posible de agitación. Esto significa que toda la materia contiene partículas cargadas que están siendo aceleradas (cambiando de velocidad o dirección), una alta temperatura es el producto de una gran aceleración. Teniendo en cuenta lo anteriormente planteado, toda la materia radia energía. La cantidad de energía radiada depende de la temperatura del objeto y de su habilidad para radiar [Hol00].

La radiación infrarroja es parte del espectro electromagnético que se encuentra entre la luz visible y las microondas, como se puede ver en la figura (2.2). Los límites exactos de este intervalo no están muy bien definidos pero una aproximación aceptable encontrada en la literatura está desde $0.7 \mu\text{m}$ hasta $100 \mu\text{m}$ [Mal01a][Mal01b][Mad82]. El espectro infrarrojo a su vez se encuentra subdividido comúnmente en: infrarrojo cercano ($0.7\text{-}3 \mu\text{m}$), infrarrojo medio ($3\text{-}6 \mu\text{m}$), infrarrojo lejano ($6\text{-}15 \mu\text{m}$) e infrarrojo extremo ($15\text{-}100 \mu\text{m}$) [Mad82][Sys04]. Esta división del espectro se realiza teniendo en cuenta las capacidades de los dispositivos detectores de radiación IR (infrarrojo)[Sys04].

$$W_{TRANSMITIDO} + W_{EMITIDO} + W_{REFLEJADO} = W_{SALIENTE} \quad (2.2)$$

La ecuación (2.2) afirma que la radiación saliente total de un cuerpo es igual a la suma de una proporción de la radiación emitida por el objeto, la reflejada desde una fuente cercana al frente del objeto, y otra transmitida desde una fuente detrás del objeto. Expresando la ecuación (2.2) como una relación, se obtienen las constantes específicas: transmisión (τ), emisión (ϵ) y reflexión (ρ) como se puede ver en la ecuación (2.3).

2.4 Termografía




Figura 2.2: Espectro Electromagnético

$$\tau + \epsilon + \rho = 1 \quad (2.3)$$

La ecuación (2.3) es conocida también como ley de Kirchhoff de la óptica [Sys04][Tor98]. Para objetos opacos se puede aproximar la propiedad de transmisión (τ) a cero, obteniéndose la ecuación (2.4).

$$\epsilon + \rho = 1 \quad (2.4)$$

Los instrumentos de detección térmica infrarroja son usados para medir y registrar sin contacto, las temperaturas superficiales de una amplia variedad de objetos (TNDT Thermography for Nondestructive Testing). Esto se realiza a través de la medición de energía radiante, en la porción infrarroja del espectro electromagnético, ver figura (2.2), emitida por la superficie del objeto y convirtiendo esta medición a su equivalente de temperatura mediante relaciones matemáticas [Mal01b][Tor98]; para ello se hace uso de detectores de infrarrojo, que permiten extraer una imagen cuantificable en temperatura.

La razón por la que se puede medir temperatura en función de la radiación infrarroja es porque las dos están relacionadas por leyes físicas. La ley física que las relaciona se conoce como *Ley de Stefan-Boltzmann* para cuerpos negros. Un cuerpo negro es un radiador ideal que emite el 100 % de su energía, lo que significa




Figura 2.3: Radiacion Cuerpo Negro

que no existe ningún otro objeto que se capaz de emitir más energía, retomando la ecuación 2.4 y aplicando lo anteriormente dicho se obtiene la ecuación 2.5 que afirma que un cuerpo negro ideal tiene un valor de emisividad igual a 1.

$$\epsilon = 1 \rightarrow (\rho + \tau = 0) \quad (2.5)$$

La *Ley de Stefan-Boltzmann* ecuación 2.6, relaciona temperatura con la energía irradiada. En otras palabras dice cuánta radiación emite un cuerpo negro a una cierta temperatura. W_{CN} es la energía radiada por el cuerpo negro, σ corresponde a la constante de Stefan-Boltzmann, y T es temperatura absoluta.

$$W_{CN} = \sigma \times T^4 \quad (2.6)$$

A cada píxel de una imagen termográfica se le asocia un color o nivel de gris, el cual representará una temperatura dada de acuerdo a una escala predeterminada. La base para la tecnología de imágenes infrarrojas es que cualquier cuerpo cuya temperatura esté por encima de 0 K (*cero absoluto*) radia energía infrarroja. La

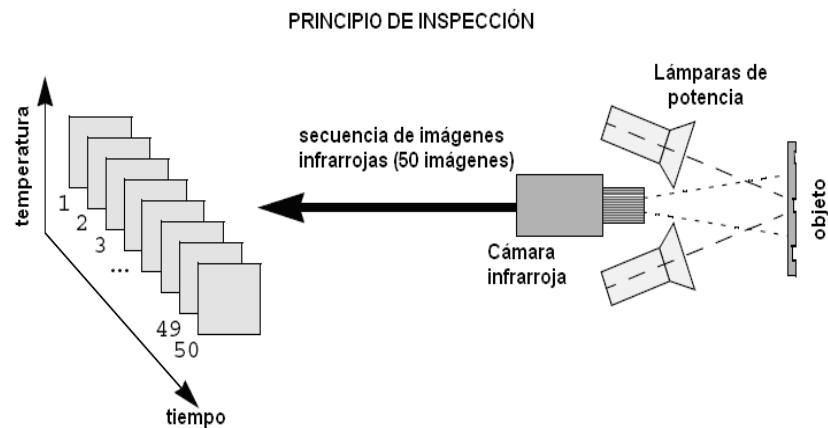


Figura 2.4: Esquema de configuración típica para implementación de Termografía Activa

cantidad de energía radiada es función de la temperatura del cuerpo y de su eficiencia relativa de radiación (*emitancia*) [Tor98].

Estrictamente hablando la temografía se define como una técnica de contacto cuyo objetivo es el de generar una distribución de temperatura de una superficie, y termografía infrarroja es una técnica libre de contacto con una amplia variedad de ventajas [Mal01b]. En adelante cuando se haga referencia a termografía se estará hablando de termografía infrarroja.

Generalmente la inspección de un objeto se realiza a temperatura ambiente, sin embargo el objeto a inspeccionar puede ser excitado con algún tipo de energía externa [Mal01a][Mal01b][Hol00]. Teniendo en cuenta estas dos posibilidades la termografía se puede dividir en: Activa y Pasiva.

2.4.1. Termografía Activa

En termografía activa, como se observa en la figura (2.4) ¹, es necesario excitar con una fuente de energía externa al material o equipo a ser inspeccionado para obtener diferencias de temperatura significativas y así poder identificar la presencia de anomalías por debajo de la superficie. Algunas de las técnicas más utilizadas para suministrar energía son: Termografía por pulsos (Pulsed Thermography “PT”), Calentamiento por pasos (Step Heating “SH”), Vibrotermografía (Vibrothermography “VT”) entre otros [Mal01b].

2.4.2. Termografía Pasiva

La termografía pasiva no necesita excitar térmicamente con fuentes externas el material o equipo a inspeccionar, solamente se toma una muestra de imágenes infrarrojas con el estado actual del elemento de interés. En este tipo de técnica, los valores de temperatura encontrados en la imagen pueden indicar un problema potencial y el término clave es la diferencia de temperatura con respecto a una referencia, frecuentemente representado por delta-T (ΔT). Un ΔT de pocos grados ($> 5\text{ }^{\circ}\text{C}$) es generalmente sospechoso, mientras grandes valores evidencian un comportamiento anormal del dispositivo inspeccionado. Este tipo de termografía generalmente es más cualitativo ya que su meta es principalmente identificar anomalías. Sin embargo algunas investigaciones proveen mediciones cuantitativas, apoyándose en el modelo térmico disponible [Mal01b].

La figura (2.5) ² indica: en *a*, *b* la fotografía y la termografía de un tanque de almacenamiento industrial típico. En *c*, *d* la fotografía y la termografía de un transformador eléctrico respectivamente. Es así como se puede apreciar de manera intuitiva algunas de las ventajas de la utilización de la inspección termografía.

¹Fuente: Theory and Practice of Infrared Technology for Nondestructive Testing. Figure 6.18. X. Maldague

²Fuente: Infrared Training Center (ITC) Image gallery, <http://infraredtraining.com/gallery/ir-image/>




Figura 2.5: Ejemplos de aplicación de Termografía: (a) Espectro visible de un tanque de almacenamiento industrial. (b) Termografía de a. (c) Espectro visible de un transformador. (d) Termografía de c.

En el primer caso se puede inferir acerca del contenido de una estructura de almacenamiento y en el segundo caso, acerca de la temperatura existente en la superficie de un transformador eléctrico en operación.

En la tabla (2.1)¹ se hace un paralelo entre algunas de las ventajas y limitaciones de la termografía en general.

Cuando se realizan inspecciones eléctricas utilizando termografía se han identificado algunas dificultades ubicadas en áreas distintas: El termógrafo, procedimientos de inspección, la radiometría del instrumento incluyendo aquí degrada-

¹Fuente: Adapted from Encyclopedia of Materials (New York: Elsevier, 2001), Table 2 in the article “Thermographic techniques for NDT” by X. Maldague.

2.5 Equipo de Inspección

Ventajas	Limitaciones
Rápida inspección superficial	Emisividad variable de materiales
Fácil implementación	Perdidas por enfriamiento
Seguro (Sin radiaciones perjudiciales)	Absorción de señales infrarrojas por la atmósfera
Amplia versatilidad de aplicaciones	Dificultad para calentamiento uniforme (procedimientos activos)
No hay contacto físico	Defectos observables son generalmente superficiales

Cuadro 2.1: Algunas ventajas y limitaciones de la Termografía

ciones de las imágenes causadas por efectos como: distorsión radiométrica, distorsión geométrica y ruido [Mal01b], condiciones ambientales [ML00], los componentes a ser inspeccionados, entre otros [Sne95b]. En el campo del diagnóstico de equipos eléctricos, la termografía es un método que ha demostrado ser efectivo para la detección de fallas y es ampliamente usado debido a sus ventajas características como su rapidez y ser libre de contacto. La mayoría del trabajo de termografía aplicado a equipos eléctricos es de naturaleza cualitativa [Sne95b], este se realiza comparando características térmicas de componentes similares, lo que resulta rápido y simple; por ejemplo con sistemas eléctricos trifásicos en donde las fases deben aparecer casi siempre con patrones de temperatura similares. Componentes que posean temperaturas diferentes (generalmente más calientes) sugieren una posible falla u operación anómala de funcionamiento [ML00].

2.5. Equipo de Inspección

Un detector térmico infrarrojo es el corazón de los sistemas de adquisición de imágenes termográficas. Estos detectores pueden censar la radiación infrarro-

2.5 Equipo de Inspección

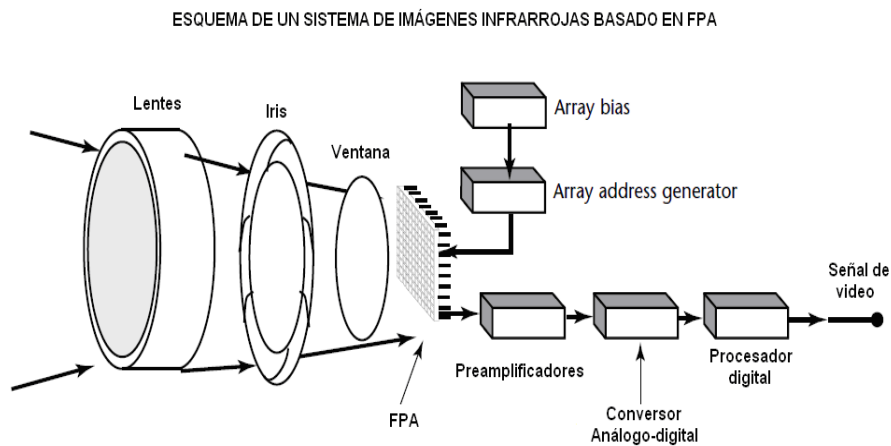


Figura 2.6: Esquema de un sistema de imágenes infrarrojas basado en FPA no refrigerado.

ja incidente y producir una señal eléctrica que es proporcional a la temperatura de la superficie de un objeto. Este tipo de detectores tienen respuesta espectral limitada, alta sensibilidad y tiempos de respuesta muy rápidos (orden de microsegundos).

Para formar una imagen termográfica existen 3 configuraciones comúnmente más utilizadas: escaneo optomecánico, escaneo electrónico e IFPA o FPA (Infrared Focal Plane Arrays) arreglo bidimensional (matriz) de sensores fotoeléctricos. Hasta mediados de los 90's el escaneo optomecánico fue el más común. En muchas aplicaciones FPA ha remplazado el método tradicional, FPA es una matriz de detectores fotoeléctricos que no necesita un mecanismo de escaneo para formar la imagen, existen varios tamaños para estos detectores 128×128 , 160×120 , 256×256 , 640×512 . Este tipo de sensores se introdujo comercialmente en el mercado aproximadamente en 1987, estos necesitaban tener un mecanismo de refrigeración incorporado en el sistema; los primeros sensores no refrigerados estuvieron disponibles comercialmente 10 años después en 1997, en la figura (2.6)

2.5 Equipo de Inspección

Tipo de detector	FPA no refrigerado 160 * 120 pixeles
Rango espectral del detector	7.5 - 13 μm
Rango de temperatura	-20 a +250 °C (-4 a + 482 °F)
Exactitud	± 2 °C ± 3.6 °F Para temperaturas +5 a +250 °C (+45 a +113 °F)
Temperatura de operación	-15 a +50 °C (+5 a +122 °F)
Temperatura de almacenamiento	-40 a +70 °C (-40 a +158 °F)
Interfaces de comunicación	Conector BNC estándar para video compuesto CVBS

Cuadro 2.2: Especificaciones técnicas ThermovisionTM A20M.

D	0.5	1.0	2.0	5.0	10.0	25.0	50.0	100.0	m
HFOV	0.22	0.44	0.87	2.18	4.35	10.88	21.76	43.53	m
VFOV	0.16	0.33	0.65	1.63	3.26	8.16	16.32	32.65	m
IFOV	1.36	2.72	5.44	13.60	27.21	68.01	136.03	272.06	mm

Cuadro 2.3: ThermovisionTM A20M. Campo de vision horizontal, vertical e instantáneo (HFOV, VFOV, IFOV) sobre algunas distancias D al objeto de inspección, para lentes IR de 17 mm.

¹ se puede observar la configuración típica de un sistema usando este tipo de sensores [Mal01a].

Para seleccionar el sistema de adquisición apropiado (cámara infrarroja) o determinar si este podrá desempeñarse adecuadamente para una aplicación específica, es necesario tener en cuenta algunos parámetros de desempeño del dispositivo.

En un sistema de adquisición de imágenes termográficas se debe tener en cuenta parámetros como: rango de temperatura, exactitud absoluta, repetibilidad, sensibilidad, campo de visión horizontal (HFOV horizontal field of view), cam-

¹Fuente: Infrared and Thermal Testing. Figure 6. pp. 277. X. Maldague.

2.5 Equipo de Inspección



Figura 2.7: Cámara ThermoVisionTM A20M.

po de visión vertical (vertical field of view), campo de visión instantáneo (IFOV instantaneous field of view), medida de resolución espacial, rata de reproducción de cuadros (frame repetition rate), rango ambiental y espectral del sensor entre otros [Mal01a], estos parámetros son entregados por los fabricantes en las especificaciones técnicas del producto. En las tablas (2.2) y (2.3)¹ se presentan como ejemplo parte de las especificaciones técnicas para una cámara ThermoVisionTM A20 M de la compañía FLIR, figura (2.7), en donde se encuentran algunos de los parámetros anteriormente mencionados.

Aparte de la cámara infrarroja, para realizar una inspección utilizando termografía pasiva puede ser necesario cierto equipo adicional:

- Trípode o similar según el caso: utilizado para fijar y ubicar la cámara lo cual ayuda a mejorar el proceso de adquisición de las termografías.
- Dispositivos de almacenamiento: cuando la cámara no posee integrado un sistema de memoria como medio de almacenamiento se hace necesario un dispositivo que cumpla esta función (grabador de video VTR digital o análogo o un dispositivo similar).

¹Fuente: FLIR Systems. ThermoVisionTM A20M Operator's manual. Publ. No. 1-557-732, revision a72, October 2004. pp. 141-154.

- Un computador generalmente no es necesario en campo ya que el procesamiento de las imágenes puede ser realizado después de la inspección, pero puede servir como medio de visualización y almacenamiento de las termografías.
- Fuentes de alimentación: para operaciones remotas.
- Medidor de variables ambientales.

La cantidad de equipo necesario varía según la aplicación que se necesite llevar a cabo, lo anteriormente mencionado sirve como base para tener en cuenta al momento de proyectar la realización de una inspección.

2.6. Imágenes Infrarrojas

Una imagen digital es una imagen $g(x,y)$ que ha sido discretizada en coordenadas espaciales e intensidad. Esta debe ser considerada como una matriz cuyos índices de filas y columnas hacen referencia a un punto dentro de la imagen, mientras que el elemento correspondiente de la matriz es el valor de intensidad del punto indicado por los índices, el valor g de una localización dada (x_i, y_i) , dentro de una imagen se le conoce como píxel. Una imagen infrarroja (termografía) es una imagen digital $g(x,y)$, donde x, y representan coordenadas espaciales y el valor de la función g es proporcional a la radiación o energía emitida por la escena u objeto en una localización específica. La representación de una termografía generalmente se hace en una escala de grises, los niveles de gris permitidos para cada píxel son generalmente potencias enteras de 2, usando $G = 2^n$ donde G indica el numero de niveles de gris y n la cantidad de bits para generarlos. Valores comunes para n son 8, 12 o 16; obteniendo respectivamente 256, 4096 o 65536 valores o niveles de intensidad. Generalmente bajas intensidades son representadas por tonalidades oscuras de gris y altas intensidades por tonalidades claras. Existen otras formas de representación como: gráficos 3D (el tercer eje




Figura 2.8: Pieza de fibra de vidrio. (a) Espectro visible. (b) Termografía en escala de grises. (c) Termografía en falso color.

representa el valor de intensidad, donde picos altos corresponden a intensidades de gran valor), seudo o falso color, negativo de la imagen (escala de gris inversa) entre otros [Mal01b].

En la figura (2.8) se puede observar dos termografías de una pieza de fibra de vidrio, *a.* está representada en escala de grises convencional (negro es bajas intensidades blanco altas intensidades), y *b.* está representada en seudo o falso color (tonos oscuros son bajas intensidades y tonos claros son altas intensidades).

El tamaño de una imagen termográfica es variable y depende directamente del tamaño del sensor de la cámara infrarroja usada. Algunos tamaños comunes van desde 64×64 hasta 512×512 , tamaños rectangulares son también posibles (ej. 120×160 , 640×512). Es así como el tamaño de la imagen queda definido por el número de filas, el número de columnas y el número de bits necesarios para representar un píxel [Mal01b].

2.7. Procesamiento Digital de Imágenes

El término procesamiento digital de imágenes (*PDI*) generalmente se refiere al procesamiento de una gráfica, foto o diagrama bidimensional realizado por un

2.7 Procesamiento Digital de Imágenes

computador. En términos más generales, la definición implica el procesamiento digital de cualquier clase de datos bidimensionales. Una imagen digital es un arreglo de números reales o complejos representado por un número finito de bits [Jai89].

El *PDI* comprende un amplio rango de hardware, software y recursos teóricos. Las etapas fundamentales para realizar *PDI* se puede apreciar en la figura (2.9): Adquisición de la imagen, pre-procesamiento de la imagen (mejoramiento de la imagen de forma que aumente la posibilidad de éxito en las etapas siguientes), segmentación (partir una imagen de entrada en sus partes constituyentes u objetos). A la salida del proceso de segmentación habitualmente se tienen los datos de píxel en bruto, que constituyen bien el contorno de una región o bien todos los puntos de una región determinada. En cada caso es necesario convertir los datos a una forma adecuada para el procesamiento por computadora. Se continúa con la descripción o selección de características (extracción de información cuantitativa de interés o fundamental para diferenciar una clase de objetos de otra). La última etapa incluye el reconocimiento que es el proceso que asigna una etiqueta a un objeto basándose en la información proporcionada por los descriptores. La interpretación implica asignar significado a un conjunto de objetos reconocidos [GW96].

Siendo las termografías imágenes digitales, es posible aplicar sobre ellas técnicas de *PDI*. El mejoramiento de la imagen usando la intensidad de pixeles individuales [IGK⁺04] busca reemplazar el valor de un píxel específico p por un valor p' dependiendo de una función de transformación $f(\dots)$ como se muestra en la ecuación 2.7. Por este medio se pueden producir efectos como binarización, aumento de contraste, compresión de rango dinámico ...

El mejoramiento a nivel de vecindad [Mal01a], utiliza un conjunto de $(n \times n)$ pixeles, conocido como máscara, el cual es desplazado por toda la imagen y el valor del píxel central p es reemplazado por p' como lo muestra la ecuación 2.8. Donde B es un factor de escalamiento que garantiza que la imagen procesada conserve el mismo rango de valores que la imagen original. Es así como se pueden

2.7 Procesamiento Digital de Imágenes

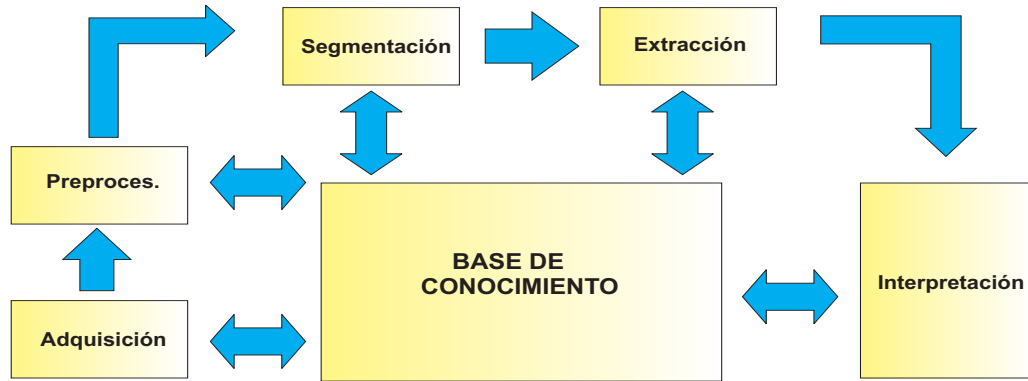


Figura 2.9: Etapas fundamentales en Procesamiento Digital de Imágenes.

obtener efectos de suavizado (cuando todos los pesos son iguales a 1), filtrado paso alto, operador de Sobel (para extracción de bordes). Aunque el efecto de suavizado es de los procedimientos mas comunes para la reducción de ruido, el hecho de que todos los valores de la máscara tenga peso unitario, produce una atenuación o desvanecimiento de los bordes, la utilización de un filtro mediana ayuda a prevenir este efecto [IGK⁺04]. Existen disponibles muchas otras técnicas para la reducción de ruido de mayor complejidad y mejoramiento de contraste de las imágenes termográficas, en [Mal01a] se puede encontrar información con mayor detalle.

$$p' = f(p) \quad (2.7)$$

$$p' = B(a_1p_1 + a_2p_2 + \dots a_np_n) \quad (2.8)$$

Una vez se logra mejorar la calidad de la imagen térmica, es posible realizar en esta la extracción de características, cuyo valores pueden utilizarse como entradas a un proceso de clasificación posterior. Trabajos como [MAMP07] y [Wie05] muestran como obtener información estadística en imágenes infrarrojas, bien sea a partir de parámetros de segundo orden, transformaciones en el dominio de Fourier

2.7 Procesamiento Digital de Imágenes

o Wavelet. Fenómenos de traslación, rotación y cambio de escala son comunes en imágenes digitales; el cálculo de los momentos invariantes, para ser usados como descriptores [GW96], es una buena alternativa cuando se trabaja con imágenes que presentan este clase de fenómenos.

El análisis y clasificación automática de la información entregada por una imagen o extraída de la misma, generalmente es responsabilidad de una etapa de clasificación, en la que generalmente podemos encontrar clasificadores de tipo estadístico o máquinas de aprendizaje como redes neuronales artificiales (*RNA*) o máquinas de soporte vectorial (*MSV*).

El hecho de no ser necesario tener un proceso bien definido para transformar algorítmicamente una entrada en una salida, una gran capacidad de generalización y robustez innata son características propias de las *RNA* [FS93], lo que genera que este tipo de máquinas de aprendizaje hayan sido a través de muchos años las más utilizadas en un amplio número de aplicaciones. En [Ben08] se hace una recopilación de trabajos en los que se han utilizado las *RNA* y además se realiza una comparación de sus logros y limitaciones tomando como referencia el Ensayo Termográfico No Destructivo (*ETND*).

En una *RNA* de tipo Perceptrón Multicapa (*MLP Multilayer Perceptron*), las neuronas son entrenadas tomando como base ejemplos de desempeño o un comportamiento deseado. El comportamiento deseado se puede resumir en un conjunto de pares ordenados de entrada y salida (ecuación 2.9) donde p es el vector de entrada a la red y t es la salida correcta (*objetivo*) correspondiente. Se busca entonces reducir el error e que se define como la diferencia entre la salida correcta t y la salida real a de la red (ecuación 2.10).

$$(p_1t_1, p_2t_2, \dots, p_nt_n) \tag{2.9}$$

$$e = t - a \tag{2.10}$$

2.7 Procesamiento Digital de Imágenes

La regla de aprendizaje tipo perceptrón calcula cambios deseados a los pesos y bias de la red, dado un vector de entrada p y el error asociado e . Cada vez que el algoritmo es ejecutado, el perceptrón tendrá mayor oportunidad de producir salidas cercanas a las correctas. Siempre y cuando exista una solución el perceptrón convergerá después de un número finito de iteraciones [PdlC02].

Otro tipo de RNA son las Redes de Base Radial (*RBF*), estas pueden requerir un mayor número de neuronas que las *MLP*, pero con la ventaja que pueden ser diseñadas y entrenadas en solo una fracción del tiempo que una *MLP* común. Una *RBF* trabaja mucho mejor cuando existe disponible un grupo de entrenamiento grande. Para este tipo de redes la expresión para la entrada a sus neuronas es diferente a la que tiene una *MLP*. El argumento para la función de activación f de la red es el vector distancia entre su vector de pesos w y el vector de entrada p .

$$f(n) = e^{-n^2} \quad (2.11)$$

La ecuación (2.11) describe la función de transferencia de una *RBF*, esta tiene un máximo de 1 cuando su entrada n es cero. Como la distancia entre el vector de pesos w y p decrece, la salida incrementa. Entonces, una neurona con función de activación de base radial se comporta como un detector que produce 1 cuando la entrada p es idéntica a su vector de pesos w .

Existen técnicas de clasificación que se basan en la utilización de muestras ejemplo para la estimación de ciertos parámetros estadísticos en cada clase involucrada. La naturaleza probabilística del enfoque Bayesiano hace que clasificadores estadísticos sean de gran utilidad. Prácticamente dada una población de muestra D , si se desea determinar la mejor hipótesis sobre esta población, podemos utilizar como herramienta la teoría de decisión bayesiana.

La teoría de decisión bayesiana es un enfoque estadístico fundamental para resolver problemas que involucren la clasificación de patrones. Se basa en el teorema de Bayes (ecuación 2.12). Donde $P(C_k/X^l)$ representa la probabilidad (aposteriori) de que tomada una observación X^l esta pertenezca a la clase C_k , $P(X^l/C_k)$

especifica la probabilidad de observar los datos X^l dado que se tenga la opción C_k y $P(C_k)$ es la probabilidad apriori.

$$P(C_k/X^l) = \frac{P(X^l/C_k) \cdot P(C_k)}{P(X^l)} \quad (2.12)$$

El ojetivo entonces es encontrar la probabilidad aposteriori de que un patrón pertenezca a la clase C_k una vez se ha observado cierto vector de características X^l . La probabilidad de error en la clasificación se minimiza seleccionando la clase C_k que tenga una mayor probabilidad aposteriori [Bis95]. En términos de un conjunto de *funciones discriminantes* $y_1(X^l), \dots, y_c(X^l)$, un vector X^l será asignado a la clase C_k de acuerdo a lo indicado en la ecuación 2.13.

$$y_k(X^l) > y_j(X^l) \forall j \neq k \quad (2.13)$$

Asumiendo una estructura probabilística normal o gaussiana, el terorema de Bayes se puede representar asi (ecuación 2.14):

$$y_k(X^l) = -1/2 (X^l - \mu_k)^T \cdot \Sigma_k^{-1} \cdot (X^l - \mu_k) - 1/2 \ln(|\Sigma_k|) + \ln(P(C_k)) \quad (2.14)$$

En la ecuación 2.14 μ_k es un vector d-dimensional de medias y Σ_k es la matriz de covarianzas de un tamaño $d \times d$. El ajuste de los parámetros necesarios para la implementación del clasificador bayesiano se realiza encontrando el vector de medias y la matriz de covarianza a partir de la información de las muestras controladas.

El tratamiento de imágenes se caracteriza por soluciones específicas a necesidades específicas. Así, técnicas que funcionan bien en un área pueden ser totalmente inadecuadas en otra. La solución de un problema específico todavía necesita un esfuerzo significativo de investigación y desarrollo [GW96].

2.8. Conclusiones

En la actualidad son muchas las aplicaciones que utilizan termografía como principal herramienta de inspección, cabe resaltar que las aplicaciones eléctricas han sido una línea de trabajo constante desde los inicios de la termografía y específicamente hablando de termografía pasiva.

Los antecedentes consultados muestran que los trabajos desarrollados principalmente abarcan estudios en áreas como metodologías para la ejecución de inspecciones y adquisición de imágenes, desarrollo de estándares, y guías prácticas para ejecución de la técnica entre otros. Es notable la ausencia de trabajos enfocados a brindar apoyo en la etapa de análisis de imágenes térmicas usando herramientas computacionales. La naturaleza de la información presente en las termografías, así como la posibilidad de relacionar fenómenos físicos como la transferencia superficial de calor en un cuerpo con ésta información a partir de técnicas de visión artificial, permiten que el desarrollo de herramientas computacionales como apoyo en el análisis de termografías sea viable. Teniendo en cuenta lo anteriormente planteado es notable la pertinencia del trabajo de investigación desarrollado.

El uso de máquinas de aprendizaje como redes neuronales tipo MLP y RBF se han aplicado con éxito en muchos trabajos que involucran termografía aunque la mayoría de éstos se han realizado utilizando la técnica activa. La aplicación de éste tipo de máquinas de aprendizaje con termografía pasiva abre las puertas a una línea de investigación que presenta un amplio potencial de trabajo.

La principal problemática asociada al análisis de termografías se puede atribuir a la forma como se relacionan los patrones de calentamiento presentes en una imagen con una condición de operación específica en un equipo. Esta interpretación la realiza actualmente un termógrafo especializado quien utiliza fundamentalmente su conocimiento y experiencia. El diseño de herramientas computacionales basadas en técnicas de visión artificial y máquinas de aprendizaje potencialmente podrán ayudar al especialista a proveer una interpretación más acertada.

Capítulo 3

Adquisición de termografías y descripción de la plataforma experimental

3.1. Introducción

Con este capítulo se busca describir el proceso para la adquisición de termografías y la plataforma experimental utilizada para el desarrollo del proyecto de investigación. La sección 3.2 hace una descripción detallada del procedimiento y de los criterios más importantes que se deben tener en cuenta para el proceso de adquisición de imágenes termográficas. La sección 3.3 presenta una descripción detallada de las características de los equipos utilizados para la inspección y los equipos inspeccionados.

3.2. Procedimiento de adquisición

El éxito de un programa de mantenimiento basado en termografía depende de muchos factores, entre los que se destacan la selección del equipo de inspección apropiado y disponibilidad de personal entrenado. Es importante además

3.2 Procedimiento de adquisición

contar con un protocolo que debe estar compuesto por guías y procedimientos que ayuden al termógrafo a optimizar su inspección, en busca de maximizar los beneficios de un programa de mantenimiento basado en inspección termográfica. La palabra protocolo dentro de un plan de mantenimiento basado en termografía comprenderá entonces todas las etapas previas y posteriores a una inspección (establecimiento del programa, mantenimiento del mismo, pre-inspección, inspección, pos-inspección). Dentro del trabajo de investigación propuesto se utilizará la palabra *protocolo* para hacer referencia a los pasos a seguir exclusivamente para la adquisición de imágenes termográficas e información válida que servirán como base para un análisis posterior.

3.2.1. Captura de la imagen

Independientemente del dispositivo de captura que se utilice para la adquisición de imágenes IR, existen 3 parámetros que no se pueden modificar o mejorar después de almacenar una imagen [ITC06].

- Rango de temperatura
- Enfoque óptico
- Composición de la Imagen

3.2.1.1. Rango de temperatura

Como con cualquier otro tipo de instrumento de medición, el rango de trabajo que se encuentre seleccionado para éste, influirá de manera directa en la precisión de una lectura. Es por esto que en termografía el *rango de temperatura* ajustado para la cámara debe estar acorde a las temperaturas que se pretenden medir o se esperan encontrar en la inspección, como se muestra en la figura 3.1. Si se ha fijado el rango de temperatura de trabajo del dispositivo de captura en una escala de -20 a 200 °C, y el equipo objeto de la inspección presenta temperaturas

3.2 Procedimiento de adquisición




Figura 3.1: Rango de una imagen.

cercanas a los 300 °C, el dispositivo no podrá tomar lecturas de radiación que representen temperaturas mayores a 200 °C. El rango de trabajo escogido para un dispositivo de captura se puede visualizar totalmente en niveles de intensidad, se puede también escoger visualizar parte del rango. La fracción del rango que se utiliza para visualización se conoce como *Campo* o *Contraste térmico*, éste se puede ampliar o reducir para mejorar la percepción de la imagen, sin que esto influya en los valores de temperatura calculados a partir de la radiación presente en el sensor. Visualmente valores de radiación menores al límite inferior del rango se codificarán con el nivel de intensidad más bajo posible dentro de la imagen (en escala de gris corresponde a negro), y valores de radiación mayores al límite superior del rango se codificarán con el nivel de intensidad más alto posible dentro de la imagen (en escala de gris corresponde a blanco), lo que producirá pérdidas de información. Las cámaras IR no tienen la funcionalidad de producir alertas cuando las mediciones de radiación se encuentran fuera del rango de captura del dispositivo.

3.2 Procedimiento de adquisición




Figura 3.2: Variaciones del contraste térmico o campo en una imagen IR. (a) Espectro visible del componente eléctrico. (b) Termografía de a con campo 1. (c) Termografía de a con campo 2. (d) Termografía de a con campo 3.

3.2 Procedimiento de adquisición

3.2.1.2. Enfoque óptico




Figura 3.3: Ejemplo del enfoque óptico. (a) Espectro visible de la escena. (b) Termografía con mal enfoque óptico. (c) Termografía con un enfoque óptico correcto.

El *enfoque óptico* es importante, no sólo porque una imagen mal enfocada pueda parecer poco profesional y visualmente distorsionada, sino porque la precisión de una medición de temperatura se verá afectada por el enfoque. Imágenes mal enfocadas producen malas lecturas de temperatura. La figura 3.3 muestra una escena con el mismo objeto, la primera imagen térmica tiene un enfoque óptico apropiado, la segunda está desenfocada, las lecturas de temperatura correspondientes a cada imagen muestran una diferencia sobre el mismo punto aproximadamente de 10.5 grados, con lo cual se puede confirmar el efecto adverso que presenta con un mal enfoque. Para ajustar el enfoque en una escena se debe identificar el punto más caliente y seleccionarlo con ayuda de alguna de las herramientas que posea el dispositivo de captura, posteriormente se varía el enfoque y se observa los cambios en la lecturas de temperatura. El mejor enfoque será el que logre obtener la mayor lectura de temperatura para el punto previamente identificado.

3.2 Procedimiento de adquisición




Figura 3.4: Ilustración gráfica del criterio de composición. (a) Variación IFOV con la distancia. (b) Criterio de composición.

3.2.1.3. Composición de la imagen

La *composición de la imagen* está relacionado con el cómo se debe presentar el objeto de interés dentro de la imagen termográfica. No debe estar muy lejos en un extremo o esquina y tampoco debe estar demasiado cerca, de forma que se pueda estar descartando información importante. Cuando el objeto a inspeccionar es demasiado pequeño su radiación emitida no podrá ser capturada por el detector (IFOV). De manera práctica se recomienda que el tamaño del objeto tenga por lo menos 2 veces el parámetro IFOV especificado para una distancia particular. El HFOV y VFOV entregan una idea del área de inspección que podemos capturar a cierta distancia y el IFOV entrega el área mínima que debe tener el objetivo a inspeccionar.

En la figura 3.4 [FLU05] el ítem a muestra la variación del IFOV de un dispositivo de captura ante variaciones de distancia. En el ítem b teniendo en cuenta los parámetros IFOV, HFOV y VFOV, se muestra como se debe tomar una imagen infrarroja. Dentro de la escena definida por HFOV y VFOV, el tamaño del objeto a inspeccionar preferiblemente debe estar en el centro de la escena y su tamaño debe ser por lo menos 2 veces el área definida por IFOV. Cuando el tamaño del objeto a inspeccionar es el mismo que el definido por IFOV se dice que la im-

agen es aceptable, pero en el caso que sea menor que éste último la imagen no estará bien adquirida.

3.2.2. Parámetros adicionales

Cuando no es indispensable obtener datos cuantitativos de temperatura de una imagen térmica, tener en cuenta los tres aspectos descritos en 3.2.1 son suficientes para contar con imágenes IR de buena calidad. Aplicaciones que exijan realizar un estudio cuantitativo de la información proporcionada por una imagen térmica, necesitan tener en cuenta parámetros adicionales para así obtener lecturas de temperatura apropiadas. La lectura de temperatura que se obtiene a partir de una imagen infrarroja generalmente se conoce como *temperatura aparente*, idealmente su valor debe estar muy cerca del valor real de temperatura del objeto a inspeccionar. Si bien la temperatura es importante en la evaluación de la condición de un equipo eléctrico, no debe ser el único parámetro tenido en cuenta; de ser así se corre el riesgo de proveer malos diagnósticos [Bai86a]. Analizar en conjunto factores adicionales como: captura de la imagen, emisividad del objeto, distancia, temperatura ambiente, temperatura reflejada, humedad, entre otros; involucrados en un diagnóstico se convierte en una tarea esencial y de gran importancia para obtener resultados productivos. Los parámetros adicionales necesarios para obtener una lectura confiable de *temperatura aparente* se pueden dividir en: parámetros del objeto y parámetros del entorno [ITC06]. El parámetro más importante relacionado al objeto a inspeccionar es la *emisividad*, y entre los más discriminantes con respecto al entorno se encuentran: *temperatura reflejada*, *temperatura ambiente*, *distancia al objeto*, *humedad* entre otros. *Carga eléctrica* y *velocidad del viento* son parámetros asociados al entorno pero su utilización para compensación se restringe a aplicaciones específicas ya que no es posible generalizar su efecto en cualquier escenario de inspección.

La cámara IR y el objetivo a inspeccionar siempre se encuentran separados por una porción de atmósfera, ésta será capaz de irradiar y absorber parte de

3.2 Procedimiento de adquisición

la radiación que emite y refleja el objeto de interés. Adicionalmente parte de esa radiación que atraviesa la atmósfera para llegar al dispositivo de captura se origina en otros objetos diferentes al objetivo de inspección, debido a los fenómenos anteriores es necesario cuantificar la magnitud de sus efectos de tal forma que se puedan eliminar para cálculos posteriores de *temperatura aparente*. De acuerdo a lo anterior la radiación que llega a una cámara IR está compuesta por:

- Emisión de la atmósfera
- Emisión del objetivo menos lo que absorbe la atmósfera
- Reflexión del entorno menos lo que absorbe la atmósfera

Por lo tanto hay dos cosas del entorno que se deben compensar: la atmósfera y la radiación reflejada. En primer lugar se debe tratar de cuantificar la cantidad de atmósfera y densidad de la misma que hay entre la cámara IR y el objetivo. La banda de longitud de onda de una cámara IR se selecciona donde la transmisividad del aire sea muy elevada [Mad82]. Los factores más relevantes que afectan la cantidad y densidad de atmósfera y por tanto su influencia en una medición son: *distancia*, *temperatura del aire* y *humedad relativa*.

3.2.2.1. Distancia, Temperatura, Humedad Relativa

Entre mayor sea la distancia entre el objeto de interés y el dispositivo de captura, mayor será la cantidad de atmósfera que podrá emitir y absorber radiación. Por otro lado la temperatura del aire (ambiente) influye directamente sobre la radiación de la atmósfera y también sobre la humedad relativa. Gran parte de la atenuación que la atmósfera ejerce sobre la radiación se debe al vapor de agua que ésta contiene, entre menor sea el número de moléculas de agua en la atmósfera, menor será su influencia [ITC06]. Los factores anteriormente mencionados se pueden cuantificar utilizando instrumentos de medición apropiados para tal fin, para el caso del presente proyecto la medición de la temperatura del aire y la humedad se obtienen a partir del medidor de variables ambientales




Figura 3.5: Radiación que llega a la cámara IR.

Kestrel 4000 y la distancia al objeto se mide usando el el medidor de distancia láser FLUKE TLM 100. Una vez se han cuantificado los valores de los parámetros anteriormente descritos, estos valores se ajustan en el dispositivo de captura directamente en campo, se pueden ajustar posteriormente en el mismo dispositivo o en un equipo de cómputo en donde se encuentren las imágenes térmicas almacenadas con ayuda del software proporcionado por el fabricante.

3.2.2.2. Temperatura reflejada

La *temperatura reflejada* es la temperatura aparente de los cuerpos que se reflejan en el objeto a inspeccionar. Normalmente se denota en los dispositivos de captura como T_{refl} o también se puede encontrar denotada como T_{amb} [ITC06]. Puesto que la parte relejada de la radiación que llega a una cámara no tiene nada que ver con la temperatura del objeto a inspeccionar, se debe cuantificar su valor y restarlo del total. En otras palabras, se desea dejar únicamente la información de la radiación que proviene del objeto de interés. El *método del reflector* es uno de los más utilizados para estimar el valor de temperatura reflejada, figura 3.6, éste consiste en utilizar una superficie rugosa de material de muy baja emisividad




Figura 3.6: Metodo del reflector para estimación de la temperatura reflejada.

(papel aluminio) adherida a una base firme (pieza de cartón). La pieza de cartón recubierta con papel aluminio se ubica cerca del objeto a inspeccionar (cara de papel aluminio frente a la cámara IR) y ajustando el dispositivo de captura para que trabaje sin compensación, se toma la lectura de temperatura sobre la pieza de papel aluminio. El valor encontrado correspondera a la temperatura reflejada.

3.2.2.3. Emisividad

La radiación que proviene de un cuerpo real W_{CR} se puede capturar con una cámara IR. Todas las cámaras que se encuentran comercialmente están calibradas con *cuerpos negros*, por tanto la lectura de temperatura que proporciona una cámara IR será la correspondiente a la temperatura de un cuerpo negro, es por esto que se debe realizar la compensación del efecto de la emisividad del objeto real. La emisividad según la ecuación 3.1 está definida como la relación entre la radiación emitida por un cuerpo real y la radiación emitida por un cuerpo negro, a la misma temperatura y longitud de onda [ITC06]. Por tanto si se conoce la radiación del cuerpo real W_{CR} , ésta se divide por su respectivo valor de emisividad ϵ y así se obtiene la radiación equivalente del cuerpo negro W_{CN} a partir de la

3.2 Procedimiento de adquisición

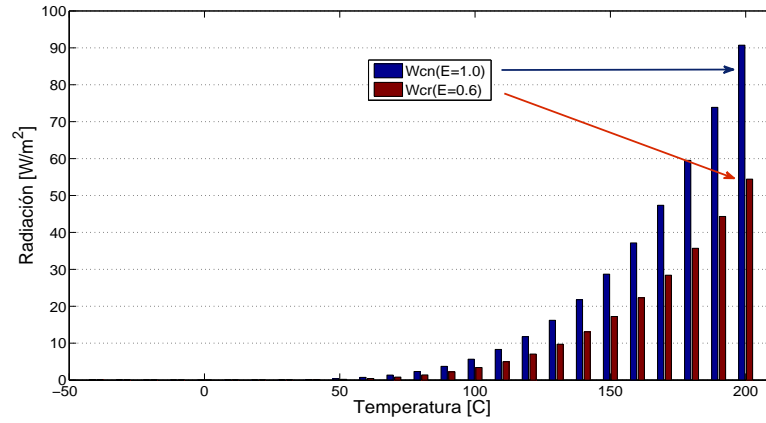


Figura 3.7: Comparación entre la radiación de un cuerpo real y la de un cuerpo negro

cual aplicando la *Ley de Stefann-Boltzmann* se puede encontrar la *temperatura aparente* de interés ya compensada por *emisividad*.

$$\varepsilon = \frac{W_{CR}}{W_{CN}} \quad (3.1)$$

En la figura 3.7 se puede observar como la radiación emitida por un cuerpo real (barras rojas) es menor a la presentada por el cuerpo negro (barras azules).

Existen tablas de emisividad para un amplio número de materiales [Hol00] [ITC06] [Mal01a] [Sys04], sin embargo todos éstos valores se han encontrado bajo condiciones particulares. Contar con valores de emisividad cercanos a los reales para mejorar las lecturas de *temperatura aparente* implica realizar estimaciones prácticas de éste parámetro, existen varias técnicas que proveen buenos resultados al respecto [Orl82] [AST02]. Por su sencillez y facilidad de implementación en campo la estimación de la emisividad utilizando una superficie de emisividad conocida, es uno de los métodos más utilizados. Este método consiste en colocar sobre el material del objeto a inspeccionar un trozo de cinta aislante con una emisividad elevada y conocida. Se recomienda que el cuerpo donde se pegue la

3.2 Procedimiento de adquisición

muestra de cinta debe estar por encima de la temperatura ambiente, se toma la lectura de *temperatura aparente* en la cinta ajustando el parámetro de emisividad en el valor conocido. Posteriormente se toma la *temperatura aparente* en una zona del objeto de interés (libre de la cinta) ajustando el parámetro de emisividad hasta obtener la misma lectura de temperatura que se presentó en la zona demarcada por la cinta. El valor ajustado será el correspondiente a la emisividad del objeto de interés, la figura 3.9 muestra gráficamente el procedimiento descrito anteriormente.

En la figura 3.10 se pueden observar dos termogramas de la mismo equipo, éstos contienen la misma información radiométrica, sin embargo los datos de *temperatura aparente* presentes en cada imagen difieren notablemente, debido a que los parámetros de compensación utilizados en cada una son distintos. Se puede apreciar como para el campo para el ítem (a) se encuentra entre 24.9 °C y 41.1 °C, para el ítem (b) se encuentra entre 31.0 °C y 55.7 °C.

Todos los parámetros anteriormente descritos intervienen en la estimación de *temperaturas aparentes*, la compensación de sus efectos se puede realizar directamente en la mayoría de dispositivos de captura (cámaras IR) comercialmente disponibles hoy en día, o se puede realizar con ayuda de paquetes software que complementan su funcionamiento y que son distribuidos por los mismos fabricantes de los dispositivos.

Aunque no existe hasta el momento un estándar ampliamente reconocido que tenga en cuenta los efectos producidos por la *velocidad del viento* y la *carga eléctrica*; se han realizado algunos estudios que introducen criterios para su compensación sobre las lecturas de *temperatura aparente* obtenidas con una cámara IR.

3.2.2.4. Velocidad del viento

Cuando una inspección se realiza a campo abierto, es necesario tener en cuenta el enfriamiento por convección que el viento puede producir, se han realizado algunos estudios prácticos acerca de la influencia de este tipo de enfriamiento

3.2 Procedimiento de adquisición




Figura 3.8: Efectos de una baja emisividad. (a) Imagen en espectro visible de un objeto con baja emisividad. (b) Termografía del objeto a (60 °C) con ajuste térmico automático. (c) Termografía del objeto a (27 °C) a temperatura ambiente con ajuste térmico automático. (d) Termografía del objeto a (2 °C) con ajuste térmico automático. (e) Termografía del objeto a (60 °C) con campo estático. (f) Termografía del objeto a (27 °C) a temperatura ambiente con campo fijo. (g) Termografía del objeto a (2 °C) con campo fijo.

3.2 Procedimiento de adquisición




Figura 3.9: Estimación de la emisividad usando una superficie de emisividad conocida. (a) T1 temperatura zona con emisividad conocida. (b) T1 temperatura zona con emisividad ajustada.

Velocidad del viento (m/s)	1	2	3	4	5	6	7
Factor de corrección FCVV	1	1,37	1,64	1,86	2,06	2,23	2,39

Cuadro 3.1: Factor de corrección para velocidad del viento FCVV.

en zonas calientes de equipos bajo inspección [ML00], los resultados muestran que la cantidad de enfriamiento depende no solamente de la velocidad del viento sino también de la potencia disipada por el objeto de interés. En [Hol00] se recomienda verificar la velocidad del viento de acuerdo al tipo de inspección a realizar. Para ejecutar inspecciones de tipo cualitativo es necesario velocidades menores a 6.7 m/s, y para inspecciones de tipo cuantitativo velocidades menores a 2.2 m/s. Existen también algunas normas [Pet98] dentro de las cuales se tiene en cuenta el enfriamiento por convección y adoptan como medida de compensación utilizar factores de corrección, ver tabla 3.1.

3.2 Procedimiento de adquisición

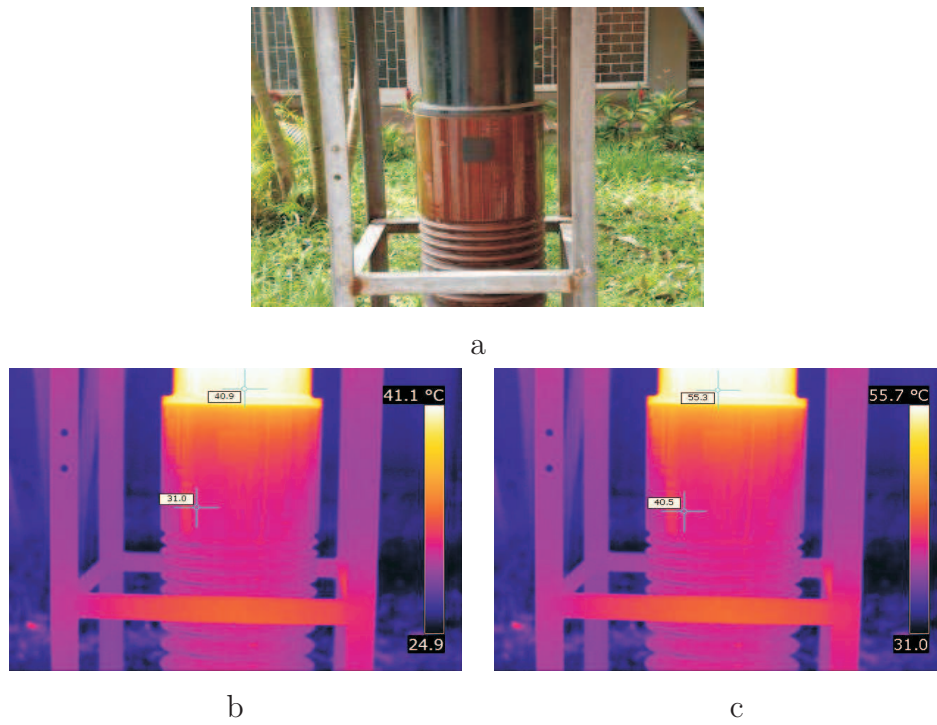


Figura 3.10: Ejemplos de compensación. (a) Espectro visible de la escena. (b) Termografía de a con compensación 1. (c) Termografía de a con compensación 2.

3.3 Plataforma experimental

Carga (%)	100	95	90	85	80	75	70	65	60	55	50
FCC	1,00	1,11	1,23	1,38	1,56	1,77	2,00	2,37	2,78	3,30	4,00

Cuadro 3.2: Factor de corrección de carga FCC.

3.2.2.5. Carga eléctrica

Un componente eléctrico genera calor en proporción a la potencia que disipa, por ley de ohm 3.2, el calor se relaciona con la cantidad de radiación que un cuerpo puede emitir y ésta radiación se puede traducir a temperatura teniendo en cuenta la *Ley de Steffan-Boltzman*. Existe por tanto una relación entre corriente y temperatura. En [PNS94] la *temperatura aparente* de un equipo debe ser corregida por medio de factor definido por la relación entre la corriente medida (I_{medida}) y la corriente nominal ($I_{nominal}$), como se muestra en la ecuación 3.3. En [Pet98] la *temperatura aparente* de un equipo inspeccionado se debe ajustar de acuerdo a un factor de corrección de carga *FCC*, éste factor de corrección solamente es válido para cargas iguales o superiores al 50 % de la carga nominal del equipo bajo inspección como se muestra en la tabla 3.2.

$$P = I^2 \cdot R \quad (3.2)$$

$$T_{corregida} = T_{aparente} \cdot \left(\frac{I_{nominal}}{I_{medida}} \right)^2 \quad (3.3)$$

3.3. Plataforma experimental

Para la recolección de imágenes termográficas se usaron dos referencias de cámaras infrarrojas, fabricadas por la compañía FLIR Systems. El primer equipo es ThermoVision A20, las características más relevantes que presenta esta cámara se presentan en la tabla 2.2, de acuerdo a las definiciones dadas en la sección



Figura 3.11: Conversor Video-USB X10-VA11A

2.5. Este equipo puede almacenar imágenes en su memoria interna, pero no es posible exportarlas directamente a un equipo de cómputo; por lo que se hace necesario realizar la transferencia de las imágenes aprovechando su salida de video compuesto CVBS (Composite Video). La forma mas sencilla de digitalizar la señal de video que sale de la ThermoVision A20 es utilizando un conversor de video digital (VA11A), fabricado por la compañía X10 (figura 3.11). Este dispositivo tiene la función de enviar la señal de video análoga hacia el puerto USB de cualquier computador compatible al que se encuentre conectado, lo que garantiza una gran portabilidad.

El otro equipo utilizado para la adquisición de imágenes es el ThermaCAM E320. En la tabla 3.3 se muestran las características más importantes del equipo. Entre las diferencias mas notables con respecto a la ThermoVision A20 está el tamaño de su sensor 320×240 , su capacidad de almacenamiento de imágenes de 80 imágenes y tal vez lo que la hace más atractiva su portabilidad y facilidad de conexión al computador para la descarga directa de imágenes via USB.

La figura 3.13 muestra gráficamente dos curvas con las que se puede distinguir la variación del IFOV a distintos distancias para la ThermoVision A20 y para la ThermaCAM E320. Se puede apreciar como el IFOV de ésta última es ciertamente mayor. Comparaciones de HFOV y VFOV de acuerdo a las tablas respectivas muestran un comportamiento similar, con lo cual se puede afirmar

3.3 Plataforma experimental



Figura 3.12: Cámara FLIR ThermaCAM E320

Tipo de detector	FPA no refrigerado 320 * 240 pixeles
Rango espectral del detector	7.5 - 13 μm
Rango de temperatura	-20 a +120 °C (-4 a + 482 °F) 80 a 500 °C
Exactitud	± 2 °C ± 3.6 °F
Temperatura de operación	-15 a +50 °C (+5 a +122 °F)
Temperatura de almacenamiento	-40 a +70 °C (-40 a +158 °F)
Interfaces de comunicación	USB 2.0 RS232 (Opcional)
Salida de video	Video compuesto CVBS (PAL y NTSC)
Capacidad almacenamiento	80 Imagenes

Cuadro 3.3: Especificaciones técnicas ThermaCAMTM E320.

3.3 Plataforma experimental

D	0.5	1.0	2.0	5.0	10.0	25.0	50.0	100.0	m
HFOV	0.49	0.98	1.96	4.90	9.80	24.49	48.98	97.96	m
VFOV	0.37	0.73	1.47	3.67	7.35	18.37	36.73	73.47	m
IFOV	1.53	3.06	6.12	15.31	30.61	76.53	153.06	306.12	mm

Cuadro 3.4: ThermaCAMTM E320. Campo de vision horizontal, vertical e instantáneo (HFOV, VFOV, IFOV) sobre algunas distancias D al objeto de inspección, para lentes IR de 14,7 mm.

Exactitud	$\pm 6mm$
Rango	0.6m - 30m
Temperatura de operación	-30 a +70 °C (-22 a +158 °F)
Temperatura de almacenamiento	5 a +40 °C (-41 a +104 °F)

Cuadro 3.5: Estanley TLM 100. Características principales del medidor de distancia láser Estanley TLM 100.

que el equipo ThermaCAM E320 presenta un rango mayor para los parámetros que describen el tamaño tanto de la escena como del objeto que se puede capturar con el dispositivo.

De acuerdo a los factores que afectan la estimación de la *temperatura aparente* obtenida con una cámara IR, se hace necesario contar con instrumentos, figura 3.14, capaces de cuantificar sus magnitudes. Para obtener lecturas de distancia se utilizó el medidor de distancia láser *Estanley TLM100*, sus características se presentan en la tabla 3.5. Las mediciones con este dispositivo se realizan sin contacto y a una distancia prudente del objeto a inspeccionar, lo que incrementa las garantías de seguridad para el operario. Para obtener las magnitudes correspondientes a la velocidad del viento, humedad relativa y temperatura ambiente se utilizó el medidor de variables ambientales *Kestrel 4000*, en la tabla 3.6 se encuentran sus características más importantes .

3.3 Plataforma experimental

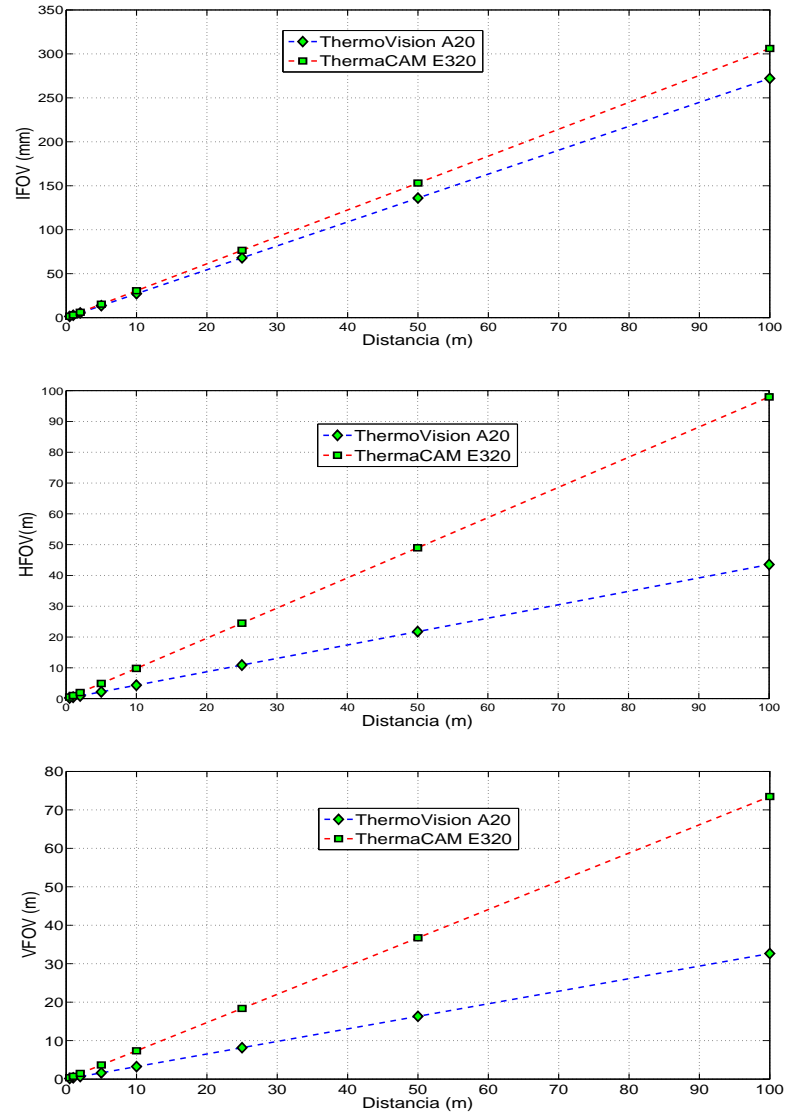


Figura 3.13: Comparación parámetros IFOV, HFOV y VFOV para Camaras ThermoVision A20 y ThermaCAM E320. (a) IFOV. (b) HFOV. (c) VFOV.

3.3 Plataforma experimental



Figura 3.14: Instrumentos básicos. (a) Medidor de distancia láser Estanley TLM100. (b) Medidor de variables ambientales Kestrel 4000. (c) Medidor de temperatura IR FLUKE 62. (d) Cámara SONY DSCW55.

Medición	Unidades	Alcance	Resolución	Precisión (\pm)
Velocidad del viento	m/s	0.4 - 60.0	0.1	3 %
Humedad	%HR	0.0 - 100.0	0.1	3
Temperatura	°C	-20.0 a +158.0	0.1	1.0

Cuadro 3.6: Características principales del medidor de variables ambientales Kestrel K4000.

3.3 Plataforma experimental

Tipo	D300-141240M/N
Tensión nominal	145 kV
Corriente nominal	1250 A
Esfuerzo en terminales	1000 N
Peso por polo	299 kg

Cuadro 3.7: Especificaciones técnicas del Seccionador ALSTOM.

Las imágenes en espectro visible se utilizan en las inspecciones termográficas como complemento para aclarar o reforzar la información que brinda una imagen IR, algunos equipos IR ya traen una cámara digital incorporada, pero las referencias utilizadas en el desarrollo del proyecto no la tienen, por lo que se hace necesario la utilización de una cámara digital para tomar de imágenes en espectro visible y así poder documentar los equipos y pruebas realizadas. La cámara utilizada es una Sony Cybershot DSCW55 de 7.2 Megapíxeles con una memoria externa de 2 Gigabytes. Se utiliza además un termómetro infrarrojo puntual de marca FLUKE 62, con el cual se obtienen lecturas de temperatura que normalmente se utilizan como datos de comparación en etapas experimentales.


Los equipos sobre los cuales se realizaron pruebas experimentales de inspección termográfica se muestran en la figura 3.15, se encuentran entre estos: un transformador de corriente, un buje capacitivo y un seccionador. Las características de cada uno de estos equipos se describen en las tablas 3.7, 3.9 y 3.8 respectivamente. Además de estos equipos se realizaron pruebas sobre un prototipo Feedback ES151 el cual se puede observar en la figura 3.17.

En la figura 3.16 se muestra una fuente de corriente variable, proporcionada por el grupo de investigación GRALTA de la Universidad del Valle, que alcanza a proveer más de 1000 A y que fue utilizada para la alimentación del transformador de corriente, el buje capacitivo y el seccionador durante las pruebas experimentales.

3.3 Plataforma experimental



a



b



c

Figura 3.15: Equipos Inspeccionados. (a) Seccionador ALSTOM. (b) Transformador de corriente BALTEAU. (c) Buje capacitivo MITSUBISHI.

Tipo	SAX 245 No. 51359
Frecuencia	60 Hz
Corriente nominal	1200 A
Terminal (1 y 2) S1 S2	2 : 1000
Terminal (3 y 4) S1 S2	500 : 1
Terminal (5 y 6) S1 S2	2 : 1000

Cuadro 3.8: Especificaciones técnicas del Transformador de Corriente BALTEAU.

3.3 Plataforma experimental

Tipo	ANSI C76-1
Corriente nominal	800 A

Cuadro 3.9: Especificaciones técnicas del Buje Capacitivo MITSUBISHI.



Figura 3.16: Fuente de corriente.

Procesador	Intel Core 2 Duo E8400 (3.0GHz, 6M, VT, 1333MHz FSB)
Sistema operativo	Windows XP SP3 Original
Memoria RAM	4.0GB DDR2 SDRAM, 800MHz, 4DIMM
Disco duro	160GB SATA 3.0Gb/s (3.0GHz, 6M, VT, 1333MHz FSB)
Tarjeta de video	Intel GMA3100 - Integrada

Cuadro 3.10: Especificaciones técnicas del equipo de cómputo DELL OptiPlex 755.



Figura 3.17: Motor unidad Feedback ES151 .

Por último el equipo de cómputo utilizado para el procesamiento de datos e imágenes fué un computador Dell OptiPlex 755 con las características que se presentan en la tabla 3.10.

3.4. Conclusiones

En el proceso de captura de una termografía existen 3 parámetros básicos que no se pueden modificar después de haber almacenado la imagen. Estos son: *rango de temperatura*, *enfoque óptico* y *composición de la imagen*. Errores en la selección del rango de temperatura de la cámara IR pueden originar pérdida de información radiométrica en una escena o equipo inspeccionado. Un mal enfoque óptico puede producir errores en la captura de la información radiométrica y consecuentemente errores en los cálculos de temperatura que presenta la cámara IR. Por último no tener en cuenta aspectos de composición producirán que objetos

de interés a inspeccionar no se encuentren dentro de la imagen térmica.

La obtención de lecturas de temperatura aparente correctas exige tener en cuenta los siguientes parámetros: distancia entre el equipo a inspeccionar y la cámara IR, temperatura ambiente, temperatura reflejada, humedad relativa del ambiente, velocidad del viento, emisividad y carga eléctrica a la cual se encuentra operando el equipo a inspeccionar. Todos los parámetros anteriormente mencionados influyen directamente en los cálculos de temperatura aparente que entrega una cámara IR, no tener en cuenta alguno de estos parámetros producirá errores en éstas lecturas de temperatura.

La emisividad de un material es uno de los factores que más pueden influenciar la interpretación de una termografía tanto cualitativamente como cuantitativamente. Este factor no solamente puede producir diferentes formas de radiación en la superficie de un cuerpo compuesto de diferentes materiales sino que también producirá errores en los cálculos de temperatura aparente en el caso en que no se realice la compensación adecuada.

Tener en cuenta las especificaciones de los equipos utilizados durante la inspección termográfica permite reducir errores en el proceso de captura de imágenes y recolección de información.

La plataforma experimental utilizada fue adecuada para los objetivos planteados en la investigación ya que se pudieron reproducir algunas de las fallas que con mayor frecuencia se encuentran en el desarrollo de inspecciones termográficas (sobre carga en motores y fallas de contactos en terminales de equipos eléctricos).

Capítulo 4

Sistema para el análisis de imágenes termográficas

4.1. Introducción

En este capítulo se describe todo lo relacionado con sistema de análisis de imágenes termográficas desarrollada para el proyecto. En 4.2 se hace una descripción general de los módulos que componen el software implementado. En 4.2.1 se describe el módulo de entrada, en la sección 4.2.2 se hace una descripción de la etapa basada en máquinas de aprendizaje. En 4.2.3 se describe la etapa basada en la información del gradiente, y por último en 4.2.4 se detalla el funcionamiento del bloque de salida del sistema.

4.2. Software del sistema

La figura 4.1 muestra una descripción general del sistema de análisis de imágenes termográficas, está compuesto por 4 módulos. Un módulo de entrada de información, dos módulos de procesamiento paralelos y un módulo de salida común que cumple tareas de interpretación. La información que llega al módulo de entrada es una imagen térmica que puede tomar dos vías (excluyentes), la

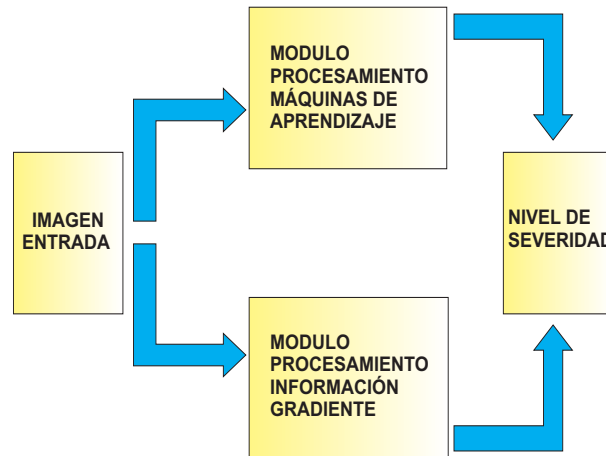


Figura 4.1: Software del sistema.

primera es el módulo de procesamiento basado en máquinas de aprendizaje y la otra corresponde al módulo de procesamiento basado en información del gradiente, la salida de cada uno de éstos módulos se conecta directamente al bloque de salida del sistema que se encarga de verificar (informar) si la imagen térmica analizada en los bloques anteriores se puede clasificar de acuerdo a unos niveles de severidad o no.

4.2.1. Módulo de entrada

El módulo de entrada del sistema se encarga de cambiar el modelo de color de las imágenes de entrada a escala de grises. El ítem (a) de la figura 4.5, muestra el diagrama de flujo de éste módulo en donde se puede observar con mayor detalle su funcionamiento. Primero se adquiere la información de imagen de un archivo almacenado en disco y se verifica su formato, si la imagen de entrada está en color se realiza su conversión a escala de grises, que es el formato adecuado para las siguientes etapas, en caso contrario no se realiza ninguna acción sobre la información. La figura 4.2 muestra dos imágenes el ítem (a) presenta el




Figura 4.2: Funcionamiento del módulo de entrada. (a) Termografía del motor con paleta de color *Iron de alta definición*. (b) Termografía de motor en escala de grises

termograma de un motor eléctrico representado con una paleta de colores *iron de alta definición*, el ítem (b) muestra el resultado que aplica el módulo de entrada, que corresponde a una imagen en *escala de grises* donde el nivel de gris blanco representa la mayor intensidad de radiación IR presente en la escena y el nivel de gris negro corresponderá a el nivel más bajo de radiación respectivamente.

4.2.2. Módulo de procesamiento con máquinas de aprendizaje

Este módulo se encarga de realizar una de las dos clases de procesamiento completo disponibles en el sistema sobre la imagen proveniente del módulo de entrada como se puede observar en la figura 4.3, la primera etapa brinda la opción de realizar un filtrado espacial sobre la información que entra al módulo, en la segunda etapa se efectúa el proceso de segmentación manual de la imagen, ésta segmentación consiste de un área rectangular previamente definida para el tipo de imágenes que se trabajan en éste módulo. En la tercera etapa se realiza la extracción de características, sobre la imagen segmentada. La cuarta etapa pre-

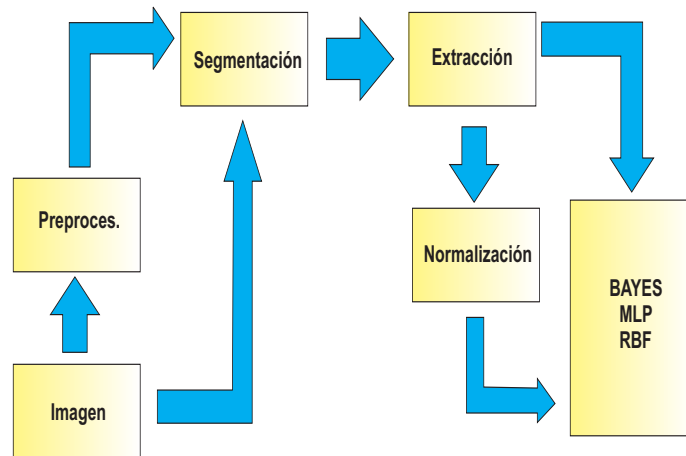


Figura 4.3: Módulo de procesamiento con máquinas de aprendizaje.

senta la opción de realizar diferentes tipos de normalización a las características extraídas de la región de interés, por último la quinta etapa corresponde al proceso de clasificación, en esta etapa se han implementado 3 tipos de clasificadores: uno estadístico y 2 basados en redes neuronales.

4.2.2.1. Filtrado

En el filtrado tipo mediana, el nivel de gris de cada píxel se reemplaza por la mediana de los niveles de gris del entorno que rodean este píxel. La mediana M de un conjunto de valores es tal que la mitad de los valores del conjunto son menores que M y la mitad de los valores mayores que M , es decir en un conjunto ordenado de mayor a menor o viceversa, el valor mediana corresponde al valor de la posición central del arreglo ordenado.

Haciendo uso de la definición de mediana se puede forzar a un píxel a tomar el valor de intensidad que más se asemeje al de sus vecinos, por tanto se escoge para ésta etapa utilizar un *filtro mediana*, el cual ayudará en la reducción de ruido y evitará el desvanecimiento de bordes en la imagen [IGK⁺04]. El ítem (b) de la figura 4.5 muestra el diagrama de flujo correspondiente a esta etapa, se




Figura 4.4: Etapa de filtrado. (a) Termografía de un motor sin filtrado. (b) Filtrado mediana de *a* con máscara 3×3 . (c) Filtrado mediana de *a* con máscara 5×5 . (d) Espectro de Fourier de *a*. (e) Espectro de Fourier de *b*. (f) Espectro de Fourier de *c*.

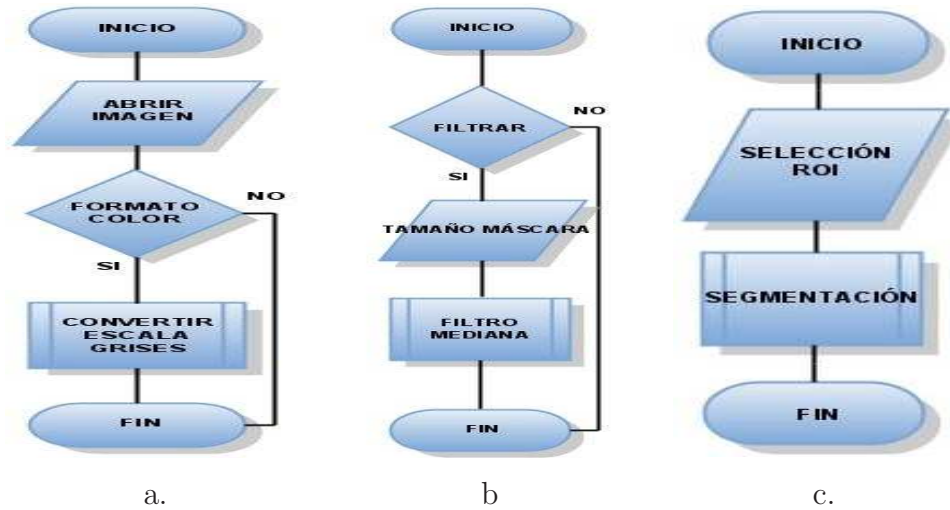


Figura 4.5: Diagramas de flujo. (a) Modulo de entrada. (b) Etapa de filtrado. (c) Etapa de segmentación.

puede observar que se puede escoger entre realizar o no el filtrado a una imagen proveniente del módulo de entrada, en el caso de escoger la opción de filtrado se debe ajustar el tamaño de la máscara a utilizar y por último se aplica el filtro. En la figura 4.4 se observa una imagen termográfica de un motor eléctrico antes y después de pasar por la etapa de filtrado, para la imagen del item (b) el tamaño de la máscara utilizado es de 3×3 y para el item (c) es de 5×5 , visualmente entre las 3 imágenes no se observan grandes diferencias, el efecto de suavizado apenas es perceptible. Sin embargo observando los items (d), (e) y (f) que corresponden a la magnitud del espectro de *Fourier* de las tres imágenes anteriores respectivamente, se puede apreciar que aunque la imagen sin filtrar no presenta un alto contenido de información en altas frecuencias, las imágenes filtradas tratan de agrupar aún más la información hacia el centro del espectro lo que produce una atenuación de altas frecuencias y por consiguiente un realce de la información en bajas frecuencias.




Figura 4.6: Segmentación manual de una imagen en el módulo de procesamiento basado en máquinas de aprendizaje.

4.2.2.2. Segmentación

Teniendo en cuenta que no toda la información de la imagen es relevante, se decidió escoger la zona en la cual los cambios de temperatura del dispositivo de interés *Unidad Feedback ES151* son más notables. La figura 4.5 ítem c muestra el diagrama de flujo de la etapa de segmentación, sobre la imagen proveniente de la etapa de filtrado se realiza la selección manual de la región de interés (*ROI*), después de lo cual se efectúa el procedimiento de segmentación. En la figura 4.6 se presenta el resultado de la segmentación manual realizada para las imágenes térmicas correspondientes, en donde se puede apreciar que la zona segmentada es un rectángulo de tamaño 110 x 125 píxeles, en ésta área se aprecia que se encuentra la información más relevante de la termografía del equipo bajo inspección.

4.2.2.3. Extracción de características

Asumiendo que la información relevante en imágenes térmicas se encuentra principalmente en las características internas de ciertas regiones, se utilizan como descriptores de las imágenes segmentadas los primeros cuatro (4) momentos estadísticos y los primeros siete (7) momentos invariantes de *Hu*. Aunque existen varias definiciones de momentos invariantes como: *afines*, de *Tsirikokias-Mertzios*

[PdlC02] o de *ejes principales* [Bal98], los momentos invariantes de *Hu* se hacen especialmente atractivos debido a que son invariantes a la rotación, traslación y cambio de escala, además tienen alta tolerancia al ruido y han sido utilizados ampliamente en aplicaciones de reconocimiento de patrones [HC95] [Bal98].

Tomando $f(x,y)$ como la intensidad del punto de coordenadas (x,y) en una región, el momento de orden $p+q$ y el momento central de mismo orden se definen como se muestra en las ecuaciones 4.1 y 4.2 respectivamente. La sumatoria se realiza sobre todas las coordenadas espaciales (x,y) de la región o imagen [PdlC02].

$$m_{pq} = \sum_x \sum_y x^p y^q f(x, y) \quad (4.1)$$

$$\mu_{pq} = \sum_x \sum_y (x - \bar{x})^p (y - \bar{y})^q f(x, y) \quad (4.2)$$

Los dos primeros momentos corresponden a la *media* y la *varianza* y proveen información sobre la localización y variabilidad de un conjunto de datos o población, el tercer momento corresponde a *skewness* el cual es una medición de la simetría de la distribución y por último el cuarto momento corresponde a *kurtosis* que representa una medida de que tan plano o pronunciado es el pico de la distribución de la población de interés. Los momentos de *Hu* se obtienen a partir de los momentos *centrales* normalizados de segundo y tercer orden [Wie05] y su definición se puede encontrar en la tabla 4.1 [Bal98].

Al final cada imagen que entra al sistema y que generalmente tiene un tamaño de 320 x 240 pixeles, después de la etapa de extracción, se convierte en un vector de 11 características conformado por los valores de los momentos estadísticos e invariantes anteriormente mencionados 4.3.

$$\begin{bmatrix} f_{(1,1)}, f_{(1,2)}, \dots, f_{(1,320)} \\ f_{(2,1)}, f_{(2,2)}, \dots, f_{(2,320)} \\ \vdots \\ f_{(240,1)}, f_{(240,2)}, \dots, f_{(240,320)} \end{bmatrix} \rightarrow \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ \vdots \\ x_{11} \end{bmatrix} \quad (4.3)$$

4.2 Software del sistema

Orden	Invariantes de Hu	Abreviaciones
1	$\psi_1 = a_{4,0}$	$a_{4,0} = \mu_{2,0} + \mu_{0,2}$
2	$\psi_2 = a_{4,2}^2 + b_{4,2}^2$	$a_{4,2} = \mu_{2,0} - \mu_{0,2}$
3	$\psi_3 = a_{4,2}(a_{5,1}^2 - b_{5,1}^2) + 2a_{5,1}b_{5,1}b_{4,2}$	$b_{4,2} = 2\mu_{1,1}$
4	$\psi_4 = a_{5,1}^2 + b_{5,1}^2$	$a_{5,1} = \mu_{3,0} + \mu_{1,2}$
5	$\psi_5 = a_{5,3}^2 + b_{5,3}^2$	$b_{5,1} = \mu_{2,1} + \mu_{0,3}$
6	$\psi_6 = a_{5,1}a_{5,3}(a_{5,1}^2 - 3b_{5,1}^2) + b_{5,1}b_{5,3}(3a_{5,1}^2 - b_{5,1}^2)$	$a_{5,3} = \mu_{3,0} - 3\mu_{1,2}$
7	$\psi_7 = a_{5,1}b_{5,3}(a_{5,1}^2 - 3b_{5,1}^2) + b_{5,1}a_{5,3}(3a_{5,1}^2 - b_{5,1}^2)$	$b_{5,3} = 3\mu_{2,1} - \mu_{0,3}$

Cuadro 4.1: Momentos invariantes de Hu .

En el ítem (a) de la figura 4.10 se puede observar el diagrama de flujo correspondiente a la etapa de extracción de características. El proceso que se utiliza para la extracción de información de la región de interés (ROI) definida previamente en la etapa de segmentación inicia calculando sobre la (ROI) los once (11) descriptores anteriormente definidos, posteriormente se identifica si la imagen segmentada que se está analizando es un patrón de entrenamiento o validación; en el primer caso se cuenta con la opción de almacenar el vector de once características en un archivo binario y posteriormente transmitirlo a la siguiente etapa, en el otro caso el vector de características encontrado se transmite a la siguiente etapa sin dejar su registro en memoria.

4.2.2.4. Normalización de datos

El vector de características proveniente de la etapa de extracción puede ser tratado de acuerdo a 5 tipos de normalización de datos disponibles en esta etapa, como se representa en el ítem (b) de la figura 4.10. El primer tipo de normalización implementado se conoce como *min max*, es una de las técnicas más simples y busca realizar una transferencia lineal sobre los datos originales para que éstos se encuentren dentro de un nuevo rango con límites entre -1 y 1, de manera que la distribución original se mantenga como se puede ver en 4.4 donde X_{\min} y X_{\max}

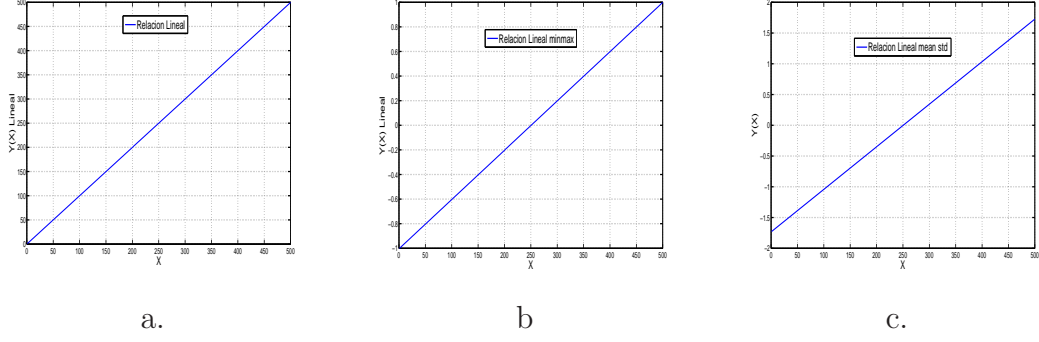


Figura 4.7: Ejemplos normalización lineal (a) Relación lineal rango $[0 \ 500]$. (b) Relación lineal min max rango $[-1 \ 1]$. (c) Relación lineal mean std media $= 0$ y varianza $= 1$.

son los valores mínimo y máximo del conjunto de valores posibles de la variable X .

$$X_{\text{mín máx}} = \frac{X - X_{\text{mín}}}{X_{\text{máx}} - X_{\text{mín}}} \quad (4.4)$$

La segunda técnica implementada se ha denominado como *mean std*, y consiste en transformar la distribución de datos original en una distribución con media (\bar{X}) cero y varianza (σ) unitaria 4.5.

$$X_{\text{MeanStd}} = \frac{X - \bar{X}}{\sigma} \quad (4.5)$$

En algunos casos es conveniente implementar una transformación de coordenadas que convierta una distribución normal multivariable en una distribución esférica, teniendo una matriz de covarianza proporcional a una matriz identidad \mathbf{I} . Definiendo Φ como la matriz cuyas columnas sean vectores propios ortonormales de la matriz de covarianza Σ , y Λ la matriz diagonal de los valores propios correspondientes, la normalización *whitening* quedará definida como se muestra en 4.6 [DHS01].

$$A_W = \Phi \Delta^{-1/2} \quad (4.6)$$

Un problema comúnmente encontrado en la extracción de características es la alta dimensionalidad de los datos [Bis95], resolver el problema de la dimensionalidad se puede realizar combinando características. Las combinaciones lineales resultan atractivas debido a su simplicidad de cálculo y análisis. Los métodos lineales buscan proyectar los datos de alta dimensionalidad en un espacio de dimensionalidad mucho menor. El análisis de componentes principales (PCA) basado en la transformada *Karhunen-Loève* busca la proyección que mejor represente los datos haciendo que su varianza sea máxima [Shl05]. En *PCA* se realiza primero el cálculo del vector de medias μ y matriz de covarianzas Σ simétrica de tamaño $d \times d$ para un conjunto de datos dado. Al igual que en la normalización *whitening* se calculan los vectores y valores propios, siendo estos últimos ordenados forma decreciente. Normalmente se seleccionan los primeros vectores propios que tengan asociado los valores propios de mayor peso. Es así como el nuevo subespacio estará representado por los k valores propios seleccionados. Por lo tanto las dimensiones sobrantes $d - k$ se dice que tienen información poco relevante, incluso algunas referencias lo definen como información redundante o ruido [Esc77]. Es así como se forma la matriz \mathbf{A} de tamaño $d \times k$ donde sus columnas representan los k vectores propios. Entonces la representación de información usando *PCA* consiste en proyectar los datos sobre un subespacio k -dimensional como se define en 4.7.

$$X_{PCA} = A^T (x - \mu) \quad (4.7)$$

El último método implementado ejecuta sobre los datos de interés la operación logaritmo natural, produciendo una compresión del rango dinámico de los datos iniciales como se muestra en 4.8, donde c es un factor de escala y la función logaritmo natural realiza la compresión deseada [GW96].




Figura 4.8: Normalización: (a) Whitening. (b) PCA.

$$X_{LOG} = c \cdot \text{Log}(1 + |X|) \quad (4.8)$$

4.2.2.5. Máquinas de aprendizaje

La etapa de reconocimiento está a cargo de 3 tipos de clasificadores: uno estadístico y dos basados en redes neuronales, una breve descripción de sus principios de funcionamiento se puede encontrar en la sección 2.6. En la implementación del clasificador estadístico se utiliza el toolbox *PRTools* de reconocimiento de patrones desarrollado en MATLAB y disponible en línea para propósitos no comerciales en <http://www.prtools.org>. Los clasificadores basados en redes neuronales se implementan utilizando el toolbox disponible en MATLAB para redes neuronales, la versión de MATLAB utilizada es la 7.4.0287 R2007a. En la figura 4.11 se puede observar un diagrama de flujo que muestra el funcionamiento de ésta etapa. Primero se debe escoger el tipo de clasificador con que se desea trabajar, se verifica si se va a realizar un proceso de entrenamiento o validación, si el proceso es de entrenamiento se cargan los datos respectivos desde un archivo en memoria o desde la etapa de extracción previa; se realiza un ajuste de parámetros acorde al tipo de máquina de aprendizaje seleccionada, se crea, inicializa, posteriormente




Figura 4.9: Ejemplos normalización logarítmica (a) Relación lineal rango [0 500]. (b) Relación logarítmica rango [0 50]. (c) Relación logarítmica rango [0 1].

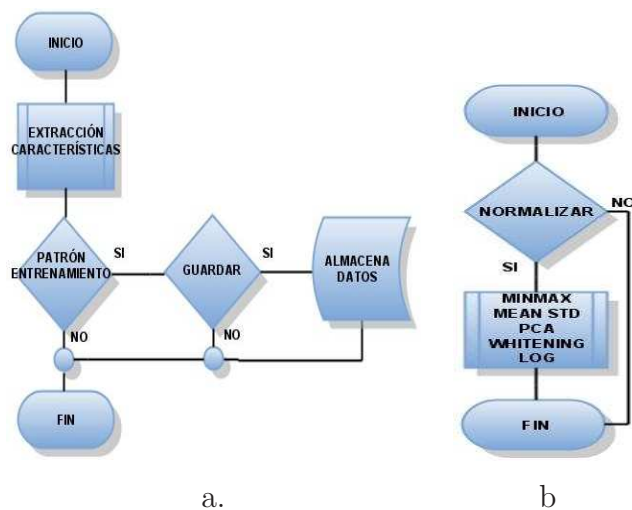


Figura 4.10: Diagramas de flujo. (a) Etapa de extracción de características. (b) Etapa de normalización.

se realiza su entrenamiento y por último la máquina de aprendizaje entrenada se almacena en memoria. Si el proceso a realizar es de validación, se debe cargar el clasificador respectivo, bien sea de la etapa de entrenamiento anterior o desde memoria, luego se cargan los datos de validación y por último se procede a validar la máquina de aprendizaje.

La primera máquina de aprendizaje basada en redes neuronales diseñada fue un perceptrón multicapa, comúnmente muy utilizado en tareas de clasificación [Fau94]. Para la capa de entrada de red se utilizan once neuronas que corresponden al número de características provenientes de la etapa de extracción, se utiliza solamente una capa oculta y se escoge que su número de neuronas sea el mismo que el presente en la capa de entrada, y en la salida se utilizan dos neuronas cada una de las cuales estará encargada de identificar uno de los dos estados posibles (presencia o ausencia de operación anómala en el dispositivo bajo análisis). Para complementar el diseño de la red se debe escoger el algoritmo de aprendizaje y las funciones de activación de cada etapa. Por defecto se utiliza la información del gradiente descendente *traingd* como algoritmo de aprendizaje, la función tangente sigmoideal *tansig* para la activación de la capa de entrada y la capa oculta y para la etapa de salida se utiliza la función de activación lineal *pureline*.

El otro tipo de máquinas de aprendizaje utilizada en esta etapa son las redes de base radial *RBF*, a diferencia del perceptrón multicapa, su arquitectura permite la presencia de una sola capa oculta y los tiempos de entrenamiento son sustancialmente mucho menores, aunque el desempeño alcanzado por los dos tipos de redes en algunos casos son muy similares, las *RBF* mejoran cuando el número de patrones de entrenamiento es numeroso [CCG91]. Su rapidez de entrenamiento radica en que el éste proceso se realiza en dos etapas [Bis95]. Utilizando el toolbox de MATLAB la implementación de *RBF* es muy simple, se ejecuta el comando *newrb* y como argumentos de entrada se entregan los vectores de entrenamiento y los vectores que contienen las etiquetas de clase correspondientes, opcionalmente se puede especificar el error cuadrático medio deseado (*MSE mean square error*).

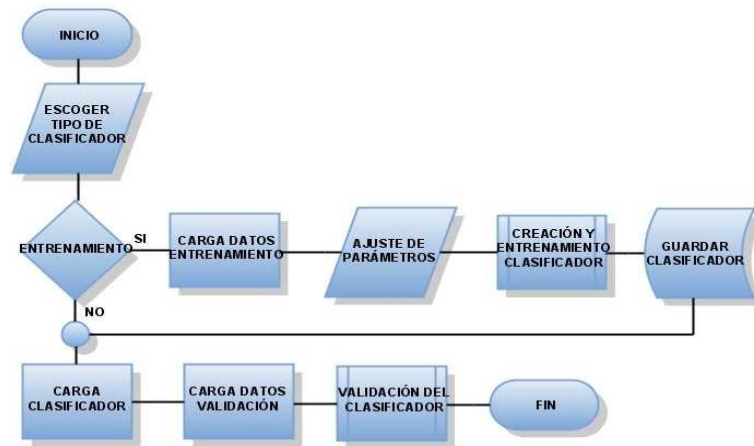


Figura 4.11: Diagrama de flujo de la etapa de clasificación.

La última máquina de aprendizaje implementada es un clasificador Bayesiano cuyo principio de funcionamiento se explica en la sección 2.6, de acuerdo al conjunto de patrones de entrenamiento organizados en sus clases respectivas, se encuentran los parámetros característicos (μ, Σ) [Bis95] [DHS01] [Esc77] de cada clase (*entrenamiento*) con base a los cuales y con ayuda de una función discriminante 2.14 derivada del *Teorema de Bayes* se realizará el posterior proceso de validación (*clasificación*), un patrón dado será asignado a la clase cuyo resultado de evaluar la función discriminante resulte mayor 2.13.

4.2.3. Módulo de procesamiento basado en información del gradiente

Este módulo software se encarga de realizar la segunda clase de procesamiento completo disponible en el sistema sobre la imagen proveniente del módulo de entrada como se puede observar en la figura 4.12, contiene etapas de filtrado y segmentación que utilizan como base las diseñadas previamente en el módulo de máquinas de aprendizaje, la etapa de filtrado se aplica antes y después de la




Figura 4.12: Módulo de procesamiento con información del gradiente.

extracción de características. En la etapa de segmentación se pueden seleccionar *ROIs* que describan una forma cerrada cualquiera o una lineal. La etapa de extracción de características se diseña tomando como base la teoría de transferencia de calor vista en la sección 2.3 y por último la etapa de clasificación se implementa con rutinas de decisión condicionales a partir de la información proveniente de la etapa de extracción de información anterior.

4.2.3.1. Filtrado

Esta etapa utiliza el filtrado tipo mediana al igual que en el módulo de procesamiento basado en máquinas de aprendizaje. El filtrado que se realiza después de la etapa de extracción de características se realiza sobre la información del gradiente de la imagen. En la figura 4.13 se observa en el ítem (a) la información del ángulo del gradiente para una termografía de un equipo en la que se evidencia un alto contenido de ruido (entendiendo por ruido a las variaciones bruscas de la información del ángulo del gradiente), el ítem (b) muestra la misma información después de aplicar el filtrado mediana con una máscara de tamaño 7×7 , en los ítems (c) y (d) se muestran los espectros de magnitud en el dominio de *Fourier*




Figura 4.13: Imagen con información del ángulo del gradiente de un motor: (a) Sin filtrar. (b) Filtrada.

respectivamente. Se puede apreciar como el espectro de magnitud de la información sin filtrar se encuentra distribuido sobre casi toda la imagen abarcando todo el rango de frecuencias, después de realizar el filtrado la información del espectro de magnitud trata de concentrarse hacia el centro de la imagen, logrando así atenuar el contenido de altas frecuencias y por consiguiente las variaciones abruptas presentes en la información del ángulo del gradiente.

4.2.3.2. Segmentación

La etapa de segmentación de este módulo tiene como objetivo seleccionar las regiones a partir de las cuales se extraerá cierto tipo de información, es así como se permite seleccionar manualmente trayectorias lineales o cerradas (preferiblemente en forma de cuadrado o rectángulo) de cualquier tamaño dentro de la




Figura 4.14: Segmentación de una ROI rectangular: (a) Whitening. (b) PCA.

imagen, dentro de esta región se debe encontrar la información térmica de la cual se espera realizar el procesamiento posterior. Cuando la región seleccionada es un paralelogramo del tipo cuadrado o rectángulo, una función adicional toma los valores de sus vértices y realiza el trazo de cuatro segmentos de línea que unen los vértices y sus puntos medios en cuatro orientaciones posibles (0° , 45° , 90° y 135°) como se puede observar en la figura 4.14. La *ROI* producto del proceso de segmentación será cada una de las trayectorias lineales generadas automáticamente a partir del paralelogramo o la seleccionada.

4.2.3.3. Extracción de características

La extracción de características sobre la *ROI* producto de la etapa de segmentación se realiza teniendo en cuenta información de intensidad e información de magnitud y ángulo del gradiente. La información de intensidad se obtiene a partir de la *ROI* seleccionada sobre el termograma original, la información del gradiente de la imagen se obtiene con ayuda de operadores de tipo *Sobel* aplicados sobre toda la imagen, una vez se encuentran las derivadas parciales en el sentido horizontal y vertical de la imagen, se extrae la información de la magnitud y ángulo del gradiente correspondiente solo a la *ROI* seleccionada. En la figura 4.15 se puede observar: en el ítem (a) la selección de una *ROI* lineal sobre una




Figura 4.15: Extracción de información del gradiente sobre una imagen térmica: (a) Imágen térmica con una *ROI* seleccionada. (b) Perfil de intensidad de la *ROI*. (c) Información de magnitud del gradiente de la *ROI*. (d) Información de ángulo del gradiente de la *ROI*.

termografía, en (b) la información de intensidad, en (c) la magnitud del gradiente y en (d) el ángulo del gradiente de la *ROI* seleccionada.

4.2.3.4. Clasificación

La clasificación de las regiones analizadas se resume en dos posibles estados, la *ROI* analizada presenta o no un patrón típico de calentamiento, para lo cual se analizará el perfil de temperatura correspondiente y además la información que se encuentra en el ángulo del gradiente, el diagrama de flujo 4.16 muestra el proceso respectivo. Se carga la información del perfil y del ángulo, se organiza el perfil de intensidad en manera ascendente y descendente y a continuación se verifica cual

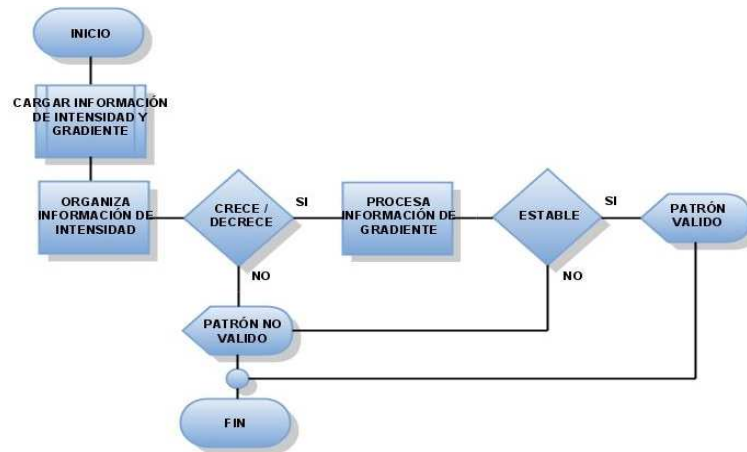


Figura 4.16: Diagrama de flujo Etapa de clasificación del módulo del gradiente.

de los dos comportamientos anteriores se ajusta mejor el perfil analizado. Si el perfil de intensidad cumple cualquiera de las dos condiciones previas, se procede a analizar la información del ángulo, si ésta última presenta un comportamiento estable dentro de un rango predefinido, se puede afirmar que la *ROI* bajo análisis corresponde a un patrón de calentamiento válido y es posible transmitir esta información para la clasificación de severidad de falla al módulo de salida del sistema, en caso contrario se genera un mensaje con la información respectiva.

4.2.4. Módulo de salida

El módulo de salida del sistema se encarga de clasificar las imágenes analizadas de acuerdo a un nivel de severidad que ha sido aproximado de varios estándares internacionalmente reconocidos [ITC06], éstos clasifican el nivel de temperatura de las anomalías detectadas de acuerdo a unos grados de severidad pre-definidos y de acuerdo a esto se presenta la posible acción a seguir como se muestra en la tabla 4.2.

4.3 Conclusiones

Acción	Estándar					
	US NAVY	NETA	NMAC	NUCLEAR	CES	APROXIMACIÓN
Observación	10 - 24 °C	1 - 10 °C	0.5 - 8 °C	5 - 15 °C	14 - 20 °C	6 - 14 °C
Intermedia	25 - 39 °C	11 - 20 °C	9 - 28 °C	16 - 35 °C	21 - 60 °C	15 - 35 °C
Crítica	40 - 69 °C	21 - 40 °C	29 - 56 °C	36 - 75 °C	-	36 - 70 °C
Inmediata	> 70 °C	> 40 °C	> 56 °C	> 75 °C	> 61 °C	> 70 °C

Cuadro 4.2: Criterios para clasificación de anomalías usando varios estándares.

4.3. Conclusiones

La solución software desarrollada permite procesar la información presente en termografías de dos formas, la primera utiliza máquinas de aprendizaje y la segunda un modelo de transferencia de calor.

El ruido presente en las termografías obtenidas con los dos dispositivos de captura disponibles para el proyecto es difícil de identificar visualmente, sin embargo se implementaron bloques de preprocesamiento usando el filtro mediana para poder reducir los componentes de alta frecuencia presentes en éstas imágenes. Para validar el desempeño de los filtros aplicados se trabajó en el dominio frecuencial, en donde se pudo comprobar que usando una máscara de 5 x 5 para el filtro, se obtienen buenos resultados.

La información del gradiente en primera instancia es difícil de interpretar debido a que contiene muchos componentes de alta frecuencia. Por lo que se hace indispensable el uso de una etapa de filtrado para éstos datos. Esta etapa se implementó con un filtro de tipo mediana encontrando que para un tamaño de máscara de 3 x 3 se obtienen los mejores resultados.

De acuerdo al módulo de procesamiento seleccionado, las respectivas etapas de extracción de características entregarán información diferente. Para el módulo basado en máquinas de aprendizaje, la extracción de características se basa en información estadística entregada por algunos momentos invariantes y algunos estadísticos. Para el otro módulo, la extracción de características se basa en la

información de magnitud y ángulo del gradiente de la región de interés seleccionada.

El bloque de normalización de datos y la implementación de distintas máquinas de aprendizaje, dentro del módulo de procesamiento respectivo, se implementaron para aumentar la disponibilidad de información antes del entrenamiento y validación de las máquinas. Esto permitirá encontrar el desempeño general de éste módulo para datos que han sido normalizados con diferentes métodos y clasificados usando distintas máquinas de aprendizaje.

Capítulo 5

Pruebas y resultados

5.1. Introducción

En este capítulo se describen y documentan las pruebas realizadas para el diseño y validación del sistema propuesto incluyendo las pruebas realizadas a cada uno de los módulos implementados.

5.2. Módulo procesamiento basado en máquinas de aprendizaje

5.2.1. Prueba No.1

5.2.1.1. Objetivo

Adquirir imágenes termográficas del motor eléctrico en funcionamiento contenido en el módulo Feedback ES151.

5.2.1.2. Descripción

Se toman imágenes termográficas del motor eléctrico del módulo Feedback ES151 bajo distintas condiciones de operación y simulando dos posibles estados

5.2 Módulo procesamiento basado en máquinas de aprendizaje

de funcionamiento (normal y anómalo). Para generar las distintas condiciones de operación del motor se utiliza la unidad de freno magnético con posición variable incluida en el prototipo ES151, ésta unidad proporciona 10 niveles distintos de carga magnética al motor, simulando diferentes estados de trabajo; con lo cual se obtienen las 10 condiciones distintas de operación bajo un funcionamiento etiquetado como *normal*. Para generar el estado de funcionamiento *anómalo* del motor, se utiliza una unidad con freno magnético adicional ajustada de tal forma que aplique al motor la mitad de su carga magnética a cada uno de las 10 condiciones de operación previamente descritas. Para el proceso de adquisición se utiliza la cámara *ThermoVision A20*, de los videos generados se seleccionan

5.2.1.3. Resultados

Las termografías adquiridas del prototipo Feedback ES151 se almacenaron en archivos de video (*extensión .avi*) con una duración de un (1) segundo para las 10 posibles condiciones de operación y los dos estados de funcionamiento. La frecuencia de muestreo del dispositivo de captura es de 30 Hz. De cada condición de operación o video de un segundo, se extrajeron 6 termogramas equidistantes en 5 frames uno del otro, con lo cual la base de datos definitiva consta de un grupo de 60 termogramas etiquetado como estado *normal* de funcionamiento y otro grupo de igual número etiquetado como estado *anómalo*, para un total de 120 imágenes térmicas.

En la figura 5.1 se puede observar el primer frame de cada una de las 10 posibles condiciones de operación para el estado de funcionamiento *normal* en su paleta de adquisición original. La figura 5.2 muestra lo mismo pero para el estado de funcionamiento *anómalo*. Los dos tipos de paleta utilizados en el proceso de adquisición son: hierro de alta definición y escala de grises positiva (blanco caliente).

5.2 Módulo procesamiento basado en máquinas de aprendizaje




Figura 5.1: Imágenes térmicas del motor eléctrico de la unidad FeedBack ES151 bajo distintos niveles de operación.

5.2 Módulo procesamiento basado en máquinas de aprendizaje




Figura 5.2: Imágenes térmicas del motor eléctrico de la unidad FeedBack ES151 bajo distintos niveles de operación aplicando a cada uno de ellos una carga magnética adicional (disturbio).

5.2 Módulo procesamiento basado en máquinas de aprendizaje

5.2.2. Prueba No.2

5.2.2.1. Objetivo

Encontrar o Identificar el número de neuronas en la capa oculta y cantidad de iteraciones necesarias para lograr que el error cuadrático medio MSE de la red MLP diseñada converja a un valor cercano a cero.

5.2.2.2. Descripción

Tomando como punto de partida los dos grupos de termografías generados en la prueba 5.2.1, se escoge que el 50 % de las imágenes de cada grupo se utilicen para entrenamiento, y el 50 % restante para validación de los sistemas diseñados. Es así como se obtienen nuevamente dos grupos de 60 imágenes termográficas, el primer grupo será para entrenamiento y el segundo para validación. El 50 % del primer grupo (*entrenamiento*) está compuesto por termografías etiquetadas como estado *normal* de funcionamiento y el 50 % restante como estado *anómalo*. El segundo grupo corresponde al conjunto de *validación* organizado de igual manera que el anterior. Cabe anotar que las termografías que componen cada grupo se escogen aleatoriamente, es así como para efectos prácticos se generan 11 conjuntos de datos los cuales contienen imágenes de entrenamiento y validación diferentes organizadas aleatoriamente con el fin de garantizar la capacidad de generalización de las máquinas de aprendizaje diseñadas. Utilizando los 11 conjuntos de datos generados anteriormente se implementan máquinas de aprendizaje tipo MLP con una distribución de neuronas $11-X-2$. El primer número de la serie (11) representa el número de neuronas en la capa de entrada, el último número (2) corresponde a las neuronas presentes en la capa de salida, y la variable X corresponde a las neuronas que se desean utilizar en la capa oculta y que son objeto del desarrollo de esta prueba. Adicionalmente al número de neuronas en la capa oculta, se desea también conocer la cantidad de iteraciones necesarias para que el error MSE de la red MLP diseñada converja a un valor cercano a cero, por lo cual utilizando

5.2 Módulo procesamiento basado en máquinas de aprendizaje

los mismos conjuntos de datos se varía el número de iteraciones de entrenamiento de la red *MLP* y se verifica el comportamiento del *MSE*.

5.2.2.3. Resultados

La figura 5.3 ítem (a) muestra el *MSE acumulado* para 20.000 iteraciones por entrenamiento, cuando el número de neuronas en la capa oculta es menor a 10, el *MSE acumulado* toma valores que oscilan entre 4.7 y 2.7 con tendencia decreciente. Cuando el número de neuronas se encuentra entre 10 y 30 la tendencia general del *MSE acumulado* es también decreciente con algunos picos, en el 80 % de los casos toma valores que oscilan entre 2.0 y 1.2. Cada color que se encuentra dentro de las diferentes barras a lo largo del eje que identifica el número de neuronas de la capa oculta representa cada uno de los once conjuntos de datos disponibles, el ancho de cada color indica el *MSE* de cada conjunto. El ítem (b) muestra el *MSE individual* de cada conjunto de datos utilizado para las pruebas de entrenamiento, se mantiene la tendencia decreciente de la curva al igual que en el *MSE acumulado* y se puede observar adicionalmente que el conjunto de datos que presenta un valor de *MSE* más bajo es el que se ha etiquetado como *D11* cuyos valores oscilan entre 0.35 y 0.05. En general se puede apreciar que el *MSE individual* toma valores entre 0.6 y 0.02. Cuando el número de neuronas se encuentra entre 10 y 30 en el 76 % de los casos el valor máximo del *MSE* tiene valores menores a 0.35. De los resultados anteriormente descritos se puede deducir que a partir de 10 neuronas en la capa oculta tanto los valores del *MSE acumulado* como *individual*, presentan un comportamiento decreciente con algunos picos aislados. La figura 5.4 ítem (a) y (b) corresponde al caso de 40.000 iteraciones por entrenamiento. Se observa en general nuevamente la tendencia decreciente tanto del *MSE acumulado* como del *MSE individual*. Particularmente el *MSE acumulado* para un número de 10 neuronas en la capa oculta toma un valor de 0.7 que corresponde a una reducción de aproximadamente 70 % con respecto al primer caso (20.000 iteraciones). El *MSE individual* en el mismo punto toma un valor de 0.02 con lo que se obtiene también una reducción de aproximadamente

5.2 Módulo procesamiento basado en máquinas de aprendizaje

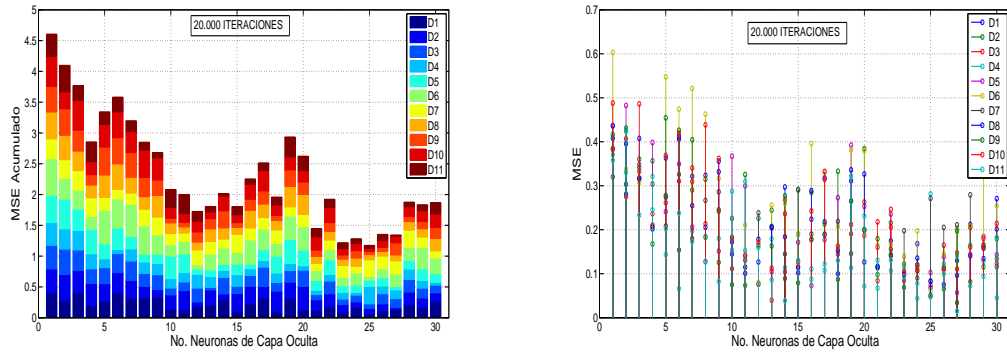


Figura 5.3: Número de neuronas en la capa oculta vs MSE para 20.000 iteraciones de entrenamiento: (a) MSE acumulado. (b) MSE.

88 %. Se encuentra nuevamente que el conjunto de datos *D11* obtiene los valores de *MSE individual* más bajos. En general se encuentra que con un entrenamiento de 40.000 iteraciones el MSE acumulado y el MSE individual mejoran notablemente con respecto al de 20.000 iteraciones. Además se puede identificar que con un número de 10 neuronas en la capa oculta el desempeño de los dos indicadores utilizados presenta un comportamiento con tendencia a cero aceptable.

5.2.3. Prueba No.3

5.2.3.1. Objetivo

Encontrar Verificar el desempeño de cada uno de los clasificadores implementados.

5.2.3.2. Descripción

Utilizando la misma distribución y conjuntos de datos descritos en la prueba anterior 5.2.1, se entrenan y validan cada uno de los clasificadores implementados (*Bayesiano*, *MLP* y *RBF*). Para el caso del *MLP* se utiliza una configuración 11-

5.2 Módulo procesamiento basado en máquinas de aprendizaje

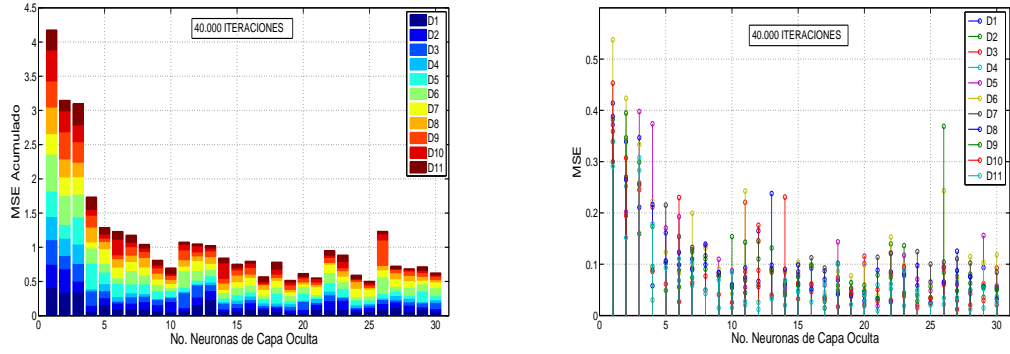


Figura 5.4: Número de neuronas en la capa oculta vs MSE para 40.000 iteraciones de entrenamiento: (a) MSE acumulado. (b) MSE.

10-2 que corresponde a 11 neuronas en la capa de entrada, 10 en la capa oculta y 2 en la salida. Para el clasificador bayesiano se utiliza probabilidad apriori igual para las dos etiquetas de clase disponibles en las termografías (*normales* y *anómalas*). Los resultados de la clasificación se organizan en matrices de confusión 5.1 de donde se obtienen los siguientes indicadores:

- *Verdaderos positivos (VP)*: Muestras de la clase B (*anómala*) que son correctamente clasificados como clase B.
- *Verdaderos negativos (VN)*: Muestras de la clase A (*normal*) que son correctamente clasificados como clase A.
- *Falsos negativos (FN)*: Muestras de la clase B (*anómala*) que son incorrectamente clasificados como clase A.
- *Falsos positivos (FP)*: Muestras de la clase A (*normal*) que son incorrectamente clasificados como clase B.
- *Sensibilidad (S)*: La sensibilidad o tasa de verdaderos positivos (*TVP*) es la capacidad de detectar, para este caso, muestras etiquetadas como *anómalas*,

5.2 Módulo procesamiento basado en máquinas de aprendizaje

		Clase		
		A B		
Clase	A	VN	FP	S
	B	FN	VP	E
		PA	TA	

Cuadro 5.1: Matriz de confusión.

matemáticamente se expresa según la ecuación 5.1.

$$S = \frac{VP}{VP + FN} \quad (5.1)$$

- *Especificidad (E)*: La especificidad o tasa de verdaderos negativos (*TVN*) es la capacidad de detectar muestras etiquetadas como *normales* y se expresa según la ecuación 5.2.

$$E = \frac{VN}{VN + FP} \quad (5.2)$$

- *Total de aciertos (TA)*: Suma de VP y VN.
- *Porcentaje de aciertos (PA)*: Porcentaje de TA en relación al número total de muestras clasificadas y se encuentra como se muestra en la ecuación 5.3.

$$PA = \frac{TA}{VP + VN + FN + FP} \times 100 \quad (5.3)$$

5.2.3.3. Resultados

En la figura 5.5 items (a), (b) y (c) se observa el desempeño de los clasificadores *Bayesiano*, *MLP* y *RBF* respectivamente, el item (d) representa una comparación de desempeño conjunta de los clasificadores anteriores. En todos los casos de validación se utilizan 11 conjuntos de datos. En (a) se observa que el índice de aciertos del clasificador *Bayesiano* tiene un valor mínimo de 73.3% y un valor máximo de 95.0% con una media (\overline{PA}) de 84.24%, desviación estándar *DE* de

5.2 Módulo procesamiento basado en máquinas de aprendizaje

6.6, sensibilidad promedio (\bar{S}) de 99.7 % y especificidad promedio (\bar{E}) de 68,8 % (ver Tabla 5.2). Es importante notar que aunque el PA del clasificador no es tan alto, su nivel de *sensibilidad promedio* es casi que perfecto, lo cual representa que el clasificador será capaz de detectar casi que en todos los casos una termografía etiquetada como *anómala*.

En el ítem (b) el índice de aciertos del clasificador *MLP* tiene un valor mínimo de 75.0 % y un valor máximo de 98.3 % con una media de 91.5 %, desviación estándar de 8.1, sensibilidad promedio (\bar{S}) de 93.6 % y especificidad promedio (\bar{E}) de 89.4 % como se puede apreciar en la tabla 5.3. El (\overline{PA}) del *MLP* presenta un desempeño superior de aproximadamente 5 % con respecto al clasificador anterior y aunque su (\bar{S}) decrece en 6 unidades, su (\bar{E}) aumenta en 21 unidades aproximadamente, lo cual hace que el desempeño del clasificador obtenga buenos resultados identificando tanto imágenes térmicas *anómalas* como *normales*.

En el ítem (c) el índice de aciertos del clasificador *RBF* tiene un valor mínimo de 86.66 % y un valor máximo de 100.0 % con una media de 94.5 %, desviación estándar de 4.2, (\bar{S}) de 93.9 % y (\bar{E}) de 95.2 % según se muestra en la tabla 5.4. Esto en términos generales significa una mejoría en el (\overline{PA}) de 10 % con respecto al clasificador *Bayesiano* y de 5 % con respecto al *MLP*, los niveles de (\bar{S}) y (\bar{E}) en conjunto son mejores que en los anteriores clasificadores lo que representa una mejor capacidad general de clasificación. Un valor ligeramente superior de (\bar{E}) con respecto a (\bar{S}) supone que se detectan mejor imágenes termográficas etiquetadas como *normales*.

Con base al ítem (d) y a los resultados consignados en la tabla 5.5 se puede apreciar que el clasificador *Bayesiano* aunque tiene un (\overline{PA}) de 84.2 % que es el más bajo en comparación a los otros dos clasificadores implementados en el 73 % de los casos, no se debe relacionar bajo con mal desempeño, ya que además presenta el índice de (\bar{S}) más alto. El clasificador *RBF* tiene el mejor desempeño en el 73 % de los casos con un (\overline{PA}) de 94.5 % y presenta en conjunto los mejores índices de (\bar{S}) y (\bar{E}), lo que corrobora el buen desempeño obtenido.

5.2 Módulo procesamiento basado en máquinas de aprendizaje

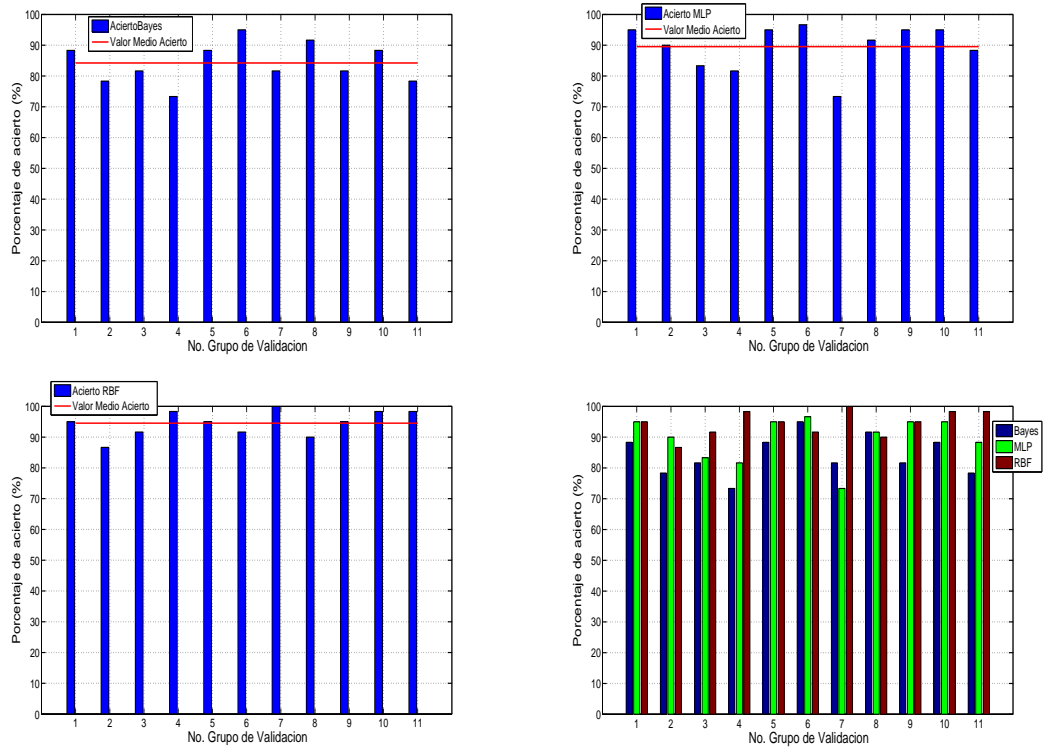


Figura 5.5: Desempeño de los clasificadores. (a) Bayesiano. (b) MLP. (c) RBF. (d) Comparación conjunta de desempeño de los clasificadores.

Clasificador	Conjunto de Datos										
Bayesiano	1	2	3	4	5	6	7	8	9	10	11
PA	88,3	78,3	81,6	73,3	88,3	95,0	81,6	91,6	81,6	88,3	78,3
S	100,0	100,0	100,0	96,7	100,0	100,0	100,0	100,0	100,0	100,0	100,0
E	76,7	56,7	63,3	50,0	76,7	90,0	63,3	83,3	63,3	76,7	56,7
\overline{PA}	84,2	DE	6,6	\overline{S}	99,7	DE	1,0	\overline{E}	68,8	DE	12,6

Cuadro 5.2: Índices de desempeño para el clasificador *Bayesiano*.

5.2 Módulo procesamiento basado en máquinas de aprendizaje

Clasificador	Conjunto de Datos										
MLP	1	2	3	4	5	6	7	8	9	10	11
PA	95,0	81,6	98,3	75,0	98,3	96,7	85,0	98,3	96,6	95,0	86,6
S	93,3	86,7	96,7	93,3	96,7	93,3	93,3	100,0	96,7	90,0	90,0
E	96,7	76,7	100,0	56,7	100,0	100,0	76,7	96,7	96,7	100,0	83,3
\overline{PA}	91,5	DE	8,1	\overline{S}	93,6	DE	3,8	\overline{E}	89,4	DE	14,3

Cuadro 5.3: Índices de desempeño para el clasificador *MLP*.

Clasificador	Conjunto de Datos										
RBF	1	2	3	4	5	6	7	8	9	10	11
PA	95,0	86,6	91,6	98,3	95,0	91,6	100,0	98,3	95,0	98,3	98,3
S	90,0	76,7	100,0	96,7	90,0	100,0	100,0	96,7	90,0	96,7	96,7
E	100,0	96,7	83,3	100,0	100,0	83,3	100,0	83,3	100,0	100,0	100,0
\overline{PA}	94,5	DE	4,2	\overline{S}	93,9	DE	7,0	\overline{E}	95,2	DE	7,7

Cuadro 5.4: Índices de desempeño para el clasificador *RBF*.

Clasificador	Índice de Desempeño					
	\overline{PA}	DE	\overline{S}	DE	\overline{E}	DE
Bayesiano	84,2	6,6	99,7	1,0	68,8	12,6
MLP	91,5	8,1	93,6	3,8	89,4	14,3
RBF	94,5	4,2	93,9	7,0	95,2	7,7

Cuadro 5.5: Comparación de Índices de desempeño para clasificadores *Bayesiano*, *MLP* y *RBF*.

5.2.4. Prueba No.4

5.2.4.1. Objetivo

Comprobar la aleatoriedad de los datos de validación utilizados con el fin de poder garantizar la capacidad de generalización de los clasificadores implementados.

5.2.4.2. Descripción

Con los clasificadores implementados en la prueba anterior 5.2.2, se comprueba su capacidad de generalización usando datos de validación tomados aleatoriamente de los conjuntos previamente establecidos 5.2.1. Las termografías han sido identificadas con índices numéricos organizados ascendentemente, un índice numérico bajo corresponde al nivel en el que la carga magnética aplicada al motor se encuentra en el nivel más bajo; un índice numérico mayor corresponderá a un nivel de carga magnética más alto y por tanto el nivel de trabajo del motor será más exigente. Esta situación se traduce visualmente en la obtención de imágenes termográficas con diferentes niveles de intensidad organizados crecientemente de acuerdo a los índices asignados, por tanto existe una correspondencia directa entre el valor del índice de la imagen térmica y el respectivo nivel de carga magnética o trabajo del objeto inspeccionado.

5.2.4.3. Resultados

La figura 5.6 corresponde a los resultados obtenidos para un clasificador *RBF* ante un conjunto de datos específicos (*D4*). El ítem (*a*) muestra gráficamente en azul los elementos que han sido correctamente clasificados (*VN*) en la primera clase (*A* = condición normal) y en color rojo los que no (*FP*); encontrando que su índice de (*E*) es de 100.0 % lo que significa que para ésta clase no existen elementos que se hayan clasificado erróneamente. En el ítem (*b*) se observa el resultado de la clasificación para la segunda clase (*B* = condición anómala), en

5.2 Módulo procesamiento basado en máquinas de aprendizaje

rojo se presentan los elementos que han sido correctamente clasificados (*VP*) y en azul los clasificados erróneamente (*FN*) obteniendo un índice de (*S*) de 96.7 % lo que corresponde a un elemento mal clasificado. El ítem (c) muestra el resultado general de la clasificación, etiquetando las dos posibles clases con los valores de 0 y 1 donde (1 es clase A) y (0 es clase B). Los resultados se representan sobre dos ejes constantes centrados en los valores de las etiquetas, para la *etiqueta 1* el color azul identifica los elementos que han sido correctamente clasificados (*VN*) y los que se encuentren en rojo los que no (*FP*). Para la *etiqueta 0* el código de colores utilizado es contrario al anterior, el rojo corresponde a (*VP*) y azul a (*FN*) respectivamente. El porcentaje de acierto (*PA*) del presente caso es de 98.3 %, con un índice de *especificidad* de 100 % y *sensibilidad* de 96.7 %. Se observa además como los valores de los índices de los elementos de validación (*Eje vertical en ítems a y b, Eje horizontal en ítem c*) se distribuyen uniformemente sobre todos los posibles valores que, como anteriormente se mencionó, representan los diferentes niveles de carga magnética aplicada al motor objeto de inspección.

En las figuras Aleatoria2 y Aleatoria3 se presentan resultados similares al descrito anteriormente para conjuntos de datos distintos. Se aprecia como en el primer caso el porcentaje general de aciertos disminuye y se observa que se presentan muchos más errores de clasificación tanto en la clase A como en la clase B,

5.2.5. Prueba No.5

5.2.5.1. Objetivo

Verificar el desempeño de los clasificadores aplicando a los conjuntos de datos disponibles (*entrenamiento y validación*) diferentes métodos de normalización.

5.2.5.2. Descripción

Los conjuntos de datos disponibles en 5.2.1 son procesados tomando como base los métodos de normalización vistos en 4.2.2.4, a partir de este proced-

5.2 Módulo procesamiento basado en máquinas de aprendizaje

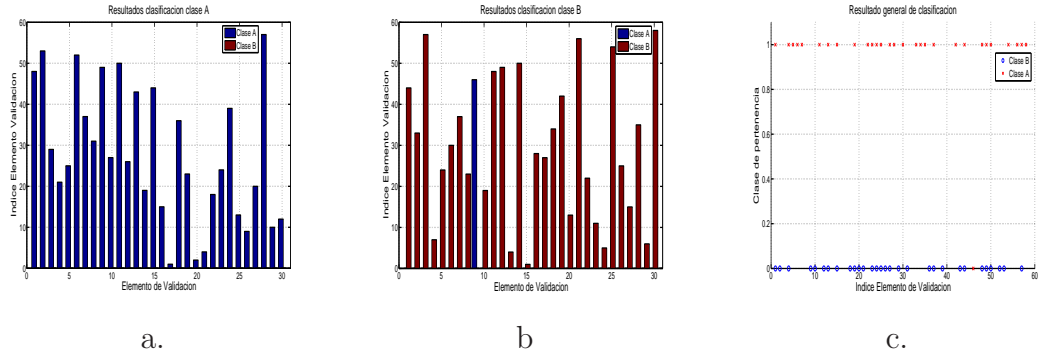


Figura 5.6: Representación gráfica de la capacidad de generalización de los clasificadores implementados. (a) Estado normal: Sensibilidad (azul), especificidad (rojo). (b) Estado anómalo: Sensibilidad (rojo), especificidad (azul). (c) Índice del elemento de validación Vs Clase de pertenencia.

imiento se dispone de conjuntos de datos adicionales con los cuales se pueden realizar nuevamente las rutinas de entrenamiento y validación de las máquinas de aprendizaje tomando como indicadores de desempeño los mismos índices utilizados en 5.2.3. Los métodos de normalización utilizados se identifican así: *SN* (1): *sin normalización*, *MM* (2): *Min-Max*, *MD* (3): *Mean-Std*, *PCA* (4): *Análisis de componentes principales*, *LOG* (5): *Logaritmo natural* y *W* (6): *Whitening*.

5.2.5.3. Resultados

Las figuras 5.7, 5.8 y 5.9 corresponden a los resultados obtenidos para los clasificadores *Bayesiano*, *MLP* y *RBF* respectivamente. Cada una está compuesta por dos items (a) y (b), el primero muestra gráficamente el porcentaje general de acierto del clasificador implementado en relación al método de normalización utilizado para cada uno de los once conjuntos de datos usados. El segundo item muestra el porcentaje general de acierto en relación al grupo de validación para cada uno de los métodos de normalización.

5.2 Módulo procesamiento basado en máquinas de aprendizaje

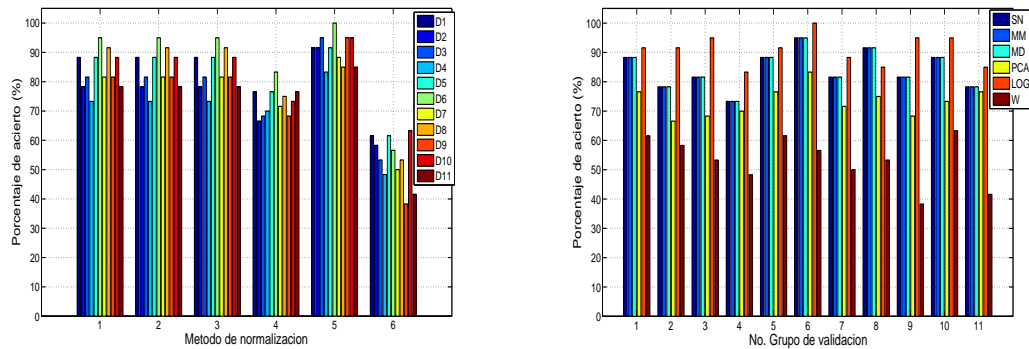


Figura 5.7: Desempeño del clasificador *Bayesiano* ante distintos métodos de normalización: (a) Método de normalización Vs Porcentaje de acierto. (b) Número del grupo de validación Vs Porcentaje de acierto.

Clasificador		Índice de Desempeño					
Bayesiano		\overline{PA}	DE	\overline{S}	DE	\overline{E}	DE
Normalización	SN	84,2	6,6	99,7	1,0	68,8	12,6
	MM	84,2	6,6	99,7	1,0	68,8	12,6
	MD	84,2	6,6	99,7	1,0	68,8	12,6
	PCA	73,3	4,9	100,0	0,0	46,7	9,9
	LOG	91,0	5,2	94,2	3,7	87,9	7,9
	W	53,3	8,2	31,8	31,5	74,8	26,8

Cuadro 5.6: Índices de desempeño para clasificador *MLP* ante distintos métodos de normalización.

5.2 Módulo procesamiento basado en máquinas de aprendizaje

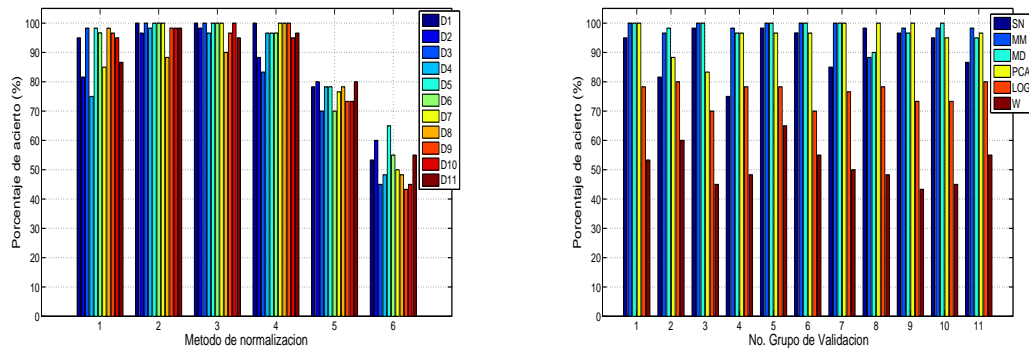


Figura 5.8: Desempeño del clasificador *Bayesiano* ante distintos métodos de normalización: (a) Método de normalización Vs Porcentaje de acierto. (b) Número del grupo de validación Vs Porcentaje de acierto.

Clasificador		Índice de Desempeño					
MLP		\overline{PA}	DE	\overline{S}	DE	\overline{E}	DE
Normalización	SN	91,5	8,1	93,6	3,8	89,4	14,3
	MM	98,0	3,4	98,8	1,7	97,3	6,1
	MD	97,9	3,2	98,5	2,3	97,3	5,1
	PCA	95,7	5,3	94,2	6,5	97,3	5,1
	LOG	76,0	3,7	76,6	16,6	76,4	16,2
	W	51,7	6,8	39,7	24,2	63,6	19,9

Cuadro 5.7: Índices de desempeño para clasificador *MLP* ante distintos métodos de normalización.

5.2 Módulo procesamiento basado en máquinas de aprendizaje

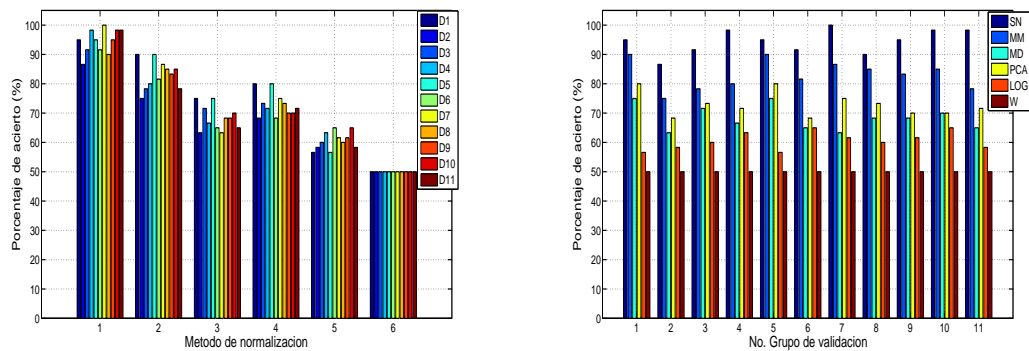


Figura 5.9: Desempeño del clasificador *RBF* ante distintos métodos de normalización: (a) Método de normalización Vs Porcentaje de acierto. (b) Número del grupo de validación Vs Porcentaje de acierto

Clasificador		Índice de Desempeño					
RBF		\overline{PA}	DE	\overline{S}	DE	\overline{E}	DE
Normalización	SN	94,5	4,2	93,9	7,0	95,2	7,7
	MM	83,0	4,9	87,9	20,9	78,2	15,5
	MD	68,3	4,2	63,3	35,4	73,3	31,1
	PCA	72,9	4,1	66,4	27,6	79,4	28,8
	LOG	60,6	3,0	55,8	42,5	65,5	39,9
	W	50,0	0,0	100,0	0,0	0,0	0,0

Cuadro 5.8: Índices de desempeño para clasificador *RBF* ante distintos métodos de normalización.

5.2 Módulo procesamiento basado en máquinas de aprendizaje

Clasificador	Normalización	Indice de Desempeño					
		\overline{PA}	DE	\overline{S}	DE	\overline{E}	DE
Bayesiano	SN	84,2	6,6	99,7	1,0	68,8	12,6
	LOG	91,0	5,2	94,2	3,7	87,9	7,9
MLP	SN	91,5	8,1	93,6	3,8	89,4	14,3
	MM	98,0	3,4	98,8	1,7	97,3	6,1
RBF	SN	94,5	4,2	93,9	7,0	95,2	7,7
	MM	83,0	4,9	87,9	20,9	78,2	15,5

Cuadro 5.9: Comparación Indices de desempeño para clasificadores *Bayesiano*, *MLP* y *RBF* de los datos *SN* frente al mejor método de normalización alcanzado.

De acuerdo a la información consignada en la figura 5.7 y tabla 5.6 el desempeño del clasificador estadístico es constante para los primeros tres métodos de normalización con un porcentaje promedio de acierto (\overline{PA}) de 84.2%, índice de (\overline{S}) de 99.7% e índice de (\overline{E}) de 68.8%. En el 90.1 % de las pruebas realizadas el método de normalización que mejor desempeño obtiene es *LOG* con un (\overline{PA}) de 91.0% lo que representa un incremento de 8.4% con respecto al porcentaje promedio de los datos sin normalizar, su índice de (\overline{S}) decrece a un valor de 94.2% pero el de (\overline{E}) aumenta a 87.9%. Esto en términos generales implica que el clasificador aunque disminuye cierto grado su capacidad de detectar termografías etiquetadas como *anómalas*, aumenta notablemente su capacidad de detectar termografías *normales* logrando que en conjunto los dos índices anteriormente mencionados alcancen un buen nivel. El desempeño más bajo, entendiendo bajo como malo, en todos los casos se obtiene con la normalización *W* que tiene un (\overline{PA}) de 53.3% para lo cual no vale la pena ni siquiera observar los índices de (\overline{S}) y (\overline{E}), que a parte de todo presentan valores de (*DE*) altos que oscilan entre 25 y 31. El decaimiento en el desempeño de éste método de normalización representa una disminución de 36.7% con respecto al (\overline{PA}) de los datos sin normalizar.

En la figura 5.8 y tabla 5.7 se observa como el clasificador *MLP* alcanza el desempeño más alto cuando los datos se normalizan utilizando *MM* y *MD*

5.2 Módulo procesamiento basado en máquinas de aprendizaje

obteniendo un (\overline{PA}) de 98.0 % y 97.9 % respectivamente e índices de (\overline{S}) de 98.8 % y (\overline{E}) de 97.3 % , para *MM* el resultado anterior corresponde a un incremento de 6.66 % con respecto al (\overline{PA}) de los datos *SN*. Igual que para el clasificador estadístico el método de normalización *W* presenta los niveles de desempeño más bajos alcanzando un porcentaje promedio de aciertos de 51.65 % lo que indica una disminución de 43.54 % con respecto al porcentaje de aciertos promedio de los datos *SN*. Se resalta el comportamiento general de los índices de desempeño para los métodos de normalización *MM* y *MD*, los cuales están muy cerca de alcanzar resultados ideales.

En la figura 5.9 y tabla 5.8 muestra que el mejor desempeño del clasificador *RBF* se obtiene solamente cuando los datos están sin normalizar *SN*, al utilizar los diferentes métodos de normalización el desempeño del clasificador sufre un decrecimiento en todos los casos y en general para todos los indicadores de desempeño; el decrecimiento es incluso menor al obtenido con los otros clasificadores. El nivel de desempeño más bajo se encuentra en la normalización *W* en donde el porcentaje promedio de aciertos es de 50.0 %, lo cual es muestra del pobre desempeño alcanzado.

En la tabla 5.9 se consignan los índices de desempeño obtenidos en los clasificadores implementados para datos sin normalizar (*SN*) y el mejor método de normalización en cada situación. Se observa que el clasificador *MLP* al utilizar datos procesados con el método *MM* mejora su propio rendimiento y el de los otros dos clasificadores alcanzando un índice de (\overline{PA}) de 98.0 % y niveles de *sensibilidad* y *especificidad* de 98.8 % y 97.3 % respectivamente. El clasificador *Bayesiano* con el método *LOG* mejora notablemente su propio desempeño obteniendo un índice de (\overline{PA}) de 91.0 %, (\overline{S}) de 94.2 % y (\overline{E}) de 87.9 %, pero se mantiene por debajo del obtenido con los otros clasificadores. Por último el clasificador *RBF* obtiene su mejor desempeño cuando los datos se encuentran sin normalizar *SN*, ya que el mejor método de normalización en este caso es el *MM* pero sus índices de desempeño se mantienen muy por debajo de los datos sin normalizar, además

5.3 Módulo de procesamiento basado en información del gradiente

las desviaciones estándar de (\overline{S}) y de (\overline{E}) tienen valores de 20.9 y 15.5 que representan una variabilidad muy alta.

5.3. Módulo de procesamiento basado en información del gradiente

5.3.1. Prueba No.1

5.3.1.1. Objetivo

Adquirir imágenes termográficas de los diferentes equipos eléctricos en funcionamiento descritos en la sección 3.3 .

5.3.1.2. Descripción

Se adquieren termografías de los equipos descritos en la sección 3.3, los cuales estuvieron sometidos a dos estados de operación. El primer estado se obtiene cuando los conectores que llegan a los equipos se encuentran ajustados correctamente y el segundo estado se obtuvo provocando un desajuste sobre éstos contactos lo cual evidenciará patrones de calentamiento válidos en la imagen térmica correspondiente.

5.3.1.3. Resultados

Las termografías adquiridas de los diferentes equipos inspeccionados se almacenaron en archivos con formato *.jpg radiométrico. Se obtuvieron así imágenes térmicas bajo dos estados de operación, el primer estado se identificó como el *normal* y el segundo como el *anómalo*. En la figura 5.10, se pueden observar cuatro termografías de diferentes equipos bajo condiciones normales de funcionamiento y en la figura 5.11 se observan cuatro termografías de diferentes equipos bajo condiciones de operación anormales. Haciendo una comparación visual entre los dos conjuntos de imágenes anteriormente descritos, se puede apreciar que no es

5.3 Módulo de procesamiento basado en información del gradiente




Figura 5.10: Imágenes equipos eléctricos sin fallas de contacto en los cables de alimentación.

fácil encontrar diferencias significativas en la información de intensidad de las termografías.

5.3.2. Prueba No.2

5.3.2.1. Objetivo

Identificar los patrones de comportamiento en la información de magnitud y ángulo del gradiente para imágenes sintéticas con distintos modelos de distribución de intensidad.

5.3.2.2. Descripción

Para esta prueba se generan imágenes sintéticas utilizando diferentes modelos (*lineal*, *exponencial*, *logartimico*, *constante* y *radial*) para la distribución de sus niveles de intensidad, con lo que se pretende simular distintos patrones de calentamiento. A partir de cada imagen generada se encuentra para una región predefinida (*region de interés ROI*) su perfil de intensidad y la información de

5.3 Módulo de procesamiento basado en información del gradiente




Figura 5.11: Imágenes equipos eléctricos con fallas de contacto en los cables de alimentación.

magnitud y ángulo del gradiente. Las figuras producto de esta prueba contienen seis items, cada uno de los cuales representa: (a) Imagen sintética en escala de grises con el modelo de distribución de intensidad utilizado y ROI seleccionada, (b) El perfil de intensidad. (c) magnitud del gradiente, (d) ángulo del gradiente con superposición de su valor medio y desviación estándar, (e) perfil de intensidad original y organizado en forma ascendente y descendente, (f) error entre el perfil de intensidad original y el perfil ordenado ascendente y descendientemente respectivamente.

5.3.2.3. Resultados

La figura 5.12 corresponde a una imagen sintética con distribución lineal de sus niveles de intensidad, se observa en (a) que la ROI seleccionada toma el ancho de la imagen sintética de izquierda a derecha en la misma dirección del calentamiento y por consiguiente al incremento de los niveles de intensidad, en (b) el perfil de intensidad de la ROI seleccionada tiene una forma creciente, la magnitud del gradiente toma un valor constante de ocho (8) para toda la ROI como se puede

5.3 Módulo de procesamiento basado en información del gradiente

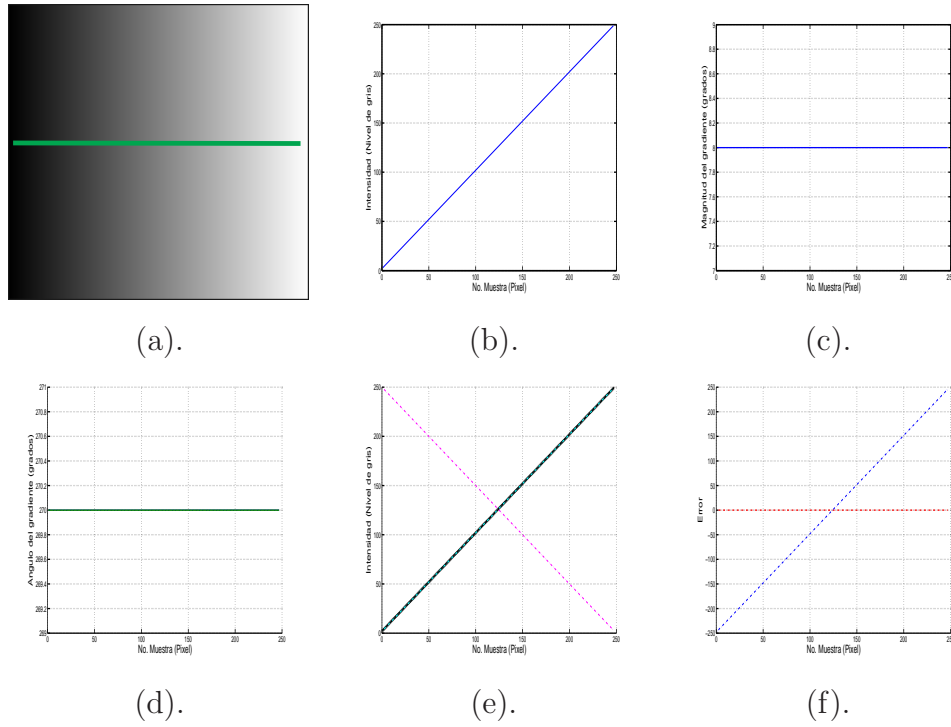


Figura 5.12: Imagen sintética con distribución lineal de niveles de gris. (a) Distribución de intensidad lineal. (b) Perfil de intensidad. (c) Magnitud del gradiente. (d) Ángulo del gradiente. (e) Perfil de intensidad ordenado ascendente y descendientemente. (f) Error entre el perfil de intensidad original y el ordenado ascendente y descendientemente.

apreciar en (c); en (d) la información del ángulo del gradiente también está representada por una línea constante con un valor de 270 con idéntico valor medio y desviación estándar nula. En (e) se observa el perfil de intensidad organizado en forma ascendente y descendente. Y por último en (f) se puede apreciar que el perfil de intensidad original coincide exactamente con el perfil de intensidad organizado ascendentemente por lo cual el error generado es cero sobre toda la ROI.

En la figura 5.13 se puede apreciar una imagen sintética con distribución de

5.3 Módulo de procesamiento basado en información del gradiente




Figura 5.13: Imagen sintética con distribución constante de niveles de gris. (a) Distribución de intensidad constante. (b) Perfil de intensidad. (c) Magnitud del gradiente. (d) Angulo del gradiente. (e) Perfil de intensidad ordenado ascendente y descendientemente. (f) Error entre el perfil de intensidad original y el ordenado ascendente y descendientemente.

niveles de gris constantes, sin variación sobre toda la *ROI* seleccionada de izquierda a derecha sobre todo el ancho de la imagen como se muestra en (a). Se observa en (b) que el perfil de intensidad de la *ROI* es constante sobre un nivel de cero. En (c) y (d) se encuentra que la información de magnitud y ángulo del gradiente toman un valor nulo. Como el perfil de intensidad original es constante, los resultados que se obtienen de la organización del perfil y el error correspondiente también son nulos como se puede observar en (e) y (f).

En la figura 5.14 representa una imagen sintética con distribución exponencial

5.3 Módulo de procesamiento basado en información del gradiente

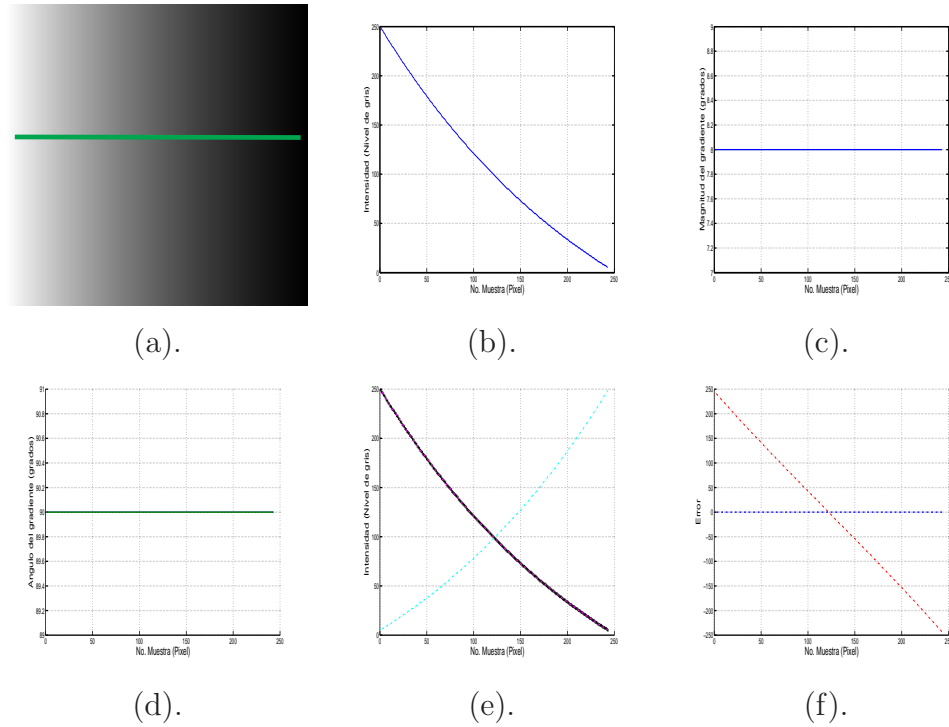


Figura 5.14: Imagen sintética con distribución exponencial de niveles de gris. (a) Distribución de intensidad exponencial. (b) Perfil de intensidad. (c) Magnitud del gradiente. (d) Angulo del gradiente. (e) Perfil de intensidad ordenado ascendente y descendientemente. (f) Error entre el perfil de intensidad original y el ordenado ascendente y descendientemente.

de sus niveles de gris, la *ROI* seleccionada va de derecha a izquierda sobre la imagen al igual que la dirección del flujo de calor como se muestra en (a). Se observa en (b) que el perfil de intensidad de la *ROI* es de forma exponencial y decreciente. En (c) la magnitud del gradiente toma un valor constante de ochenta, en (d) se encuentra que la información de ángulo del gradiente toman un valor de noventa (90). A partir de (e) y (f) se puede apreciar como el perfil que coincide con el original y por tanto genera una curva de error nulo es el que está organizado descendientemente.

5.3 Módulo de procesamiento basado en información del gradiente

La figura 5.15 corresponde a una imagen sintética con distribución de forma logarítmica de niveles de gris, la *ROI* seleccionada va en sentido de derecha a izquierda de la imagen en la misma dirección del calentamiento como se muestra en (a). En (b) se observa que el perfil de intensidad de la *ROI* es tiene una forma logarítmica y decreciente. En (c) la información de magnitud no sigue un comportamiento uniforme, presenta varias oscilaciones entre los valores de cuatro, ocho y doce. En (d) se encuentra que la información de ángulo del gradiente presenta un valor constante de noventa (90°), lo que representa el ángulo formado entre el eje vertical y la dirección del calentamiento. Con la información presente en (e) y (f) se verifica que el perfil que mejor se ajusta al original es el que se ordena de forma descendente por lo que su error es cero.

En la figura 5.16 se observa una imagen sintética con distribución radial de niveles de gris como se muestra en (a). En (b) se muestra que el perfil de intensidad de la *ROI* se ha seleccionado desde el centro de la imagen hasta su esquina superior derecha y tiene una forma linealmente creciente. En (c) se encuentra que la la magnitud del gradiente toma valores oscilatorios entre 10 y 14, sin presentar un comportamiento predecible. En (d) la información de ángulo del gradiente toma un valor de 135° grados, lo que corresponde al ángulo formado entre el eje vertical de la imagen y la dirección de calentamiento. Se observa nuevamente en (e) y (f) que el perfil ordenado que mayor similitud presente con el de la *ROI* original es por consiguiente el que tendrá un perfil de error menor idealmente nulo.

En la tabla 5.10 se resumen los resultados del análisis realizado a las imágenes sintéticas descritas anteriormente utilizando la siguiente nomenclatura: (ANG_{ROI}) ángulo entre la *ROI* seleccionada y el eje vertical de la imagen. (\overline{MAG}) es el valor medio de la magnitud del gradiente, (\overline{ANG}) es el valor medio del ángulo del gradiente, (\overline{EA}) valor medio del perfil de error ascendente, (\overline{ED}) valor medio del perfil de error descendente y (DE) es la desviación estándar respectiva a cada medida. Se puede observar que a excepción del modelo de distribución constante, el ángulo formado entre la *ROI* y el eje vertical de la imagen (ANG_{ROI}) coincide exactamente con el ángulo del gradiente que corresponde a la dirección del

5.3 Módulo de procesamiento basado en información del gradiente

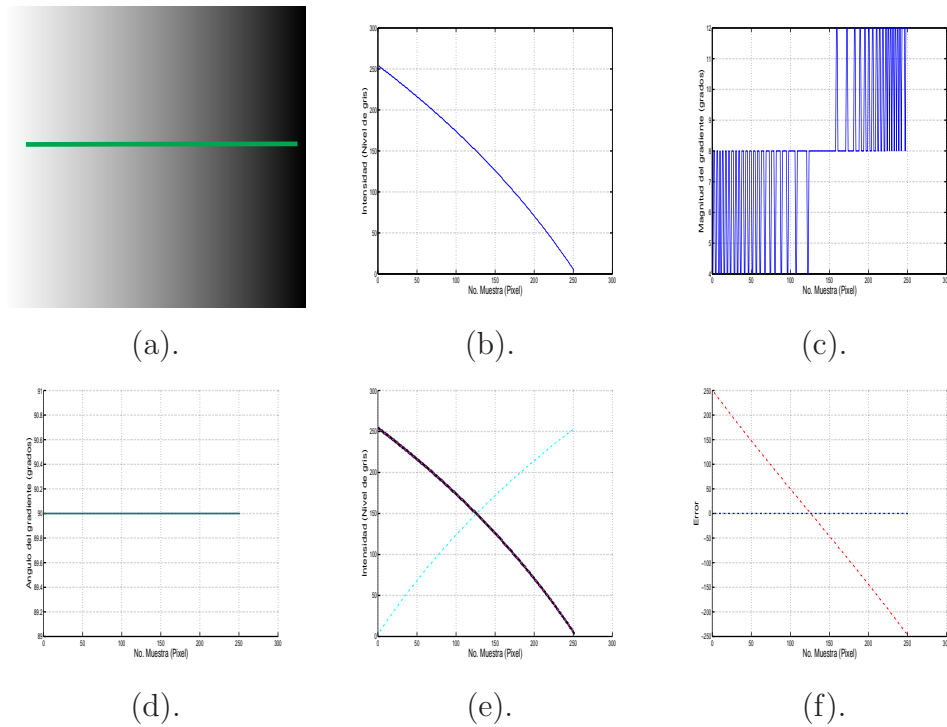


Figura 5.15: Imagen sintética con distribución logarítmica de niveles de gris. (a) Distribución de intensidad logarítmica. (b) Perfil de intensidad. (c) Magnitud del gradiente. (d) Angulo del gradiente. (e) Perfil de intensidad ordenado ascendente y descendente. (f) Error entre el perfil de intensidad original y el ordenado ascendente y descendente.

5.3 Módulo de procesamiento basado en información del gradiente

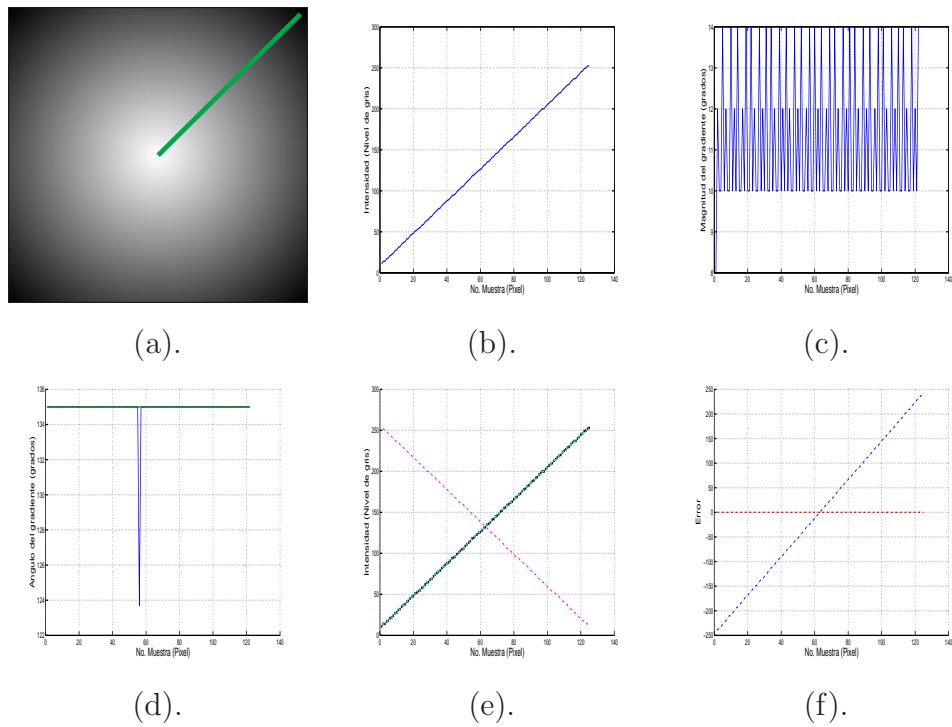


Figura 5.16: Imagen sintética con distribución radial lineal de niveles de gris. (a) Distribución de intensidad radial. (b) Perfil de intensidad. (c) Magnitud del gradiente. (d) Angulo del gradiente. (e) Perfil de intensidad ordenado ascendente y descendientemente. (f) Error entre el perfil de intensidad original y el ordenado ascendente y descendientemente.

5.3 Módulo de procesamiento basado en información del gradiente

Modelo	ANG ROI	\overline{MAG}	DE	\overline{ANG}	DE	\overline{EA}	DE	\overline{ED}	DE
Lineal	270,0	8,0	0,0	270,0	0,0	0,0	0,0	126,0	72,3
Constante	270,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
Exponencial	90,0	8,0	2,8	90,0	0,0	123,6	11,6	0,0	0,0
Logaritmo	90,0	7,9	2,4	89,3	0,2	123,5	72,6	0,0	0,0
Radial	135,0	11,2	2,0	135,4	20,5	85,5	49,5	0,0	0,0

Cuadro 5.10: Datos extraídos de la información del gradiente aplicada a *ROI*'s de imágenes sintéticas.

patrón de calentamiento. La información de magnitud aunque numéricamente parece estable sobre ciertos valores con desviaciones estándar bajas, visualmente presenta un comportamiento muy variable al contrario de lo que se observa con la información de ángulo. Cuando los niveles de gris de la imagen sintética tienen un valor constante, los valores de magnitud y ángulo del gradiente son nulos lo que se puede interpretar como no existencia de información del gradiente. Cuando el valor medio del error de un perfil (ascendente o descendente) es cero significa que el perfil de intensidad correspondiente coincide exactamente con el perfil de intensidad original.

5.3.3. Prueba No.3

5.3.3.1. Objetivo

Identificar y ajustar los parámetros para que el módulo de procesamiento basado en información del gradiente determine correctamente la presencia o ausencia de patrones de calentamiento válidos sobre las termografías a analizar.

5.3.3.2. Descripción

Utilizando las termografías descritas en la sección 5.3.1 y tomando como base los resultados obtenidos de la extracción de información basada en el gradiente de

5.3 Módulo de procesamiento basado en información del gradiente

Umbrales	Conjunto de Datos										
U1	1	2	3	4	5	6	7	8	9	10	11
PA	65,8	60,5	52,6	39,5	47,4	50,0	28,9	44,7	52,6	31,6	60,5
S	72,2	38,9	55,6	50,0	38,9	38,9	38,9	27,8	27,8	22,2	50,0
E	60,0	80,0	50,0	30,0	55,0	60,0	20,0	60,0	75,0	40,0	70,0
\overline{PA}	48,6	DE	11,8	\overline{S}	41,9	DE	14,4	\overline{E}	54,5	DE	18,5

Cuadro 5.11: Índices de desempeño umbrales $U1$.

Umbrales	Conjunto de Datos										
U2	1	2	3	4	5	6	7	8	9	10	11
PA	76,3	89,5	71,1	78,9	57,9	63,2	73,7	60,5	76,3	81,6	63,2
S	88,9	77,8	88,9	83,3	83,3	61,1	66,7	72,5	83,3	77,8	83,3
E	65,0	100,0	55,0	75,0	35,0	65,0	80,0	27,5	70,0	85,0	45,0
\overline{PA}	72,0	DE	9,9	\overline{S}	78,8	DE	8,9	\overline{E}	63,9	DE	21,8

Cuadro 5.12: Índices de desempeño umbrales $U2$.

las imágenes sintéticas y que fueron descritos en la sección 5.3.2, se ajustaron los parámetros del módulo de procesamiento respectivo para poder definir la presencia o ausencia de patrones de calentamiento válidos en las imágenes analizadas. Este ajuste se realizó de forma experimental utilizando un conjunto de datos de treinta y ocho (38) imágenes, veinte de las cuales representan el primer estado de funcionamiento y las dieciocho (18) restantes el segundo. El ajuste de los parámetros se realizó con la mitad del conjunto de imágenes escogidas aleatoriamente y con la mitad restante se procedió a ejecutar el proceso de validación.

5.3.3.3. Resultados

En la tabla 5.11 se observa que el índice de aciertos (PA) usando los umbrales $U1$ presenta un bajo desempeño, tiene un valor mínimo de 28.9% y un valor máximo de 65.8% con una media de 48.6%, desviación estándar de 11.8,

5.3 Módulo de procesamiento basado en información del gradiente

Umbrales	Conjunto de Datos										
U3	1	2	3	4	5	6	7	8	9	10	11
PA	92,1	63,2	84,2	78,9	73,7	76,3	76,3	71,1	68,4	81,6	89,5
S	88,9	44,4	88,9	66,7	61,1	77,8	61,1	50,0	50,0	66,7	83,3
E	95,0	80,0	80,0	90,0	85,0	75,0	90,0	90,0	85,0	95,0	95,0
\overline{PA}	77,8	DE	8,8	\overline{S}	67,2	DE	15,8	\overline{E}	87,3	DE	6,8

Cuadro 5.13: Índices de desempeño umbrales $U3$.

Umbrales	Índice de Desempeño					
	\overline{PA}	DE	\overline{S}	DE	\overline{E}	DE
U1	48,6	11,8	41,9	14,4	54,5	18,5
U2	72,0	9,9	78,8	8,9	63,9	21,8
U3	77,8	8,8	67,2	15,8	87,3	6,8

Cuadro 5.14: Comparación de Índices de desempeño para Umbrales $U1$, $U2$ y $U3$.

sensibilidad promedio (\overline{S}) de 41.9% y especificidad promedio (\overline{E}) de 54.5%.

En las tablas 5.12 y 5.13 se consignan los resultados obtenidos para otros dos conjuntos de umbrales identificados como $U2$ y $U3$, se puede apreciar como el índice de aciertos mejora notablemente en los dos casos en comparación con el conjunto de umbrales $U1$, obteniendo valores que varían entre 57.9% y 92.1%. En la tabla 5.14 se sintetizan los resultados obtenidos con los tres conjuntos de umbrales. Se observa que el porcentaje general de aciertos promedio (\overline{PA}) para $U2$ y $U3$ es de 72.0% y 77.8% respectivamente, por lo que se podría pensar que con el último conjunto de umbrales se obtienen los mejores resultados. Sin embargo analizando el índice de desempeño de sensibilidad promedio (\overline{S}), se observa que se alcanzan mejores resultados con el segundo conjunto de umbrales, con un valor de 77.8% frente a 67.2% de $U3$, lo que se traduce en términos prácticos en una mejor capacidad para identificar la presencia de patrones de calentamiento anómalos.

La tabla 5.15 muestra la clasificación de los niveles de severidad obtenidos a

Acción	APROXIMACIÓN	RESULTADOS
Observación	6 - 14 °C	11.1 %
Intermedia	15 - 35 °C	55.5 %
Crítica	36 - 70 °C	22.2 %
Inmediata	> 70 °C	11.1 %

Cuadro 5.15: Resultados clasificacion niveles de severidad.

partir de las imágenes en donde se encontraron patrones de calentamiento anómalos, para la clasificación se utilizó la aproximación de los estándares consignados en la tabla 4.2 de la sección 4.2.4.

5.4. Conclusiones

Se pudo encontrar que las diferencias visuales para las imágenes térmicas adquiridas del motor incluido en la unidad Feedback ES151 bajo distintas condiciones de funcionamiento, son casi imperceptibles al ojo humano. Esta situación es una problemática común del análisis clásico de imágenes térmicas.

Usar el MSE como indicador de desempeño para el diseño de máquinas de aprendizaje tipo *MLP* permitió obtener una arquitectura adecuada para la implementación de este tipo de máquinas. Se pudo comprobar que la tendencia de este indicador era decreciente ante incrementos del número de iteraciones para el entrenamiento de la red y también ante el crecimiento del número de neuronas en la capa oculta de la misma. Se pudo establecer que usando un número de neuronas en la capa oculta igual al de la capa de entrada y con 40.000 iteraciones para el entrenamiento de la red se obtienen resultados satisfactorios para esta aplicación en particular.

Teniendo en cuenta los resultados de desempeño de las tres máquinas de aprendizaje implementadas, cuando las condiciones de captura y la escena de la imagen térmica permanecen invariantes, los descriptores escogidos para ésta aplicación

y extraídos (*momentos estadísticos y momentos invariantes*) de las ROI seleccionadas, son lo suficientemente discriminantes para diferenciar correctamente en un buen nivel los cambios sutiles de información térmica y así identificar el posible estado de funcionamiento de un equipo o dispositivo.

La normalización de las características de entrada para el módulo de procesamiento basado en máquinas de aprendizaje permitió encontrar que para el caso de las máquinas de tipo *Bayesiano* y *MLP* los mejores resultados se obtienen cuando se utilizan como técnicas de normalización la *logarítmica* y *mín-max* respectivamente. Las máquinas de aprendizaje tipo *RBF*, presentaron un mejor desempeño cuando no se utiliza ningún método de normalización.

Usar matrices de confusión para organizar los resultados provenientes del proceso de clasificación permitió obtener indicadores de desempeño adicionales al índice común de desempeño general. Esto permite interpretar mejor los resultados, la *sensibilidad* y la *especificidad* dan a conocer las tasas de verdaderos positivos y falsos positivos, logrando así identificar fácilmente la capacidad del sistema para detectar condiciones de operación anómalas y normales respectivamente.

El análisis de imágenes sintéticas que simulan diferentes patrones de calentamiento permitió encontrar un punto de referencia inicial para el ajuste de parámetros necesarios en el módulo de procesamiento basado en información del gradiente. El ajuste final de estos parámetros para ser utilizados con imágenes térmicas de equipos en condiciones reales de funcionamiento se logró a través de varias pruebas experimentales utilizando la información extraída de los equipos inspeccionados organizada de forma aleatoria.

Las diferentes pruebas realizadas permitieron evaluar la capacidad de clasificación de los módulos de procesamiento implementados en el sistema. En general los resultados obtenidos están acordes a los esperados.

Se logró implementar un sistema de visión artificial para la detección de anomalías en equipo eléctrico a partir de sus imágenes térmicas adquiridas bajo

5.4 Conclusiones

diferentes condiciones de operación. Se implementaron dos módulos de procesamiento: el primero basado en máquinas de aprendizaje a partir de información estadística extraída de las ROI seleccionadas y el segundo basado en información del gradiente. Los módulos implementados funcionan de manera excluyente ya que el primero se diseñó para trabajar con termografías de un equipo particular en donde la escena y las condiciones de captura permanecen invariantes y el segundo módulo se utiliza para inspección de varios equipos en escenas diferentes.

Capítulo 6

Conclusiones Generales

Los antecedentes consultados muestran la ausencia de trabajos enfocados a brindar apoyo en el análisis de imágenes térmicas usando herramientas computacionales. Con el trabajo desarrollado se logró la implementación de un sistema de visión artificial para el análisis de termografías usando máquinas de aprendizaje e información del gradiente. La plataforma diseñada puede ser utilizada como herramienta para ampliar la línea de investigación en termografía usando técnicas de visión artificial y reconocimiento de patrones y también como herramienta de apoyo para el análisis de termografías por parte de termógrafos calificados.

La utilización de máquinas de aprendizaje tipo *MLP* y *RBF* con termografía pasiva abre las puertas a una línea de investigación que presenta un amplio potencial de trabajo.

Se pudo comprobar que los descriptores estadísticos e invariantes utilizados con las máquinas de aprendizaje son lo suficientemente discriminantes para lograr obtener un buen desempeño y capacidad de generalización característica de sistemas basados en redes neuronales.

Se pudo asociar el fenómeno físico de transferencia de calor presente en la operación de equipos eléctricos, al comportamiento de la información del gradiente que se puede obtener fácilmente a partir de los niveles de intensidad encontrados en las imágenes térmicas.

Las dos referencias de cámaras infrarrojas utilizadas para el proyecto, *ThermoVision A20* y *ThermaCAM E320*, permitieron poner en práctica los conceptos de adquisición de termografías aplicados a diferentes equipos eléctricos y también sirvieron para la creación de la base de datos de imágenes térmicas con las cuales se desarrollaron las distintas pruebas de éste trabajo.

Con el sistema desarrollado fue posible identificar si un equipo eléctrico como el motor utilizado se encuentra bajo condiciones normales o anómalas de operación. También fue posible identificar patrones de calentamiento normales o anómalos y realizar la respectiva clasificación del nivel de severidad en las líneas de alimentación de algunos equipos frecuentemente utilizados en sistemas de transmisión de energía eléctrica.

El *rango de temperatura, enfoque óptico y composición de la imagen* son los tres parámetros que no se pueden modificar después de haber almacenado una imagen IR. Parámetros adicionales como *distancia, temperatura ambiente, temperatura reflejada, velocidad del viento, carga eléctrica y emisividad* influyen directamente en los cálculos de temperatura aparente que se pueden obtener a partir de una termografía. Es importante tener en cuenta los efectos de cada uno de los parámetros anteriores para así lograr minimizar los errores de interpretación de la información proporcionada por las imágenes térmicas.

En una termografía se pueden encontrar diferentes patrones de radiación y también diferentes lecturas de temperatura entre ciertas zonas de la imagen. En algunos casos este resultado puede ser producido por diferencias de emisividad en los materiales que componen la escena de interés, es por esto que la *emisividad* se convierte tal vez en uno de los parámetros que más pueden influenciar la interpretación de una imagen térmica tanto a nivel cualitativo como cuantitativo.

Encontrar valores elevados en el desempeño general del sistema diseñado no garantiza que se puedan identificar las condiciones de operación anómalas en los equipos inspeccionados, éstas condiciones en particular resultan ser más críticas en términos de confiabilidad de un sistema eléctrico. Los índices de desempeño utilizados: *porcentaje general de aciertos, sensibilidad y especificidad*, también ex-

presados en forma de porcentaje; proveen información consistente para evaluar el comportamiento general del sistema diseñado. El índice de *sensibilidad* permite establecer la capacidad que tiene el sistema para identificar las condiciones anómalas de funcionamiento de los equipos inspeccionados o en otras palabras la tasa de verdaderos positivos, su valor ideal es 100 %.

Es importante resaltar que los resultados obtenidos con éste proyecto toman como base solamente la información de intensidad presente en las imágenes térmicas. Los datos de corriente o carga instantánea en el equipo inspeccionado así como cualquier otro tipo de información relacionada podrá combinarse con la originalmente utilizada para así obtener patrones de características más discriminantes que los encontrados hasta el momento.

Debido al gran volumen de información que puede encontrarse después del desarrollo de una inspección termográfica y que debe ser examinada por un termógrafo calificado, contar con herramientas para fortalecer el análisis de termografías como la presentada en este trabajo, ayudará a que la tarea de análisis sea más fácil de desarrollar; produciendo posiblemente una reducción en los errores de diagnóstico.

Capítulo 7

Perspectivas Futuras

Los resultados obtenidos del trabajo descrito en éste documento aunque pueden clasificarse como satisfactorios, representan el primer paso en la línea de investigación que relaciona la termografía pasiva con técnicas de visión artificial y reconocimiento de patrones. Por tanto para continuar con el desarrollo en este área se pueden tener en cuenta los siguientes aspectos:

- Utilizar una plataforma de experimentación adecuada para poder cuantificar los efectos producidos por cambios en variables ambientales o corrientes de alimentación de los equipos y así comparar los resultados con algunos referentes encontrados en la literatura consultada.
- Implementar técnicas para que la segmentación de las regiones de interés se realice de manera automática.
- La fusión de información presente en espectro visible y espectro infrarrojo, permitirá identificar cambios de emisividad en una escena, posibles valores de emisividad de los materiales, efectos de reflexión y también potencialmente realizar la compensación por emisividad para el cálculo de temperaturas aparentes.

-
- Explorar la combinación de la información de diferentes fuentes (gradiente, momentos estadísticos, invariantes así como también con información relacionada al proceso u objeto bajo inspección), podrá explotarse no solo para la detección del posible estado de funcionamiento de un equipo particular sinó también para generar indicadores para los posibles tiempos de atención o mantenimiento que se le deban prestar al equipo.

Bibliografía

- [AM06] Edwin Alférez and Oscar Morantes. Algoritmo de segmentación automática para la detección de defectos en imágenes termográficas. *XI Simposio de Tratamiento de Señales, Imágenes y Visión Artificial*, 2006. 2.2.2
- [AST02] ASTM, editor. *Standard Test Methods for Measuring and Compensating for Reflected Temperature Using Infrared Imaging Radiometers*, number E1897-97. American Society for Testing and Materials, 2002. 3.2.2.3
- [Bai82] George S. Baird. Thermographic aspects of industrial predictive maintenance. *n Thermosense V, D. Burleigh and J. Snell eds., Selected SPIE papers on CD-ROM, Volume 31*, 371:55–59, 1982. 2.2.3
- [Bai84] George S. Baird. Economics of thermographic predictive maintenance inspections. *In Thermosense VII, D. Burleigh and J. Snell eds., Selected SPIE papers on CD-ROM, Volume 31*, 520:193–196, 1984. 2.2.3
- [Bai86a] George S. Baird. Quality aspects of electric utility inspections. *In Thermosense VIII, D. Burleigh and J. Snell eds., Selected SPIE papers on CD-ROM, Volume 31*, 581:98–102, 1986. 2.2.3, 3.2.2

BIBLIOGRAFÍA

- [Bai86b] George S. Baird. Questions of quality in thermographic services. *In Thermosense VIII, D. Burleigh and J. Snell eds., Selected SPIE papers on CD-ROM, Volume 31*, 581:14–16, 1986. 2.2.3
- [Bai87] George Baird. The effect of circuit loading on electrical problem temperature. *In Thermosense IX, D. Burleigh and J. Snell eds., Selected SPIE papers on CD-ROM, Volume 31*, 780:47–49, 1987. 2.2.3
- [Bal98] Balslev. Noise tolerance of moment invariants in pattern recognition. *Pattern recognition letters*, 19:1183–1189, 1998. 4.2.2.3, 4.2.2.3
- [BB82] A. P. Bruno and C. J. Burrer. Analytical interpretation of thermograms including digital processing techniques. *In Thermosense V, D. Burleigh and J. Snell eds., Selected SPIE papers on CD-ROM, Volume 31*, 371:230–239, 1982. 2.2.3
- [Ben08] Hernán Benitez. *Contribución a la Caracterización de Defectos en Termografía Infrarroja Mediante Máquinas de Aprendizaje*. PhD thesis, Universidad del Valle, 2008. 2.7
- [BIB⁺06] Hernán Benitez, Clemente Ibarra, A. Bendada, Xavier Maldague, Humberto Loaiza, and Eduardo Caicedo. Modified differential absolute contrast using thermal quadrupoles for the nondestructive testing of finite thickness specimens by infrared thermography. *CCECE Canadian conference on Electrical and computer Engineering, Paper No. 398 Ottawa (Ontario) Canadá*, 2006. 2.2.1
- [BIL⁺06] Hernán Benitez, Clemente Ibarra, Humberto Loaiza, Eduardo Caicedo, A. Bendada, and Xavier Maldague. Defect quantification with thermographic signal reconstruction and artificial neural networks. *Proceeding 8th conference on Quantitative Infrared Technology*, Padova Italy, June 28-30, 2006. 2.2.1

BIBLIOGRAFÍA

- [Bis95] Christopher Bishop. *Neural Networks for Pattern Recognition*. Oxford University Press Inc., 1995. 2.7, 4.2.2.4, 4.2.2.5
- [BLBA06] Hernán Benitez, Humberto Loaiza, Bladimir Bacca, and J Acevedo. Sistema de visión artificial para el procesamiento y análisis de imágenes infrarrojas. *XI Simposio de Tratamiento de Señales, Imágenes y Visión Artificial [Disponible en CD]*, Bogotá, Colombia, Septiembre 13-15 de 2006. 2.2.1
- [BLC04] Hernán Benitez, Humberto Loaiza, and Eduardo Caicedo. Application of image processing algorithms for image enhancement and defects detection in infrared thermography for nondestructive testing. *Memorias del IX Simposio de Tratamiento Digital de Señales, Imágenes y Visión Artificial, Universidad Nacional de Colombia Manizales, Colombia*, Septiembre 15-17, 2004. 2.2.1
- [BLC05] Hernán Benitez, Humberto Loaiza, and Eduardo Caicedo. Redes neuronales para la detección y caracterización de defectos en ensayo térmico no destructivo. *Memorias del Congreso Internacional de Inteligencia computacional, Universidad del Sinú, Monteria, Colombia*, Agosto 10-12, 2005. 2.2.1
- [CCG91] S. Chen, C. Cowan, and P. Grant. Orthogonal least squares learning algorithm for radial basis function networks. *IEEE Transactions on Neural Networks*, 2:302–309, 1991. 4.2.2.5
- [CSL00] W. L. Chan, A. T. P. So, and L. L. Lai. Three-dimensional thermal imaging for power equipment monitoring. *IEEE Proc-Gener. Transm. Distrib*, 147 No. 6:355–360, 2000. 2.2.3
- [DHS01] Richard Duda, Peter Hart, and David Stork. *Pattern Classification*. Wiley Interscience, 2001. 4.2.2.4, 4.2.2.5

BIBLIOGRAFÍA

- [EHE87] Richard A. Epperly, G. Erich Heberlein, and Lowry G. Eads. A tool for reliability and safety: Predict and prevent equipment failures with thermography. *Copyright Material IEEE. Paper No. PCIC-97-06*, pages 59–68, 1987. 2.2.3
- [Eis82] Steven E. Eisenbath. Infrared scanning for electrical maintenance. In *Thermosense V*, D. Burleigh and J. Snell eds., *Selected SPIE papers on CD-ROM, Volume 31*, 371:67–70, 1982. 2.2.3
- [Esc77] Laureano Escudero. *Reconocimiento de Patronos*. Paraninfo, 1977. 4.2.2.4, 4.2.2.5
- [Fac86] Rocco A. Faccinto. The use of infrared thermography in evaluating substation transformers. In *Thermosense VIII*, D. Burleigh and J. Snell eds., *Selected SPIE papers on CD-ROM, Volume 31*, 581:103–107, 1986. 2.2.3
- [Fau94] L Fausett. *Fundamentals of neural networks: architectures, algorithms and applications*. Prentice - Hall, 1994. 4.2.2.5
- [FGO06] Lina M. Fuentes, Oscar Gualdrón, and Gabriel Ordoñez. Termografía: Diagnóstico de la condición de equipos de alta tensión. *XI Simposio de Tratamiento de Señales, Imágenes y Visión Artificial*, 2006. 2.2.2
- [FLU05] FLUKE. *Manual de Usuario TI30*, pn081003 edition, January 2005. 3.2.1.3
- [FM04] Gloria Fernández and Juan Maya Montoya. Efecto de la temperatura elevada en las propiedades mecánicas de los conectores de alta tensión. *Dyna*, año 71, 143:37’43, 2004. 2.2.2

BIBLIOGRAFÍA

- [Fri81] P. M. Frisk. Digital image processing for thermogram interpretation. *In Thermosense IV, D. Burleigh and J. Snell eds., Selected SPIE papers on CD-ROM, Volume 31*, 313:169–176, 1981. 2.2.3
- [FS93] James Freeman and David Skapura. *Redes Neuronales Algoritmos, Aplicaciones y Técnicas de Programación*. Addison-Wesley / diaz de Santos, 1993. 2.7
- [Gri78] Ted J. Griffith. Doing a tough job the easy way with infrared thermography. *In Thermosense I, D. Burleigh and J. Snell eds., Selected SPIE papers on CD-ROM, Volume 31*, 1:87–91, 1978. 2.2.3
- [Gro92] Paul Grover. Applying ansi/ieee/nema temperature standards to infrared inspections. *In Thermosense XIV, D. Burleigh and J. Snell eds., Selected SPIE papers on CD-ROM, Volume 31*, 1682:101–107, 1992. 2.2.3
- [GW96] Rafael C. González and Richard E. Woods. *Tratamiento Digital de Imágenes*. Addison-Wesley / Díaz de Santos, 1996. 2.7, 2.7, 2.7, 4.2.2.4
- [HBL⁺07] Manuel Hurtado, Hernán Benitez, Humberto Loaiza, Jaime Millán, Jesús González, and Clemente Ibarra Castañedo. Images processing and flow measurement applied to the thermographic analysis of heat losses in boilers isolation. *Thrmosense XXIX*, 6541, 2007. 2.2.1
- [HC95] T. Hupkens and J. Clippeleir. Noise and intensity invariant moments. *Pattern Recognition Letters*, 16:371–376, 1995. 4.2.2.3
- [Hol00] Gerrald C. Holst. *Common Sense Approach to Thermal Imaging*. JCD Publishing & SPIE - The International Society for Optical Engineering, 2000. 2.2, 2.3, 2.4, 2.4, 3.2.2.3, 3.2.2.4

BIBLIOGRAFÍA

- [Hou98] Niancang Hou. The infrared thermography diagnostic technique of high-voltage electrical equipments with internal faults. Thermal Power Research Institute, The Ministry of Electric Power Industry, Xian 710032, Shaanxi, P. R. China, 1998. [2.2.3](#)
- [Hur90] Thomas L. Hurley. Infrared qualitative and quantitative inspections for electric utilities. *In Thermosense XII, D. Burleigh and J. Snell eds., Selected SPIE papers on CD-ROM, Volume 31*, 1313:6–24, 1990. [2.2.3](#)
- [IGB⁺06] Clemente Ibarra, D. A. González, Hernán Benitez, A. Bendada, and X. Maldague. Estado del arte en el procesado de señales e imágenes por termografía pulsada. *XI Simposio de Tratamiento de Señales, Imágenes y Visión Artificial [disponible en CD] Bogotá Colombia*, Septiembre 13-15, 2006. [2.2.1](#)
- [IGK⁺04] C. Ibarra, D. González, M. Klein, M. Pilla, S. Vallerand, and X. Maldague. Infrared image processing and data analysis. *Infrared physics & technology*, 46:75–83, 2004. [2.7](#), [4.2.2.1](#)
- [ITC06] ITC. *Thermography Level 1 Course Manual*. Infrared Training Center, 1560093es edition, 01 2006. [3.2.1](#), [3.2.2](#), [3.2.2.1](#), [3.2.2.2](#), [3.2.2.3](#), [3.2.2.3](#), [4.2.4](#)
- [Jai89] Anil K. Jain. *Fundamentals of Digital Image Processing*. Prentice Hall Inc., 1989. [2.7](#)
- [Kap95] Herbert Kaplan. An application of differential infrared thermography in power generation facilities. *In Thermosense XVII, D. Burleigh and J. Snell eds., Selected SPIE papers on CD-ROM, Volume 31*, 2473:67–74, 1995. [2.2.3](#)

BIBLIOGRAFÍA

- [KF01] Zbigniew Korendo and Marek Florkowski. Thermography-based diagnostics of power equipment. *Power Engineering Journal*, pages 33–42, 2001. 2.2.3
- [LOP00] Jr Bernard R. Lyon, Gary L. Orlove, and Donna L. Peters. The relationship between current load and temperature for quasi-steady state and transient conditions. In *Thermosense XXI*, D. Burleigh and J. Snell eds., *Selected SPIE papers on CD-ROM, Volume 31*, 4020:62–70, 2000. 2.2.3
- [Luc87] Ronald D. Lucier. Non problems in power plant a primer on correct diagnosis. In *Thermosense IX*, D. Burleigh and J. Snell eds., *Selected SPIE papers on CD-ROM, Volume 31*, 780:50–52, 1987. 2.2.3
- [Mad82] Robert P. Madding. Science behind thermography. In *Thermosense V*, D. Burleigh and J. Snell eds., *Selected SPIE papers on CD-ROM, Volume 31*, 371:2–9, 1982. 2.2.3, 2.4, 3.2.2
- [Mal93] Xavier Maldague. *Advances in Signal Processing for Nondestructive Evaluation of Materials*. Kluwer Academic Publishers, 1993. 2.2.3
- [Mal01a] Xavier Maldague. *Infrared and Thermal Testing. Series: Nondestructive Testing Handbook*. American Society for Nondestructive Testing, 2001. 1, 2.2, 2.2.3, 2.3, 2.4, 2.4, 2.5, 2.5, 2.7, 3.2.2.3
- [Mal01b] Xavier Maldague. *Theory and Practice of Infrared Technology for Nondestructive Testing*. Wiley-Interscience, 2001. 2.2, 2.2.3, 2.3, 2.4, 2.4, 2.4, 2.4.1, 2.4.2, 2.4.2, 2.6, 2.6
- [MAMP07] Nigel Morris, Shai Avidan, Wojciech Matusik, and Hanspeter Pfister. Statistics of infrared images. *IEEE*, 1-4244-1180-7:1–7, 2007. 2.7

BIBLIOGRAFÍA

- [Mar81] Stephen J. Marshall. We need to know more about infrared emissivity. In *Thermosense IV*, D. Burleigh and J. Snell eds., *Selected SPIE papers on CD-ROM*, Volume 31, 313:119–122, 1981. 2.2.3
- [ML00] Robert P. Madding and Jr. Bernard R. Lyon. Wind effects on electrical hot spots - some experimental ir data. *Proc SPIE Thermosense XXII*, 4020:80–84, 2000. 2.2.3, 2.4.2, 3.2.2.4
- [MM84] Stephen J. Marshall and Richard H. Munis. A proposed model for thermal image scene analysis. In *Thermosense VII*, D. Burleigh and J. Snell eds., *Selected SPIE papers on CD-ROM*, Volume 31, 520:36–39, 1984. 2.2.3
- [OC] Vivian Ohis and Tadeusz Czaszejko. Techniques for estimation of hot spot temperatures in transformers. Department of Electrical and Computer Systems Engineering, Monash University, Clayton, Victoria, Australia. 2.2.3
- [Orl82] Gary L. Orlove. Practical thermal measurement techniques. In *Thermosense V*, D. Burleigh and J. Snell eds., *Selected SPIE papers on CD-ROM*, Volume 31, 371:72–81, 1982. 2.2.3, 3.2.2.3
- [PdlC02] G Pajares and J de la Cruz. *Visión por Computador*. 2002. 2.7, 4.2.2.3
- [Pet98] Petrobras, editor. *Inspección Termográfica en Sistemas Eléctricos*, number N2475. Petrobras, CONTEC, 1998. 3.2.2.4, 3.2.2.5
- [PM83] John A. Pearce and Zee Man. Non linear processing of quantitative thermographic images. In *Thermosense VI*, D. Burleigh and J. Snell eds., *Selected SPIE papers on CD-ROM*, Volume 31, 446:218–225, 1983. 2.2.3

- [PNS94] Thomas Perch-Nielsen and J. C. Sorensen. Guidelines to thermographic inspections of electrical installations. In *Thermosense XVI*, D. Burleigh and J. Snell eds., *Selected SPIE papers on CD-ROM*, Volume 31, 2245:2–13, 1994. [1](#), [2.2.3](#), [3.2.2.5](#)
- [PTLK02] G. Pudio, S. Tenbohlen, M. Linders, and G. Krost. Integration of power transformer monitoring and overload calculation into the power system control surface. *IEEE/PES Transmission and Distribution Conference*, pages 1–5, 2002. [2.2.3](#)
- [SBI⁺06] M. Susa, Hernán Benitez, Clemente Ibarra, H. Loaiza, A. Bendada, and X. Maldague. Phase contrast using differentiated absolute contrast method. *Quantitative Infrared Thermography Journal*, 3, No. 2:219–230, 2006. [2.2.1](#)
- [Shl05] Jonathon Shlens. A tutorial on principal component analysis. 2005. [4.2.2.4](#)
- [SL95] E. A. Simoronson and J. A. Lapworth. Thermal capability assessment for transformers. The Reliability of Transmission and Distribution Equipment, 29-31 March 1995, Conference Publication No. 406, 1995. [2.2.3](#)
- [SML01a] Glenn Swift, Tom S. Molinsk, and Waldermar Lehn. A fundamental approach to transformer thermal modeling-part ii: Field verification. *IEEE Transactions on Power Delivery*, 16 No. 2:176–180, 2001. [2.2.3](#)
- [SML01b] Glenn Swift, Tom S. Molinski, and Waldermar Lehn. A fundamental approach to transformer thermal modeling-part i: Theory and equivalent circuit. *IEEE Transactions on Power Delivery*, 16 No. 2:171–175, 2001. [2.2.3](#)

BIBLIOGRAFÍA

- [Sne95a] Jr. John R. Snell. Problems inherent to quantitative thermographic electrical inspections. *In Thermosense XVII, D. Burleigh and J. Snell eds., Selected SPIE papers on CD-ROM, Volume 31*, 2473:75–81, 1995. 2.2.3
- [Sne95b] Jr. R. Snell. Problems commonly encountered in quantitative thermographic electrical inspections. *QIRT 94 - Eurotherm Series 42*, pages 37–43, 1995. 2.4.2
- [Sne03] J. Snell. A new approach to prioritizing anomalies found during thermographic electrical inspections. *Proceedings of SPIE Vol. 5073*, 2003. 1
- [Ste82] D. C. Stevens. Monitoring of generator stator core lamination repairs using thermographic techniques. *In Thermosense V, D. Burleigh and J. Snell eds., Selected SPIE papers on CD-ROM, Volume 31*, 371:38–43, 1982. 2.2.3
- [Sys04] Flir Systems. *ThermoVision A20M Operato's Manual*, publication no. 1-557-732 revision a72 edition, October 2004. 2.4, 2.4, 3.2.2.3
- [Tor98] C. Torres. Análisis de imágenes infrarrojas: Inspección de cableado eléctrico. Master's thesis, Universidad Autónoma de Puebla. Escuela de Ciencias de la Electronica, 1998. 2.4, 2.4, 2.4
- [Wie05] B. Wiecek. Review on thermal image processing for passive and active thermography. *Proceedings of the 2005 IEEE. Engineering in Medicine and Biology 27th Annual conference*, pages 686–689, 2005. 2.7, 4.2.2.3