




Listas de contenidos disponibles en ScienceDirect

Energía renovable

revista Página de inicio: www.elsevier.com/locate/renene

Clasificación de firmas de fallas en plantas solares fotovoltaicas mediante imágenes RGB y redes neuronales convolucionales

Alejandro Rico Espinosa *, Michael Bressan, Luis Felipe Giraldo

Universidad de Los Andes, Bogotá, Colombia

información del artículo

Historia del artículo:

Recibido el 13 de mayo de 2020

Recibido en forma revisada el 29 de

julio de 2020

Aceptado el 31 de julio de 2020 Disponible

online el 10 de agosto de 2020

Palabras clave:

Sistema fotovoltaico

Imágenes RGB

Segmentación semántica

Red neuronal convolucional

abstracto

La detección de fallas físicas en paneles que forman parte de plantas fotovoltaicas (PV) generalmente implica el análisis de imágenes térmicas y electroluminiscentes, lo que dificulta o imposibilita identificar la fuente de la falla en la planta. Este artículo propone un método de clasificación automática de fallas físicas para plantas fotovoltaicas utilizando redes neuronales convolucionales para la segmentación semántica y la clasificación a partir de imágenes RGB. Este estudio muestra resultados experimentales para 2 clases de salida identificadas como falla y sin falla, y 4 clases de salida como sin falla, grietas, sombras y polvo que no se pueden detectar fácilmente. El método propuesto presenta una precisión promedio del 75% para 2 clases de salida y del 70% para 4 clases, lo que muestra un enfoque positivo del método de clasificación propuesto para sistemas fotovoltaicos.

© 2020 Elsevier Ltd. Todos los derechos reservados.

1. Introducción

Los sistemas solares fotovoltaicos (PV) aumentaron su capacidad instalada en todo el mundo de 40.277 MW a 580.159 MW en solo 9 años (2010mi2019) debido a los beneficios que ofrece este tipo de energía renovable. A pesar de este hecho, esta tecnología aún necesita ser desarrollada porque actualmente tiene una eficiencia muy baja (15%mi20%). Por lo tanto, es importante estudiar todas las fuentes de pérdida en el sistema, ya que los sistemas fotovoltaicos son sensibles a la aparición de fallas [1]. El estudio en [2] categoriza las fallas típicas que ocurren en las plantas de energía fotovoltaica en i) fallas del panel, ii) fallas asociadas con la sombra, y iii) fallas eléctricas. Para detectar la presencia de una falla en cualquiera de estas categorías, es habitual estudiar la curva característica corriente-voltaje (IV) ya que las anomalías en el proceso de generación modifican su forma [3,4]. Sin embargo, identificar la causa de la falla sigue siendo una tarea desafiante ya que muchos de estos modelos en la literatura no consideran el efecto del sesgo inverso. Se requiere un análisis más profundo de las curvas IV para identificar fallas [3,5]. Además, las comprobaciones manuales periódicas consumen mucho tiempo, son costosas y laboriosas en sistemas de gran escala [6]. En cualquier caso, identificar la causa de una falla en un panel solar facilita definir y tomar acciones para mitigar los impactos en la eficiencia del sistema fotovoltaico. En este documento,

proponen una metodología para ello basada en imágenes RGB como fuente de información.

Algunas de las fuentes de firmas de fallas que son más difíciles de identificar son las causas del sombreado parcial en los paneles solares. Debido al desajuste actual debido a la presencia de sombreado parcial, la eficiencia de los módulos fotovoltaicos disminuye drásticamente y aumenta el riesgo de puntos calientes [4]. Un punto caliente se refiere a un aumento de temperatura debido a la disipación de energía en una celda con polarización inversa [7]. Recientemente se han propuesto varias soluciones basadas en la implementación de dispositivos eléctricos y herramientas de simulación para mitigar el impacto del sombreado en los sistemas fotovoltaicos [5,8mi10]. Sin embargo, la mayoría de estos enfoques pueden ser difíciles y costosos de implementar, y no permiten la detección precisa de escenarios físicos que generan puntos calientes en una matriz solar. Es importante minimizar el uso de dispositivos eléctricos adicionales para evitar el aumento de los costos y la complejidad del sistema.

Las metodologías alternativas recientes para detectar problemas causados por el sombreado parcial en paneles solares implican el reconocimiento de patrones en las imágenes. Por ejemplo, se ha utilizado un filtro astuto para resaltar las imperfecciones en los paneles solares para facilitar la detección realizada por un experto humano [11,12]. Otra técnica utiliza la formación de imágenes electroluminiscentes para la detección de imperfecciones superficiales, normalmente implementada durante la fabricación de paneles. El trabajo en [13] propone un detector automático de defectos de superficie para células fotovoltaicas mediante imágenes electroluminiscentes. Compararon el uso de una red neuronal convolucional (CNN) y una máquina de vectores de soporte (SVM) para realizar una clasificación binaria (dañada o no),

* Autor correspondiente. Universidad de los Andes, Cra 1 N° 18A-12, Bogotá, Colombia.

Correos electrónicos: aa.rico@uniandes.edu.co (A. Rico Espinosa), m.bressan@uniandes.edu.co (M. Bressan), lf.giraldo404@uniandes.edu.co (LF Giraldo).




Figura 1. Una metodología propuesta para la detección y clasificación de fallas.

concluyendo que las CNN pueden superar potencialmente a las SVM para la clasificación de imágenes. Además, la termografía se ha utilizado para la identificación de problemas en granjas solares. El trabajo de [14] utiliza CNN para identificar puntos de calentamiento en paneles solares basados en imágenes térmicas.

La mayoría de los estudios que se han propuesto para analizar firmas de fallas en paneles solares permiten la detección de daños pero no clasifican el origen del problema. En esta carta, nuestro aporte es introducir una metodología para detectar, basada en imágenes RGB, si existe o no firma de falla, y el tipo de fuentes que pueden generar los puntos calientes. Esta metodología tiene como objetivo proporcionar una herramienta de soporte para las técnicas tradicionales de reconocimiento de fallas a través de un sistema automático de detección y clasificación, reduciendo tiempo y esfuerzo en sistemas fotovoltaicos a gran escala. Utilizando técnicas de segmentación y clasificación basadas en el aprendizaje profundo sobre imágenes RGB, nuestro método (Sección 2) realiza una rápida detección y clasificación de problemas potenciales (Sección 3), reduciendo los esfuerzos de auditoría y los costos de implementación. Nuestro objetivo es clasificar entre 4 clases de factores que pueden conducir a una reducción de potencia (Sección 4) y suelen ser difíciles de detectar automáticamente en los conjuntos fotovoltaicos: sombras, roturas, polvo visible y ausencia de fallos. Es importante distinguir entre sombras y polvo, ya que los niveles de opacidad pueden diferir. Si bien el sombreado parcial reduce la irradiancia solar, el polvo crea una pequeña capa de partículas que cubre la superficie fotovoltaica y afecta la entrega de energía en general [1]. El proceso de aprendizaje se llevó a cabo en una base de datos de imágenes que recopilamos y etiquetamos manualmente. Vemos este trabajo como un paso importante en la formulación de metodologías que integren diferentes fuentes de información y tecnologías de reconocimiento de patrones en sistemas solares fotovoltaicos.

2. Metodología

La metodología propuesta tiene dos bloques principales, como se ilustra en Figura 1. Dada una imagen RGB de una matriz de paneles solares bajo una perspectiva desconocida, el primer paso es extraer los objetos del panel utilizando una CNN, eliminando el ruido ambiental. En este paso, aplicamos el proceso conocido como segmentación semántica [15, dieciséis]. Luego, la detección y clasificación de fallas también se realiza usando CNN [17, 18]. A continuación, explicamos cómo construimos las bases de datos de entrenamiento y los detalles de implementación de las redes para la segmentación y clasificación.

2.1. Construcción de la base de datos

Se utilizaron varias bases de datos durante todo el proceso. La mayoría de las imágenes fueron tomadas de diferentes motores de búsqueda de Internet que brindan imágenes de instalaciones solares en todo el mundo. Una pequeña parte de las imágenes se tomó de instalaciones locales, como el aeropuerto internacional y paneles en el campus universitario. En este estudio, se consideraron imágenes RGB que i) tienen una perspectiva donde se muestra claramente la superficie del panel, y ii) cuya calidad es tal que el ojo humano puede identificar fallas. Tomamos 345 imágenes de tamaño 200-200, donde cada una se etiquetó manualmente con píxeles con la etiqueta 0 para el fondo y 1 para el panel fotovoltaico. Para la etapa de detección del panel solar, se entrenó una CNN para la segmentación semántica utilizando un subconjunto de 145 imágenes. Las 200 imágenes restantes se utilizaron para el estudio de clasificación. En este conjunto de datos, las imágenes pertenecían a las clases de fallas 'grietas', 'sombra', 'polvo' y 'sin fallas', 50 imágenes por clase. Aunque el conjunto de datos de prueba es más grande que el de entrenamiento para la etapa de segmentación, los resultados muestran un error bajo en la clasificación de píxeles, lo que muestra que la cantidad de imágenes de entrenamiento fue suficiente para realizar la segmentación de imágenes durante la etapa de clasificación.

2.2. La arquitectura de la red neuronal convolucional

Usamos CNN para realizar tareas de detección y clasificación de paneles solares. Figura 2 muestra la arquitectura habitual para este tipo de red. Normalmente, una CNN tiene dos etapas principales: una etapa en la que se llevan a cabo los procesos de convolución y muestreo descendente (agrupación máxima) y una etapa con una red neuronal completamente conectada. La primera etapa identifica los filtros necesarios para extraer las características más importantes de las imágenes en diferentes niveles de granularidad [19]. En la segunda etapa, la capa completamente conectada está configurada para compartir información entre una gran cantidad de neuronas que buscan relaciones y patrones para asignar una probabilidad para cada una de las salidas definidas (clases) en función de sus etiquetas. Debido a su topología y la forma en que transforma la información de entrada, las CNN se utilizan mucho para problemas de clasificación de imágenes [19].

La arquitectura de la CNN utilizada para la segmentación semántica utiliza 4 capas convolucionales. A cada uno le sigue un conjunto de unidades ReLu (para establecer valores negativos en cero) y capas de agrupación máxima. Después de la última convolución, se utilizó una capa completamente conectada y una capa con funciones de activación SoftMax. Las capas convolucionales para esta topología utilizan de 3 a 3 filtros. La arquitectura de la CNN utilizada para la clasificación de fallas era más compleja que la utilizada para la segmentación semántica. Está compuesto por 5 capas convolucionales que utilizan de 5 a 5 filtros. A cada capa convolucional le siguió una capa de normalización por lotes (para acelerar el proceso), una capa con unidades ReLu y una capa de agrupación máxima. Similar a lo que se implementó en la semántica

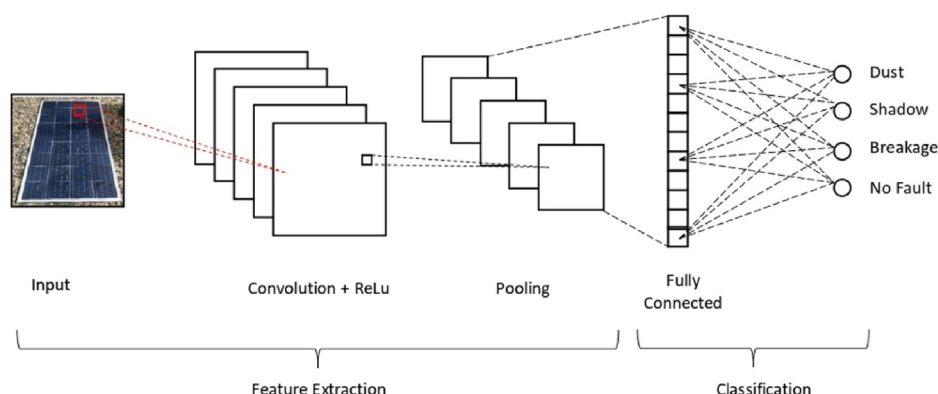


Figura 2. Topología de CNN.




Fig. 3. Ejemplos de segmentación de paneles solares utilizando una CNN para segmentación semántica.




Figura 4. Error porcentual de clasificación de píxeles para cada imagen de prueba en la etapa de segmentación de la metodología propuesta.



Figura 5. Uno de los filtros aprendidos en CNN para la segmentación de paneles.

Se utilizó una red de segmentación, una capa completamente conectada con activaciones SoftMax para hacer la clasificación. Estos parámetros son típicos cuando se usa CNN para tareas de clasificación en imágenes [11mi14]. Implementamos el proceso de aprendizaje utilizando la caja de herramientas de aprendizaje profundo en MATLAB.

3. Resultados de la detección del panel solar

El método de segmentación semántica utiliza una etiqueta por cada píxel de la imagen. Este método nos permite distinguir entre el fondo y los paneles solares, creando una máscara para los paneles solares. Usamos 145 imágenes que fueron etiquetadas manualmente para entrenamiento y 200 para pruebas. Estas imágenes de prueba son las que se utilizan para la clasificación. Algunos resultados de la detección del panel solar usando este método se muestran en Fig. 3. Tenga en cuenta que los paneles defectuosos (incluido el polvo, las roturas y las sombras) en diferentes perspectivas se pueden segmentar con este método. Figura 4 muestra el porcentaje de error de segmentación de píxeles para cada una de las 200 imágenes probadas. De este conjunto de resultados, observe que el error de segmentación promedio es 5.75%, donde el peor error de segmentación es 24%. Es importante mencionar que probamos el algoritmo YOLO (You Only Look Once) para identificar paneles solares [20], pero el enfoque de segmentación semántica proporcionó resultados de segmentación más precisos. YOLO es un

algoritmo de detección de objetos basado en un enfoque de ventana deslizante para reconocer objetos específicos en tiempo real. Aquí, un conjunto de cuadros de anclaje está predefinido en el que su tamaño se determina agrupando valores típicos del objeto a reconocer.

Uno de los filtros en una capa convolucional que se aprendió se muestra en Figura 5, y algunas de las imágenes que resultaron de aplicar este filtro para la segmentación del panel solar se muestran en Figura 6. Tenga en cuenta que este filtro, como muchos de los filtros aprendidos en las capas convolucionales, tiende a resaltar los bordes de la imagen. Este es un resultado esperado dada la geometría de los paneles, lo que permite que la capa completamente conectada de la red clasifique con precisión entre el panel y las regiones de fondo.

4. Resultados de la clasificación de fallas

Una vez que el panel solar está correctamente segmentado en la imagen, procedemos a clasificar el panel solar según las firmas de fallas físicas. Las clases seleccionadas son: 'rotura', 'sombra', 'polvo', 'sin falla'. Se etiquetó manualmente un conjunto de 200 imágenes que contenían imágenes para cada una de las clases para evaluar el desempeño del sistema de clasificación. Además de calcular la precisión de la clasificación, calculamos la recuperación, la precisión y F1 puntuaciones para tener una evaluación completa del modelo de clasificación [21]. DejarTPi ser el número de imágenes predichas correctamente de la clase I (verdaderos positivos), Tennessel ser el número de imágenes predichas correctamente que no son de la clase I (verdadero negativo), FPi ser el número de imágenes predichas incorrectamente como claseI (falsos positivos), y FNi sea el número de imágenes de la clase I que están clasificados incorrectamente (falsos negativos). Recordargramoi y precisión ri para clase I se calculan como

$$\text{gramoi} = \frac{TP_i}{TP_i + FN_i}; r = \frac{TP_i}{TP_i + FP_i} \quad (1)$$

F1 índice es el promedio ponderado de recuperación y precisión en la ecuación (1) y se calcula como

$$F1 = 2 \frac{\text{gramoi} \cdot r}{\text{gramoi} + r} \quad (2)$$

A continuación, mostramos los resultados de la etapa de clasificación de la metodología propuesta. Primero exploramos el caso cuando tenemos una clasificación binaria ('culpa', 'sin culpa'), para luego estudiar el caso de clasificación de cuatro clases.

4.1. Clasificación para 2 clases de salida

Para evaluar la capacidad del modelo para realizar una clasificación binaria, en primer lugar, tomamos las 50 imágenes de la clase 'sin culpa'. Para crear la clase 'falla', se seleccionaron al azar 17 imágenes de cada uno de los conjuntos de datos restantes en el estudio (roturas, sombra, polvo) para completar un total de 51 imágenes para esta clase. Luego, estimamos la exactitud, recuperación, precisión y F1 puntajes usando una validación cruzada de 4 veces, y repitió el proceso 10 veces. Figura 7 muestra la precisión y la pérdida promedio durante el entrenamiento (línea continua) y las pruebas (línea discontinua) a lo largo del tiempo para uno de los lotes. Tenga en cuenta que, durante el proceso de entrenamiento, el modelo puede aprender un patrón a pesar del pequeño tamaño del conjunto de datos.

Tablas 1 y 2 mostrar la matriz de confusión y el cálculo del recuerdo promedio, la precisión y las puntuaciones F1 de las ecuaciones (1) y (2). En este caso, la detección de fallas del sistema fotovoltaico con imágenes RGB alcanza una precisión promedio del 75,39%, mostrando la capacidad del modelo para detectar si hay una falla en el panel solar o no. También, Tabla 2 muestra el cálculo del recuerdo promedio, la precisión y las puntuaciones F1. Tenga en cuenta que estos son valores razonablemente buenos que están por encima de un umbral de 0,7.




Figura 6. Imágenes después de una de las convoluciones en la CNN.

4.2. Clasificación para 4 clases de salida

De manera similar a como se hizo en el caso de clasificación binaria, evaluamos la capacidad del modelo para realizar una tarea de clasificación de 4 clases. Recuerde que las clases de firmas de fallas físicas son roturas, polvo y sombras. Estimamos la exactitud de clasificación, recuperación, precisión y F1 puntuaciones utilizando un esquema de validación cruzada de 4 veces. [Figura 8](#) muestra la precisión y la pérdida promedio durante el entrenamiento (línea continua) y las pruebas (línea discontinua) a lo largo del tiempo para uno de los lotes. Tenga en cuenta que, en este caso, durante el proceso de entrenamiento, el modelo también puede aprender un patrón a pesar del pequeño tamaño del conjunto de datos.

También estudiamos las imágenes filtradas en la capa convolucional de

CNN para clasificación. [Figura 9](#) es el filtro con la mayor activación en una de las capas convolucionales del modelo, y [Figura 10](#) muestra imágenes con fallas que resultan de aplicar el proceso de convolución. A diferencia de la tarea de segmentación, CNN para clasificación usa filtros para descartar cambios rápidos de contraste, permitiendo que la red completamente conectada se enfoque en aquellos patrones que revelan la presencia de sombras, polvo visible y grietas que ocupan grandes porciones del panel. Las pequeñas roturas y grietas se pueden filtrar de la imagen en esta capa, lo que explica las bajas tasas de clasificación para esta clase.

[Tablas 3 y 4](#) mostrar la matriz de confusión y el cálculo del recuerdo promedio, la precisión y las puntuaciones F1. Tenga en cuenta que la clasificación 'sin culpa', 'polvo' y 'sombras' tiene las puntuaciones de precisión más altas


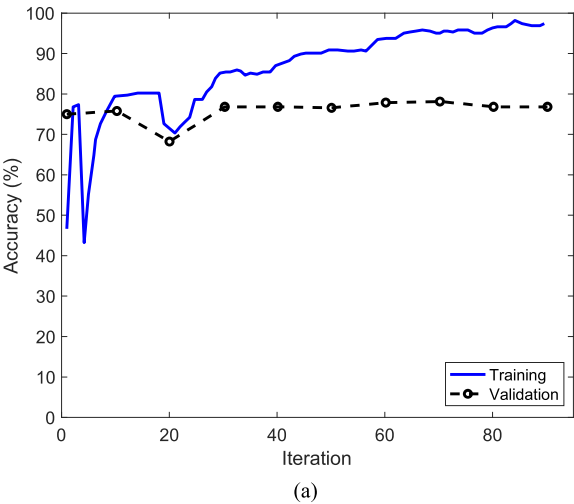


Figura 7. (a) Precisión promedio y (b) pérdida a lo largo del tiempo para uno de los lotes en la tarea de clasificación binaria. La línea continua corresponde al entrenamiento y la línea discontinua corresponde a la prueba.

tabla 1 Matriz de confusión para la tarea de clasificación binaria.

	Culpa	Sin culpa
Culpa	75,39%	24,61%
Sin culpa	30,00%	70,00%

Tabla 2 Recuperación promedio, precisión y F1 puntajes para la tarea de clasificación binaria.

Recordar	Precisión	F1
0,7539	0,7153	0,73

(casi 70%, 65,71% y 41,03%).

Aunque la clase 'rotura' tiene un error promedio por encima de la probabilidad, tiene un error de clasificación alto, lo que demuestra que es una tarea difícil de resolver. El modelo tiende a pasar por alto las grietas en las imágenes, clasificándolas como imágenes "sin fallas". Además, las puntuaciones de memoria, precisión y F1 mostraron una capacidad de clasificación razonable de la CNN. En general,





Figura 8. (a) Precisión y (b) pérdida a lo largo del tiempo para uno de los lotes en la tarea de clasificación de cuatro clases. La línea continua corresponde al entrenamiento y la línea discontinua corresponde a la prueba.




Figura 9. Filtro de activación más grande.

Estos resultados nos llevan a argumentar que la metodología propuesta realmente puede diferenciar los tipos de firmas de fallas que se presentan en los sistemas fotovoltaicos.




Figura 10. Imágenes de salida de una capa convolucional del modelo aprendido para la clasificación de imágenes con (a) sombras, (b) polvo y (c) roturas.

Tabla 3

Matriz de confusión para la tarea de clasificación de 4 clases.

	Roturas	Oscuridad	Polvo	Sin culpa
Roturas	28,21%	18,43%	22,59%	30,77%
Oscuridad	24,36%	41,03%	10,42%	24,20%
Polvo	12,18%	2,08%	69,23%	16,51%
Sin culpa	11,86%	14,26%	8,17%	65,71%

Cuadro 4

Recuperación promedio, precisión y F1 para la tarea de clasificación de cuatro clases.

Clase	Recordar	Precisión	F1
Rotura	0.2821	0.3682	0,32
Sombra	0.4103	0.5413	0,47
Polvo	0.6923	0.6270	0,66
Sin culpa	0.6571	0.4790	0,55

5. Conclusiones y labor futura

Se presenta una metodología para la detección y clasificación automática de firmas físicas de fallas en paneles fotovoltaicos a partir de imágenes RGB. Esta metodología se basa en una etapa de detección de panel solar y un factor de disminución de la etapa de clasificación del rendimiento fotovoltaico. La detección se lleva a cabo mediante una red neuronal convolucional para la segmentación semántica, y la clasificación se realiza mediante una red neuronal convolucional que clasifica entre roturas, sombras, polvo y sin fallas. Los modelos fueron entrenados usando imágenes que fueron recolectadas y etiquetadas manualmente. Se demuestra que la metodología propuesta es capaz de detectar prácticamente paneles en una imagen dada, y hacer clasificación binaria (falla, no falla) y clasificación de 4 clases. Aunque el conjunto de datos recopilado es relativamente pequeño, se obtiene una precisión de hasta el 70% para el caso de clasificación de 4 clases,

El trabajo futuro incluye la optimización de los parámetros y valores arquitectónicos utilizados para la segmentación y clasificación. Además, este estudio consideró escenarios reales que incluían imágenes de varios sistemas fotovoltaicos en condiciones no controladas (por ejemplo, ángulos, calidad, rango). Creemos que aumentar el conjunto de datos de imágenes ayudará a mejorar el rendimiento de la CNN. Asimismo, se puede considerar el estudio de más escenarios, como la inclusión de otro tipo de cuestiones que pueden disminuir el rendimiento fotovoltaico y la implementación de estos modelos en dispositivos portátiles para procesamiento en tiempo real.

Declaración de contribución de autoría de CRediT

Alejandro Rico Espinosa: Conceptualización, Metodología, Software, Investigación, Redacción - borrador original, Redacción - revisión y edición. Michael Bressan: Metodología, redacción - revisión y edición, supervisión. Luis Felipe Giraldo: Metodología, redacción - revisión y edición, supervisión.

Declaración de intereses en competencia

Los autores declaran que no tienen intereses económicos en competencia o relaciones personales conocidas que puedan haber influido en el trabajo informado en este documento.

Reconocimiento

Agradecemos al Departamento de Servicios de Información y Tecnología (DSIT) y a la Facultad de Ingeniería de la Universidad de Los Andes, que aportaron la capacidad de almacenamiento necesaria para realizar esta investigación.

Referencias

- [1] Mohammad Reza Maghami, Hashim Hizam, Chandima Gomes, Mohd Amran Radzi, Mohammad Ismael Rezadad, Shahrooz Hajjghorbani, Pérdida de energía debido a la suciedad en el panel solar: una revisión, *Renovar. Sostener. Energy Rev.* 59 (2016) 1307mi1316.
- [2] DS Pillai, N. Rajasekar, Una revisión integral sobre los desafíos de protección y diagnóstico de fallas en sistemas fotovoltaicos, *Renew. Sostener. Energy Rev.* 91 (2018) 18mi40.
- [3] YE Basri, M. Bressan, L. Seguíer, H. Alawadhi, C. Alonso, Un método de supervisión de firmas eléctricas gráficas propuesto para estudiar las fallas del módulo fotovoltaico, *Sol. Energía* 116 (2015) 247mi256.
- [4] M. Bressan, YE Basri, A. Galeano, C. Alonso, Un método de detección de fallas en la sombra basado en el análisis de error estándar de las curvas iv, *Renew. Energía* 99 (2016) 1181mi1190.
- [5] KA Kim, PT Kerin, Reexamen de la detección de puntos calientes fotovoltaicos para mostrar la insuficiencia del diodo de derivación, *IEEE J. Photovoltaics* 5 (2015) 1435mi1441.
- [6] D. Ji, C. Zhang, M. Lv, Y. Ma, N. Guan, Detección de fallas de paneles fotovoltaicos por reconfiguración automática, *Energies* 10 (2017) 699, <https://doi.org/10.3390/en10050699>.
- [7] KA Kim, PT Kerin, Hot spotting and second breakdown effects on reverse iv features for monocristalino si fotovoltaico, en: 2013IEEE Energy Conversion Congress and Exposition, 2013, pp. 1007mi1014.
- [8] S. Daliento, FD Napoli, P. Guerriero, V. d'Alessandro, Un circuito de derivación modificado para mejorar la confiabilidad de los puntos calientes de los paneles solares sujetos a sombreado parcial, *Sol. Energía* 134 (2016) 211mi218.
- [9] V. D'Alessandro, FD Napoli, P. Guerriero, S. Daliento, Una herramienta automatizada de alta granularidad para una evaluación rápida del rendimiento de plantas fotovoltaicas que tienen en cuenta los efectos de sombreado, *Renew. Energía* 83 (2015) 294mi304.
- [10] M. Bressan, A. Gutierrez, LG Gutierrez, C. Alonso, Desarrollo de una prevención de puntos calientes en tiempo real usando un emulador de sistemas fotovoltaicos parcialmente sombreados, *Renew. Energía* 127 (2018) 334mi343.
- [11] S. Vergura, O. Falcone, Filtrado y procesamiento de imágenes infrarrojas de módulos pv, *Renew. Energía Potencia Qual. J.* 1 (9) (2011) 1209mi1214.
- [12] JA Tsanakas, D. Chrysostomou, PN Botsaris, A. Gasteratos, Diagnóstico de fallas de módulos fotovoltaicos mediante procesamiento de imágenes y detección de bordes astutos en mediciones termográficas de campo, *Int. J. Sustain. Energía* 34 (2015) 351mi372.
- [13] S. Deitsch, V. Christlein, S. Berger, C. Buerhop-Lutz, A. Maier, F. Gallwitz, C. Riess, Clasificación automática de celdas de módulos fotovoltaicos defectuosos en imágenes de electroluminiscencia, 2018 arXiv preprint arXiv, 1807.02894.
- [14] R. Pierdicca, E. Malinverni, F. Piccinini, M. Paolanti, A. Felicetti, P. Zingaretti, Red neuronal convolucional profunda para la detección automática de células fotovoltaicas dañadas, *Int. Arco. Fotograma. Movimiento rápido del ojo. Sens. Spatial Inf. Sci.* 42 (2018).
- [15] J. Long, E. Shelhamer, T. Darrell, Redes totalmente convolucionales para la segmentación semántica, en: *Actas de la Conferencia IEEE sobre Visión por Computadora y Reconocimiento de Patrones*, 2015, págs. 3431mi3440.
- [dieciséis] Juan Jose Rubio, Takahiro Kashiwa, Teera Laiteerapong, Wenlong Deng, Kohei Nagai, Sergio Escalera, Kotaro Nakayama, Yutaka Matsuo, Helmut Prendinger, Segmentación de daños estructurales de clases múltiples utilizando redes totalmente convolucionales, *Comput. Ind.* 112 (2019).
- [17] G. Yao, T. Lei, J. Zhong, Una revisión del reconocimiento de acciones basado en redes neuronales convolucionales, *Reconocimiento de patrones. Letón.* 118 (2019) 14mi22.
- [18] Renxiang Chen, Xin Huang, Lixia Yang, Xiangyang Xu, Xia Zhang, Yong Zhang, método de diagnóstico inteligente de fallas de cajas de engranajes planetarios basado en una red neuronal convolucional y una transformada de ondícula discreta, *Computación. Ind.* 106 (2019) 48mi59.
- [19] I. Goodfellow, Y. Bengio, A. Courville, *Deep Learning*, MIT press, 2016.
- [20] J. Redmon, S. Divvala, R. Girshick, A. Farhadi, Solo miras una vez: detección unificada de objetos en tiempo real, en: *Actas de la Conferencia IEEE sobre Visión por Computadora y Reconocimiento de Patrones*, 2016, págs. 779mi788.
- [21] P. Flach, M. Kull, Curvas de precisión-recuperación-ganancia: análisis de Pr bien hecho. *Avances en los sistemas de procesamiento de información neuronal*, 2015, págs.838mi846.