

# **PROYECTO FIN DE CARRERA**

Presentado a

**LA UNIVERSIDAD DE LOS ANDES  
FACULTAD DE INGENIERÍA  
DEPARTAMENTO DE INGENIERÍA ELÉCTRICA Y ELECTRÓNICA**

Para obtener el título de

**INGENIERO ELECTRÓNICO**

por

***Federico Alvarez Gonzalez***

---

***DISEÑO E IMPLEMENTACIÓN DE UN SISTEMA DE DETECCIÓN DE  
SOMBRAS Y POLVO EN PANELES SOLARES USANDO TRATAMIENTO DE  
IMAGEN POR MEDIO DE REDES CONVOLUCIONALES.***

---

## Contenido

1	INTRODUCCIÓN .....	4
2	OBJETIVOS .....	4
2.1	Objetivo General .....	4
2.2	Objetivos Específicos .....	4
3	DESCRIPCIÓN DE LA PROBLEMÁTICA Y JUSTIFICACIÓN DEL TRABAJO .....	4
4	MARCO TEÓRICO .....	5
5	DEFINICION Y ESPECIFICACION DEL TRABAJO.....	7
5.1	Definición .....	7
5.2	Especificaciones .....	8
6	TRABAJO REALIZADO .....	8
7	VALIDACIÓN DEL TRABAJO .....	15
7.1	Metodología de prueba .....	15
7.2	Validación de los resultados del trabajo.....	15
7.2.1	Resultados de CNN para segmentación de sombra .....	16
7.2.2	Resultados de CNN para segmentación de polvo .....	16
7.2.3	Resultados de CNN para segmentación de paneles.....	17
8	CONCLUSIONES.....	18
9	AGRADECIMIENTOS.....	19
10	REFERENCIAS .....	19

## Lista de Figuras

Figura. 1. Estructura general de una red neuronal. [1] .....	5
Figura. 2 Estructura general de redes neuronales convolucionales. ....	6
Figura. 3 Ejemplo de segmentación semántica.....	6
Figura. 4. Demostración grafica del concepto.....	7
Figura. 5. Demostración grafica del concepto.....	7
Figura. 6. Imagen del dataset Deep Solar Eye .....	8
Figura. 7. Imagen de panel con sombra .....	9
Figura. 8. Etiquetado de imágenes utilizando la herramienta de Matlab “ImageLabeler” ..	9
Figura. 9. Segmentación de imagen en polvo y panel fotovoltaico .....	10
Figura. 10. Extracción de fondo.....	10
Figura. 11. Segmentación semántica del polvo en un panel fotovoltaico. ....	11
Figura. 12. Preprocesamiento para imágenes de paneles con sombra. ....	11
Figura. 13. Segmentación semántica de la sombra en un panel fotovoltaico. ....	12
Figura. 14 Asignación de opacidad al área con sombra .....	12
Figura. 15 Detección de puntos en borde de panel solar. ....	13
Figura. 16. Detección de esquinas en panel solar. ....	13
Figura. 17. Imagen del panel con perspectiva corregida. ....	14
Figura. 18. Estructura del sistema de detección de fallas de sombra y polvo. ....	15
Figura. 19. Matriz de confusión de segmentación de sombra .....	16
Figura. 20. Matriz de confusión de segmentación de polvo .....	17
Figura. 21. Matriz de confusión de segmentación del panel .....	18

## Lista de Tablas

Tabla 1. Métricas de rendimiento global de segmentación de sombra.....	16
Tabla 2. Métricas de rendimiento por clase de segmentación de sombra .....	16
Tabla 3. Métricas de rendimiento global de segmentación de polvo .....	17
Tabla 4. Métricas de rendimiento por clase de segmentación de polvo .....	17
Tabla 5. Métricas de rendimiento global de segmentación del panel .....	17
Tabla 6. Métricas de rendimiento por clases de segmentación del panel.....	18

## 1 INTRODUCCIÓN

En el siguiente documento se expondrá el desarrollo del diseño e implementación de un sistema de detección de sombras y polvo en un panel fotovoltaico por medio de visión por computadora usando “deep learning”, más específicamente redes neuronales convolucionales (CNN) para realizar segmentación semántica sobre la imagen. Con este proyecto se busca crear una herramienta que permita detectar este tipo de fallas en un sistema fotovoltaico.

Para realizar el proyecto primero se utilizó un “dataset” para entrenar las redes neuronales. Debido a los pocos datos disponibles se optó por realizar transferencia de aprendizaje usando una red pre-entrenada. Se usaron en total 3 CNN para realizar el reconocimiento del polvo y las sombras. Primero se utilizó una CNN para realizar la segmentación semántica entre el fondo de la imagen y el panel y así se filtra la imagen para que se retire el fondo de la imagen. Después de este preprocesamiento se usa una CNN para realizar la segmentación semántica entre el panel y el polvo y una diferente para las sombras.

## 2 OBJETIVOS

### *2.1 Objetivo General*

Diseñar e implementar un sistema de detección de sombras y polvo el cual sea capaz de entregar la forma y el área de estos haciendo uso de tratamiento de imagen por medio de redes convolucionales.

### *2.2 Objetivos Específicos*

- Realizar una toma y etiquetado de imágenes con el fin de entrenar las redes convolucionales que se van a utilizar para resolver el problema de identificación de fallas en el panel solar.
- Desarrollar un algoritmo que identifique el área y la opacidad de un panel solar usando visión por computadora y redes convolucionales.
- Validar el funcionamiento del sistema poniéndolo en funcionamiento.

## 3 DESCRIPCIÓN DE LA PROBLEMÁTICA Y JUSTIFICACIÓN DEL TRABAJO

Uno de los principales problemas que tienen los paneles fotovoltaicos es el incremento en temperatura y disminución de la tasa de producción de energía debido al efecto de la presencia de sombra y polvo en ciertas partes del panel. Identificar y ubicar este tipos de fallas puede resultar complicado con mediciones eléctricas convencionales. La implementación de un sistema de detección de polvo y sombra usando procesamiento de imagen permitiría la ubicación exacta de la falla.

#### 4 MARCO TEÓRICO

- Machine Learning: Se tratan de algoritmos que les permiten a los computadores aprender a resolver problemas a partir de una serie de ejemplos. [2]
- Deep Learning: Es una rama de Machine Learning la cual el modelo esta conformado por redes neuronales de mas de una capa, por lo que las neuronas no aprenden directamente de las características de los datos de entrenamiento sino de la salida de las neuronas de las capas predecesoras.[2]
- Red neuronal: Una red neuronal es un modelo de computación cuya estructura de capas se asemeja a la estructura interconectada de las neuronas en el cerebro, con capas de nodos conectados. Una red neuronal puede aprender de los datos, de manera que se puede entrenar para que reconozca patrones, clasifique datos y pronostique eventos futuros.[1]




Figura. 1. Estructura general de una red neuronal. [1]

- Redes neuronales convolucionales (CNN): Este tipo de red neuronal es una herramienta de Deep Learning principalmente utilizada para imágenes como datos de entrada. El tipo de capas ocultas mas relevantes en una CNN son las capas de convolución, activación y agrupación. Estas 3 capas se repiten varias veces aprendiendo cada vez diferentes características de la imagen. Finalmente se tiene unas capas de salidas que varían dependiendo del tipo de aplicación, ya sea clasificación, regresión o segmentación.[4]
- Capa de convolución: Esta capa hace pasar a la imagen por diferentes filtros convolucionales para identificar diferentes características de la imagen.[4]
- Capa de activación: Esta capa permite acelerar el proceso de entrenamiento al igualar a cero todos los valores negativos de la salida de la capa de convolución.[4]
- Capa de agrupación: Disminuye el tamaño de las muestra agrupando ciertas áreas de la imagen.[4]

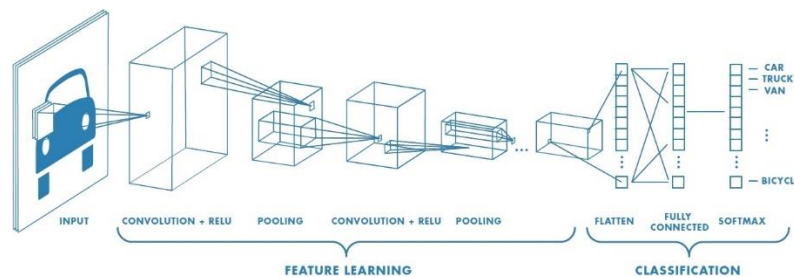


Figura. 2 Estructura general de redes neuronales convolucionales.

- Segmentación semántica: Es un tipo de problema que pueden solucionar las redes neuronales convolucionales. Este consiste en clasificar cada pixel de la imagen en unas clases significativas de objetos.[5]




Figura. 3 Ejemplo de segmentación semántica.

- Transfer Learning: Es una técnica en Machine Learning en la que se utiliza un modelo previamente entrenado para una tarea en específico como punto de inicio para entrenar otro modelo para otra tarea. Esta técnica permite entrenar un modelo mas rápido y con menos imágenes de entrenamiento.
- DeepLab V3+: Es un framework para segmentación de imágenes la cual se basa en una CNN ResNet pre-entrenada.
- Superpixel: Es un algoritmo que agrupa los pixeles conectados parecidos, estos grupos los llaman “superpixels”.
- Corrección de perspectiva: Es una método en el que se distorsiona y transforma una imagen para para cambiar la perspectiva de un objeto a la deseada. Para esto se debe hallar los puntos donde están las esquinas de los objetos y los puntos donde se desea que queden esas esquinas.
- Métricas de rendimiento en segmentación semántica: Para saber si la aplicación de segmentación semántica está teniendo un buen rendimiento se utilizan ciertas métricas de rendimiento:

- Accuracy (precisión): Se calcula como el porcentaje de pixeles etiquetados correctamente.
- IoU (Intersection-Over-Union): Se calcula como el número de pixeles que están en la intersección entre la segmentación predicha y la real etiquetada sobre el número de pixeles de la unión. En este caso el 0 quiere decir que no se tiene sobrelapamiento entre lo predicho y lo real, y un 1 significa que hay un sobrelapamiento perfecto.




Figura. 4. Demostración grafica del concepto de IoU (Intersection over Union).

- BFScore (F1 score): Se calcula como dos veces el numero de pixeles entre la segmentación predicha y la real dividido entre la suma del número de pixeles de cada una.




Figura. 5. Demostración grafica del concepto de F1 score.

## 5 DEFINICION Y ESPECIFICACION DEL TRABAJO

### 5.1 Definición

El problema principal que se planteó en este proyecto fue la detección de falla en los paneles fotovoltaicos causadas por la presencia de sombra y polvo. La ubicación de este tipo de falla ha resultado ser complicada usando métodos eléctricos, y para aplicar estos métodos es necesario en ciertos casos desconectar parte del sistema fotovoltaico interrumpiendo así la producción. Lo que se propuso fue crear un método utilizando tratamiento de imagen, visión por computadora, y métodos de Deep Learning para

reconocer la ubicación exacta de este tipo de fallas, su forma, su área, y en caso de ser una sombra su opacidad.

### **5.2 Especificaciones**

El sistema de detección de fallas de polvo y sombra en un panel fotovoltaico debe ser capaz de cumplir los siguientes requerimientos:

- Ser capaz de identificar los paneles solares en una imagen.
- Ser capaz de identificar fallas de polvo o sombra presentes en un panel y realizar una segmentación de estos para saber la región exacta de la imagen en donde se encuentra la imagen.
- En el caso de la falla de la sombra se debe poder realizar una estimación sobre la opacidad en la zona sombreada.
- Poder calcular el área del panel en el cual se presenta la falla.

## **6 TRABAJO REALIZADO**

Para realizar el método de detección de sombra y polvo se utilizó el software Matlab debido a la gran cantidad de herramientas de Deep Learning, tratamiento de imagen entre otras cosas.

Lo primero que se realizó fue la colección de imágenes de paneles fotovoltaicos, tanto como sin fallas, como con polvo y sombras. Para las imágenes con polvo se utilizó un dataset llamado Deep Solar Eye el cual tiene más de 45000 imágenes de paneles fotovoltaicos con diferentes patrones de polvo. Para las imágenes de los paneles solares con sombra se tomaron imágenes en el laboratorio Kiosol de la Universidad de los Andes.



*Figura. 6. Imagen del dataset Deep Solar Eye*



# DISEÑO E IMPLEMENTACIÓN DE UN SISTEMA DE DETECCIÓN DE SOMBRAS Y POLVO EN PANELES SOLARES USANDO TRATAMIENTO DE IMAGEN POR MEDIO DE REDES CONVOLUCIONALES.

9



Figura. 7. Imagen de panel con sombra

Una vez recopiladas las imágenes se tuvo que etiquetar cada imagen con cada una de las clases presentes en las imágenes:

- Fondo
- Panel
- Polvo
- Sombra

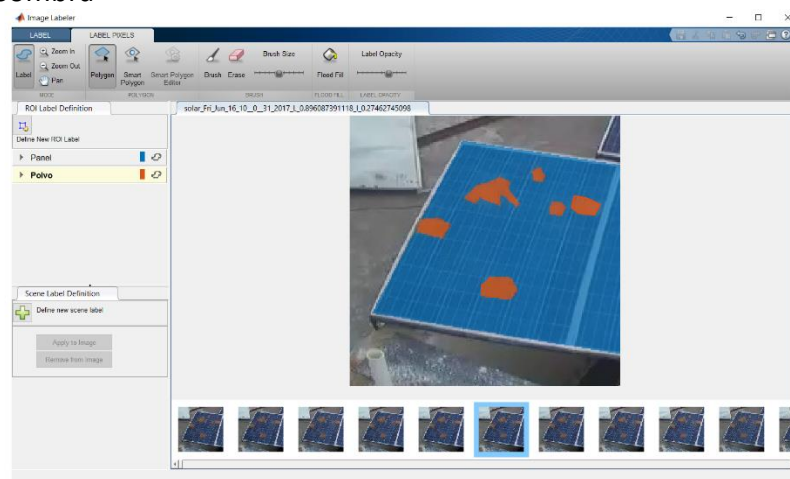


Figura. 8. Etiquetado de imágenes utilizando la herramienta de Matlab "ImageLabeler".

Estas imágenes de etiquetas resultantes se separaron para poder entrenar 3 CNN diferentes:

- Labels 1: Fondo, Panel.
- Labels 2: Fondo, Panel, Polvo.
- Labels 3: Fondo, Panel, Sombra.

Después de terminar el etiquetado de las imágenes se prosigue a entrenar la primera CNN. Para esto se tuvo que encontrar una CNN pre-entrenada para realizar segmentación ya que el número de imágenes etiquetadas no era suficiente para entrenar una desde cero. La

mejor opción que se encontró para este tipo de aplicación fue el framework creado por Google para realizar segmentación llamado DeepLab V3+, el cual consta de una CNN de 101 capas. La primera CNN fue entrenada solo para reconocer el panel del fondo de la imagen.





Figura. 9. Segmentación de imagen en polvo y panel fotovoltaico

Esta segmentación entre los paneles y el fondo de la imagen nos permite extraer únicamente la región de la imagen en donde esta el panel y eliminar el resto, mandándolo a negro. Esto lo realizamos como un preprocesamiento para las siguientes CNN. Esto se realizó ya que, al intentar identificar directamente la sombra y el polvo, el fondo de la imagen causaba que el modelo tuviera un mal rendimiento.



Figura. 10. Extracción de fondo

Una vez realizado este preprocesamiento se prosiguió a realizar el entrenamiento de la segunda CNN la cual tiene como objetivo identificar el polvo del panel. Se utilizó la misma red pre-entrenada para empezar el entrenamiento del modelo. Ya con la extracción del fondo de la imagen el rendimiento de este modelo fue bastante bueno.



*Figura. 11. Segmentación semántica del polvo en un panel fotovoltaico.*

Después de terminar la segmentación del polvo se prosiguió con la de la sombra. Para realizar la segmentación de la sombra se tuvo que realizar un preprocesamiento adicional, se utilizó un algoritmo de clustering para crear superpixels en la imagen y así disminuir la cantidad de detalles innecesarios de la imagen. También se cambio el fondo de la imagen por un fondo blanco.



*Figura. 12. Preprocesamiento para imágenes de paneles con sombra.*

Una vez realizado el preprocesamiento de las imágenes se entreno la CNN de las misma forma en la que se entrenaron las anteriores CNN. Utilizando estos diferentes métodos de procesamiento se pudo obtener una segmentación de sombra aceptable.




Figura. 13. Segmentación semántica de la sombra en un panel fotovoltaico.

Finalmente se calculó el área y la opacidad de las imágenes, la opacidad solo se calculo para la sombra. Para calcular la opacidad calculamos el promedio de la intensidad de los pixeles en área de sombra y los que están en el área sin sombra y encontramos su relación.

$$Opacidad = \frac{Prom. intensidad de la sombra}{Prom. intensidad sin sombra}$$

Este valor de opacidad se le asigno a la área sombrada en la imagen de la segmentación.



Figura. 14 Asignación de opacidad al área con sombra

Ya que usando la perspectiva actual de los paneles fotovoltaicos no podemos hallar el área exacta de la sombra o el polvo es necesario realizar una corrección de la perspectiva. Para realizar esto lo primero fue encontrar las esquinas del panel. Para esto se encuentra varios puntos en el borde del panel usando la función corner.




Figura. 15 Detección de puntos en borde de panel solar.


Teniendo en cuenta estos puntos encontramos los 4 en las esquinas. Estos se encuentran de la siguiente forma:

- $E(1) = \max(x + y)$
- $E(2) = \min(x + y)$
- $E(3) = \max(x - y)$
- $E(4) = \min(x - y)$



Figura. 16. Detección de esquinas en panel solar.

Finalmente usamos una transformación geométrica proyectiva para transformar la imagen a la perspectiva deseada. Con esta transformación también podemos cambiar la perspectiva de la segmentación



*Figura. 17. Imagen del panel con perspectiva corregida.*

Como se puede observar se obtuvieron de las anteriores imágenes, el modelo tiene resultados favorables que nos permiten saber el área forma y opacidad de las fallas presentes en los paneles fotovoltaicos.

A continuación se muestra la estructura básica del sistema de detección y segmentación de polvo y sombra en los paneles fotovoltaicos:

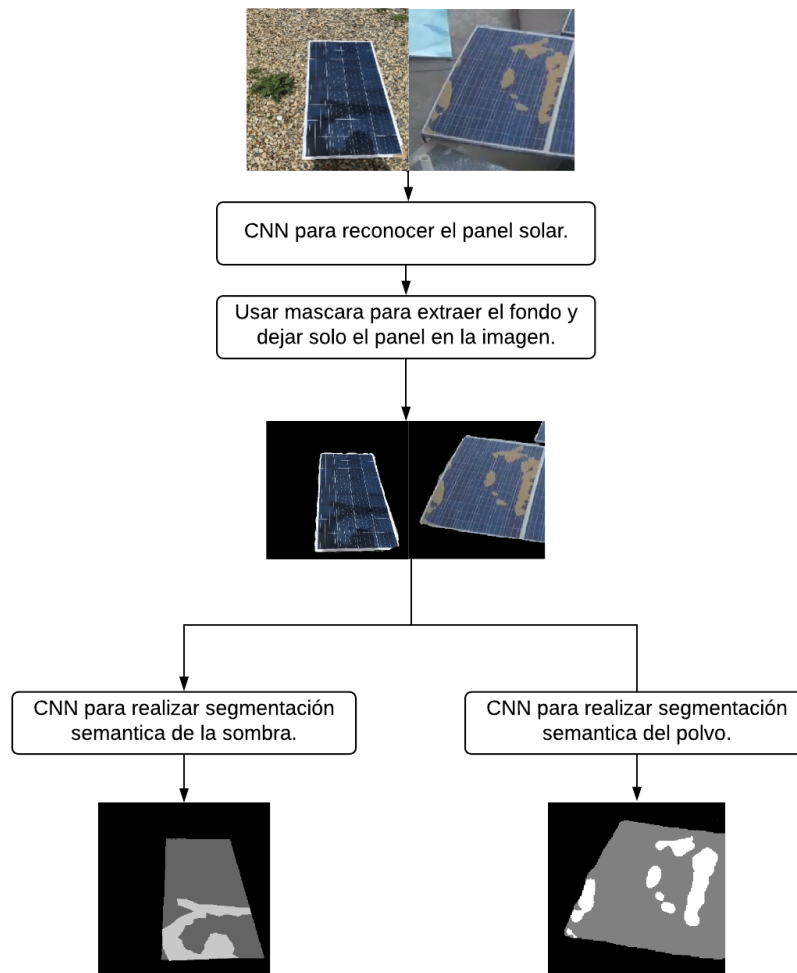


Figura. 18. Estructura del sistema de detección de fallas de sombra y polvo.

## 7 VALIDACIÓN DEL TRABAJO

### 7.1 Metodología de prueba

Para probar el rendimiento de las CNN y de la segmentación semántica se utilizarán varias métricas de rendimiento como lo son la precisión, IoU (Intersection over Union) y el FBScore. También se presentará una matriz de confusión en la cual se mostrarán el porcentaje de los píxeles etiquetados correcta y erróneamente por cada clase.

### 7.2 Validación de los resultados del trabajo

A continuación, se pueden ver una serie de tablas en donde podemos ver diferentes tipos de métricas de rendimiento de la segmentación semántica. Podemos ver métricas



globales, promediadas y por cada clase. Con esto podemos identificar cada modelo que es lo que hace mejor.

### 7.2.1 Resultados de CNN para segmentación de sombra

Tabla 1. Métricas de rendimiento global de segmentación de sombra

Global Accuracy	Mean Accuracy	MeanIoU	WeightedIoU	Mean BSF score
0,93705219	0,838780785	0,728914398	0,888929261	0,654250745

Tabla 2. Métricas de rendimiento por clase de segmentación de sombra

	Accuracy	Iou	Mean BFScore
<b>Fondo</b>	0,961690139	0,938755797	0,828855769
<b>Panel</b>	0,897528239	0,793388864	0,549275433
<b>Sombra</b>	0,657123978	0,454598533	0,524469948




Figura. 19. Matriz de confusión de segmentación de sombra

### 7.2.2 Resultados de CNN para segmentación de polvo



Tabla 3. Métricas de rendimiento global de segmentación de polvo

Global Accuracy	Mean Accuracy	MeanIoU	WeightedIoU	Mean BFScore
0,968344013	0,970000864	0,853160698	0,943784521	0,856267638

Tabla 4. Métricas de rendimiento por clase de segmentación de polvo

	Accuracy	Iou	Mean BFScore
<b>Fondo</b>	0,979721678	0,972051744	0,966244054
<b>Panel</b>	0,95700343	0,938434535	0,87174753
<b>Polvo</b>	0,973277485	0,648995815	0,716422472




Figura. 20. Matriz de confusión de segmentación de polvo

### 7.2.3 Resultados de CNN para segmentación de paneles

Tabla 5. Métricas de rendimiento global de segmentación del panel

Global Accuracy	Mean Accuracy	MeanIoU	WeightedIoU	Mean BFScore
0,98991537	0,989660828	0,979812686	0,980031428	0,977859241

Tabla 6. Métricas de rendimiento por clases de segmentación del panel

	Accuracy	Iou	Mean BFScore
<b>Fondo</b>	0,987211727	0,977708037	0,979495193
<b>Panel</b>	0,992109928	0,981917335	0,976223289




Figura. 21. Matriz de confusión de segmentación del panel

## 8 CONCLUSIONES

El método planteado de Deep Learning utilizando redes neuronales convolucionales y tratamiento de imagen nos permitió identificar y segmentar las fallas de polvo y sombra en los paneles fotovoltaicos con un rendimiento aceptable. Con este también pudimos encontrar la opacidad y el área de las fallas utilizando un método de corrección de perspectiva.

Sin embargo, el modelo está sujeto a las condiciones de las imágenes, es decir que es posible que, si se toman imágenes con fondos, ángulos, u otros factores puede que el modelo no tenga el mismo rendimiento. Esto se debe a que tanto las imágenes de

entrenamiento como de prueba se tomaron con condiciones muy similares por lo que no se puede generalizar el modelo para todos los factores posibles en donde pueda haber paneles fotovoltaicos.

Para poder realizar un sistema global para todo tipo de condiciones en las que se pueda presentar el panel y con diferentes condiciones de la cámara. Si se realiza esto con una gran cantidad de imágenes de entrenamiento el modelo podrá tanto generalizar mejor la detección independientemente de las condiciones de la imagen como mejorar el rendimiento global del sistema.

Otro de las mejoras que se puede tener a este tipo de sistemas a futuro es utilizar un método que encuentre las esquinas de los paneles en caso de que exista mas de un panel en la imagen. Esto permitirá realizar una corrección de perspectiva de cada panel en una imagen de un sistema fotovoltaico grande, permitiendo así realizar el análisis de falla en un sistema completo.

## 9 AGRADECIMIENTOS

Agradezco a mis papas y a mi familia por estar pendientes de mi avance durante este proyecto. Agradezco al profesor Michael Bressan por la guía y consejos brindados en el transcurso del proyecto. Agradezco a Valentina Parra por el constante apoyo y ayuda que me ha brindado durante su desarrollo.

## 10 REFERENCIAS

- [1]. "¿Qué es una red neuronal?," ¿Qué es una red neuronal? - MATLAB & Simulink. [Online]. Available: <https://la.mathworks.com/discovery/neural-network.html>. [Accessed: 25-Nov-2019].
- [2]. A. Burkov, The hundred-page machine learning book. Canada: Andriy Burkov., 2019.
- [3]. A. Rosebrock, Deep learning for computer vision with Python: starter bundle. United States: PyImageSearch, 2017.
- [4]. "Redes Neuronales Convolucionales," Redes Neuronales Convolucionales - MATLAB & Simulink. [Online]. Available: <https://la.mathworks.com/solutions/deep-learning/convolutional-neural-network.html>. [Accessed: 25-Nov-2019].
- [5]. Geva, "Image Segmentation in Deep Learning: Methods and Applications," MissingLink.ai. [Online]. Available: <https://missinglink.ai/guides/computer-vision/image-segmentation-deep-learning-methods-applications/>. [Accessed: 25-Nov-2019].
- [6]. S. Mehta, A. P. Azad, S. A. Chemmengath, V. Raykar, and S. Kalyanaraman, "DeepSolarEye: Power Loss Prediction and Weakly Supervised Soiling Localization

via Fully Convolutional Networks for Solar Panels,” 2018 IEEE Winter Conference on Applications of Computer Vision (WACV), 2018.

- [7]. X. Hu, L. Zhu, C.-W. Fu, J. Qin, and P.-A. Heng, “Direction-Aware Spatial Context Features for Shadow Detection,” *2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2018.
- [8]. D. Kim, M. Arsalan, and K. Park, “Convolutional Neural Network-Based Shadow Detection in Images Using Visible Light Camera Sensor,” *Sensors*, vol. 18, no. 4, p. 960, 2018.